



open bydata
competence center



Handreichung

zur Verbesserung der Metadatenqualität von offenen Daten

In der Umsetzung von offenen Datenprojekten ist die Qualität der Metadaten entscheidend für deren Auffindbarkeit und Nutzbarkeit.

Trotz des Standards DCAT-AP.de bestehen Unsicherheiten bei dessen Anwendung und der Bedarf an weiteren Empfehlungen. Dieses Dokument zeigt praxisnah, wie Datenbereitsteller die Metadatenqualität verbessern und die Nutzung für Menschen und KI erleichtern können.

Handreichung zur Datenqualität

Mit dieser Handreichung will das oc.bydata (das open bydata competence center der byte) Datenbereitstellern Vorschläge und Best-Practice-Beispiele an die Hand geben, um die (Meta)datenqualität offener Daten zu verbessern. Zwar gibt es mit DCAT-AP.de einen umfänglichen Metadatenstandard, der maßgeblich zur Vereinheitlichung von Datenbeschreibungen beiträgt. Doch ist das Regelwerk nicht für alle Anwender selbsterklärend und durch unseren Austausch mit Datenbereitstellern und Datennutzenden wissen wir, dass es Unsicherheiten bei der Anwendung des Standards gibt. Auch der Wunsch nach ergänzenden Empfehlungen jenseits von DCAT-AP.de ist bei uns angekommen.

Die Qualität der Metadaten spielt eine zentrale Rolle, um offene Daten auffindbar, zugänglich und nachnutzbar zu machen. Korrekte und konsistente Metadaten sind daher unverzichtbar, nicht nur für Datennutzende, sondern z. B. auch für Künstliche Intelligenz, um verwertbare Ergebnisse liefern zu können.

Inhalt

- Qualität vor Quantität
- Übersicht über die notwendigen Metadatenfelder
- Allgemeine Hinweise
- Titel des Datensatzes bzw. einer Distribution (dcterms:title)
- Beschreibung des Datensatzes bzw. einer Distribution (dcterms:description)
- Schlagwörter (dcat:keyword)
- Datenstruktur für Daten, die thematisch miteinander verbunden sind/sich ergänzen oder fortführen
- Qualität auf allen Ebenen: deskriptive Metadaten und gute Rohdaten
- Abschluss
- Zum Weiterlesen
- Nachnutzung
- Anhang: Beispielkatalog im RDF-Format

Qualität vor Quantität

Der DCAT-AP.de-Standard bietet eine große Menge an möglichen Metadatenfeldern. Da bei Metadaten die Qualität mindestens genauso wichtig ist wie die Quantität, haben wir in unserer Handreichung zur Dateninventur (S.4) bereits die für open.bydata.de unverzichtbaren Felder herausgestellt. Darüber hinausgehende Metadatenfelder sind eine wertvolle Ergänzung, aber nicht zwingend erforderlich. Entscheidend für die Auffindbarkeit und Weiternutzung ist das Vorhandensein der wesentlichen Metadatenfelder in guter Qualität. Eine anschauliche Übersicht mit Kurzbeschreibungen ist weiter unten verfügbar.

Doch was macht „gute Qualität“ bei Metadaten konkret aus? Das kann – je nach Feld – unterschiedlich aussehen. Zu den wichtigsten Feldern, zu denen uns immer wieder Nachfragen erreichen, haben wir im Folgenden Informationen und Best-Practice-Beispiele zusammengefasst. Es werden einzelne Metadatenfelder benannt und beschrieben, ihre Bedeutung für die Qualität eines Datensatzes wird mit Beispielen sichtbar gemacht.

Das oc.bydata unterstützt hier neben Beratung und Handreichungen auch durch das Quality-Skript.

Quality-Skript

Unser Angebot, um die Qualität der Metadaten bei automatischen Anbindungen zu verbessern. Das Skript führt während des Harvestings Überprüfungen – z.B. der Lizenzen – durch und ergänzt ggf. fehlende Metadatenfelder. Im Anschluss wird ein Report der vorgenommenen Änderungen generiert. Für detaillierte Informationen steht das oc.bydata unter oc@bydata.de gerne zur Verfügung.

Übersicht über die notwendigen Metadatenfelder

Feldbezeichnung nach DCAT-AP.de	Pflichtfelder für Datensätze	Beschreibung / Hinweise
dct:title	Titel	Der Titel des Datensatzes.
dct:identifier	Datensatz-ID	Eine eindeutige ID.
dct:description	Beschreibung	Die Beschreibung des Datensatzes.
dcat:Catalog	Katalog	Der Katalog, welcher den Datensatz beinhaltet.
dct:publisher	Datenbereitsteller	Die Organisation oder Person, die den Datensatz zur Verfügung stellt.
dcat:theme	Kategorie	Eine geeignete Kategorie aus dem genormten EU-Vokabular: https://op.europa.eu/de/web/eu-vocabularies/concept-scheme/-/resource?uri=http://publications.europa.eu/resource/authority/data-theme

Übersicht über die notwendigen Metadatenfelder

dct:modified	Aktualisierungsdatum	Letztes Aktualisierungsdatum des Datensatzes.
dcat:contactPoint	Kontakt	Eine Mailadresse, nicht personenbezogen, sondern eine Serviceadresse.
Pflichtfelder für Distributionen		
dcat:AccessURL	Zugangs-URL	Der Link, über welchen auf die Daten zugegriffen werden kann.
dct:title	Distributionstitel	Der Titel der Distribution.
dct:description	Distributionsbeschreibung	Die Beschreibung der Distribution.
dct:license	Lizenz	Die Lizenz (inkl. Version) unter welcher die Daten veröffentlicht werden.
dcatde:licenseAttribution ByText	Namensnennungstext für Byte-Clauses (für Lizenz)	Angabe der gewünschten Erwähnung bei Lizenz mit Namensnennung (zB. CC-BY). I.d.R. der Datenbereitsteller.

Übersicht über die notwendigen Metadatenfelder

dct:format	Format	Das (Datei-)Format, in welchem die Distribution vorliegt.
dct:modified	Aktualisierungsdatum	Letztes Aktualisierungsdatum der Distribution.
empfohlene Felder für Datensätze		
dct:issued	Veröffentlichungsdatum	Das Datum, an welchem der Datensatz zum ersten Mal veröffentlicht wurde.
dcatde:politicalGeocodingLevelURI	Ebene der geopolitischen Abdeckung	Bezeichnet die geopolitische Ebene des Datensatzes. Beispiele sind: bundesweit, landesweit oder kommunal.
dcatde:politicalGeocodingURI	Geopolitische Abdeckung	Die konkrete Abdeckung der geopolitischen Ebene. Zum Beispiel: Bundesrepublik Deutschland, Freistaat Bayern, Stadt München.
dcat:keyword	Datensatzschlagworte	Selbst gewählte Schlagworte zur Erleichterung der Suche.

Übersicht über die notwendigen Metadatenfelder

dct:temporal	Zeitliche Abdeckung	Der Zeitraum, welchen der Datensatz umfasst.
dct:accrualPeriodicity	Aktualisierungsfrequenz	Wichtige Angabe bei Livedaten --> dann Angabe "kontinuierlich" oder "ständige Aktualisierung".
Empfohlene Felder für Distributionen		
dct:language	Sprache	Die natürliche Sprache, in welcher der Datensatz oder die Distribution vorliegt.

Allgemeine Hinweise

Bei der Beschreibung von Datensätzen ist

Konsistenz ein wichtiger Punkt:

Einheitliche Benennungen schaffen

Übersichtlichkeit und Vergleichbarkeit. Sie ermöglichen effizientes Suchen und automatisierte Auswertungen.

Inkonsistente Bezeichnungen hingegen erschweren die Nachnutzung und führen zu Missverständnissen. Dies reduziert den Mehrwert offener Daten.

Beispiel:

Das Feld „Datenbereitsteller“

(dct:publisher)

Eine Kommune X hat einen Fachbereich für Tiefbau und möchte dieses Amt als Datenbereitsteller bei verschiedenen Datensätzen angeben. In diesem Fall ist es wichtig, dass eine einheitliche Bezeichnung (z. B. „Kommune X - Fachbereich Tiefbau“) gewählt und beibehalten wird. Wenn stattdessen verschiedene Varianten („Fachabteilung Tiefbau“ oder „Fachbereich Tiefbau – Geodaten und Vermessung“) verwendet werden, ist eine Filterung oder Suche nach dem Datenbereitsteller schwer – nicht alle Datensätze werden gefunden.

Titel des Datensatzes bzw. einer Distribution

(dctterms:title)

Worum geht es?

Der Titel ist das zentrale, erste Feld, das Suchende beim Stöbern nach Datensätzen sehen. Er benennt den Inhalt des Datensatzes und ermöglicht eine schnelle Einordnung.

Warum ist hier gute Datenqualität wichtig?

- **Auffindbarkeit:** Der Titel wird bei der Suche und Indexierung berücksichtigt und erleichtert damit die Suche nach relevanten Datensätzen.
- **Auffindbarkeit vergleichbarer Daten:** Wenn die Titel vergleichbarer Datensätze verschiedener Datenbereitsteller eine ähnliche Struktur haben, können Nutzende schneller ähnliche Daten finden und nutzen. Hilfreich als Beispiel wie andere Kommunen Datensätze erfassen und wie diese strukturiert und beschrieben werden, kann der Musterdatenkatalog der Bertelsmann Stiftung sein. Hier gibt es Beispiele zu Daten, die in anderen Kommunen erhoben wurden.
- **Verständlichkeit:** Ein klarer, präziser Titel gibt den Nutzer:innen eine schnelle Einschätzung, ob der Datensatz für sie relevant ist.
- **Vergleichbarkeit:** Gerade bei mehrfach veröffentlichten Datentypen (z. B. Einwohnerzahlen) hilft ein gut gesetzter Titel bei der Unterscheidung ähnlicher Datensätze verschiedener Datenbereitsteller.
- **Kontext:** Zusatzangaben wie Zeitraum oder geografische Bezugsebene verhindern Missverständnisse und erleichtern die Zuordnung.
- **Beispiel:** Der Titel „Einwohnerstatistik 2025 Kommune [abc oder xy]“ macht es dem Nutzer leichter, die vergleichbaren Datensätze von Kommune abc und xy zu finden. Wenn stattdessen die Titel „Statistik der Einwohner“ und „Bevölkerungsstatistik 2025“ lauten, leidet darunter die Auffindbarkeit bzw. Vergleichbarkeit; erst durch das Heranziehen der Informationen zum örtlichen Bezug ist der Datensatz eindeutig zuzuordnen.

Titel des Datensatzes bzw. einer Distribution (dctterms:title)

Was ist sinnvoll?

Ein sinnvoller Titel...

- ist **aussagekräftig, konkret** und **so kurz wie möglich, so lang wie nötig**
- enthält bei Bedarf einen **zeitlichen** und/oder **räumlichen Bezug** (z.B. "2025" oder "Kommune XY")
- verzichtet auf ausführliche Erklärungen, diese gehören in die Beschreibung.

Was sollte vermieden werden?

- **Zu allgemeine oder sehr kurze Titel:** z.B. "Einwohnerzahlen". Hier fehlen relevante Rahmenangaben (z.B. Ort, Jahr,).
- **Zu ausführliche oder beschreibende Titel:** Detailinformationen und methodische Hinweise gehören nicht in den Titel, sondern ins Beschreibungsfeld.



Der Titel funktioniert wie eine prägnante Überschrift: informativ, klar, eindeutig! Zudem ist bei Datensätzen, die mehrfach in ähnlicher Form vorliegen dürften, eine Recherche über open.bydata.de hilfreich, um ggf. eine vergleichbare Titelansetzung zu wählen.

Wie sieht ein gutes Beispiel aus?

Der Titel „Einwohnerzahlen der Stadt XY nach Altersgruppen 2025“

https://open.bydata.de/datasets/einwohner_nach_altersgruppen_-5_klasse_n-_unterbezirksebene_ingolstadt?locale=de

Beschreibung des Datensatzes bzw. einer Distribution (dcterms:description)

Worum geht es?

Die **Beschreibung** ist das zentrale Feld, um die Inhalte, den Kontext und die Struktur eines Datensatzes umfassend darzustellen. Im Gegensatz zum Titel können hier alle relevanten Details aufgeführt werden.

Warum ist hier gute Datenqualität wichtig?

- Die Beschreibung gibt den Nutzenden einen Eindruck, um welche Rohdaten es sich handelt und hilft zu beurteilen, ob der Datensatz für den jeweiligen Zweck geeignet ist.
- Sie ermöglicht ein besseres Verständnis der Inhalte, Herkunft und Methodik und schafft Transparenz.

Was ist sinnvoll?

Beantworten Sie zentrale Fragen zu Ihrem Datensatz:

- **Was ist enthalten?** Welche Inhalte und Datenfelder liegen vor?
- **Wie ist der Datensatz strukturiert?** Format, Aufbau, z.B. Tabellenstruktur, Felder, Kategorien.
- **Wie und wieso wurden die Daten erhoben?** Umfang, Verfahren, Quelle, evtl. Stichprobeninformationen.

- **Weshalb wurden die Daten gesammelt?** Wofür sind sie nutzbar?
- **Gibt es Besonderheiten?** z.B. Stichtag, Zeiträume, KI-Unterstützung, Qualitäts-Disclaimer.
- **Hilfreiche Links und Hinweise** z.B. zur Ursprungswebsite, weiterführende Dokumentationen oder Anleitungen.
- **Bei der Beschreibung auf Distributionsebene:** Zusätzliche Informationen zum Dateiformat, z.B. bei CSV: verwendete Trennzeichen oder Zeichencodierung.



Hilfreich ist es, sich in die Rolle des potenziellen Nutzers oder der Nutzerin zu versetzen. Welche Informationen werden benötigt, um entscheiden zu können, ob der Datensatz für den gewünschten Zweck relevant ist?

Beschreibung des Datensatzes bzw. einer Distribution (dctterms:description)

Was sollte vermieden werden?

- **Unvollständige oder sehr knappe Beschreibungen:** Lassen Sie das Feld nicht leer und verzichten Sie nicht auf wichtige Informationen zur Datenstruktur, Besonderheiten oder Einschränkungen.
- **Technisches Markup (z.B. HTML):** Kann zu Darstellungsproblemen oder Fehlern bei der maschinellen Lesbarkeit führen. Daher auf Fettungen oder Kursivsetzungen lieber verzichten. Links können eingefügt werden.

Wie sieht ein gutes Beispiel aus?

Beispiel auf Datensatzebene mit Angabe zum Datensatzinhalt und -ursprung

„Freizeittouren in Bayern“:

„Der Datensatz enthält Routenbeschreibungen aller Art, die für Freizeitunternehmungen interessant sind. Zu diesen zählen beispielsweise Wanderungen, Radtouren, Stadtpaziergänge oder auch motorisierte Touren mit GPS-Daten. Die Daten stammen aus der BayernCloud Tourismus (<https://bayerncloud.digital/>), die dort von Gemeinden, Landkreisen, touristischen Regionalverbänden sowie thematischen Datenquellen bereitgestellt werden.

Der Datensatz, aufbauend auf der Ontologie von schema.org, umfasst eine vielfältige Zusammenstellung von Datenobjekten aus unterschiedlichen Quellen. Jedes dieser Objekte ist mit einer individuellen Lizenz – CC0, CC-BY oder CC-BY-SA – versehen. Diese spezifischen Lizenzen bestimmen die Art und Weise, wie jedes im Datensatz enthaltene Objekt genutzt werden darf.“

Beispiel auf Distributionsebene mit Angabe des Trennzeichens (aus „Bevölkerungsstruktur 2023“):

„###Bevölkerung 2023 Haushalte

Herkunft: Melderegister der Stadt Erlangen, Zuordnung der Haushalte durch das Sachgebiet Statistik und Stadtforschung mithilfe des Programms HHGen

Stichtag: 31.12.2023__Merkmale: __

Bezirk: Statistische Bezirke der Stadt Erlangen, zweite Ebene der kleinräumigen Gliederung

Haushalte: Die Haushalte werden aus den im Einwohnermelderegister gemeldeten Einzelpersonen aufgrund mehrerer Indizien gebildet. Dabei wurden nur Einwohner berücksichtigt, die mit Hauptwohnsitz gemeldet sind.

Beschreibung des Datensatzes bzw. einer Distribution (dcterms:description)

Heimbewohner außerhalb von

Haushalten: Bewohner von Heimen wie z.B. Studentenwohnheimen werden nicht zu Haushalten zusammengefasst.

(Ehe-)paare ohne Kind: Haushalte mit einem Ehepaar oder einem Paar in nichtehelicher Lebensgemeinschaft, kein Kind unter 18 Jahren

(Ehe-)paare mit Kindern: Haushalte mit einem Ehepaar oder einem Paar in nichtehelicher Lebensgemeinschaft, mindestens ein Kind unter 18 Jahren

Alleinerziehende: Haushalt mit einem Erwachsenen und mindestens einem Kind unter 18 Jahren

In der CSV-Datei wird als Feldtrennzeichen das Komma und als Dezimaltrennzeichen der Punkt verwendet.“

Schlagwörter (dcat:keyword)

Worum geht es?

Schlagwörter sind zentrale Metadaten für eine inhaltliche Beschreibung von Daten. Sie tragen dazu bei, Datensätze im open.bydata Portal schnell und gezielt auffindbar zu machen – auch für Nutzende, die den genauen Titel nicht kennen. Sie verknüpfen Datensätze thematisch und erleichtern das Filtern und Gruppieren ähnlicher Angebote auf den verschiedenen Portalen.

Warum ist hier gute Datenqualität wichtig?

- Sie verbessert die Suche und Auffindbarkeit.
- Sie unterstützt die Verknüpfung und thematische Bündelung verwandter Inhalte.
- Sie erhöht die Chancen, dass Ihr Datensatz gefunden und genutzt wird.

Was ist sinnvoll?

- **Angemessene Anzahl:** Verwenden Sie mindestens drei relevante Schlagwörter. Diese können Ort, Thema etc. abdecken. Zu viele Schlagwörter sind nicht sinnvoll, je nach Inhalt der Daten sollten maximal 15 Begriffe ausreichen. Für jedes Schlagwort wird ein neues Feld verwendet. Sie werden nicht gebündelt angegeben.
- **Klar und kurz:** Wählen Sie kurze und prägnante Begriffe (z.B. „Mobilität“, „Sozialleistungen“, „Sport“).
- **Verständliche Sprache:** Vermeiden Sie reine Fachbegriffe oder Abkürzungen. Wählen Sie Schlagwörter, nach denen auch Laien suchen würden (z.B. „Baugesetz“, nicht „BauGB“).
- **keine Komposita und Singular statt Plural:** Verwenden Sie einzelne Begriffe im Singular und keine langen zusammengesetzten Schlagwörter (z.B. „Museum“, „Kultur“, nicht „Museumskulturangebot“, bzw. „Veranstaltung“, „Radtour“ und nicht „Veranstaltungen“, „Radtouren“).

Schlagwörter (dcat:keyword)

- **Keine redundanten oder offensichtlichen Keywords:** Tags wie eine Jahreszahl oder „Gemeinde“ haben eher einen formalen als einen inhaltlichen Charakter und sind oft bereits durch andere Metadatenfelder abgedeckt. Sie bringen wenig Mehrwert.
- **Schreibweisen beachten:** Groß- und Kleinschreibung sowie Sonderzeichen sind für die Suche irrelevant. Die Verwendung mehrerer Schreibvarianten ist nicht erforderlich (bei Angabe „COVID-19“ muss „covid 19“ nicht auch noch angegeben werden).
- **Mehrsprachigkeit:** Für die bessere Auffindbarkeit auf bspw. dem EU-weiten Portal <https://data.europa.eu/> bietet es sich an Keywords auch in anderen Sprachen zu verwenden. Also nicht nur „Einwohner“, sondern auch „population“ oder „habitants“. In diesem Kontext ist es auch hilfreich Umlaute zu vermeiden, bzw. zwei Notationen anzubieten (z.B. „Fußgänger“ und „Fussgaenger“).

Was sollte vermieden werden?

- **Zu spezifische oder lange Keywords und komplexe Zusammensetzungen:** Detaillierte Formulierungen gehören in den Titel oder vor allem in die Beschreibung. Die Schlagwörter sollen diese inhaltlich ergänzen und nicht wiederholen. Also lieber „Finanzen“ und „Vermögen“ als „Vermögens- und Finanzlage“. Verwenden Sie keine Phrasen wie „Anteil Einw. mit Migr.Hintergrund an Gesamt“ - vergeben Sie lieber mehrere Schlagwörter, wie „Einwohner“, „Migration“ und „Statistik“.
- **Nicht nur Fachjargon verwenden:** Schlagwörter sollten auch ohne Spezialwissen verständlich sein.

Wie sieht ein gutes Beispiel aus?

- Datensatz "Augsburg: Passanten Annastraße" Keywords: Fußgänger, Passanten, Innenstadt
- Datensatz "Passantenzählung in der Schönbornstrasse": Keywords: fußgänger, fussgaenger, passanten, innenstadt, sensor, schönbornstraße, schoenbornstrasse

Datenstruktur für Daten, die thematisch miteinander verbunden sind bzw. einander ergänzen oder fortführen

Sollen thematisch eng verbundene Daten veröffentlicht werden, muss entschieden werden, ob und wie sich die Datensätze inhaltlich abgrenzen lassen. Denn: Bei der Veröffentlichung von **thematisch zusammengehörigen Daten** gilt das Prinzip, dass alle Distributionen eines Datasets „weitestgehend dieselben Daten beinhalten“¹, wobei diese „in unterschiedlichen Formaten vorliegen“² können. Das heißt inhaltlich abweichende, aber trotzdem thematisch zusammengehörige Daten sollten als einzelne Datensätze veröffentlicht werden.

Ein Beispiel: **Zeitreihen**:

Die fortlaufenden, jährlich veröffentlichten Daten zur Einwohnerstatistik sollten nicht als unterschiedliche Distributionen eines Datensatzes („Einwohnerstatistik 2020-2025 Stadt xy), sondern als getrennte Datensätze angelegt werden. Sie enthalten unterschiedliche Rohdaten und können im Aufbau voneinander abweichen, wenn z.B. ein neues Wohngebiet bezogen wird.

Wenn für jedes Jahr ein eigener Datensatz („Einwohnerstatistik 2020 Stadt xy“) angelegt wird, kann dieser mehrere Distributionen enthalten, z.B. für jedes vorhandene Datenformat eine mit entsprechender Erwähnung im Titel:

- Titel Distribution 1 „Einwohnerstatistik 2020 Stadt xy als CSV-Datei“
- Titel Distribution 2 „Einwohnerstatistik 2020 Stadt xy als Flat-CSV-Datei“ etc.

Diese Struktur ermöglicht eine detaillierte und spezifische Beschreibung und Verschlagwortung verfügbar gemachter Rohdaten sowohl auf der Ebene des Datensatzes als auch der Distribution, da eine Verallgemeinerung zu Gunsten einer Gesamt(Zeit)Reihe vermieden wird. Außerdem verbessert dieses Vorgehen die Auffindbarkeit, da gezielt nach den gewünschten Jahren gesucht werden kann.

[1] <https://www.dcat-ap.de/def/dcatde/2.0/implRules/#konventionen-zur-dcat-distribution>

[2] <https://www.dcat-ap.de/def/dcatde/2.0/implRules/#konventionen-zur-dcat-distribution>

Datenstruktur für Daten, die thematisch miteinander verbunden sind bzw. einander ergänzen oder fortführen

Ein weiteres Beispiel: **Bebauungspläne:**

Bebauungspläne kann es in verschiedenen Fortschrittsstufen bzw. Rechtszuständen geben. Auch diese Prozessstufen sollten nicht in einem Datensatz zusammengefasst werden; jeder Verfahrensstand sollte einzelne erfasst werden, u.a. um die Transparenz der verfügbaren Daten zu erhöhen: „Bebauungspläne im Verfahren der Kommune xy“; „Bebauungspläne in Kraft der Kommune xy“; „Übergeleitete Baulinienpläne in Kraft der Kommune xy“ als Datensätze erlauben einen gezielteren Zugriff als deren Zusammenführung in den Distributionen eines allgemeinen Datensatzes „Bebauungspläne der Kommune xy“.

Wie kann eine Beziehung zwischen diese thematisch zusammengehörenden Datensätzen hergestellt werden?

Die Kennzeichnung und damit Zusammenführung inhaltlich verwandter Datensätze ist über separate Metadatenfelder möglich. Dazu gehört bisher „verwandte Ressource“ ([dcterms:relation](#)) womit per URL auf einen anderen Datensatz oder Katalog verwiesen werden kann.

Neu ab Version 3.0 von DCAT-AP.de und zu bevorzugen ist die Möglichkeit eine **Datensatzserie** ([dcat: DatasetSeries](#)) anzulegen. Über [dcat:inSeries](#) kann vom einzelnen Datensatz auf die Serie verwiesen werden, so dass auf der Ebene der Datensatzserie alle zusammengehörigen Datensätze gebündelt werden können.

Qualität auf allen Ebenen: deskriptive Metadaten und gute Rohdaten

Wenn gute Metadaten dazu beitragen, offene Daten auffindbar zu machen, dann trägt die Qualität der „eigentlichen“ Daten dazu bei, diese in die Nachnutzung zu bringen. Also gilt: auch Rohdaten sollten bestimmte Qualitätsmerkmale erfüllen.

Grundsätzlich gelten hier ähnliche Punkte wie bei den Metadaten: Konsistenz, Vergleichbarkeit, Einheitlichkeit und Nachvollziehbarkeit müssen gegeben sein. Aufgrund der großen Varianz der Art und Herkunft von Rohdaten (Geodaten, Statistiken, Eventdaten, Sensordaten und vieles mehr), ist es schwierig hier allgemeingültige Empfehlungen auszusprechen.

Es bietet sich an, die jeweiligen Fachabteilungen einzubinden bzw. die Qualität der Rohdaten von ihnen prüfen zu lassen. Ihnen sind die jeweiligen Fachstandards (z.B. für Geodaten oder Statistik) geläufig, die sich als Orientierungshilfe für eine einheitliche Aufbereitung von Daten anbieten. Das gilt für die Strukturierung der Daten genauso wie für offene Datenformate für eine Veröffentlichung. Durch Einhaltung von (Fach)Standards wird die Vergleichbarkeit erhöht und eine einfachere Anbindung und Nachnutzung verbessert.

Ein Beispiel zu CSV-Dateien:

Bei CSV-Dateien sollte – im wortwörtlichen Sinne des „character separated values“ - immer dasselbe Trennelement verwendet und vor allem klar in der Beschreibung benannt werden. Auch eindeutige Spaltenbezeichnungen, eine Angabe der Struktur in der Beschreibung und die Einhaltung der allgemeinen Standards für CSV-Dateien sind nützlich. Zur Kontrolle und Überarbeitung von CSV-Dateien kann der Open Data Editor der Open Knowledge Foundation hilfreich sein.

Prinzipiell ist die Form der Aufbereitung der Rohdaten wichtig. Bei Offenen Daten heißt das immer, dass das Format **maschinenlesbar** und **nichtproprietär** sein muss. Also eine CSV-Datei statt einer XLS-Datei oder eine TXT-Datei statt einem proprietären Word-Format.³ Weiter ist die Aktualität der Daten wichtig: bei z.B. Statistiken die Fortführung von Zeitreihen oder bei anderen Daten, die einen Einmalstand wiedergeben, ist die historische Nachverfolgbarkeit wichtig.



In der CSV-Datei wird als Feldtrennzeichen das Komma und als Dezimaltrennzeichen der Punkt verwendet.

³Mehr zu Rohdatenformaten in einer Handreichung von open.rlp.de

Qualität auf allen Ebenen: deskriptive Metadaten und gute Rohdaten

Bei der Frage, welche Konvention für die Erfassung von Rohdaten sinnvoll sein können, berät das oc.bydata gerne. Sprechen Sie uns an, auch wenn es darum geht, wie Rohdaten automatisiert für den Zugriff aus Portalen wie open.bydata.de aufbereitet werden können. Der Zugriff auf offene Daten über Schnittstellen ist das Ziel, dass wir uns alle in puncto Transparenz und Aktualität von Offenen Daten setzen und an dem wir gerne gemeinsam mit Ihnen arbeiten.

Wir freuen uns auf Ihre Nachricht unter oc@bydata.de

Abschluss

Nachdem die Meta- und Rohdaten nun eine gute Qualität haben, ist ein großer Schritt in Hinblick auf eine einfache Nachnutzung und Weiterverbreitung getan. Aktuelle und gepflegte Meta- und Rohdaten sind eine wertvolle Ressource. Das heißt die **Aktualisierung** der Daten sollte - je nach Datenbestand – in regelmäßigen Zyklen durchgeführt werden.

Die Rohdaten ändern sich nicht bei allen Datensätzen, z.B. historische Daten oder abgeschlossenen Daten wie die „Einwohnerstatistik 2020“ bleiben sehr wahrscheinlich unverändert. Trotzdem kann es bei einer Umstellung der Datenbankstruktur dazu führen, dass der Zugriffslink sich geändert hat – wenn es hier keinen regelmäßigen Check gibt, sind diese Daten nicht mehr auffindbar.

Wenn ein Datensatz tote Links oder veraltete Rohdaten enthält, sind die besten Metadaten nutzlos. Darum sollten regelmäßige Kontroll- bzw. Updatezyklen eingeplant werden, um die Datenqualität auch auf Dauer auf einem guten Niveau zu halten.

Zum Weiterlesen:

- Der Metadatenstandard [DCAT-AP.de](#) 3.0. Open.bydata.de wird momentan noch mit [Version 2.0](#) betrieben, die Aktualisierung ist in Planung.
- Das Handout [How to – Metadaten](#) der ODIS Berlin.
- Der [Leitfaden Metadaten](#) des CCOD.
- Der siebenteilige kostenlose Onlinekurs der data.europa academy: „[Improving open data and metadata quality](#)“.
- Der [Musterdatenkatalog](#) der Bertelsmann Stiftung gibt Beispiele und Anregungen für Datensätze.
- Mehr Informationen zu [Rohdatenformaten](#) von open.rlp.de.
- Der [Normentwurf](#) für qualitativ hochwertige Daten und Metadaten von Fraunhofer Fokus.

Nachnutzung:

Wir freuen uns, wenn unsere Handreichung nachgenutzt wird! Nutzen Sie die Texte und Informationen daraus gerne weiter.



[CC BY 4.0](#) “oc.bydata, open bydata competence center”

Stand Dezember 2025

Anhang: Beispielkatalog im RDF-Format

Hinweis:

Dieses Beispiel kann bei Interesse auch als Muster.xml zur Verfügung gestellt werden.

```
<rdf:RDF xmlns:vcard="http://www.w3.org/2006/vcard/ns#"
  xmlns:dcatde="http://dcat-ap.de/def/dcatde/"
  xmlns:foaf="http://xmlns.com/foaf/0.1/"
  xmlns:dct="http://purl.org/dc/terms/"
  xmlns:dcat="http://www.w3.org/ns/dcat#"
  xmlns:dcatap="http://data.europa.eu/r5r/"
  xmlns:rdf="http://www.w3.org/1999/02/22-rdf-syntax-ns#">
  <!-- Definition Datensatz -->
  <dcat:dataset>
    <dcat:Dataset rdf:about="https://open.bydata.de/dataset/strassennamen-im-
stadtgebiet-xy">
      <dct:identifizier>strassennamen-im-stadtgebiet-xy</dct:identifizier>
      <!-- Datensatztitel -->
      <dct:title> Straßennamen im Stadtgebiet XY</dct:title>
      <!-- Datensatzbeschreibung -->
      <dct:description> Eine Liste aller Straßennamen in der Stadt XY, ihre Geokoordinaten und ihre
historische Bedeutung.
      Stand ist 10/2025, die Daten werden jährlich aktualisiert. Rechtliche Grundlage für die Erhebung
der Daten ist xy.
      Weitere Infos zum Vorgehen unter: www.kommunexy.de/Straßenerhebung</dct:description>
      <!-- Kategorie -->
      <dcat:theme
rdf:resource="http://publications.europa.eu/resource/authority/data-theme/REGI"/>
      <!-- Veröffentlichungsdatum -->
      <dct:issued
rdf:datatype="http://www.w3.org/2001/XMLSchema#dateTime">2025-05-
17T12:00:00</dct:issued>
      <!-- Bearbeitungsdatum -->
      <dct:modified
rdf:datatype="http://www.w3.org/2001/XMLSchema#dateTime">2025-01-17T12:00:00</dct:modified>
      <!-- Kontaktdaten -->
      <dcat:contactPoint>
        <vcard:Organization>
          <vcard:fn> Stadt xy </vcard:fn>
          <vcard:hasEmail> open.data@xy.de </vcard:hasEmail>
        </vcard:Organization>
      </dcat:contactPoint>
      <!-- Sprache -->
      <dct:language
rdf:resource="http://publications.europa.eu/resource/authority/language/DEU"/>
```

<!-- Schlagworte -->

<dc:keyword> Strassennamen </dc:keyword>

<dc:keyword> Strasse </dc:keyword>

<dc:keyword> Stadt xy </dc:keyword>

<dc:keyword> street names </dc:keyword>

<dc:keyword> streets </dc:keyword>

<!-- Datensatzveröffentlicher -->

<dc:publisher>

<foaf:Organization rdf:about="https://www.xy.de/Service/Weitere-Themen/Open-Data/">

<foaf:name>Stadt xy</foaf:name>

<vcard:hasEmail>open.data@kommunexy.de</vcard:hasEmail>

</foaf:Organization>

</dc:publisher>

<!-- Zeitliche Abdeckung -->

<dc:temporal>

<dc:PeriodOfTime>

<dc:startDate

rdf:datatype="http://www.w3.org/2001/XMLSchema#dateTime">1924-01-01T00:00:00</dc:startDate>

<dc:endDate

rdf:datatype="http://www.w3.org/2001/XMLSchema#dateTime">2024-12-31T00:00:00</dc:endDate>

</dc:PeriodOfTime>

</dc:temporal>

<!-- Geopolitisches Level -->

<dc:politicalGeocodingLevelURI rdf:resource="http://dc:ap.de/def/politicalGeocoding/Level/municipality"/>

<!-- Definition Distribution -->

<dc:distribution>

<dc:Distribution

rdf:about="https://www.xy.de/output/download.123.CSV">

<!-- Distributionstitel -->

<dc:title> Straßennamen im Stadtgebiet XY als CSV</dc:title>

<!-- Distributionsbeschreibung -->

<dc:description> Die CSV-Datei enthält eine strukturierte Liste aller Straßennamen in der Stadt XY

und ihre historische Bedeutung, sowie die Geokoordinaten. Das verwendete Trennzeichen ist das Semikolon.</dc:description>

<dc:modified

rdf:datatype="http://www.w3.org/2001/XMLSchema#dateTime">2025-01-17T12:00:00</dc:modified>

<dc:issued

rdf:datatype="http://www.w3.org/2001/XMLSchema#dateTime">2020-05-17T12:00:00</dc:issued>

```

    <!-- Dateiformat -->
    < dct:format
rdf:resource="http://publications.europa.eu/resource/authority/file-type/CSV"/>
    <!-- Zugriffslink -->
    < dcat:accessURL
rdf:resource="https://www.KOMMUNE.de/Strassennamen.csv"/>
    <!-- Lizenz -->
    < dct:license rdf:resource="http://dcat-ap.de/def/licenses/cc-by/4.0"/>
    < dcatde:licenseAttributionByText> Stadt xy
</dcatde:licenseAttributionByText>
    <!-- Sprache -->
    < dct:language
rdf:resource="http://publications.europa.eu/resource/authority/language/DEU"/>
    </dcat:Distribution>
    </dcat:distribution>
    </dcat:Dataset>
    </dcat:dataset>
</rdf:RDF>

```