

Master-Thesis

Qualitätsmessung von Metadaten nach DCAT-AP.de Standard

von

Lars Bürger

als Teil der Voraussetzungen für den Titel

Master of Science

in Informatik

an der Hochschule Konstanz Technik, Wirtschaft und Gestaltung,

Matrikelnummer: 301662

Abgabedatum: 30.09.2026

Betreuer: **Prof. Dr. Markus Eiglsperger**

2. Betreuer: **Stephanie Bornholdt**

Hiermit erkläre ich, Lars Bürger, geboren am 14.08.2000 in Friedrichshafen,

(1) dass ich meine Master-Thesis mit dem Titel:

„Qualitätsmessung von Metadaten nach DCAT-AP.de Standard“

bei der **SEITENBAU GmbH** unter Anleitung von **Stephanie Bornholdt** selbständig und ohne fremde Hilfe angefertigt habe und keine anderen als die angeführten Hilfen benutzt habe.

(2) dass ich die Übernahme wörtlicher Zitate, von Tabellen, Zeichnungen, Bildern und Programmen aus der Literatur oder anderen Quellen (Internet) sowie die Verwendung der Gedanken anderer Autoren an den entsprechenden Stellen innerhalb der Arbeit gekennzeichnet habe.

(3) dass die eingereichten Abgabe-Exemplare in Papierform und im PDF-Format vollständig übereinstimmen.

Ich bin mir bewusst, dass eine falsche Erklärung rechtliche Folgen haben wird.

Konstanz, 30.09.2026

Verwendung von KI-Werkzeugen

Bei der Erstellung dieser Arbeit wurden folgende KI-gestützte Werkzeuge eingesetzt:

Anthropic Claude Opus 4.8 & Sonnet 4.6	Zur Generierung von Quellcode sowie von Analyse- und Visualisierungscode. Zur Umsetzung der automatisierten Qualitätsbewertung. Zur Korrektur von $\LaTeX$ -Code.
Anthropic Claude Opus 4.8	Zur Auf- und Nachbereitung der qualitativen Experteninterviews. Zur Erstellung einzelner Textpassagen sowie zu deren Rechtschreibkorrektur und Umformulierung. Zur Unterstützung bei der Literaturrecherche und bei der Auffindung von Dokumentationsressourcen zu den verwendeten Standards und Frameworks.
Anthropic Claude Fable 5	Zur Generierung von Quellcode. Zur Erstellung einzelner Textpassagen. Zur Unterstützung bei der Literaturrecherche und bei der Auffindung von Dokumentationsressourcen zu den verwendeten Standards und Frameworks.
OpenAI GPT-5.5	Zur Umsetzung der automatisierten Qualitätsbewertung. Zur Unterstützung bei der Literaturrecherche und bei der Auffindung von Dokumentationsressourcen zu den verwendeten Standards und Frameworks.
DeepL	Zur Unterstützung bei der Übersetzung von Textpassagen.

Alle durch KI-Werkzeuge unterstützten Inhalte wurden vom Verfasser kritisch geprüft, fachlich validiert und bei Bedarf überarbeitet. Die Verantwortung für die endgültige Fassung liegt vollständig beim Verfasser.

Inhaltsverzeichnis

1	Einleitung	7
1.1	Problemstellung und Motivation	7
1.2	Zielsetzung der Arbeit.	7
1.3	Forschungsfragen	8
1.4	Aufbau der Arbeit	9
2	Theoretische und konzeptionelle Grundlagen	10
2.1	Open Government Data und das GovData-Portal	10
2.2	Metadaten im Open-Data-Kontext.	11
2.3	DCAT-AP.de als Metadatenstandard	12
2.4	RDF, Linked Data und SHACL.	13
2.5	Datenqualität	15
2.5.1	Definition nach Wang and Strong 1996	15
2.5.2	Qualitätsmodell der ISO-Norm 25012	16
2.5.3	FAIR-Prinzipien	18
2.6	Metadatenqualität und Qualitätsbewertung von Linked Data	19
2.6.1	Linked-Data-Qualität nach Zaveri et al.	19
2.6.2	Automatisierte Metadatenbewertung in Open-Data-Portalen nach Neumaier et al.	20
2.6.3	Gewichtung und Ranking von Open-Data-Portalen nach Kubler et al.	23
2.6.4	Operationalisierung der Metadatenqualitätsbewertung durch MQA/Piveau 24	
2.6.5	ISO 19157 als Qualitätsinstrument.	25
2.6.6	Vergleich bestehender Ansätze und offene Bewertungslücken	27
3	Konzeption eines Metadatenqualitätsmodells	30
3.1	Experteninterviews: Ziel, Auswahl und Durchführung	30
3.2	Auswertungsverfahren der Interviews	32
3.3	Zentrale Ergebnisse der Interviews	36
3.4	Ableitung relevanter Qualitätsdimensionen	40

3.5	Ableitung formaler, technischer und semantischer Einzelindikatoren	42
3.5.1	Konzeptionelles Messmodell	44
3.5.2	Auffindbarkeitsindikatoren	47
3.5.3	Zugänglichkeitsindikatoren	48
3.5.4	Nachnutzbarkeitsindikatoren	49
3.5.5	Aussagekraftsindikatoren	50
4	Prototypische Operationalisierung	51
4.1	Zielsetzung und Funktionsumfang des Prototyps	51
4.2	Systemarchitektur und Verarbeitungspipeline	52
4.3	Extraktion und Anreicherung der Metadaten	54
4.4	Implementierung der Einzelindikatoren	56
4.4.1	Abbildung des konzeptionellen Modells auf implementierte Indi- katoren	57
4.4.2	Auffindbarkeitsindikatoren	57
4.4.3	Zugänglichkeitsindikatoren	58
4.4.4	Nachnutzbarkeitsindikatoren	60
4.5	LLM-gestützte Bewertung der Aussagekraft	61
4.5.1	Ein-Aufruf-Architektur	61
4.5.2	Strukturierte Ausgabe	62
4.5.3	Eingabe und Prompt	64
4.5.4	Determinismus und Konfiguration	65
4.6	Scoring-, Gewichtungs- und Aggregationslogik	65
4.6.1	Punktevergabe je Indikator	65
4.6.2	Aggregation zum Gesamtscore	66
4.6.3	Gewichtung der Indikatoren und Dimensionen	67
4.7	Maschinenlesbare Ergebnisreports	68
4.8	Menschenlesbares Qualitätsreporting	71
4.8.1	Zielgruppen und Gestaltungsziele	71
4.8.2	Einbettung in eine Portalumgebung	72
4.8.3	Anbindung an den Bewertungskern	73
4.8.4	Vom Prüfergebnis zum Befund	74
4.8.5	Von der Meldung zur Handlungsanweisung	75
4.8.6	Darstellung und Bedienung	77
5	Evaluation	80
5.1	Evaluationsdesign und Hypothesen	80
5.2	Datengrundlage und Stichprobe	81
5.3	Ground-Truth-Erhebung	82

5.4	Vergleichsbaseline: MQA-Reimplementierung und A/B/C-Klassifikation . .	83
5.5	Auswertungsverfahren und Kennzahlen	84
5.6	Modellauswahl für die LLM-gestützte Bewertung	86
5.6.1	Auswahl des Sprachmodells	87
5.6.2	Reproduzierbarkeit der Bewertung	89
5.7	Ergebnisse: Prototyp und Ground Truth	90
5.7.1	Kernstichprobe (n=50)	91
5.7.2	Extremfälle (n=20)	92
5.8	Ergebnisse: Prototyp und MQA im Vergleich	95
5.8.1	Kernstichprobe (n=50)	95
5.8.2	Extremfälle (n=20)	97
5.8.3	Triangulation gegen die Ground Truth (H3)	98
5.9	Limitationen der Evaluation	100
6	Diskussion	100
6.1	Beitrag der Arbeit zur Metadatenqualitätsbewertung im GovData-Kontext .	100
6.2	Bedeutung kontext- und semantikbezogener Prüfungen	100
6.3	Potenziele und Grenzen KI-gestützter Verfahren	100
6.4	Nachvollziehbarkeit als Gestaltungsziel des Qualitätsreportings	100
7	Fazit und Ausblick	100
7.1	Zusammenfassung der zentralen Ergebnisse	101
7.2	Beantwortung der Forschungsfragen	101
7.3	Limitationen.	101
7.4	Weiterer Forschungs- und Entwicklungsbedarf	101
	Abkürzungsverzeichnis	103
	Abbildungsverzeichnis	105
	Tabellenverzeichnis	106
	Literatur	107
A	Interviewleitfaden	112
B	Induktiv entwickelte Unterkategorien	116
C	Kodierleitfaden der Interviewauswertung	117
D	Transkript Interview I1	121
E	Transkript Interview 2	130

F	Transkript Interview 3	139
G	Kodierte Auswertungsmatrix der Interviews	145
H	Prompts der semantischen Anreicherung für die Aussagekraft	148
I	Abbildungen zur MQA-Extremfallanalyse	152
J	A/B/C-Zuordnung der Prototyp-Indikatoren zur MQA	155

1 Einleitung

1.1 Problemstellung und Motivation

In den vergangenen Jahren hat die Bereitstellung offener Verwaltungsdaten im Rahmen von Open Government Data (OGD) zunehmend an Bedeutung gewonnen. Durch die Veröffentlichung öffentlich finanzierter Daten sollen Transparenz, Innovation und wissenschaftliche Nutzung gefördert werden. Offene Daten können dabei neue wirtschaftliche und gesellschaftliche Mehrwerte schaffen, indem sie Forschung, datenbasierte Anwendungen und evidenzbasierte Entscheidungsprozesse unterstützen [1].

In Deutschland erfolgt die zentrale Bereitstellung von Metadaten zu offenen Verwaltungsdaten über das nationale Datenportal GovData. GovData fungiert als übergreifender Metadatenkatalog, über den Bund, Länder und Kommunen ihre offenen Datensätze auffindbar machen und einen zentralen Zugang zu Verwaltungsdaten bereitstellen [2, 3]. Die eigentlichen Datensätze werden dabei weiterhin von den jeweiligen Datenbereitstellern dezentral verwaltet, während das Portal die zugehörigen Metadaten aggregiert und über standardisierte Schnittstellen zugänglich macht.

Für die Auffindbarkeit und Nachnutzbarkeit dieser Daten spielt die Qualität der Metadaten eine zentrale Rolle. Unvollständige, inkonsistente oder fehlerhafte Metadaten können die Nutzung offener Daten erheblich erschweren und damit den Nutzen von Open-Data-Initiativen reduzieren. Vor diesem Hintergrund gewinnt die systematische Bewertung und Verbesserung der Metadatenqualität in Open-Data-Portalen zunehmend an Bedeutung.

1.2 Zielsetzung der Arbeit

Ziel dieser Masterthesis ist die Entwicklung und Evaluation eines strukturierten Verfahrens zur Bewertung und zum Reporting der Qualität von Metadaten im Kontext von GovData auf Basis des Data Catalog Vocabulary Application Profile for Germany (DCAT-AP.de) Standards. Ausgangspunkt bilden Validierungsergebnisse, die mithilfe eines bestehenden RDF-/SHACL-Validators erzeugt wurden. Diese liefern formale Aussagen über strukturelle und syntaktische Eigenschaften der Metadaten, erlau-

ben jedoch keine aggregierte oder kontextualisierte Qualitätsbewertung. Die Thesis verfolgt daher das Ziel, aus vorhandenen Validierungsmetriken ein transparentes und praxisrelevantes Bewertungsmodell abzuleiten. Hierzu wird zunächst der Forschungsstand zu Datenqualität, Metadatenqualität sowie Bewertungsansätzen im Bereich Linked Data und Open Government Data analysiert, um geeignete Qualitätsdimensionen und Metriken zu identifizieren. Dabei wird insbesondere untersucht, ob bestehende Ranking- oder Scoring-Modelle für Data Catalog Vocabulary (DCAT), DCAT-AP und DCAT-AP.de existieren und inwiefern diese auf den deutschen Metadatenkatalog (GovData) übertragbar sind. Darauf aufbauend wird ein konzeptionelles Bewertungsverfahren entwickelt, das Validierungsergebnisse zu interpretierbaren Qualitätsindikatoren aggregiert. Ergänzend wird untersucht, inwiefern KI-gestützte Verfahren eingesetzt werden können, um Validierungsergebnisse zu interpretieren, zusätzliche Kontextinformationen aus Metadaten zu berücksichtigen und daraus verbesserte Qualitätsbewertungen abzuleiten. Ein möglicher Ansatz besteht dabei in der Nutzung agentenbasierter Architekturen, in denen spezialisierte KI-Agenten unterschiedliche Analyseaufgaben, etwa die Interpretation von Validierungsverletzungen oder die semantische Analyse von Metadatenfeldern, übernehmen. Die entwickelten Metriken und Analyseverfahren werden prototypisch umgesetzt, auf repräsentative Metadatenansätze angewendet und hinsichtlich ihrer Aussagekraft und praktischen Anwendbarkeit evaluiert. Ziel ist es, die rein formale RDF-Validierung um ein kontextsensitives und nachvollziehbares Qualitätsbewertungs- und Reportingsystem zu erweitern, das regelbasierte Validierung mit KI-gestützten Analyseverfahren kombiniert.

1.3 Forschungsfragen

Ausgehend vom dargestellten Forschungsstand zeigt sich, dass zwar zahlreiche Modelle und technische Verfahren zur Bewertung von Daten- und Metadatenqualität existieren, deren Übertragbarkeit auf den spezifischen Kontext von DCAT-AP.de und GovData jedoch gesondert untersucht werden muss. Insbesondere stellt sich die Frage, wie formale Prüfergebnisse um kontext- und semantikbezogene Qualitätsindikatoren ergänzt werden können, ohne die Nachvollziehbarkeit des Bewertungsmodells zu beeinträchtigen. Vor diesem Hintergrund lautet die zentrale Forschungsfrage dieser Arbeit:

„Wie kann ein Bewertungsmodell für die Qualität von DCAT-AP.de-Metadaten im GovData-Kontext entwickelt werden, das formale Prüfverfahren mit ergänzenden kontext- und semantikbezogenen Qualitätsindikatoren verbindet?“

Zur Beantwortung dieser Leitfrage werden folgende Teilfragen untersucht:

1. Inwiefern sind bestehende Ansätze zur Bewertung von Metadaten auf den Kontext von DCAT-AP.de und GovData übertragbar?
2. Welche Qualitätsdimensionen und Indikatoren sind für die Bewertung von DCAT-AP.de-Metadaten im GovData-Kontext relevant?
3. Welche ergänzenden kontext- und semantikbezogenen Prüfungen können das formale Qualitätsmodell sinnvoll erweitern, ohne die Nachvollziehbarkeit und Verlässlichkeit des Scorings zu gefährden?
4. Wie kann ein mehrdimensionales Bewertungsmodell konzeptionell entwickelt und prototypisch operationalisiert werden?
5. Wie kann ein menschenlesbares Qualitätsreporting prototypisch umgesetzt werden, das Bewertungsergebnisse und betroffene Qualitätsdimensionen nachvollziehbar darstellt?

1.4 Aufbau der Arbeit

Es werden theoretische und konzeptionelle Grundlagen beleuchtet. In diesem Kontext werden grundlegende Konzepte wie Open Government Data und das GovData.de Portal erklärt. Metadaten im Open-Data-Kontext sowie RDF, LinkedData und SHACL ausgearbeitet. Aufbauend auf die theoretischen Grundlagen wird das methodische Vorgehen dieser Arbeit beleuchtet. Im Anschluss wird das Konzept und die Operationalisierung des Metadatenqualitätsmodell definiert und ausgearbeitet. Es wird die Zielsetzung und Anforderungen basierend auf der Literaturrecherche, Informationen aus Experteninterviews und analysierten fehlender Dimensionen definiert. Im Anschluss wird das evaluierte Konzept prototypisch in Python implementiert. Die Ergebnisse des Prototyps werden im letzten Kapitel evaluiert und überprüft in wiefern sich das evaluierte Konzept und damit der Prototyp eignet.

2 Theoretische und konzeptionelle Grundlagen

2.1 Open Government Data und das GovData-Portal

Open Data bezeichnet Daten, die frei genutzt, weiterverwendet, und weiterverbreitet werden können. Open Government Data (OGD) ist die öffentliche Ausprägung dieses Konzepts und umfasst Daten und Informationen, die von staatlichen Stellen erzeugt, erhoben, oder beauftragt und unter offenen Bedingungen bereitgestellt werden. Im Zentrum stehen dabei nicht nur der Zugang zu Daten, sondern auch ihre tatsächliche Nutzbarkeit. Damit Daten als offen gelten können, müssen sie möglichst in maschinenlesbaren, nicht-proprietären Formaten, ohne diskriminierende Zugangsbeschränkungen, und unter Bedingungen bereitgestellt werden, die ihre Wiederverwendung erlauben. OGD ist damit mehr als die bloße Veröffentlichung staatlicher Informationen im Internet; gemeint ist die proaktive Bereitstellung wiederverwendbarer Datenbestände des öffentlichen Sektors. [4, 5]

Die Relevanz von OGD begründet sich vor allem mit seinem Beitrag zu Transparenz, Partizipation, Innovation, und öffentlicher Wertschöpfung. Durch die Veröffentlichung staatlicher Daten können Bürger, Medien, Wissenschaft, Zivilgesellschaft, und Unternehmen staatliches Handeln besser nachvollziehen, kontrollieren, und analysieren. OGD kann damit Transparenz und Rechenschaft stärken und zugleich neue Formen gesellschaftlicher Beteiligung unterstützen. Darüber hinaus eröffnet es die Möglichkeit, aus vorhandenen staatlichen Daten neue Anwendungen, Dienstleistungen, und Informationsangebote zu entwickeln. Offene Regierungsdaten werden daher nicht nur als Mittel demokratischer Kontrolle verstanden, sondern auch als Ressource für wirtschaftliche und soziale Innovation. [4]

Datenpolitik ist demnach dann wirksam, wenn sie sich nicht nur auf die Angebotsseite fokussiert, sondern auch Nutzungsbedürfnisse, Datenqualität, Metadaten, und Wiederverwendungsbedingungen berücksichtigt. OGD ist deshalb ein zentrales Element moderner datengetriebener Verwaltung: Es unterstützt Transparenz und gute Regierungsführung, kann innovative und bürgerzentrierte Dienste fördern, und bildet zugleich eine wichtige Grundlage für datenbasierte Entscheidungen im öffentlichen Sektor. Sei-

ne Relevanz ergibt sich damit aus der Verbindung von politischer Offenheit, technischer Nachnutzbarkeit, und gesellschaftlicher Wertschöpfung. [5]

In Deutschland bildet GovData das nationale Metadatenportal für offene Verwaltungsdaten. Das Portal fungiert als zentraler Zugangspunkt zu Datenangeboten von Bund, Ländern, und Kommunen, verwaltet jedoch nicht die physischen Datensätze selbst. Vielmehr werden Metadaten gebündelt, über die auf die dezentral in verschiedenen Fach- und Verwaltungsportalen veröffentlichten Daten verwiesen wird. GovData übernimmt damit vor allem eine Aggregations- und Sichtbarkeitsfunktion, indem verteilte Datenbestände über einen gemeinsamen Metadatenzugang auffindbar gemacht werden. [6]

Im institutionellen Rahmen wird GovData von der Förderalen IT-Kooperation (FITKO) im Produktmanagement betreut. Die FITKO ordnet das Portal ihrem einheitlichen Produktmanagement-Modell für Produkte des IT-Planungsrats zu und verweist für GovData auf ein eigenes föderal besetztes Produktboard [3].

2.2 Metadaten im Open-Data-Kontext

Metadaten lassen sich in Anlehnung an die National Information Standards Organization (NISO) als Informationen verstehen, die erstellt, gespeichert, und geteilt werden, um Informationsressourcen zu beschreiben und dadurch ihren Gebrauch zu ermöglichen. Die klassische Kurzformel „data about data“ greift dabei nur verkürzt. Entscheidend ist der funktionale Aspekt: Metadaten machen eine Ressource identifizierbar, beschreibbar, auffindbar, und in einem bestimmten Nutzungskontext verständlich. NISO betont zudem, dass Metadaten typischerweise strukturiert sind, also in bekannten Kategorien erfasst werden, damit Menschen und Systeme mit ihnen arbeiten können. Für Datensätze im Open-Data-Kontext bedeutet dies, dass Metadaten nicht bloß Begleitinformationen sind, sondern die Beschreibungsschicht, über die Datensätze gefunden, eingeordnet, und verwendet werden können. [7]

NISO unterscheidet grundlegend zwischen deskriptiven, administrativen, strukturellen und Markup Metadaten. Diese sind zur Orientierung in Tabelle 2.1 aufgelistet.

Im Open-Data-Kontext kommt Metadaten eine besondere Bedeutung zu, da offene Datensätze nur dann praktisch nutzbar sind, wenn sie standardisiert beschrieben und dadurch auffindbar, verständlich, und zwischen verschiedenen Katalogen interoperabel gemacht werden. DCAT ist hierfür das zentrale W3C-Vokabular, das die interoperable Beschreibung von Datenkatalogen, Datensätzen, und Datendiensten im Web ermöglichen soll. [8]

In funktionaler Hinsicht lassen sich die im GovData-Kontext verwendeten Metadaten

Metadatatyp	Beschreibung
Deskriptive Metadaten	Dienen der inhaltlichen Beschreibung einer Ressource und unterstützen deren Identifikation und Auffindbarkeit.
Administrative Metadaten	Unterstützen die Verwaltung einer Ressource, etwa durch Angaben zu Rechten, technischen Eigenschaften, Provenienz oder Erhaltung.
Strukturelle Metadaten	Beschreiben den Aufbau einer Ressource sowie die Beziehungen zwischen ihren Bestandteilen.
Markup-Metadaten	Kennzeichnen die logische oder semantische Struktur innerhalb eines digitalen Objekts.

Tabelle 2.1: Metadatatypen in Anlehnung an NISO, eigene Übersetzung und Paraphrase [7]

vor allem als deskriptive und administrative Metadaten einordnen, da sie einerseits der Beschreibung und Auffindbarkeit von Verwaltungsdaten dienen und andererseits Informationen zur Bereitstellung, zu Formaten, zu offenen Lizenzen, und zur Nachnutzbarkeit enthalten [7, 3]. Da GovData selbst als nationales Metadatenportal fungiert, einen Metadatenkatalog bereitstellt, und die beschriebenen Verwaltungsdaten weiterhin dezentral bei den bereitstellenden Stellen verbleiben, kommt dieser Beschreibungsschicht eine zentrale infrastrukturelle Funktion zu [3].

2.3 DCAT-AP.de als Metadatenstandard

Für den Austausch offener Verwaltungsdaten im deutschen Open-Data-Kontext kommt DCAT-AP.de eine zentrale Rolle zu. Der Standard definiert ein gemeinsames deutsches Metadatenmodell, mit dem Metadaten aus unterschiedlichen Open-Data-Portalen interoperabel bereitgestellt und über GovData zentral auffindbar gemacht werden können. [9, 10, 11]

Für den Austausch offener Verwaltungsdaten im deutschen Open-Data-Kontext kommt dem Standard DCAT-AP.de eine zentrale Rolle zu. DCAT-AP.de ist das gemeinsame deutsche Metadatenmodell für den Austausch offener Verwaltungsdaten und dient dazu, Metadaten aus unterschiedlichen Portalen in einer einheitlichen Struktur bereitzustellen [9]. Sein Zweck liegt insbesondere darin, Metadaten offener Verwaltungsdaten zwischen deutschen Open-Data-Portalen interoperabel auszutauschen und diese Da-

ten über GovData zentral auffindbar zu machen [11, 10].

DCAT-AP.de ist keine isolierte nationale Eigenentwicklung, sondern eine deutsche Ableitung des europäischen Standards DCAT-AP, der wiederum auf dem W3C-Vokabular DCAT aufbaut. Damit steht der Standard in einem mehrstufigen Interoperabilitätszusammenhang: vom allgemeinen Modell für Datenkataloge im Web über das europäische Anwendungsprofil bis hin zur deutschen Spezifikation für offene Verwaltungsdaten [9, 11]. Diese Einbettung ist insbesondere deshalb relevant, weil Metadaten im GovData-Kontext nicht nur innerhalb Deutschlands ausgetauscht, sondern zugleich an europäische Entwicklungen anschlussfähig bleiben sollen [3].

Die Qualität und Standardkonformität der Metadaten ist damit eine zentrale Voraussetzung dafür, dass Datensätze portalübergreifend auffindbar, maschinell verarbeitbar und interoperable nachnutzbar werden [3, 12].

Zugleich zeigt sich an DCAT-AP.de, dass Metadaten im Open-Data-Kontext nicht nur eine dokumentierende, sondern auch eine strukturierende Funktion haben. Der Standard legt fest, welche Informationen in welcher Form beschrieben werden sollen, und schafft so die Grundlage für einheitliche semantische Beschreibungen, föderierte Suche, und die Weiterverarbeitung von Metadaten über Schnittstellen und Portale hinweg [11, 13]. Für die vorliegende Arbeit ist DCAT-AP.de damit der maßgebliche Referenzrahmen, innerhalb dessen sich die Frage nach der Qualität von Metadaten im GovData-Kontext konkretisiert.

2.4 RDF, Linked Data und SHACL

RDF bildet die technische Grundlage für die Beschreibung von Metadaten im Semantic-Web-Kontext. Nach der W3C-Spezifikation ist RDF ein Modell zur Repräsentation von Informationen im Web, dessen Kernstruktur aus Subjekt-Prädikat-Objekt-Tripeln besteht, die gemeinsam als RDF-Graph modelliert werden. RDF ist damit nicht primär als konkretes Dateiformat zu verstehen, sondern als abstraktes Datenmodell, auf dem unterschiedliche RDF-basierte Sprachen und Serialisierungen aufbauen. [14]

Für GovData ist RDF unmittelbar relevant, da die zuliefernden Stellen ihre Datenkataloge im RDF-Format und konform zum geltenden Metadatenstandard DCAT-AP.de für den Import in das Portal bereitstellen. Die Original-Metadaten können dabei über den Endpunkt eines Triple Stores mittels SPARQL-Abfragen durchsucht und kombiniert werden. Ein Triple Store ist eine auf RDF-Daten spezialisierte Datenbank, in der Informationen als RDF-Tripel beziehungsweise RDF-Graphen gespeichert und abgefragt werden können. SPARQL ist die standardisierte Abfragesprache für RDF-Daten und

ermöglicht es, RDF-Graphen beziehungsweise RDF-Datenbestände über Graphmuster zu durchsuchen und auszuwerten [15, 16]. RDF fungiert in diesem Kontext somit als gemeinsames Modell, in dem Metadaten standardisiert beschrieben, gespeichert, und verarbeitet werden.

Die Bedeutung von RDF hängt eng mit den Prinzipien von Linked Data zusammen. Linked Data zielt darauf, Daten im Internet so zu veröffentlichen, dass sie maschinell verarbeitbar, referenzierbar, und mit anderen Datenbeständen verknüpfbar sind. Für Datenkataloge ist dies insbesondere deshalb relevant, weil Metadaten nicht nur innerhalb einzelner Portale genutzt, sondern auch katalogübergreifend aggregiert und durchsucht werden sollen. Das W3C-Vokabular DCAT ist genau für diesen Zweck konzipiert: Es soll die Interoperabilität zwischen im Web veröffentlichten Datenkatalogen erleichtern, die Aggregation von Metadaten aus mehreren Katalogen unterstützen, die Auffindbarkeit von Datensätzen erhöhen, und föderierte Suche über verschiedene Kataloge hinweg ermöglichen. [8]

Zur formalen Validierung von RDF-basierten Metadaten dient SHACL. Die W3C beschreibt SHACL als eine Sprache zur Validierung von RDF-Graphen gegen eine Menge von Bedingungen, die in Form sogenannter Shapes ausgedrückt werden. Auf diese Weise lassen sich etwa Kardinalitäten, Datentypen, Klassenzugehörigkeiten, oder Wertebereiche prüfen. SHACL ermöglicht somit die formale Überprüfung, ob ein RDF-Datenbestand vorgegebene strukturelle und syntaktische Anforderungen erfüllt. [17]

Gleichzeitig ist formale Validierung nicht mit umfassender Qualitätsbewertung gleichzusetzen. SHACL dient der Prüfung von RDF-Graphen gegen formal definierte Constraints und erlaubt damit insbesondere Aussagen über strukturelle und syntaktische Konformität [17]. In der Literatur zu Linked Data und Metadatenqualität wird Validierung zwar als zentraler Bestandteil der Qualitätsprüfung betrachtet, zugleich aber betont, dass darüber hinaus weitere Qualitätsdimensionen wie Vollständigkeit, Auffindbarkeit, Genauigkeit, oder Nachnutzbarkeit relevant sind [18, 19, 20]. SHACL kann folglich wichtige Aussagen über Regelkonformität liefern, erfasst jedoch nicht automatisch alle Aspekte, die für die praktische Qualität von Metadaten entscheidend sind. Dies gilt insbesondere im GovData-Kontext, in dem Metadaten nicht nur formal korrekt, sondern auch für die zentrale Auffindbarkeit und Nachnutzung dezentral bereitgestellter Verwaltungsdaten geeignet sein müssen [3].

2.5 Datenqualität

Datenqualität wird in der Forschung nicht als eindimensionale Eigenschaft verstanden, sondern als mehrdimensionales Konzept, das sich erst im Verhältnis zu einem konkreten Nutzungskontext bestimmen lässt.

2.5.1 Definition nach Wang and Strong 1996

Einen zentralen Referenzpunkt bildet die Arbeit von Wang und Strong, die Datenqualität als „fitness for use“ definieren und damit die Perspektive der Datennutzenden in den Mittelpunkt stellen [21]. Ausgehend von einer empirischen Untersuchung von Datenkonsumentinnen und -konsumenten entwickeln sie ein hierarchisches Rahmenmodell, in dem Datenqualitätsmerkmale nicht allein aus theoretischen Vorannahmen oder aus Sicht von Systementwickelnden abgeleitet werden, sondern aus den Anforderungen tatsächlicher Nutzungssituationen hervorgehen [21]. Damit verschiebt sich der Fokus von einem engen Verständnis von Datenqualität als bloßer Fehlerfreiheit zu einem breiteren Verständnis, das auch Relevanz, Verständlichkeit, Zugänglichkeit, und Nutzungseignung umfasst.

Wang und Strong unterscheiden vier übergeordnete Kategorien von Datenqualität: intrinsische, kontextuelle, repräsentationale, und zugangsbezogene Qualität [21]. Diese Kategorien bündeln insgesamt 15 untergeordnete Dimensionen und beschreiben unterschiedliche Perspektiven auf Datenqualität.

- **Intrinsische Qualität** betrifft Eigenschaften, die den Daten selbst zugeschrieben werden können. Darunter befinden sich die Dimensionen *Genauigkeit*, *Objektivität*, *Glaubwürdigkeit* und *Reputation*.
- **Kontextuelle Qualität** verweist darauf, dass Daten nur in Relation zu einem bestimmten Verwendungszweck bewertet werden können und umfasst daher insbesondere *Relevanz*, *Mehrwert*, *Aktualität*, *Vollständigkeit* und eine *angemessene Datenmenge*.
- **Repräsentationale Qualität** betrifft die Form der Darstellung, also *Interpretierbarkeit*, *Verständlichkeit*, *prägnante Repräsentation* und *konsistente Darstellung*.
- **Zugangsbezogene Qualität** beschreibt, ob Daten für ihre Nutzung überhaupt verfügbar und unter angemessenen Sicherheitsbedingungen zugänglich sind.

Qualität ist in diesem Verständnis weder vollständig inhärent noch allein technisch gegeben. Vielmehr hängt sie davon ab, ob Daten in einem bestimmten Arbeits- oder Ent-

scheidungskontext brauchbar sind [21]. Diese Perspektive wurde von Strong, Lee, und Wang weiter ausgebaut, die betonen, dass Datenqualitätsprobleme nicht nur in gespeicherten Daten selbst entstehen, sondern im weiteren Kontext von Informationssystemen, also auch in Produktions-, Speicher-, und Nutzungskontexten [22].

Ergänzend zu diesem nutzungsbezogenen Rahmen schlagen Wand und Wang eine ontologische Fundierung von Datenqualität vor [23]. Ausgangspunkt ihres Ansatzes ist die Annahme, dass Informationssysteme reale Sachverhalte repräsentieren. Datenqualitätsprobleme lassen sich dann als Repräsentationsdefizite zwischen der beobachtbaren realen Welt und ihrer Abbildung im Informationssystem beschreiben [23]. Auf dieser Grundlage unterscheiden sie insbesondere Defizite wie Unvollständigkeit, Mehrdeutigkeit, Bedeutungslosigkeit, und Fehlerhaftigkeit. Der Beitrag dieses Ansatzes liegt weniger in einer nutzungsbezogenen Typologie als vielmehr in einer begrifflich präziseren theoretischen Herleitung von Qualitätsdimensionen. Während Wang und Strong den empirisch wahrgenommenen Qualitätsbedarf von Datennutzenden systematisieren, zeigen Wand und Wang, dass Datenqualität auch als Frage adäquater Repräsentation modelliert werden kann. Beide Perspektiven ergänzen sich daher: Die eine macht die Anwendungs- und Nutzerseite sichtbar, die andere präzisiert die begriffliche und modelltheoretische Grundlage von Qualitätsdefiziten.

2.5.2 Qualitätsmodell der ISO-Norm 25012

Ergänzend zur Definition von Wang und Strong bietet der Standard ISO/IEC 25012 einen normativen Bezugsrahmen. Der Standard ist weiterhin aktuell und die Ausgabe von 2008 wurde von ISO im Jahr 2025 bestätigt. Er definiert ein allgemeines Datenqualitätsmodell für strukturiert in Computersystemen gehaltene Daten. Datenqualitätsmerkmale werden den Perspektiven inhärenter und systemabhängiger Qualität zugeordnet. [24]

Figur 2.1 veranschaulicht den definierten Standard. Das Modell umfasst 15 Qualitätsmerkmale und betont ausdrücklich, dass deren Relevanz je nach Stakeholdern und Anwendungskontext variiert.

Inhärente Datenqualität beschreibt den Grad, zu dem Daten das ihnen inhärente Potenzial besitzen, festgelegte Anforderungen bei ihrer Nutzung unter bestimmten Bedingungen zu erfüllen. Aus dieser Perspektive bezieht sich Datenqualität auf Eigenschaften, die den Daten selbst zugeschrieben werden können. Dazu zählen insbesondere:

- die Wertebereiche von Daten sowie mögliche Einschränkungen,
- die Beziehungen zwischen einzelnen Datenwerten,
- sowie die zugehörigen Metadaten.




Abbildung 2.1: Schematische Darstellung inhärenter und systemabhängiger Datenqualitätsmerkmale in Anlehnung an ISO/IEC 25012. [24]

Systemabhängige Datenqualität bezeichnet demgegenüber den Grad, zu dem Datenqualität innerhalb eines Computersystems erreicht und aufrechterhalten wird, wenn die Daten unter festgelegten Bedingungen verwendet werden.

Im Vergleich zu Wang und Strong fällt auf, dass ISO/IEC 25012 stärker normativ und modellorientiert vorgeht, während Wang und Strong die Qualitätswahrnehmung empirisch aus Sicht von Datennutzenden rekonstruieren. Gleichwohl bestehen deutliche Überschneidungen. Merkmale wie Genauigkeit, Vollständigkeit, Zugänglichkeit, Verständlichkeit, und Aktualität erscheinen in beiden Ansätzen als zentrale Komponenten von Datenqualität. Die Unterschiede liegen vor allem im jeweiligen Erkenntnisinteresse: Wang und Strong strukturieren Datenqualität aus der Perspektive der Nutzung, Wang und Wang fundieren Datenqualität über die Angemessenheit der Repräsentation realweltlicher Sachverhalte, und ISO/IEC 25012 stellt ein standardisiertes Qualitätsmodell für Daten in Computersystemen bereit.

Diese Datenqualitätsmodelle liefern eine notwendige Grundlage, reichen für die Bewertung von Metadaten im Open-Data-Kontext jedoch nicht aus. Metadaten dienen nicht primär der unmittelbaren Abbildung realweltlicher Sachverhalte, sondern der strukturierten Beschreibung, Auffindbarkeit, Zugänglichkeit, Interoperabilität, und Wiederver-

wendbarkeit von Datenressourcen. Damit verschiebt sich der Bewertungsfokus von einzelnen Datenwerten hin zu der Frage, ob Metadaten die Nutzung und Nachnutzung der beschriebenen Ressourcen ermöglichen.

2.5.3 FAIR-Prinzipien

Eine weitere zentrale Referenz bilden die FAIR-Prinzipien von Wilkinson et al. [25]. Die im Jahr 2016 veröffentlichten FAIR Guiding Principles formulieren einen domänenunabhängigen Orientierungsrahmen für gutes Datenmanagement und Data Stewardship. Ziel ist es, die Nachnutzbarkeit digitaler Ressourcen zu verbessern, indem Daten und Metadaten so beschrieben, bereitgestellt, und strukturiert werden, dass sie von Menschen und Maschinen gefunden, abgerufen, integriert, und wiederverwendet werden können.

Ein zentrales Merkmal der FAIR-Prinzipien ist ihr Fokus auf Maschinenlesbarkeit und maschinelle Handlungsfähigkeit. Wilkinson et al. betonen, dass die Prinzipien nicht nur die Nachnutzung durch menschliche Forschende unterstützen sollen, sondern ausdrücklich auch die Fähigkeit von Maschinen verbessern, Daten automatisch zu finden und zu nutzen [25]. FAIR adressiert damit nicht nur die formale Existenz von Daten, sondern auch die Qualität der umgebenden Metadaten, Identifikatoren, Zugriffspfade, Vokabulare, Lizenzen, Provenienzangaben, und Standards.

Die FAIR-Prinzipien gliedern sich in vier Kategorien:

- **F**indable (Auffindbarkeit),
- **A**ccessible (Zugänglichkeit),
- **I**nteroperable (Interoperabilität),
- **R**eusable (Wiederverwendbarkeit).

Diese vier Kategorien werden durch 15 Teilprinzipien konkretisiert, die in Tabelle 2.2 dargestellt sind. Die Prinzipien sind dabei bewusst als hochlevelige Leitlinien formuliert. Ihre Umsetzung kann daher inkrementell erfolgen und hängt vom jeweiligen Datenbestand, Fachkontext, und technischen Ökosystem ab.[25]

Im Kontext von DCAT-AP.de sind die FAIR-Prinzipien insbesondere deshalb relevant, weil die Metadaten viele FAIR-Anforderungen direkt adressieren können. FAIR eignet sich damit nicht als alleinige Bewertungsmetrik, wohl aber als konzeptionelle Grundlage zur Ableitung metadatenspezifischer Qualitätsdimensionen und Einzelindikatoren.

Auffindbar (Findable)	
F1	(Meta-)Daten erhalten einen global eindeutigen und persistenten Identifikator.
F2	Daten werden mit reichhaltigen Metadaten beschrieben, wie in R1 definiert.
F3	Metadaten enthalten den Identifikator der beschriebenen Daten klar und explizit.
F4	(Meta-)Daten sind in einer durchsuchbaren Ressource registriert oder indexiert.
Zugänglich (Accessible)	
A1	(Meta-)Daten sind über ihren Identifikator mithilfe eines standardisierten Kommunikationsprotokolls abrufbar.
A1.1	Das Protokoll ist offen, kostenlos und universell implementierbar.
A1.2	Das Protokoll ermöglicht, falls erforderlich, Authentifizierungs- und Autorisierungsverfahren.
A2	Metadaten bleiben zugänglich, auch wenn die Daten selbst nicht mehr verfügbar sind.
Interoperabel (Interoperable)	
I1	(Meta-)Daten verwenden eine formale, zugängliche, gemeinsame und breit anwendbare Sprache zur Wissensrepräsentation.
I2	(Meta-)Daten verwenden Vokabulare, die selbst den FAIR-Prinzipien folgen.
I3	(Meta-)Daten enthalten qualifizierte Verweise auf andere (Meta-)Daten.
Wiederverwendbar (Reusable)	
R1	Meta(daten) werden mit einer Vielzahl genauer und relevanter Attribute reichhaltig beschrieben.
R1.1	(Meta-)Daten werden mit einer klaren und zugänglichen Nutzungslizenz veröffentlicht.
R1.2	(Meta-)Daten sind mit detaillierter Provenienz verknüpft.
R1.3	(Meta-)Daten erfüllen domänenspezifische Community-Standards.

Tabelle 2.2: FAIR-Prinzipien nach Wilkinson et al. [25]

2.6 Metadatenqualität und Qualitätsbewertung von Linked Data

Im Kontext von Metadaten und Linked Data wird sichtbar dass oben genannte Konzepte nur bedingt greifen. Neben regulären Dimensionen wie Vollständigkeit, Auffindbarkeit oder Wiederverwendbarkeit wurden im Bereich Linked Data spezifische Qualitätsanforderungen entwickelt die über die klassischen Konzepte hinausgehen.

2.6.1 Linked-Data-Qualität nach Zaveri et al.

Einen zentralen Referenzpunkt für die systematische Einordnung von Metadatenqualität im Semantic-Web- und Linked-Data-Kontext bildet die Arbeit von Zaveri et al. [20]. In ihrem Survey konsolidieren die Autorinnen und Autoren den Forschungsstand zur Qualitätsbewertung von Linked Data. Grundlage ist eine systematische Literaturliteraturauswertung, in der 118 potenziell relevante Arbeiten identifiziert, 73 Arbeiten näher geprüft, und schließlich 30 Kernansätze sowie 12 Werkzeuge zur Linked-Data-Qualitätsbewertung vergleichend analysiert werden [20]. Der Beitrag ist deshalb besonders geeignet als Ausgangspunkt, weil er zuvor isoliert betrachtete Qualitätsprobleme, Bewertungsansätze, Metriken, und Werkzeuge in einem gemeinsamen konzeptionellen Rahmen zusam-

menführt.

Ausgangspunkt der Arbeit ist die Beobachtung, dass die bloße Veröffentlichung von Daten im RDF-Format oder unter Verwendung dereferenzierbarer URIs noch keine hohe Datenqualität garantiert. Linked Data kann formal korrekt publiziert sein und zugleich unvollständig, inkonsistent, veraltet, schwer interpretierbar, oder unzureichend mit anderen Datenquellen verknüpft sein [20].

Zaveri et al. strukturieren diese Anforderungen in einem umfassenden Qualitätsrahmen mit insgesamt 18 Dimensionen und 69 Metriken [20]. Die Dimensionen werden vier übergeordneten Kategorien zugeordnet: Zugänglichkeit, intrinsische Qualität, kontextuelle Qualität und repräsentationale Qualität. Die zusammengefasste Metrik wird als Orientierung in Tabelle 2.3 dargestellt.

Die Metriken werden bei Zaveri et al. zusätzlich danach unterschieden, ob sie quantitativ oder qualitativ bewertbar sind. Quantitative Metriken (QN) sind Metriken, für die ein konkreter numerischer Wert berechnet werden kann. Häufig handelt es sich dabei um Verhältniswerte, bei denen die Anzahl beobachteter oder erfüllter Entitäten ins Verhältnis zu einer erwarteten Gesamtmenge gesetzt wird, etwa bei Schema- oder Property-Vollständigkeit. Qualitative Metriken (QL) sind dagegen nicht unmittelbar objektiv berechenbar, sondern hängen von Einschätzungen, Wahrnehmungen, Expert:innenurteilen, Umfragen, oder externen Vertrauensbewertungen ab. Dies betrifft insbesondere Metriken der Vertrauenswürdigkeit, etwa die Einschätzung eines Datenanbieters oder einer Datenquelle [20].

Die Prüfung der Metriken erfolgt nicht über ein einheitliches technisches Verfahren, sondern hängt vom jeweiligen Qualitätsaspekt ab. Zaveri et al. beschreiben unterschiedliche Prüflogiken, darunter Verhältnisberechnungen, Syntax- und Datentypprüfungen, URI-Analysen, Link- und Dereferenzierbarkeitsprüfungen, Lizenz- und Vokabularprüfungen, Konsistenzanalysen, Provenienz- und Vertrauensbewertungen, sowie nutzer- oder expert:innenbasierte Einschätzungen. Bewertet werden können dabei unterschiedliche Ebenen von Linked Data, insbesondere einzelne RDF-Tripel, RDF-Graphen, Entitäten, oder ganze Datensätze [20].

2.6.2 Automatisierte Metadatenbewertung in Open-Data-Portalen nach Neumaier et al.

Während Zaveri et al. die Qualität von Linked Data domänenübergreifend systematisieren, weisen Neumaier et al. einen deutlich stärkeren Praxisbezug für Open-Data-Portale auf. In ihrer Arbeit entwickeln sie einen automatisierten Ansatz zur Bewertung von Metadatenqualität über unterschiedliche Datenportale hinweg [19]. Ausgangspunkt ist die Beobachtung, dass Open-Data-Portale zwar zunehmend Datensätze veröffentlichen,

Unterdimension	Metrik	Beschreibung
Zugänglichkeit		
Verfügbarkeit	A1	Zugänglichkeit des SPARQL-Endpunkts und Servers.
	A2	Zugänglichkeit von RDF-Dumps.
	A3	Dereferenzierbarkeit von URIs.
	A4	Keine falsch gemeldeten Content Types.
	A5	Dereferenzierbarkeit ausgehender Links.
Lizenzierung	L1	Maschinenlesbare Lizenzangabe.
	L2	Menschenlesbare Lizenzangabe.
	L3	Korrekte Lizenz angegeben.
Interlinking	I1	Qualitativ hochwertige externe Links.
	I2	Existenz externer Verlinkungen.
	I3	Dereferenzierbarkeit eingehender Links.
Sicherheit	S1	Verwendung digitaler Signaturen.
	S2	Authentizität des Datensatzes.
Performanz	P1	Geeignete URI-Strategie.
	P2	Niedrige Latenz.
	P3	Hoher Durchsatz.
	P4	Skalierbarkeit.
Intrinsische Qualität		
Syntaktische Validität	SV1	Keine Syntaxfehler.
	SV2	Korrekte Werteformate.
	SV3	Gültige Datentypliterale.
Semantische Genauigkeit	SA1	Keine Ausreißer.
	SA2	Keine ungenauen Werte.
	SA3	Korrekte Annotationen und Klassifikationen.
	SA4	Kein Missbrauch von Properties.
	SA5	Gültige Regeln erkannt.
Konsistenz	CN1	Keine disjunkten Klassenverletzungen.
	CN2	Keine falsch platzierten Klassen oder Properties.
	CN3	Korrekte Property-Typisierung.
	CN4	Keine veralteten Klassen oder Properties genutzt.
	CN5	Korrekte inverse funktionale Properties.
	CN6	Kein Ontologie-Hijacking.
	CN7	Keine negativen Abhängigkeiten.
	CN8	Keine räumlichen Inkonsistenzen.
	CN9	Korrekte Domain- und Range-Definitionen.
	CN10	Keine widersprüchlichen Werte.
Prägnanz	CS1	Hohe intensionale Prägnanz.
	CS2	Hohe extensionale Prägnanz.
	CS3	Eindeutige Labels.
Vollständigkeit	CP1	Schemakomplettheit.
	CP2	Property-Komplettheit.
	CP3	Populationskomplettheit.
	CP4	Interlinking-Komplettheit.
Kontextuelle Qualität		
Relevanz	R1	Relevante Begriffe in Metadaten.
	R2	Abdeckung.
Vertrauenswürdigkeit	TW1	Vertrauenswürdigkeit von Aussagen.
	TW2	Vertrauenswürdigkeit durch Reasoning.
	TW3	Vertrauenswürdigkeit von Datensatz und Regeln.
	TW4	Vertrauenswürdigkeit der Ressource.
	TW5	Vertrauenswürdigkeit des Anbieters.
	TW6	Vertrauenswürdigkeit der Information.
	TW7	Reputation des Datensatzes.
Verständlichkeit	U1	Menschenlesbare Labels.
	U2	Beispielhafte URIs vorhanden.
	U3	URI-Muster dokumentiert.
	U4	Beispielhafte SPARQL-Query vorhanden.
	U5	Verwendete Vokabulare angegeben.
	U6	Supportkanäle vorhanden.
Aktualität	T1	Frische auf Basis von Currency und Volatility.
	T2	Frische auf Basis der Datenquelle.
Repräsentationale Qualität		
Repräsentationsprägnanz	RC1	Kurze URIs.
	RC2	Keine unnötig komplexen RDF-Features.
Interoperabilität	ITO1	Wiederverwendung existierender Terme.
	ITO2	Wiederverwendung etablierter Vokabulare.
Vielseitigkeit	V1	Mehrere Serialisierungsformate verfügbar.
	V2	Mehrsprachigkeit.
Interpretierbarkeit	ITP1	Selbstbeschreibende Formate.
	ITP2	Gute Interpretierbarkeit.
	ITP3	Keine undefinierten Klassen oder Properties.
	ITP4	Keine Fehlinterpretation fehlender Werte.

Tabelle 2.3: Qualitätsdimensionen und Metriken für Linked Data nach Zaveri et al. [20]

deren tatsächliche Auffindbarkeit, Zugänglichkeit, und Nachnutzbarkeit jedoch maßgeblich von der Qualität der zugehörigen Metadaten abhängt. Fehlende, fehlerhafte, oder inkonsistente Metadaten reduzieren damit den praktischen Wert veröffentlichter Datenbestände erheblich.

Methodisch besteht der Ansatz aus drei zentralen Bausteinen. Erstens modellieren die Autorinnen und Autoren Open-Data-Portale formal als Webportale, die Funktionen zum Listen, Abrufen, Anzeigen, und Verarbeiten von Datensätzen und Ressourcen

cen bereitstellen. Zweitens werden die heterogenen Metadatenmodelle verschiedener Portalsoftware-Systeme auf ein gemeinsames semantisches Referenzmodell überführt. Berücksichtigt werden dabei Comprehensive Knowledge Archive Network (CKAN), Socrata und OpenDataSoft. Als Harmonisierungsschicht dient dabei DCAT, wodurch portalübergreifende Vergleiche überhaupt erst möglich werden. Drittens definieren die Autoren konkrete Qualitätsmetriken auf Basis zentraler DCAT-Eigenschaften, die automatisiert, skalierbar, und effizient berechnet werden können [19].

Die Ableitung der Metriken erfolgt dabei nicht beliebig, sondern orientiert sich an zwei Anforderungen: Einerseits sollen die Qualitätskriterien für die Nutzbarkeit von Open Data relevant sein, andererseits müssen sie technisch automatisiert überprüfbar sein. Berücksichtigt werden daher vor allem Eigenschaften, die direkt aus Portalmetadaten oder durch maschinelle Prüfungen von Ressourcen-URLs ableitbar sind. Ergänzend werden externe Prüfungen eingesetzt, etwa HTTP-Requests zur Erreichbarkeit von Ressourcen oder Validierungen von Datums-, URL-, und E-Mail-Formaten. Der Fokus liegt somit auf objektiv messbaren und reproduzierbaren Kriterien.

Aus diesen Überlegungen leiten Neumaier et al. fünf Qualitätsdimensionen ab, die unterschiedliche Aspekte von Metadatenqualität adressieren. Die Dimensionen und zugehörigen Metriken sind in Tabelle 2.4 dargestellt.

Metrik	Beschreibung	dcat:Dataset	dcat:Distribution
Existence			
Access*	Existieren Zugriffsinformationen für Ressourcen?	–	dcat:accessURL, dcat:downloadURL
Discovery	Sind Informationen vorhanden, die das Auffinden oder Suchen von Datensätzen unterstützen?	dct:title, dct:description, dcat:keyword	–
Contact*	Existieren Informationen, die eine Kontaktaufnahme mit dem Datenanbieter ermöglichen?	dcat:contactPoint, dct:publisher	–
Rights	Existieren Informationen zur Lizenz des Datensatzes oder der Ressource?	dct:license	–
Preservation	Existieren Informationen zu Format, Größe, oder Aktualisierungsfrequenz der Ressourcen?	dct:accrualPeriodicity	dct:format, dcat:mediaType, dcat:byteSize
Date	Existieren Informationen zu Erstellungs- und Änderungsdatum von Metadaten beziehungsweise Ressourcen?	dct:issued, dcat:modified	dct:issued, dcat:modified
Conformance			
AccessURL*	Sind die Werte der Zugriffseigenschaften gültige HTTP-URLs?	–	dcat:accessURL, dcat:downloadURL
ContactEmail*	Sind die Werte der Kontakteigenschaften gültige E-Mail-Adressen?	dcat:contactPoint, dct:publisher	–
ContactURL*	Sind die Werte der Kontakteigenschaften gültige HTTP-URLs?	dcat:contactPoint, dct:publisher	–
DateFormat	Sind Datumsinformationen in einem gültigen Datumsformat angegeben?	dct:issued, dcat:modified	dct:issued, dcat:modified
License	Kann die Lizenz auf die von opendefinition.org geprüfte Lizenzliste abgebildet werden?	dct:license	–
FileFormat	Ist das angegebene Dateiformat oder der Medientyp bei IANA registriert?	–	dct:format, dcat:mediaType
Retrievability			
Retrievable	Können die beschriebenen Ressourcen von einem Agenten abgerufen werden?	–	dcat:accessURL, dcat:downloadURL
Accuracy			
FormatAccr	Ist das angegebene Dateiformat korrekt?	–	dct:format, dcat:mediaType
SizeAccr	Ist die angegebene Dateigröße korrekt?	–	dcat:byteSize
Open Data			
OpenFormat	Basiert das Dateiformat auf einem offenen Standard?	–	dct:format, dcat:mediaType
MachineRead	Kann das Dateiformat als maschinenlesbar gelten?	–	dct:format
OpenLicense	Entspricht die verwendete Lizenz der Open Definition?	dct:license	–

Tabelle 2.4: Qualitätsdimensionen auf DCAT-Schlüsseln nach Neumaier et al. [19]

Der empirische Mehrwert des Ansatzes liegt in seiner großskaligen Anwendung. Neumaier et al. implementieren das Modell in der Plattform *Open Data Portal Watch* und

wenden es auf eine große Zahl internationaler Portale an. Dadurch zeigen sie, dass automatisierte Qualitätsbewertung nicht nur konzeptionell möglich, sondern auch im produktiven Monitoring größerer Portalökosysteme praktikabel ist. Gleichzeitig werden typische Qualitätsprobleme sichtbar, etwa fehlende Lizenzen, nicht erreichbare Ressourcen, unvollständige Beschreibungen, oder mangelnde Standardisierung bestimmter Felder.

2.6.3 Gewichtung und Ranking von Open-Data-Portalen nach Kubler et al.

Am im Abschnitt 2.6.2 beschriebenen Ansatz setzen Kubler et al. unmittelbar bei der Frage an, wie solche heterogenen Einzelmetriken zu einer vergleichenden Gesamtbewertung aggregiert werden können.

Kubler et al. beschreiben die Bewertung von Open-Data-Portalen als Multi-Criteria Decision Making Problem und entwickeln mit dem Open Data Portal Quality Framework einen Ansatz, der automatisiert berechnete Qualitätsindikatoren mit nutzerspezifischen Präferenzen verbindet [26].

Die zugrunde liegenden Qualitätsdimensionen schließen an die von Neumaier et al. entwickelte Metrikstruktur an und umfassen *Existence*, *Conformance*, *Retrievability*, *Accuracy*, and *Open Data*. Diese Dimensionen wurden bereits in Tabelle 2.4 zusammengefasst. Der wesentliche Beitrag von Kubler et al. liegt in der nachgelagerten Gewichtungs- und Rankinglogik. Hierfür verwenden sie den Analytic Hierarchy Process (AHP), da dieser unterschiedliche Qualitätsdimensionen, Subdimensionen, und Alternativen hierarchisch strukturieren und Nutzerpräferenzen in Gewichtungen überführen kann. Die Hierarchie besteht aus einem Zielniveau, das die Bewertung und Rangordnung der überwachten Open-Data-Portale nach Metadatenqualität beschreibt, einem Kriterien- und Subkriterienniveau, das den Qualitätsdimensionen und Metriken entspricht, sowie einem Alternativenniveau, das durch die verglichenen Portale gebildet wird. Die technische Operationalisierung trennt die Erhebung der Qualitätsindikatoren von der nutzerspezifischen Präferenz- und Rankingberechnung. Open Data Portal Watch übernimmt die Sammlung und Speicherung der Portaldaten, die Abbildung der Metadaten auf DCAT sowie die Berechnung der Qualitätsmetriken. Das ODPQ-Dashboard nutzt diese berechneten Qualitätswerte, stellt sie für den Vergleich von Portalen bereit, speichert Nutzerpräferenzen und berechnet daraus ein Ranking für einen bestimmten Zeitpunkt oder eine Entwicklung der Rangordnung über mehrere Zeitpunkte hinweg. In dieser Architektur können Nutzer einzelne Qualitätsdimensionen oder Subdimensionen priorisieren. Die Rangordnung der Portale ergibt sich anschließend aus der Kombination der verfügbaren Qualitätswerte mit den gesetzten Präferenzen. [26]

Der Ansatz zeigt, dass eine Qualitätsbewertung von Metadaten nicht bei der Erhebung

einzelner Validierungs- oder Qualitätswerte stehen bleiben sollte, sondern eine explizite Aggregationslogik benötigt.

2.6.4 Operationalisierung der Metadatenqualitätsbewertung durch MQA/Piveau

Das MQA-Framework von Wentzel et al. stellt eine praxisnahe Operationalisierung der automatisierten Qualitätsbewertung von DCAT-AP-Metadaten dar. Wentzel et al. definieren die *DCAT-AP Quality Metrics*, die auf den FAIR-Prinzipien und den 5-star Linked Open Data Principles aufbauen. Die Metriken sind den fünf Dimensionen *Findability*, *Accessibility*, *Interoperability*, *Reusability* und *Contextuality* zugeordnet. Die in Tabelle 2.5 dargestellten Metriken zeigen, dass der Ansatz nicht nur verpflichtende DCAT-AP-Angaben berücksichtigt, sondern auch empfohlene und optionale Eigenschaften bewertet, die für Auffindbarkeit, Zugriff, Interoperabilität und Wiederverwendung praktisch relevant sind.

Dimension	Indikator	Beschreibung	Gewicht
Auffindbarkeit	Schlagwörter	Prüft, ob <code>dcat:keyword</code> gesetzt ist.	30
	Kategorien	Prüft, ob <code>dcat:theme</code> gesetzt ist.	30
	Geographische Suche	Prüft, ob <code>dct:spatial</code> gesetzt ist.	20
	Zeitbasierte Suche	Prüft, ob <code>dct:temporal</code> gesetzt ist.	20
Zugänglichkeit	Erreichbarkeit der Access-URL	Prüft, ob <code>dcat:accessURL</code> technisch erreichbar ist.	50
	Download-URL	Prüft, ob <code>dcat:downloadURL</code> gesetzt ist.	20
	Erreichbarkeit der Download-URL	Prüft, ob <code>dcat:downloadURL</code> technisch erreichbar ist.	30
Interoperabilität	Format	Prüft, ob <code>dct:format</code> gesetzt ist.	50
	Medientyp	Prüft, ob <code>dcat:mediaType</code> gesetzt ist.	10
	Format-/Medientypvokabular	Prüft, ob Format oder Medientyp einem kontrollierten Vokabular zugeordnet werden kann.	10
	Nicht-proprietäres Format	Prüft, ob das angegebene Format nicht proprietär ist.	20
	Maschinenlesbarkeit	Prüft, ob das angegebene Format maschinenlesbar ist.	20
Wiederverwendbarkeit	DCAT-AP-Konformität	Prüft die Metadaten über SHACL gegen DCAT-AP.	30
	Lizenzinformation	Prüft, ob <code>dct:license</code> gesetzt ist.	20
	Lizenzvokabular	Prüft, ob die Lizenz einem kontrollierten Vokabular zugeordnet werden kann.	10
	Zugriffsbeschränkungen	Prüft, ob <code>dct:accessRights</code> gesetzt ist.	10
	Vokabular für Zugriffsbeschränkungen	Prüft, ob <code>dct:accessRights</code> ein kontrolliertes Vokabular verwendet.	5
	Kontaktpunkt	Prüft, ob <code>dcat:contactPoint</code> gesetzt ist.	20
Kontextualität	Herausgeber	Prüft, ob <code>dct:publisher</code> gesetzt ist.	10
	Rechteangaben	Prüft, ob <code>dct:rights</code> gesetzt ist.	5
	Dateigröße	Prüft, ob <code>dcat:byteSize</code> gesetzt ist.	5
	Veröffentlichungsdatum	Prüft, ob <code>dct:issued</code> gesetzt ist.	5
	Änderungsdatum	Prüft, ob <code>dct:modified</code> gesetzt ist.	5

Tabelle 2.5: MQA-Qualitätsmetriken und Gewichtungen nach Wentzel et al. [27, 28]

Die Gewichtung erfolgt über ein Punktesystem mit maximal 405 Punkten. Die höchsten Gewichte entfallen auf Auffindbarkeit, Zugänglichkeit und Interoperabilität, während Kontextualität deutlich geringer gewichtet wird. Dadurch operationalisiert MQA/Piveau Metadatenqualität primär über praktische Nutzbarkeit, technische Zugänglichkeit, strukturelle Interoperabilität und rechtliche Wiederverwendbarkeit. [27, 28]

Ein methodisch wichtiger Bestandteil des Ansatzes ist die Repräsentation der Messergebnisse mithilfe der Data Quality Vocabulary (DQV). DQV erweitert DCAT um ein Vokabular zur maschinenlesbaren Beschreibung von Qualitätsinformationen. Dadurch

können Qualitätsdimensionen, Metriken, Messwerte, geprüfte Ressourcen und Bewertungszeitpunkte explizit miteinander verknüpft werden. Einzelne Messergebnisse werden als `dqv:QualityMeasurement` modelliert, während SHACL-basierte Validierungsergebnisse zur DCAT-AP-Konformität als Qualitätsannotation eingebunden werden können. [28] Beide Modellierungsformen sind in Tabelle 2.6 dargestellt.

(a) Quality Measurement	(b) Quality Annotation
DQV Quality Measurement	DQV Quality Annotation
<code>rdf:type dqv:QualityMeasurement</code> <code>dqv:isMeasurementOf</code> <code>dqv:value</code> <code>dqv:computedOn</code> <code>prov:generatedAtTime</code>	<code>rdf:type dqv:QualityAnnotation</code> <code>oa:hasBody</code> <code>dqv:inDimension</code> <code>oa:motivatedBy</code> <code>dc:isVersionOf</code> <code>oa:hasTarget</code> <code>prov:generatedAtTime</code>

Tabelle 2.6: Modellierung von Quality Measurements und Quality Annotations nach Wentzel et al. [28]

Diese Modellierung trennt geprüfte Ressource, angewandte Metrik, berechneten Wert, Qualitätsdimension und Evidenz voneinander und macht Qualitätsinformationen damit nachvollziehbar sowie maschinenlesbar weiterverarbeitbar. MQA/Piveau zeigt damit, wie formale Validierungsergebnisse, technische Verfügbarkeitsprüfungen und feldbezogene Qualitätsmetriken in ein einheitliches Qualitätsmodell überführt und für Reportingzwecke nutzbar gemacht werden können.

2.6.5 ISO 19157 als Qualitätsinstrument

Der ISO-19157-basierte Ansatz von Nogueras-Iso et al. erweitert eine ursprünglich für geografische Metadaten entwickelte Qualitätsbewertungsmethode auf DCAT-basierte Open-Data-Metadaten. ISO 19157 bietet einen normativen Rahmen, in dem sogenannte *Quality Elements* jeweils durch eine *Measure*, eine *Evaluation Method* und ein oder mehrere *Results* beschrieben werden. Diese Struktur erlaubt es, verschiedene Fehlerarten präziser voneinander zu unterscheiden und Qualitätsmessungen nicht nur als einfache Punktwerte, sondern als methodisch nachvollziehbare Prüfergebnisse zu modellieren. [29]

Für Open-Data-Metadaten übertragen Nogueras-Iso et al. insbesondere Qualitätskategorien wie *Completeness*, *Logical Consistency*, *Temporal Quality*, *Thematic Accuracy*, *Positional Correctness* und *Quality of Free Text*. Tabelle 2.7 fasst die Qualitätselemente, ihre jeweiligen Scopes und Evaluationsarten zusammen.

Anmerkung: SI = DQ_SampleBasedInspection; FI = DQ_FullInspection; AD = DQ_AggregationDerivation.

Qualitätselement	Scope	Measure	Evaluation
DQ_ThematicClassificationCorrectness	Dataset (theme)	D.63 (ISO 19157)	SI / AD
DQ_NonQuantitativeAttributeCorrectness	Dataset (references)	D.68 (ISO 19157)	SI / AD
	Dataset (conformsTo)	D.68 (ISO 19157)	SI / AD
	Distribution (accessURL)	D.68 (ISO 19157)	SI / AD
	Distribution (license)	D.68 (ISO 19157)	SI / AD
DQ_QualityOfFreeText	Dataset (title)	Overall quality of free text	SI / AD
	Dataset (description)	Overall quality of free text	SI / AD
DQ_CompletenessCommission	Dataset (identifier, modified, issued, accrualPeriodicity, license, valid, publisher)	D.3 (ISO 19157)	FI / AD
	Distribution (identifier, accessURL, mediaType, byteSize)	D.3 (ISO 19157)	FI / AD
DQ_CompletenessOmission	Dataset (title, publisher, description, theme, distribution)	D.7 (ISO 19157)	FI / AD
DQ_ConceptualConsistency	Distribution (accessURL, mediaType)	D.7 (ISO 19157)	FI / AD
	Dataset	D.13 (ISO 19157)	FI / AD
	Distribution	D.13 (ISO 19157)	FI / AD
DQ_DomainConsistency	Distribution (format gegenüber accessURL)	D.13 (ISO 19157)	FI / AD
	Dataset.title (string domain)	D.17 (ISO 19157)	FI / AD
	Dataset.description (string domain)	D.17 (ISO 19157)	FI / AD
	Dataset.theme (skos:Concept domain)	D.17 (ISO 19157)	FI / AD
	Dataset.keyword (string domain)	D.17 (ISO 19157)	FI / AD
	Dataset.identifier (URI domain)	D.17 (ISO 19157)	FI / AD
	Dataset.issued (date-time domain)	D.17 (ISO 19157)	FI / AD
	Dataset.modified (date-time domain)	D.17 (ISO 19157)	FI / AD
	Dataset.accrualPeriodicity (frequency domain)	D.17 (ISO 19157)	FI / AD
	Dataset.language (linguistic system domain)	D.17 (ISO 19157)	FI / AD
	Dataset.publisher (foaf:Agent domain)	D.17 (ISO 19157)	FI / AD
	Dataset.spatial (resource URI from predefined province list)	D.17 (ISO 19157)	FI / AD
	Dataset.temporal (period of time domain)	D.17 (ISO 19157)	FI / AD
	Dataset.valid (date-time domain)	D.17 (ISO 19157)	FI / AD
	Dataset.references (URI domain)	D.17 (ISO 19157)	FI / AD
	Dataset.conformsTo (URI domain)	D.17 (ISO 19157)	FI / AD
	Dataset.distribution (Distribution domain)	D.17 (ISO 19157)	FI / AD
	Distribution.identifier (URI domain)	D.17 (ISO 19157)	FI / AD
	Distribution.title (string domain)	D.17 (ISO 19157)	FI / AD
	Distribution.accessURL (URL domain)	D.17 (ISO 19157)	FI / AD
	Distribution.format (IMT domain)	D.17 (ISO 19157)	FI / AD
	Distribution.byteSize (decimal number domain)	D.17 (ISO 19157)	FI / AD
	Distribution.license (URI domain)	D.17 (ISO 19157)	FI / AD
DQ_TemporalConsistency	Dataset (issued, modified, valid)	Similar to D.62 using a rate	FI / AD
DQ_TemporalValidity	Dataset (harvest date gegenüber issued, modified, valid)	D.18 (ISO 19157)	FI / AD
DQ_NonQuantitativeAttributeCorrectness	Dataset.references	D.69 (ISO 19157)	FI / AD
	Dataset.conformsTo	D.69 (ISO 19157)	FI / AD
	Distribution.accessURL	D.69 (ISO 19157)	FI / AD
	Distribution.license	D.69 (ISO 19157)	FI / AD
DQ_PositionalCorrectness	Dataset (spatial)	Similar to D.33 (ISO 19157)	FI / AD
DQ_QualityOfFreeText	Dataset (title gegenüber language)	Readability of free text	FI / AD
	Dataset (description gegenüber language)	Readability of free text	FI / AD

Tabelle 2.7: Kombinierte Übersicht der ISO-19157-Qualitätselemente, Scopes, Measures und Evaluationsarten nach Noguera-Iso et al. [29]

Dabei wird deutlich, dass der Ansatz nicht nur prüft, ob bestimmte Metadatenelemente vorhanden sind, sondern unterschiedliche Arten von Qualitätsproblemen systematisch trennt. Fehlende Elemente werden als *Completeness Omission* erfasst, während überzählige oder unzulässig wiederholte Elemente unter *Completeness Commission* fallen. Widersprüche zur konzeptuellen Modellstruktur werden als *Conceptual Consistency* bewertet, während fehlerhafte Wertebereiche, Datentypen oder kontrollierte Vokabulare unter *Domain Consistency* fallen. Zeitliche Inkonsistenzen werden über *Temporal Consistency* und *Temporal Validity* adressiert. Darüber hinaus berücksichtigt der Ansatz auch nicht-quantitative Attributkorrektheit, räumliche Korrektheit, thematische Klassifikation und die Qualität von Freitextfeldern wie Titel und Beschreibung.

Ein wichtiger Unterschied zu einfacheren Scoringmodellen besteht darin, dass Noguera-Iso et al. zwischen quantitativen Messergebnissen, stichprobenbasierten Bewertungen und abgeleiteten Konformitätsergebnissen unterscheiden. Automatisierbare Prüfungen werden als *DQ_FullInspection* auf die vollständige betrachtete Grundgesamtheit an-

gewendet. Semantisch oder fachlich stärker interpretationsbedürftige Aspekte können dagegen als `DQ_SampleBasedInspection` geprüft werden. Aus den quantitativen oder stichprobenbasierten Ergebnissen können anschließend über `DQ_AggregationDerivation` Konformitätsergebnisse abgeleitet werden. Dadurch entsteht eine zweistufige Bewertungslogik, die Rohmessung, Prüfverfahren und Qualitätsurteil voneinander trennt. [29]

2.6.6 Vergleich bestehender Ansätze und offene Bewertungslücken

Die in den vorangegangenen Abschnitten dargestellten Ansätze unterscheiden sich vor allem in zwei Hinsichten: in ihrer Nähe zum konkreten Anwendungskontext von DCAT-AP.de-Metadaten im GovData-Umfeld und in ihrer praktischen Operationalisierbarkeit. Daraus ergibt sich ein Spannungsverhältnis, das für die vorliegende Arbeit zentral ist. Allgemeine Qualitätsmodelle erfassen Datenqualität breit, bleiben aber für den konkreten Anwendungskontext zu unspezifisch. Linked-Data- und Metadatenqualitätsmodelle beschreiben relevantere Qualitätsprobleme RDF-basierter Metadaten, sind jedoch in ihrer vollständigen Breite nur begrenzt automatisiert prüfbar. Portalnahe Bewertungsansätze sind dagegen technisch gut umsetzbar, vereinfachen Metadatenqualität aber häufig auf Kriterien, die besonders leicht messbar sind.

Der Vergleich bestehender Ansätze wird daher nicht autorenweise vorgenommen, sondern entlang ihres Beitrags zur Modellbildung. Im Mittelpunkt steht nicht die vollständige Wiederholung der einzelnen Qualitätsdimensionen, sondern die Frage, welche Rolle die Ansätze für ein Bewertungsmodell im GovData- und DCAT-AP.de-Kontext übernehmen können.

Abstrakte Qualitätskonzepte als begriffliche Grundlage

Eine erste Gruppe bilden abstrakte Qualitätskonzepte wie Wang and Strong, ISO/IEC 25012 und FAIR. Diese Ansätze für ein grundlegendes Verständnis von Datenqualität relevant, weil sie diese als mehrdimensionales und nutzungsabhängiges Konzept begründen. Wang and Strong verstehen Datenqualität als *fitness for use* und rücken damit die Eignung von Daten für konkrete Nutzungssituationen in den Mittelpunkt [21]. ISO/IEC 25012 ergänzt diese Perspektive durch ein normatives Qualitätsmodell für in Computersystemen gehaltene Daten [24]. Die FAIR-Prinzipien betonen insbesondere die Anforderungen an Auffindbarkeit, Zugänglichkeit, Interoperabilität und Wiederverwendbarkeit [25].

Der Beitrag dieser Modelle liegt damit vor allem in der theoretischen Rahmung. Sie zeigen, dass Qualität nicht auf syntaktische Korrektheit oder Fehlerfreiheit reduziert werden kann. Für die konkrete Bewertung von DCAT-AP.de-Metadaten bleiben sie jedoch zu abstrakt. Sie legen nicht fest, welche Metadatenelemente, RDF-Strukturen, Vokabu-

lare oder Zugriffspfade geprüft werden sollen und wie daraus ein operationalisierbares Bewertungsverfahren entsteht.

Linked-Data- und Metadatenqualitätsmodelle als Erweiterung des Qualitätsbegriffs

Eine zweite Gruppe bilden Ansätze, die stärker auf RDF, Linked Data und Metadatenqualität ausgerichtet sind. Dazu zählen insbesondere Zaveri et al. sowie der ISO-19157-basierte Ansatz von Nogueras-Iso et al. Diese Modelle sind näher am Gegenstand der vorliegenden Arbeit, weil sie Qualitätsprobleme berücksichtigen, die bei Verknüpfen, RDF-basierten und maschineninterpretierbaren Daten auftreten.

Zaveri et al. machen deutlich, dass Linked-Data-Qualität über formale Validität hinausgeht und auch Aspekte wie Verknüpfbarkeit, Konsistenz, Verständlichkeit, Aktualität und semantische Genauigkeit umfasst [20]. Nogueras-Iso et al. ergänzen diese Perspektive durch eine methodisch genauere Unterscheidung von Qualitätsdimensionen, Metriken, Evaluationsmethoden und Ergebnistypen [29]. Beide Ansätze sind deshalb wichtig, weil sie Qualitätsaspekte sichtbar machen, die in rein feld- oder syntaxbezogenen Prüfungen nicht ausreichend erfasst werden.

Ihre Grenze liegt jedoch in der praktischen Umsetzbarkeit. Viele der vorgeschlagenen Prüfungen setzen Kontextwissen, externe Referenzdaten, semantische Vergleichsverfahren, fachliche Plausibilitätsprüfungen oder manuelle Bewertungen voraus. Damit liefern diese Ansätze eine differenzierte Qualitätslogik, aber kein ohne Weiteres skalierbares Bewertungsverfahren für DCAT-AP.de-Metadaten im GovData-Kontext.

Portalnahe Bewertungsmodelle als operationalisierte Vereinfachung

Eine dritte Gruppe bilden stärker operationalisierte Ansätze zur Bewertung von Metadaten in Open-Data-Portalen. Dazu zählen insbesondere Neumaier et al. und MQA/Piveau. Diese Ansätze sind dem Anwendungskontext der vorliegenden Arbeit am nächsten, weil sie Metadatenqualität im Umfeld von Open-Data-Portalen beziehungsweise DCAT-AP bewerten.

Neumaier et al. zeigen, dass Metadatenqualität automatisiert über portalübergreifend verfügbare Indikatoren bewertet werden kann [19]. MQA/Piveau führt diese Richtung im DCAT-AP-Kontext weiter und verbindet DCAT-AP-nahe Qualitätsmetriken mit FAIR, 5-Star-Linked-Open-Data-Prinzipien, technischer Erreichbarkeitsprüfung, Scoring und Reporting [28]. Die Stärke dieser Modelle liegt in ihrer technischen Anschlussfähigkeit. Sie definieren Kriterien, die automatisiert prüfbar, vergleichbar und für Datenbereitsteller kommunizierbar sind.

Gleichzeitig zeigt sich an diesen Ansätzen die zentrale Reduktionsproblematik operationalisierter Modelle. Die theoretisch breiten Qualitätskonzepte werden in der praktischen Umsetzung auf Kriterien konzentriert, die zuverlässig maschinell prüfbar sind. Dadurch entstehen robuste und skalierbare Bewertungsverfahren, deren Aussagekraft

jedoch vor allem auf formalen, feldbezogenen und technischen Prüfungen beruht. Weitergehende semantische und kontextuelle Qualitätsaspekte werden dadurch nur eingeschränkt abgebildet.

Bewertungslücke im DCAT-AP.de- und GovData-Kontext

Aus dem Vergleich der Literatur werden bereits unterschiedliche Bausteine bereitgestellt: allgemeine Qualitätsdimensionen, Linked-Data-spezifische Qualitätslogiken, portalnahe Indikatoren sowie Verfahren zur Aggregation und Repräsentation von Qualitätsmessungen. Die zentrale Lücke liegt in der Verbindung dieser Bausteine zu einem Bewertungsmodell, das zugleich anwendungsspezifisch, operationalisierbar und inhaltlich hinreichend aussagekräftig ist.

Ein geeignetes Modell muss die technische Umsetzbarkeit portalnaher Ansätze beibehalten, darf Metadatenqualität aber nicht auf leicht messbare Mindestkriterien verengen. Feldexistenz, Formatvalidität, Erreichbarkeit, Lizenzinformationen, Konformität und Maschinenlesbarkeit sind notwendige Bestandteile einer Qualitätsbewertung. Sie reichen jedoch nicht aus, um die praktische Nutzbarkeit und Aussagekraft von Metadaten vollständig zu erfassen.

Besonders unterrepräsentiert bleiben in bestehenden operationalisierten Modellen solche Qualitätsaspekte, die über die bloße formale oder technische Prüfbarkeit hinausgehen. Dazu gehören insbesondere die semantische Aussagekraft von Titeln und Beschreibungen, die Verständlichkeit für Nutzende, die kontextabhängige Relevanz einzelner Felder, die Plausibilität zwischen Metadatenangaben und die Kongruenz zwischen Metadaten und der tatsächlich beschriebenen Ressource. Diese Aspekte sind schwieriger zu prüfen, aber für die Bewertung von Metadatenqualität im Open-Data-Kontext zentral.

Die vorliegende Arbeit setzt an dieser Stelle an. Ziel ist es ein domänenspezifisches Bewertungsmodell für DCAT-AP.de-Metadaten im GovData-Kontext zu entwickeln, das formal und technisch gut prüfbare Indikatoren mit ausgewählten semantischen und kontextbezogenen Qualitätsaspekten verbindet.

3 Konzeption eines Metadatenqualitätsmodells

@TODO hier sagen was gemacht wird

3.1 Experteninterviews: Ziel, Auswahl und Durchführung

Ergänzend zur Literaturanalyse wurden qualitative, leitfadengestützte Experteninterviews durchgeführt. Ziel der Interviews war es, die in Kapitel 2 dargestellten theoretischen und konzeptionellen Ansätze durch praxisbezogene Einschätzungen aus dem Open-Data- und Metadatenkontext zu ergänzen. Die Interviews dienten damit nicht der statistischen Generalisierung, sondern der fachlichen Vertiefung und Plausibilisierung der Modellbildung. Sie sollten insbesondere dazu beitragen, praxisrelevante Anforderungen an ein Bewertungsmodell für DCAT-AP.de-Metadaten zu identifizieren, bestehende Ansätze der Metadatenqualitätsmessung kritisch einzuordnen und mögliche Erweiterungen durch kontextbezogene oder KI-gestützte Analyseverfahren zu bewerten. Im Mittelpunkt standen drei Zielsetzungen. Erstens sollten die Interviews klären, welche Merkmale Expertinnen und Experten als konstitutiv für hochwertige Metadaten im GovData- und DCAT-AP.de-Kontext ansehen. Zweitens sollten aktuelle Schwächen bestehender Quality-Score-Ansätze, insbesondere im Hinblick auf formale Validierung, semantische Qualität und praktische Nutzbarkeit, herausgearbeitet werden. Drittens sollten Potenziale und Grenzen KI-gestützter Verfahren eingeordnet werden, insbesondere mit Blick auf Freitextanalyse, Kontextprüfung, Rohdatenbezug und agentenbasierte Unterstützungsformen.

Es wurden drei Experteninterviews im Zeitraum vom 16. April 2026 bis zum 24. April 2026 geführt. Die Auswahl der Interviewpartner erfolgte gezielt nach fachlicher Expertise im Bereich Open Data, Metadatenqualität, GovData, DCAT-AP.de und praktischer Datenbereitstellung. Die interviewten Personen stammen aus dem Umfeld der FITKO beziehungsweise aus dem Open Data Competence Center Bayern. Damit decken die Interviews sowohl die Perspektive des GovData-Produktmanagements und der DCAT-AP.de-Standardisierung als auch die Perspektive der praktischen Qualitätsberatung und Datenbereitstellung ab.

Die Interviews dauerten zwischen 24 und 41 Minuten. Sie wurden aufgezeichnet, anschließend transkribiert und für die Auswertung sprachlich bereinigt. Die Transkription orientierte sich an einem inhaltlich-semanticen Transkriptionsverständnis nach Dressing und Pehl [30]. Ziel war daher nicht die lautsprachlich exakte Wiedergabe gesprochener Sprache, sondern die nachvollziehbare Sicherung der fachlichen Aussagen. Die folgenden Transkriptions- und Bereinigungsregeln wurden angewendet:

- Fülllaute, nicht sinntragende Wiederholungen und abgebrochene Satzanfänge wurden entfernt.
- Grammatik und Satzstellung wurden behutsam geglättet, sofern der Aussagegehalt unverändert blieb.
- Fachbegriffe, Beispiele, Einschränkungen, Bewertungen und inhaltliche Unsicherheiten wurden beibehalten.
- Personenbezogene Angaben wurden pseudonymisiert, soweit sie für die Auswertung nicht erforderlich waren.
- Konkrete Funktionsbezeichnungen wurden in den Transkripten nicht ausgewiesen, sofern sie zur Re-Identifikation der befragten Personen beitragen könnten. Stattdessen wurden institutioneller Kontext und Expertisebereich angegeben.
- Die Sprecher wurden einheitlich als INT für den Interviewer und EXP für die interviewte Person gekennzeichnet.
- Die Transkripte wurden absatzweise nummeriert, um eine eindeutige Referenzierung der Interviewstellen zu ermöglichen.
- Einleitende Fragen zur Person sowie abschließende organisatorische Gesprächsteile wurden für die Auswertung entfernt, sofern sie keinen inhaltlichen Beitrag zur Forschungsfrage leisteten.
- Die Transkripte wurden nach den thematischen Hauptteilen des Interviewleitfadens gegliedert.

Direkte und indirekte Bezüge auf Interviewaussagen erfolgen im weiteren Verlauf über Interview-ID und Absatznummer, zum Beispiel I1_024. Die bereinigten Interviewtranskripte sind im Anhang dokumentiert (Anhang D bis Anhang F).

Die Interviews wurden anhand eines halbstrukturierten Leitfadens geführt. Der Leitfaden enthielt neben einer kurzen Einleitung und einem Abschluss vier thematische Hauptblöcke:

- die perfekten Metadaten,
- bestehende Quality Scores und SHACL,
- Relevanz des eigentlichen Datensatzes,
- Potenziale von AI Agents und KI-gestützten Verfahren.

Die Hauptblöcke des Leitfadens wurden aus den Forschungsfragen und der literaturbasierten Vorarbeit abgeleitet. Sie waren so angelegt, dass sie die für die Modellbildung zentralen Themenfelder systematisch adressieren: Qualitätsverständnis, formale Validierung, semantische und kontextbezogene Qualität, Rohdatenbezug sowie KI-gestützte Erweiterungsmöglichkeiten. Der vollständige Interviewleitfaden befindet sich in Anhang A.

3.2 Auswertungsverfahren der Interviews

Die Auswertung der Experteninterviews erfolgte mithilfe einer qualitativen Inhaltsanalyse in Anlehnung an Mayring [31, 32]. Gewählt wurde eine inhaltlich strukturierende Vorgehensweise mit kombinierter deduktiv-induktiver Kategorienbildung. Dieses Vorgehen eignet sich für die vorliegende Arbeit, da bereits ein theoretischer Bezugsrahmen aus der Literatur, den Forschungsfragen und dem Interviewleitfaden vorlag, die Interviews jedoch zugleich genutzt wurden, um praxisbezogene Anforderungen und zusätzliche Qualitätsaspekte aus dem Material herauszuarbeiten.

Im ersten Schritt wurden deduktive Hauptkategorien aus den Forschungsfragen, dem Interviewleitfaden und den in Kapitel 2 dargestellten Qualitätsansätzen abgeleitet. Die Hauptkategorien bilden die analytische Grundstruktur der Interviewauswertung und stellen zugleich die Verbindung zwischen den empirischen Aussagen und dem zu entwickelnden Bewertungsmodell her. Insgesamt wurden zehn Hauptkategorien identifiziert, die im weiteren Verlauf mit den Codes K1 bis K10 gekennzeichnet werden. Tabelle 3.1 zeigt die Hauptkategorien, ihre deduktive Herleitung und ihre jeweilige Funktion im Bewertungsmodell.

Code	Hauptkategorie	Deduktive Herleitung	Funktion im Bewertungsmodell
K1	Qualitätsverständnis und ideale Metadaten	Forschungsfrage zur Entwicklung eines praxisrelevanten Bewertungsmodells; Leitfadenblock „perfekte Metadaten“; Datenqualitätsverständnis nach [21].	Ableitung übergeordneter Anforderungen an ein gutes DCAT-AP.de-Metadatenmodell.
K2	Vollständigkeit, Reichhaltigkeit und Feldrelevanz	Leitfadenfrage zu Qualitätsmerkmalen; Literatur zu Vollständigkeit nach [28, 25, 10, 11].	Bestimmung, welche Metadatenfelder für einen Score geprüft und wie Pflicht-, empfohlene und optionale Angaben gewichtet werden.
K3	Formale und syntaktische Qualität	Forschungsfrage zur Integration von RDF-/SHACL-Prüfungen; Literatur zu Conformance, syntaktischer Validität und DCAT-AP.de-Konformität nach [14, 17, 10, 11, 13, 18].	Erfassung regelbasierter, automatisierbarer Fehler über SHACL, XML/RDF, URI-, Vokabular- und Datentypprüfungen.
K4	Semantische und inhaltliche Qualität	Forschungsfrage zu KI-gestützten Analyseverfahren; Literatur zu Verständlichkeit, Accuracy, semantischer Konsistenz und Qualität von Freitextfeldern nach [21, 23, 22, 20, 29].	Ergänzung formaler Prüfungen um Aussagekraft, Verständlichkeit, Plausibilität und inhaltliche Passung.
K5	Technische Zugänglichkeit, Aktualität und Nutzbarkeit	Literatur zu Accessibility, Retrievability, Open Data Fitness und MQA/Piveau nach [25, 27, 19, 26, 28].	Bewertung, ob Ressourcen erreichbar, technisch nutzbar, aktuell genug und praktisch weiterverarbeitbar sind.
K6	Interoperabilität und Linked-Data-Qualität	Literatur zu FAIR, Linked Data, RDF-Grundlagen, DCAT und Linked-Data-Qualität nach [25, 14, 8, 20, 18].	Bewertung, ob Metadaten über URIs, Normdaten, kontrollierte Vokabulare und Graphbezüge interoperabel und verknüpfbar sind.
K7	Kontextsensitivität und Fit for Purpose	Forschungsfrage zur praxisrelevanten Bewertung; Literatur zu Fit for Purpose, Kontextualität, FAIR-Nachnutzung und domänenspezifischer Datenqualität nach [21, 22, 23, 25, 4].	Ermittlung von Bewertung, Gewichtung und Interpretation an Nutzungskontext, Domäne und Stakeholderperspektive.
K8	Rohdatenbezug und Metadaten-Daten-Kongruenz	Forschungsfrage zur Kombination formaler Validierung mit kontextbezogenen Prüfverfahren; Leitfadenblock „Relevanz des eigentlichen Datensatzes“; Literatur zu Accuracy und Daten-Metadaten-Konsistenz nach [21, 23, 22, 29].	Prüfung, ob Metadaten mit der tatsächlichen Ressource übereinstimmen und ob Rohdaten zur Plausibilisierung herangezogen werden können.
K9	Scoring, Gewichtung, Reporting und Verbesserungshinweise	Forschungsfrage zu aggregiertem Qualitätsindikator; Literatur zu MQA/Piveau, AHP-basierter Gewichtung, DQV-nahen Qualitätsdimensionen und ISO-orientierten Qualitätsmodellen nach [27, 26, 19, 28, 24, 33, 34].	Überführung von Einzelindikatoren in Teilscores, Gesamtscore und handlungsorientiertes Qualitätsreporting.
K10	KI-gestützte Analyseverfahren und Automatisierungsgrenzen	Forschungsfrage zu KI-basierter Unterstützung und agentenbasierten Ansätzen; Leitfadenblock „KI-gestützte Ansätze und AI Agents“; Literatur zu automatisierter Metadatenqualitätsbewertung, SHACL-gestützter Qualitätsprüfung und Grenzen regelbasierter beziehungsweise automatisierter Verfahren nach [19, 28, 35, 18, 20, 36].	Einordnung, welche Qualitätsaspekte durch KI unterstützt werden können und wo regelbasierte oder menschliche Bewertung notwendig bleibt.

Tabelle 3.1: Deduktiv abgeleitete Hauptkategorien der Interviewauswertung

Ergänzend zu den deduktiven Hauptkategorien wurden in einem zweiten Schritt induktive Unterkategorien aus dem Interviewmaterial gebildet. Diese Unterkategorien konkretisieren die Hauptkategorien anhand wiederkehrender oder für das Bewertungsmodell besonders relevanter Aussagen der Expertinnen und Experten. Insgesamt wurden 52 Unterkategorien identifiziert und den zehn Hauptkategorien zugeordnet. Ein exemplarischer Auszug der Unterkategorien ist in Tabelle 3.2 dargestellt. Die vollständige Übersicht ist in Anhang B dokumentiert. Die Belegstellen verweisen auf die jeweiligen Interviewabsätze, in denen die Kategorien empirisch begründet oder besonders deutlich sichtbar werden.

Code	Hauptkategorie	induktive Unterkategorie	Belegstellen
K3.2	Formale und syntaktische Qualität	SHACL-Konformität als Basisdimension	I1_027–I1_029; I3_015
K4.1	Semantische und inhaltliche Qualität	nichtssagende oder zu kurze Titel	I2_008
K4.2	Semantische und inhaltliche Qualität	Titel-Beschreibung-Redundanz	I2_008
K5.1	Technische Zugänglichkeit, Aktualität und Nutzbarkeit	Dead Links und Linkrot	I1_015; I2_011
K6.1	Interoperabilität und Linked-Data-Qualität	URI statt Literal	I1_020–I1_022
K8.1	Rohdatenbezug und Metadaten-Daten-Kongruenz	Formatkongruenz zwischen Metadaten und Ressource	I2_045; I3_020
K9.2	Scoring, Gewichtung, Reporting und Verbesserungshinweise	SHACL als Teildimension statt Gesamtscore	I1_028–I1_029
K9.5	Scoring, Gewichtung, Reporting und Verbesserungshinweise	verständliche Fehlermeldungen und Handlungshinweise	I2_040–I2_041; I3_017
K10.2	KI-gestützte Analyseverfahren und Automatisierungsgrenzen	Freitextprüfung und Beschreibungsgüte	I1_035; I1_043–I1_044
K10.8	KI-gestützte Analyseverfahren und Automatisierungsgrenzen	Halluzination, stochastische Ausreißer und fachliche Fehlinterpretation	I1_037; I1_046; I2_052

Tabelle 3.2: Auszug aus den induktiv entwickelten Unterkategorien

Für die Codierung wurden die Analyseeinheiten vorab festgelegt. Als Kodiereinheit wurde die kleinste sinntragende Aussage definiert, die sich auf eine Qualitätsanforderung, ein Qualitätsproblem, einen Prüfindikator, eine Grenze oder eine mögliche Modellfolge bezieht. Als Kontexteinheit diente jeweils der zusammenhängende Antwortabschnitt innerhalb einer Leitfadenfrage. Auswertungseinheit war jeweils ein vollständiges Interviewtranskript. Die Interviewstellen werden über Interview-ID und Absatznummer referenziert, zum Beispiel I1_024.

Aus dem deduktiv-induktiv entwickelten Kategoriensystem wurde anschließend ein Kodierleitfaden erstellt. Während die Kategorientabelle dokumentiert, welche Haupt- und Unterkategorien gebildet wurden, operationalisiert der Kodierleitfaden die Anwendung dieser Kategorien im Codierprozess. Er enthält für jede codierrelevante Unterkategorie eine Definition, eine Kodierregel sowie ein Ankerbeispiel mit Bezug zum Bewertungsmodell. Dadurch wurde festgelegt, wann eine Textstelle einer bestimmten Kategorie zugeordnet wird und welche analytische Funktion diese Kategorie für die weitere Modellbildung erfüllt.

Tabelle 3.3 zeigt exemplarisch den Aufbau des Kodierleitfadens. Der vollständige Kodierleitfaden befindet sich im Anhang C.

Code	Kategorie	Definition	Kodierregel	Ankerbeispiel / Modellbezug
K4.1	Nichtssagende oder zu kurze Titel	Aussagen zu Titeln, die vorhanden sind, aber den Datensatz nicht ausreichend beschreiben.	Codieren, wenn Titel als zu kurz, generisch, mehrdeutig oder unverständlich beschrieben werden.	„Los 1“ als Titel ohne erkennbare Aussage. Modellbezug: semantischer Titelindikator.
K8.1	Formatkongruenz zwischen Metadaten und Ressource	Aussagen zum Abgleich zwischen angegebenem Format und tatsächlicher Ressource.	Codieren, wenn geprüft werden soll, ob das in den Metadaten angegebene Format mit Datei, Service oder Inhalt übereinstimmt.	Metadaten geben CSV an, aber der Inhalt ist kein CSV. Modellbezug: Kongruenzindikator.
K9.2	SHACL als Teildimension statt Gesamtscore	Aussagen, die SHACL- oder DCAT-AP.de-Konformität als Teil, aber nicht als vollständiges Qualitätsurteil verstehen.	Codieren, wenn formale Validierung als eigene Dimension im Gesamtscore beschrieben wird.	DCAT-AP.de-Qualität sollte als eine Dimension im Gesamtscore angezeigt werden. Modellbezug: separater formaler Teilschritt.

Tabelle 3.3: Auszug aus dem Kodierleitfaden

Der Kodierleitfaden wurde anschließend auf alle drei Interviewtranskripte angewendet. Die Codierung erfolgte absatzweise in einer Auswertungsmatrix. Für jede relevante Textstelle wurden Fundstelle, paraphrasierte Aussage, Primärkode, gegebenenfalls Sekundärkode und eine analytische Notiz zur möglichen Modellfolge dokumentiert. Mehrfachcodierungen waren möglich, wenn eine Aussage mehrere Qualitätsaspekte berührte. In diesen Fällen wurde ein Primärkode vergeben, der den dominierenden analytischen Bezug der Aussage markiert; ein Sekundärkode wurde ergänzt, wenn ein weiterer relevanter Qualitätsaspekt erkennbar war.

Die codierte Auswertungsmatrix bildet die Grundlage für die anschließende Ergebnisdarstellung. Sie dient dazu, die Interviewaussagen nicht interviewweise nachzu-erzählen, sondern thematisch entlang der Haupt- und Unterkategorien zu verdichten. Auf dieser Grundlage werden in den folgenden Abschnitten zentrale Interviewbefunde herausgearbeitet und anschließend in Anforderungen an das Bewertungsmodell überführt. Die vollständige codierte Auswertungsmatrix befindet sich im Anhang [G](#).

3.3 Zentrale Ergebnisse der Interviews

Die Ergebnisse der Interviewauswertung werden nicht entlang der einzelnen Interviews, sondern thematisch entlang der zentralen Analysebereiche dargestellt. Diese Darstellungsform ist für die vorliegende Arbeit zweckmäßig, da die Interviews nicht der Rekonstruktion einzelner Fallperspektiven dienen, sondern der Ableitung fachlicher Anforderungen an ein Bewertungsmodell für DCAT-AP.de-Metadaten. Im Zentrum stehen daher wiederkehrende Befunde, fachliche Ergänzungen zur Literatur und konkrete Konsequenzen für die Modellbildung.

Tabelle 3.4 fasst die zentralen Interviewbefunde entlang der deduktiv-induktiv entwickelten Kategorien zusammen. Die Tabelle verdichtet die codierten Aussagen aus der Auswertungsmatrix und übersetzt sie in Anforderungen an das Bewertungsmodell. Die Belegstellen verweisen auf die jeweiligen Interviewabsätze.



Code	Analysebereich	zentraler Interviewbefund	Belegstellen
K1	Qualitätsverständnis und ideale Metadaten	Metadatenqualität wird nicht mit bloßer Mindestvalidität gleichgesetzt. Hochwertige Metadaten erfüllen zwar DCAT-AP.de-Mindestanforderungen, gehen aber durch Best-Practice-Empfehlungen, relevante Zusatzinformationen, semantische Modellierung und Nachnutzbarkeit darüber hinaus.	I1.002–I1.004; I2.003–I2.006; I3.002–I3.005
K2	Vollständigkeit, Reichhaltigkeit und Feldrelevanz	Vollständigkeit wird als relative und kontextabhängige Vollständigkeit verstanden. Entscheidend ist nicht, ob alle möglichen DCAT-Felder gefüllt sind, sondern ob die für den jeweiligen Datensatz relevanten Informationen vorhanden sind.	I1.007–I1.010; I2.026; I3.002–I3.003; I3.013
K3	Formale und syntaktische Qualität	SHACL- und DCAT-AP.de-Validierung werden als notwendige Grundlage der Qualitätsbewertung angesehen. Sie prüfen unter anderem Feldvorhandensein, Syntax, URI-Korrektheit, Vokabulare, Datentypen und XML-/RDF-Strukturen.	I1.027–I1.029; I3.015; I3.017–I3.018
K4	Semantische und inhaltliche Qualität	Feldexistenz und syntaktische Korrektheit garantieren keine inhaltliche Qualität. Titel, Beschreibungen, Keywords und Kategorien können vorhanden sein, aber nichtssagend, redundant, fachsprachlich unverständlich oder widersprüchlich sein.	I2.008–I2.011; I2.027; I3.010; I3.028–I3.029
K5	Technische Zugänglichkeit, Aktualität und Nutzbarkeit	Defekte Links, nicht erreichbare Downloads, nicht funktionierende Services, Linkrot und fehlende Aktualitätsinformationen werden als zentrale praktische Qualitätsprobleme beschrieben.	I1.015; I1.019; I1.024–I1.025; I2.011; I2.028
K6	Interoperabilität und Linked-Data-Qualität	Hochwertige Metadaten sollten nicht nur Freitext enthalten, sondern maschineninterpretierbare Verknüpfungen nutzen. URIs, Normdaten, kontrollierte Vokabulare, Wikidata, GND, Thesauri und Graphbezüge werden als Qualitätsmerkmale hervorgehoben.	I1.020–I1.022; I2.003–I2.006; I2.055–I2.056; I3.018
K7	Kontextsensitivität und Fit for Purpose	Qualität hängt von Zweck, Domäne und Stakeholderperspektive ab. Bestimmte Felder sind etwa bei Geodaten relevant, bei Statistikdaten aber weniger. Auch föderale Vergleichbarkeit ist kontextabhängig.	I1.006; I1.009–I1.010; I1.031–I1.033; I1.040; I1.047–I1.049
K8	Rohdatenbezug und Metadaten-Daten-Kongruenz	Metadatenqualität kann teilweise nur durch Bezug auf die beschriebene Ressource geprüft werden. Beispiele sind Formatkongruenz, Serviceverhalten, Bounding Boxes und die Passung zwischen Titel, Beschreibung und tatsächlichem Dateninhalt.	I2.013; I2.045–I2.047; I2.059; I3.020–I3.022
K9	Scoring, Gewichtung, Reporting und Verbesserungshinweise	Bestehende Scores werden kritisiert, wenn ihre Kriterien nicht fachlich begründet sind. Zugleich werden Teil-Scores, regelmäßige Prüfungen und Rankings als nützlich beschrieben, sofern sie verständlich erklärt und auf Verbesserung ausgerichtet sind.	I1.028–I1.029; I2.021–I2.024; I2.034–I2.041; I3.017
K10	KI-gestützte Analyseverfahren und Automatisierungsgrenzen	KI wird als unterstützendes Werkzeug für Freitextprüfung, Keyword-Mapping, SPARQL-Unterstützung, Rohdatenanalyse und Kontextprüfung gesehen. Eine autonome generative Bewertung wird wegen Halluzinationen, stochastischer Ausreißer, Datenhoheit und Ressourcenaufwand kritisch bewertet.	I1.035–I1.049; I2.049–I2.063; I3.024–I3.031

Tabelle 3.4: Zentrale Ergebnisse der Interviewauswertung

Formale Validierung als notwendige, aber nicht hinreichende Grundlage

Ein zentrales Ergebnis der Interviews ist die klare Einordnung formaler Validierung als Basisanforderung. Die Expertinnen und Experten beschreiben DCAT-AP.de-Konformität und SHACL-Validierung als notwendige Grundlage einer Qualitätsbewertung. Ein Metadatensatz, der die Mindestanforderungen des Standards nicht erfüllt, kann demnach nicht als hochwertig gelten. Formale Prüfungen erfassen insbesondere Pflichtfelder, Kardinalitäten, Datentypen, URI-Strukturen, kontrollierte Vokabulare sowie RDF- beziehungsweise XML-bezogene Strukturfehler.

Gleichzeitig wird formale Validität nicht als hinreichendes Qualitätsurteil verstanden. Ein Metadatensatz kann formal valide sein und dennoch aus Nutzendensicht unzureichend bleiben, wenn etwa Titel und Beschreibung wenig aussagekräftig sind, eine Ressource nicht erreichbar ist oder relevante Kontextinformationen fehlen. Für das Bewertungsmodell folgt daraus, dass SHACL-Ergebnisse nicht als Gesamtscore interpretiert werden dürfen. Sie bilden vielmehr die formale Basisschicht der Bewertung, die strukturelle und syntaktische Konformität abbildet. Diese Basisschicht ist grundlegend, muss aber durch weitergehende Qualitätsdimensionen ergänzt werden.

Methodisch ergibt sich daraus eine Trennung zwischen Basiskonformität und weitergehender Metadatenqualität. Basiskonformität beschreibt, ob ein Metadatensatz die formalen Mindestanforderungen erfüllt. Weitergehende Qualität beschreibt dagegen, ob der Metadatensatz auffindbar, verständlich, zugänglich, interoperabel und praktisch nachnutzbar ist.

Vollständigkeit als relative Feldrelevanz

Die Interviews zeigen außerdem, dass Vollständigkeit nicht als maximale Befüllung aller verfügbaren DCAT-AP.de-Felder verstanden werden sollte. Entscheidend ist nicht, ob möglichst viele Felder ausgefüllt sind, sondern ob die für den jeweiligen Datensatz relevanten Informationen vorhanden sind. Damit wird Vollständigkeit als relative und kontextabhängige Eigenschaft gefasst.

Diese Perspektive ist für das Bewertungsmodell wesentlich. Eine reine Feldzählung würde Datensätze begünstigen, die viele Angaben enthalten, auch wenn diese für die konkrete Ressource nur geringen Nutzen haben. Umgekehrt könnten Datensätze abgewertet werden, obwohl sie die für ihren Nutzungskontext relevanten Informationen vollständig und präzise bereitstellen. Deshalb muss das Modell zwischen Pflichtfeldern, empfohlenen Feldern und kontextspezifisch relevanten Feldern unterscheiden.

Pflichtfelder bilden die Mindestanforderung. Empfohlene Felder erhöhen die praktische Nutzbarkeit, etwa durch bessere Auffindbarkeit, Kontaktierbarkeit oder Wiederverwendbarkeit. Kontextspezifische Felder sind nur für bestimmte Datentypen oder Domänen besonders relevant, beispielsweise räumliche Angaben bei Geodaten oder Aktualisierungsfrequenzen bei regelmäßig fortgeschriebenen Datenbeständen. Vollständigkeit

wird somit nicht absolut, sondern bezogen auf den jeweiligen Bewertungsgegenstand operationalisiert.

Semantische Qualität als zentrale Bewertungslücke

Besonders deutlich wird in den Interviews die Grenze feldbezogener und syntaktischer Prüfungen. Mehrere Aussagen verweisen darauf, dass Metadatenfelder zwar vorhanden sein können, aber dennoch keinen ausreichenden Informationswert besitzen. Beispiele hierfür sind sehr kurze oder generische Titel, Beschreibungen ohne zusätzlichen Mehrwert, identische Titel- und Beschreibungstexte, unverständliche Fachbegriffe, regionale Sonderbegriffe oder nicht passende Keywords und Kategorien.

Damit wird semantische Qualität zu einer zentralen Erweiterung gegenüber bestehenden, vor allem regel- und feldbasierten Bewertungsansätzen. Während formale Prüfungen feststellen können, ob ein Feld vorhanden ist und einem erwarteten Datentyp entspricht, erfassen sie nicht, ob der Feldinhalt für Nutzende verständlich, aussagekräftig und plausibel ist. Für ein praxisrelevantes Bewertungsmodell ist diese Unterscheidung entscheidend, da Auffindbarkeit und Nachnutzbarkeit wesentlich von der inhaltlichen Qualität der beschreibenden Felder abhängen.

Aus den Interviews lassen sich daher mehrere semantische Prüfaspekte ableiten. Erstens sollte geprüft werden, ob Titel und Beschreibung einen erkennbaren Informationswert besitzen. Zweitens sollte Redundanz zwischen Titel und Beschreibung erkannt werden. Drittens sollten Keywords, Kategorien und Themenfelder hinsichtlich ihrer Passung zum beschriebenen Datensatz bewertet werden. Viertens sollten offensichtliche Widersprüche zwischen Metadatenfeldern berücksichtigt werden, etwa wenn räumliche Angaben, Herausgeber, Titel und Beschreibung nicht plausibel zusammenpassen.

Technische Nutzbarkeit und Metadaten-Daten-Kongruenz

Neben formaler und semantischer Qualität wurde die technische Nutzbarkeit als wiederkehrendes Problemfeld identifiziert. Defekte Links, nicht erreichbare Download-URLs, nicht funktionierende Services, veraltete Verweise und unklare Aktualitätsangaben beeinträchtigen die praktische Nutzbarkeit eines Metadatensatzes erheblich. Ein Metadatensatz kann formal korrekt beschrieben sein, ist für Nutzende aber nur eingeschränkt wertvoll, wenn die referenzierte Ressource nicht abrufbar oder nicht weiterverarbeitbar ist.

Daraus folgt, dass das Bewertungsmodell technische Zugänglichkeit als eigene Qualitätsdimension erfassen sollte. Dazu gehören insbesondere die Erreichbarkeit von `dcat:accessURL` und `dcat:downloadURL`, die Prüfung von HTTP-Statuscodes, das Verhalten von Datenservices, die Plausibilität von Formatangaben und die Aktualität der Metadaten. Diese Prüfungen sind weitgehend automatisierbar und können konkrete Verbesserungshinweise erzeugen.

Darüber hinaus zeigen die Interviews, dass einige Qualitätsprobleme erst durch einen begrenzten Abgleich zwischen Metadaten und beschriebener Ressource sichtbar werden. Beispiele sind abweichende Dateiformate, unplausible Dateigrößen, nicht erwartungskonformes Serviceverhalten oder räumliche Angaben, die nicht zur tatsächlichen Datenabdeckung passen. Das Bewertungsmodell sollte daher eine begrenzte Metadaten-Daten-Kongruenzprüfung vorsehen. Diese Prüfung darf jedoch nicht mit einer umfassenden fachlichen Bewertung der Rohdaten verwechselt werden. Bewertet wird nicht die inhaltliche Qualität des Datensatzes selbst, sondern die Konsistenz zwischen Metadatenbeschreibung und zugänglicher Ressource.

KI-gestützte Verfahren als ergänzende Analyseebene

Die Einschätzungen zu KI-gestützten Verfahren fallen differenziert aus. Einerseits sehen die Expertinnen und Experten Potenzial bei Aufgaben, die mit rein formalen Regeln nur schwer abbildbar sind. Dazu zählen insbesondere die Bewertung von Freitextqualität, die Erkennung nichtssagender Beschreibungen, das Mapping von Keywords auf kontrollierte Vokabulare, die Unterstützung bei SPARQL-Abfragen, die semantische Plausibilisierung sowie ausgewählte Rohdatenanalysen.

Andererseits werden klare Grenzen benannt. **Generative KI kann halluzinieren, fachliche Begriffe falsch interpretieren, stochastische Ausreißer produzieren und schwer reproduzierbare Bewertungen erzeugen. Hinzu kommen Fragen der Datenhoheit, der technischen Betriebslast und der Nachvollziehbarkeit. Aus methodischer Sicht ist daher eine autonome KI-basierte Bewertungsinstanz nicht geeignet, wenn das Ziel ein transparentes und auditierbares Qualitätsmodell ist.**

Für die Modellbildung folgt daraus, dass KI-gestützte Verfahren nur ergänzend eingesetzt werden sollten. Sie können Hinweise, Plausibilitätsbewertungen oder Verbesserungsvorschläge erzeugen, sollten aber nicht die alleinige Grundlage des Scores bilden. Die eigentliche Scoringlogik bleibt regelbasiert, dokumentiert und nachvollziehbar. KI-basierte Ergebnisse werden als zusätzliche Evidenzebene behandelt und müssen im Reporting entsprechend gekennzeichnet werden.

Zusammenfassung der empirischen Modellanforderungen

Zusammenfassend bestätigen die Interviews zentrale literaturbasierte Qualitätsdimensionen wie Vollständigkeit, Konformität, Zugänglichkeit, Interoperabilität und Wiederverwendbarkeit. Gleichzeitig konkretisieren sie mehrere Bewertungslücken, die für den GovData- und DCAT-AP.de-Kontext besonders relevant sind. Dazu gehören semantische Aussagekraft, relative Feldrelevanz, technische Nutzbarkeit, Metadaten-Daten-Kongruenz, kontextsensitive Gewichtung und verständliches Reporting.

Für die weitere Modellbildung ergeben sich daraus fünf zentrale Anforderungen. Erstens muss formale Validierung als eigene Basisschicht berücksichtigt werden, ohne

sie mit Gesamtqualität gleichzusetzen. Zweitens muss Vollständigkeit kontextsensitiv und feldrelevanzbezogen operationalisiert werden. Drittens müssen semantische Qualitätsaspekte ergänzt werden, insbesondere bei Titel, Beschreibung, Keywords und Kategorien. Viertens muss die technische Nutzbarkeit der referenzierten Ressourcen geprüft werden. Fünftens muss das Bewertungsmodell transparente Teilscores und konkrete Verbesserungshinweise erzeugen.

Die Interviewauswertung liefert damit keine eigenständige Alternativsystematik zur Literatur, sondern eine praxisbezogene Präzisierung und Priorisierung der literaturbasierten Qualitätsdimensionen. Sie bildet die empirische Grundlage für die im folgenden Abschnitt vorgenommene Ableitung relevanter Qualitätsdimensionen.

3.4 Ableitung relevanter Qualitätsdimensionen

Die Qualitätsdimensionen werden nicht unmittelbar aus einem einzelnen bestehenden Modell übernommen, sondern durch eine Synthese aus Literatur, identifizierten Bewertungslücken und Interviewbefunden abgeleitet. Die Literatur liefert etablierte Qualitätskonzepte und bereits operationalisierte Metriken. Die Problemanalyse zeigt, welche Aspekte bestehender Bewertungsansätze im DCAT-AP.de- und GovData-Kontext nur unvollständig abdecken. Die Experteninterviews ergänzen diese Perspektive durch praxisbezogene Anforderungen und Hinweise auf besonders relevante Qualitätsprobleme. Im ersten Schritt werden aus den in Kapitel 2 dargestellten Ansätzen wiederkehrende Qualitätsdimensionen und Metriken extrahiert. Diese werden anschließend mit den in Abschnitt 2.7 beschriebenen Bewertungslücken sowie mit den Ergebnissen der Interviewauswertung abgeglichen. Ziel dieses Vorgehens ist nicht die vollständige Übernahme vorhandener Modelle, sondern die Bildung einer domänenspezifischen Longlist von Kandidatendimensionen für die Bewertung von DCAT-AP.de-Metadaten. Eine Dimension wird in die Longlist aufgenommen, wenn sie die folgenden Kriterien erfüllt:

1. Sie ist in mindestens einem relevanten Literaturansatz verankert.
2. Sie wird durch Interviewbefunde gestützt oder ist für den GovData-Kontext plausibel begründbar.
3. Sie ist für die Bewertung von DCAT-AP.de-Metadaten fachlich relevant.
4. Sie lässt sich zumindest durch einen Indikator operationalisieren.
5. Sie wird nicht vollständig durch eine andere Dimension abgedeckt.

Tabelle 3.5 zeigt die auf dieser Grundlage gebildete Longlist. Sie bündelt unterschiedliche Konzepte aus der Literatur und ordnet sie den Interviewbefunden zu. Die Longlist ist dabei noch nicht als finales Bewertungsmodell zu verstehen.

Nr.	Dimension	Bezugsquellen	Interviewbezug
1	Formale und syntaktische Konformität	<i>Conformance</i> [19]; <i>DCAT-AP conformity</i> [28, 27]; <i>syntactic validity, consistency</i> [20]; SHACL-Constraints für Kardinalitäten, Datentypen, Klassen, Properties und Wertebereiche [17]; <i>conformity</i> [24]	K1.1; K3.1–K3.5; K9.2; (I1.002; I1.027–I1.029; I3.015; I3.017–I3.018)
2	Vollständigkeit und feldbezogene Reichhaltigkeit	<i>Completeness, appropriate amount of data, value-added</i> [21]; <i>completeness</i> [24]; FAIR F2, R1 [25]; <i>schema completeness, property completeness</i> [20]; <i>Existence</i> [19]; feldbezogene MQA-Metriken [28, 27]; <i>completeness omission</i> [29]	K1.1–K1.3; K2.1–K2.4; (I1.007–I1.010; I2.026; I3.002–I3.003; I3.013)
3	Auffindbarkeit und Identifizierbarkeit	FAIR F1–F4 [25]; <i>Findability</i> : keywords, categories, spatial search, temporal search [28, 27]; <i>Discovery</i> : dct:title, dct:description, dcat:keyword [19]; DCAT-Identifikatoren und Katalogmodell [8]; <i>relevance</i> [21, 20]	K1.3; K4.1; K4.4; K4.6; K6.1; (I2.008; I2.027; I3.005; I3.028–I3.029)
4	Technische Zugänglichkeit und Abrufbarkeit	FAIR A1, A1.1, A2 [25]; <i>availability, dereferenceability</i> [20]; <i>Access, AccessURL, Retrievable</i> [19]; <i>Accessibility</i> : accessURL, downloadURL, URL availability [28, 27]	K5.1–K5.3; K8.2; (I1.015; I1.019; I1.024–I1.025; I2.011; I2.028; I2.046)
5	Aktualität und temporale Konsistenz	<i>Timeliness</i> [21]; <i>currentness</i> [24]; <i>timeliness, freshness, currency</i> [20]; <i>Date, Preservation</i> [19]; dct:issued, dct:modified [28, 27]; <i>temporal consistency, temporal validity</i> [29]	K5.3; K7.5; (I1.019; I1.024–I1.025)
6	Interoperabilität und Linked-Data-Reife	FAIR I1–I3 [25]; <i>interoperability, interlinking, reuse of existing terms, reuse of vocabularies, dereferenceability</i> [20]; <i>Interoperability</i> [28, 27]; RDF-/DCAT-basierte Katalogbeschreibung [8, 14]; Linked-Data-Prinzipien [36]	K1.4; K6.1–K6.5; (I1.020–I1.022; I2.003–I2.006; I2.029; I2.055–I2.056; I3.018)
7	Vokabular-, Normdaten- und Klassifikationsqualität	FAIR I2 [25]; MQA-Vokabularmetriken für Format, Lizenz, Zugriffsrechte und Kategorien [28, 27]; <i>vocabulary reuse, semantic accuracy</i> [20]; <i>thematic classification correctness, domain consistency</i> [29]	K3.3; K4.6; K6.2–K6.3; K10.3; (I1.022; I1.041; I2.005; I2.055–I2.056; I3.018; I3.028)
8	Wiederverwendbarkeit und organisatorische Nutzbarkeit	FAIR R1, R1.1, R1.2, R1.3 [25]; <i>Reusability</i> : license, access rights, contact point, publisher [28, 27]; <i>Rights, OpenLicense, Contact</i> [19]; <i>value-added, relevance</i> [21]	K1.3; K2.3; K5.4; K7.1; (I2.030–I2.031; I3.021)
9	Format- und Maschinenlesbarkeitsqualität	<i>FileFormat, FormatAccr, OpenFormat, MachineRead</i> [19]; format, media type, format vocabulary, non-proprietary format, machine readability [28, 27]; FAIR R1.3 [25]; <i>versatility, interoperability</i> [20]	K5.4; K8.1; (I2.028; I2.045; I3.020–I3.021)
10	Semantische Aussagekraft und Verständlichkeit	<i>interpretability, ease of understanding, concise representation</i> [21]; <i>understandability</i> [24]; <i>understandability, interpretability</i> [20]; <i>quality of free text</i> [29]	K4.1–K4.4; K10.2; (I1.035; I1.043–I1.044; I2.008–I2.010; I2.027; I3.005)
11	Inhaltliche Plausibilität und semantische Konsistenz	<i>semantic accuracy, consistency, no contradictory values, correct annotations</i> [20]; <i>conceptual consistency, domain consistency, nonquantitative attribute correctness</i> [29]; <i>accuracy, consistent representation</i> [21]; <i>accuracy, consistency</i> [24]; ontologische Repräsentationsdefizite [23]	K4.5; K4.6; K8.3; (I2.011; I2.047; I3.010; I3.028–I3.029)
12	Metadaten-Daten-Kongruenz	<i>FormatAccr, SizeAccr, Retrievable</i> [19]; <i>nonquantitative attribute correctness, positional correctness, domain consistency</i> [29]; <i>accuracy, consistency</i> [20]; FAIR R1: genaue und relevante Attribute [25]	K8.1–K8.5; (I2.013; I2.045–I2.047; I2.059; I3.020–I3.022)
13	Räumliche domänenspezifische und Kontextqualität	<i>positional correctness, spatial domain consistency</i> [29]; geographic search, dct:spatial [28, 27]; spatial information [19]; FAIR R1.3 [25]; <i>fitness for use, relevance</i> [21]; ISO 19157 als geodatenbezogener Qualitätsrahmen [34]	K7.1–K7.3; K8.4; (I1.006; I1.009–I1.010; I1.031–I1.033; I1.040; I2.013; I2.059; I3.022)
14	Vertrauenswürdigkeit, Provenienz und Verantwortlichkeit	<i>believability, reputation, objectivity</i> [21]; <i>credibility, traceability</i> [24]; <i>trustworthiness, reputation</i> [20]; FAIR R1.2 [25]; publisher, contact point [28, 27]	K2.3; K6.2; K7.5; (I2.030–I2.031)
15	Nutzungsrelevanz und Fit for Purpose	<i>fitness for use, relevance, value-added, appropriate amount of data</i> [21]; Datenqualität im Nutzungskontext [22]; kontextabhängige Relevanz von Qualitätsmerkmalen [24]; FAIR R1/R1.3 [25]; <i>relevance</i> [20]	K1.3; K7.1; K7.4–K7.5; (I1.006; I1.047–I1.049)

Tabelle 3.5: Longlist gebündelter Kandidatendimensionen

Die Longlist enthält eine hohe Zahl potenziell relevanter Dimensionen. Für ein prototypisch operationalisierbares Bewertungsmodell ist diese Struktur jedoch zu umfangreich. Zum einen würden sich zahlreiche Indikatoren überschneiden. Zum anderen ist ein solches Modell nur eingeschränkt nachvollziehbar, **schwer zu implementieren** und in der Evaluation schlecht vergleichbar. Daher werden die Kandidatendimensionen im nächsten Schritt zu vier Hauptdimensionen verdichtet.

Die Verdichtung folgt zwei Prinzipien. Erstens werden Dimensionen zusammengeführt, wenn sie dieselbe Bewertungsfunktion erfüllen. Zweitens werden Dimensionen nicht

danach gruppiert, aus welchem Literaturmodell sie stammen, sondern danach, welchen Qualitätsaspekt sie im DCAT-AP.de-Kontext prüfen. Tabelle 3.6 visualisiert die finalen Dimensionen und ihre Bewertungsfunktion im Modell. Zu beachten ist das bestimmte Dimensionen der Longlist auf mehrere finale Dimensionen aufgeteilt wurden, da hier eine exakte Zuordnung nicht möglich ist.

Nr.	Finale Dimension	Gebündelte Kandidatendimensionen	Bewertungsfunktion im Modell
1	Auffindbarkeit	2. Vollständigkeit und feldbezogene Reichhaltigkeit 3. Auffindbarkeit und Identifizierbarkeit 5. Aktualität und temporale Konsistenz	Bewertet, ob ein Datensatz im Metadatenportal gefunden, identifiziert und grundlegend eingeordnet werden kann.
2	Zugänglichkeit	4. Technische Zugänglichkeit und Abrufbarkeit 5. Aktualität und temporale Konsistenz 9. Format- und Maschinenlesbarkeitsqualität 12. Metadaten-Daten-Kongruenz	Bewertet, ob die in den Metadaten beschriebene Ressource technisch erreichbar und praktisch nutzbar ist.
3	Nachnutzbarkeit	1. Formale und syntaktische Konformität 6. Interoperabilität und Linked-Data-Reife 7. Vokabular-, Normdaten- und Klassifikationsqualität 8. Wiederverwendbarkeit und rechtlich-organisatorische Nutzbarkeit 14. Vertrauenswürdigkeit, Provenienz und Verantwortlichkeit	Bewertet, ob Metadaten und Ressourcen über den bloßen Zugriff hinaus rechtlich, organisatorisch und maschinell weiterverwendbar sind.
4	Aussagekraft	10. Semantische Aussagekraft und Verständlichkeit 11. Inhaltliche Plausibilität und semantische Konsistenz 12. Metadaten-Daten-Kongruenz 13. Räumliche und domänenspezifische Kontextqualität 15. Nutzungsrelevanz und Fit for Purpose	Bewertet, ob vorhandene Metadaten inhaltlich verständlich, plausibel und kontextangemessen sind.

Tabelle 3.6: Verdichtung der Kandidatendimensionen zu finalen Qualitätsdimensionen

3.5 Ableitung formaler, technischer und semantischer Einzelindikatoren

Die vier Qualitätsdimensionen Auffindbarkeit, Zugänglichkeit, Nachnutzbarkeit und Aussagekraft beschreiben zunächst abstrakte Bewertungsbereiche. Für die prototypische Operationalisierung müssen diese Bereiche in konkrete, prüfbare Einzelindikatoren überführt werden. Ein Indikator übersetzt eine Qualitätsdimension in eine messbare oder nachvollziehbar bewertbare Prüflogik. Während die Dimension festlegt, welcher Qualitätsaspekt betrachtet wird, bestimmt der Indikator, welches Metadatenfeld, welche Ressource oder welche Relation geprüft wird.

Die formale DCAT-AP.de-Konformität wird dabei nicht als eigene Qualitätsdimension geführt. Pflichtfeldbezogene Existenz- und Strukturprüfungen werden im GovData-Kontext bereits durch die SHACL-basierte Validierung adressiert und im Bewertungsmodell nicht feldweise dupliziert. Stattdessen geht die formale Standardkonformität als ein einzelner, aggregierter Indikator in die Dimension Nachnutzbarkeit ein: Verletzungen der Mindestanforderungen des Standards beeinträchtigen die maschinelle Verarbeitbarkeit und die portalübergreifende Weiterverwendung eines Metadatensatzes unmittelbar. Dieses Vorgehen ist anschlussfähig an die MQA, die die DCAT-AP-Konformität ebenfalls als eine Metrik innerhalb ihres Dimensionsmodells führt [27, 28]. Der Qualitätsscore wird folglich aus den vier Dimensionen Auffindbarkeit, Zugänglichkeit, Nachnutzbarkeit und Aussagekraft gebildet. Alle übrigen Indikatoren erfassen Qualitätsaspekte, die über die formale Standardkonformität hinausgehen.

Die Ableitung der Einzelindikatoren erfolgt regelgeleitet. Ausgangspunkt bilden die vier finalen Qualitätsdimensionen. Für jede Dimension werden zunächst Qualitätskriterien formuliert, die beschreiben, welche Eigenschaft der Metadaten oder der beschriebenen Ressource bewertet werden soll. Anschließend wird geprüft, durch welche Einzelindikatoren diese Kriterien operationalisiert werden können.

Die Auswahl der Indikatoren orientiert sich an sechs Kriterien:

1. **Standardbezug:** Der Indikator ist aus verpflichtenden, empfohlenen oder optionalen Anforderungen des DCAT-AP.de-Standards ableitbar.
2. **Konventionsbezug:** Der Indikator greift eine technische, semantische oder organisatorische Konvention des DCAT-AP.de-Konventionenhandbuchs auf.
3. **Literaturbezug:** Der Indikator schließt an etablierte Metriken bestehender Qualitätsmodelle an.
4. **Interviewbezug:** Der Indikator adressiert ein in den Experteninterviews benanntes Qualitätsproblem.
5. **Operationalisierbarkeit:** Der Indikator ist mit den im Prototyp verfügbaren Datenquellen und Verfahren zumindest teilweise prüfbar.
6. **Reportingfähigkeit:** Das Prüfergebnis ist so interpretierbar, dass daraus ein verständlicher Reportinghinweis abgeleitet werden kann.

Aufgenommen werden Indikatoren, die über die reine Pflichtfeldprüfung hinausgehen. Dazu zählen empfohlene oder optionale Angaben, technische Erreichbarkeitsprüfungen, kontrollierte Vokabularnutzung, URI-Nutzung statt Plain Literals, Format- und Lizenzqualität, semantische Aussagekraft sowie begrenzte Plausibilitäts- und Kongruenzprüfungen.

Die Auswahl erhebt damit keinen Anspruch auf eine vollständige Abbildung aller theoretisch denkbaren Qualitätsaspekte von Metadaten. Priorisiert werden solche Indikatoren, die für den GovData-Kontext fachlich relevant, aus Standard oder Konventionen begründbar, prototypisch operationalisierbar und für ein menschenlesbares Reporting geeignet sind. Für das Bewertungsmodell werden drei Indikatortypen unterschieden.

Formale Indikatoren prüfen regelbasierte Eigenschaften der Metadatenstruktur. Dazu gehören insbesondere empfohlene und optionale Felder, kontrollierte Vokabulare, URI-Strukturen, Wertebereiche sowie nicht-blockierende SHACL-Warnings und SHACL-Infos. Sie werden im Folgenden mit FI abgekürzt.

Technische Indikatoren prüfen technisch beobachtbare Eigenschaften der beschriebenen Ressource oder Zugriffsinfrastruktur. Dazu gehören insbesondere die Erreichbarkeit von Zugriffspfaden, die Abrufbarkeit von Dateien oder Diensten, HTTP-Statuscodes, Formatangaben, Medientypen und Maschinenlesbarkeit. Sie werden mit TI abgekürzt.

Semantische Indikatoren prüfen inhaltliche, sprachliche oder kontextbezogene Eigenschaften, die nicht allein durch Feldexistenz oder syntaktische Validität erfasst werden können. Dazu gehören insbesondere Aussagekraft, Verständlichkeit, Redundanz, thematische Passung und Plausibilität von Metadatenangaben. Sie werden mit SI abgekürzt.

Die konkrete technische Implementierung der Indikatoren wird in Kapitel 4 beschrieben. Der vorliegende Abschnitt definiert die konzeptionelle Funktion der Indikatoren, ihre Zuordnung zu den Qualitätsdimensionen und die jeweils geprüften DCAT-AP.de-Elemente.

3.5.1 Konzeptionelles Messmodell

Bevor die Einzelindikatoren je Dimension abgeleitet werden, werden die Messprinzipien festgelegt, die für alle Indikatoren gleichermaßen gelten. Diese Festlegungen sind Teil des Konzepts, da sie bestimmen, welche Aussagen ein Indikator überhaupt treffen kann.

Ergebnisstufen

Jeder Indikator liefert ein dreistufiges Prüfergebnis: *erfüllt*, *teilweise erfüllt* oder *nicht erfüllt*. Die Zwischenstufe ist erforderlich, da zahlreiche Prüfungen fachlich sinnvolle Teilzustände aufweisen, die eine binäre Bewertung nicht abbilden kann. So kann ein Datensatz eine Themenkategorie angeben, die nicht aus dem vorgesehenen kontrollierten Vokabular stammt. Eine solche Angabe ist höherwertiger als eine fehlende Angabe, erfüllt jedoch nicht die Anforderungen einer standardkonformen Angabe. Eine binäre Prüfung müsste diesen Fall entweder zu streng oder zu nachsichtig bewerten. Darüber hinaus verlangt das Auswahlkriterium der Reportingfähigkeit abgestufte und

handlungsorientierte Verbesserungshinweise, die erst durch die Zwischenstufe möglich werden (INT-K9, Tabelle 3.4). Indikatoren ohne fachlich sinnvolle Teilerfüllung, beispielsweise die Prüfung auf das Vorhandensein einer Geometrieangabe, nutzen ausschließlich die beiden äußeren Stufen.

Ternäre und graduelle Indikatoren

Das Modell unterscheidet zwei Messformen. **Ternäre Indikatoren** bilden ihr Prüfergebnis unmittelbar auf die drei Ergebnisstufen ab. Dies betrifft Eigenschaften mit klar abgrenzbaren Zuständen, insbesondere Vokabular- und Strukturprüfungen auf Datensatzebene. **Graduelle Indikatoren** messen dagegen einen kontinuierlichen Erfüllungsgrad zwischen 0 und 1, aus dem die Ergebnisstufe nachgelagert abgeleitet wird, diese allerdings keinen Einfluss auf den Wert hat. Graduell gemessen werden zwei Klassen von Eigenschaften. Die erste Klasse umfasst anteilige Eigenschaften, die sich auf mehrere Teilobjekte eines Datensatzes beziehen, beispielsweise den Anteil der Distributionen mit erreichbarer Download-URL. Die zweite Klasse umfasst semantische Urteile, die naturgemäß keine scharfe Erfüllungsgrenze besitzen, beispielsweise die Aussagekraft einer Beschreibung. Diese Trennung stellt sicher, dass der kontinuierliche Erfüllungsgrad unverfälscht in die Aggregation eingeht, während die Ergebnisstufe der verständlichen Darstellung im Reporting dient.

Bewertungsebene und Aggregation über Distributionen

Ein DCAT-Datensatz kann mehrere Distributionen besitzen. Zahlreiche Qualitätseigenschaften, darunter Formatangaben, Medientypen, Lizenzangaben und technische Erreichbarkeit, sind Eigenschaften der einzelnen Distribution und nicht des Datensatzes. Das Bewertungsmodell prüft solche Indikatoren daher je Distribution und aggregiert die Einzelergebnisse als Mittelwert über alle Distributionen zum Datensatzergebnis.

Damit grenzt sich das Modell bewusst von der MQA ab. Die MQA bewertet distributionsbezogene Metriken nach dem Best-Distribution-Prinzip. Bei mehreren Distributionen bestimmt die am besten bewertete Distribution das Ergebnis, unter der Annahme, dass alle Distributionen denselben Datensatz lediglich in unterschiedlichen Formaten repräsentieren [27, 37]. Diese Annahme trägt in der Praxis jedoch nicht durchgängig. Bereits die DCAT-Spezifikation dokumentiert, dass bestehende Implementierungen Distributionen auch zur Modellierung inhaltlich eigenständiger Teildatensätze verwenden, indem etwa die Mitglieder einer Datensatzserie als Distributionen eines einzelnen Datensatzes typisiert werden. Erst mit DCAT 3 wurde für diesen Fall die eigene Klasse `dcat:DatasetSeries` eingeführt [8, Abschnitt 12.3]. Distributionen desselben Datensatzes können sich damit inhaltlich unterscheiden und folglich auch in ihrer Qualität voneinander abweichen. Empirische Untersuchungen von Open-Data-Portalen verorten zentrale Fehlerbilder wie nicht abrufbare Ressourcen entsprechend auf der Ebene

der einzelnen Ressource, weshalb Neumaier et al. die Abrufbarkeit je Ressource und nicht je Datensatz prüfen [19]. Die Interviews bestätigen dieses Bild und benennen defekte Einzelverweise und heterogene Distributionsqualität als zentrales Praxisproblem (INT-K5, INT-K8). Unter dem Best-Distribution-Prinzip bleibt eine nicht erreichbare Download-URL zudem folgenlos, solange eine einzige Distribution funktioniert. Aus Nutzendensicht wird ein solcher Datensatz systematisch überbewertet. Die Mittelwertbildung macht dagegen jede Distribution im Ergebnis sichtbar und setzt zugleich einen Anreiz, fehlerhafte Distributionen zu korrigieren oder zu entfernen, statt sie durch eine einzelne funktionierende Distribution zu maskieren.

Malus-Prinzip

Innerhalb der graduellen, distributionsbezogenen Messung werden ausgewählte Defekte nicht mit null, sondern mit einem negativen Beitrag bewertet. Dies betrifft Zustände, die aus Nutzendensicht schlechter sind als das Fehlen der Angabe, weil sie irreführen oder die Nachnutzung aktiv verhindern. Dazu zählen eine angegebene, aber nicht erreichbare Zugriffs- oder Download-URL sowie eine eingeschränkte, unklare oder fehlende Lizenz. Eine nicht erreichbare URL täuscht Verfügbarkeit vor und verursacht vergeblichen Zugriffsaufwand (INT-K5). Eine unklare Lizenz macht die Nachnutzung rechtlich unsicher und damit faktisch unmöglich [19]. Ein nicht maschinenlesbarer Zugriffsweg fällt dagegen bewusst nicht unter das Malus-Prinzip: **Eine solche Distribution täuscht keine Verfügbarkeit vor, sondern liefert, was sie ankündigt, und wird in der Bereitstellungspraxis häufig ergänzend zu einem maschinenlesbaren Zugriffsweg angeboten;** sie geht deshalb lediglich mit null in die Messung ein. Würden solche Defekte lediglich mit null bewertet, wäre ein Datensatz mit fünf Distributionen, von denen vier defekt sind, kaum von einem Datensatz mit einer einzigen fehlenden Angabe unterscheidbar. Der negative Beitrag senkt das Datensatzergebnis aktiv, wobei der Dimensionswert konzeptionell bei null nach unten begrenzt ist. Die konkrete Höhe der Malus-Beiträge wird in Kapitel 4 festgelegt.

Nicht-Anwendbarkeit

Nicht jedes Qualitätskriterium trifft auf jeden Datensatz zu. Die Interviews fassen Vollständigkeit als relative Feldrelevanz auf und betonen die Kontextabhängigkeit der Bewertung (INT-K2, INT-K7). Das Messmodell sieht deshalb ergänzend die Ergebnisstufe *nicht anwendbar* vor. **Ein Kriterium, das auf einen Datensatz fachlich nicht zutrifft, wird neutral übersprungen und geht weder positiv noch negativ in die Aggregation ein.** Ein Beispiel hierfür ist die Anforderung kontextueller Qualifizierer wie Stichtags- oder Vorläufigkeitsangaben bei einem einmaligen, statischen Datensatz. Auf diese Weise wird verhindert, dass Datensätze für Angaben abgewertet werden, die für sie nicht relevant sind. Zugleich setzt diese Ergebnisstufe die aus den Interviews abgeleitete Anforderung einer kontextsen-

sitiven Bewertung um.

Herleitungsnachweis der Indikatoren

In den folgenden Indikatortabellen weist die Spalte *Herleitung* je Indikator die Quellen der Anforderung aus und macht damit die eingangs definierten Auswahlkriterien nachprüfbar. Die verwendeten Kurzzeichen sind in Tabelle 3.7 definiert.

Kurzzeichen	Quelle der Anforderung	Referenz
SPEC	DCAT-AP.de-Spezifikation	[11]
KONV xx	Konvention xx des DCAT-AP.de-Konventionenhandbuchs	[13]
MQA	Metrik des Metadata Quality Assessment	[27, 28]
NEU	Metrik nach Neumaier et al.	[19]
ZAV	Metrik nach Zaveri et al.	[20]
FAIR	FAIR-Prinzipien	[25]
HMQ	Handreichung zur Verbesserung der Metadatenqualität von offenen Daten	[38]
INT-Kx	Interviewkategorie Kx	Tabelle 3.4

Tabelle 3.7: Kurzzeichen der Herleitungssignale in den Indikatortabellen

3.5.2 Auffindbarkeitsindikatoren

Auffindbarkeitsindikatoren prüfen, ob ein Datensatz im Metadatenportal über zusätzliche Such-, Filter- und Identifikationsmerkmale besser gefunden und eingeordnet werden kann. Verpflichtende Basisfelder wie Titel und Beschreibung werden hier nicht als Vorhandenseinsindikatoren aufgenommen, da sie bereits durch SHACL geprüft werden. Bewertet werden stattdessen empfohlene, optionale oder qualitätssteigernde Angaben.

Kürzel	Indikatorname	Typ	Messung	Geprüfte Elemente	Herleitung
A1	Schlagwortumfang in angemessenem Bereich	FI	ternär	<code>dcat:keyword</code>	MQA; NEU; INT-K4
A2	Themenkategorie aus kontrolliertem Vokabular	FI	ternär	<code>dcat:theme</code>	MQA; SPEC; INT-K6
A3	Räumliche Geometrieangabe vorhanden	FI	ternär	<code>locn:geometry</code>	MQA; INT-K7
A4	Politische Geokodierung aus DCAT-AP.de-Vokabular	FI	ternär	<code>dcatde:political-GeocodingURI</code> ; <code>locn:adminUnitL2</code>	KONV 08; INT-K6
A5	Ebene der politischen Geokodierung aus Vokabular	FI	ternär	<code>dcatde:political-GeocodingLevelURI</code>	KONV 09
A6	Zeitliche Abdeckung mit valider Datumsangabe	FI	ternär	<code>dct:temporal (dcat:startDate, dcat:endDate)</code>	MQA; NEU
A7	Veröffentlichungsdatum valide typisiert	FI	graduell	<code>dct:issued</code> (Dataset und Distribution)	MQA; NEU
A8	Änderungsdatum valide typisiert	FI	graduell	<code>dct:modified</code> (Dataset und Distribution)	MQA; NEU

Tabelle 3.8: Auffindbarkeitsindikatoren

3.5.3 Zugänglichkeitsindikatoren

Zugänglichkeitsindikatoren prüfen, ob die in den Metadaten beschriebene Ressource technisch erreichbar, korrekt beschrieben und praktisch abrufbar ist. Das bloße Vorhandensein der verpflichtenden `dcat:accessURL` wird nicht erneut als Indikator aufgenommen. Bewertet werden stattdessen technische Erreichbarkeit, Download-Angaben, Formatqualität und Maschinenlesbarkeit. Alle Zugänglichkeitsindikatoren setzen an der einzelnen Distribution an und werden nach dem in Abschnitt 3.5.1 definierten Messmodell graduell über alle Distributionen aggregiert. Die Erreichbarkeitsprüfungen unterliegen dem Malus-Prinzip.

Kürzel	Indikatorname	Typ	Messung	Geprüfte Elemente	Herleitung
Z1	Download-URL angegeben	FI	graduell	dcat:downloadURL	MQA; NEU
Z2	Formatangabe aus kontrolliertem Vokabular	FI	graduell	dct:format	MQA; NEU
Z3	Medientyp als IANA-Medientyp	FI	graduell	dcat:mediaType	MQA; NEU
Z4	Nicht-proprietäres Format	FI	graduell	dct:format	MQA; FAIR
Z5	Download-URL technisch erreichbar	TI	graduell	dcat:downloadURL	MQA; NEU; INT-K5
Z6	Access-URL technisch erreichbar	TI	graduell	dcat:accessURL	MQA; NEU; INT-K5
Z7	Maschinenlesbarer Zugriffsweg (abgestuft)	TI	graduell	dct:format; dcat:mediaType; dcat:accessURL; dcat:downloadURL	MQA; INT-K5, INT-K6

Tabelle 3.9: Zugänglichkeitsindikatoren

3.5.4 Nachnutzbarkeitsindikatoren

Nachnutzbarkeitsindikatoren prüfen, ob Metadaten und Ressourcen über den bloßen Zugriff hinaus rechtlich, organisatorisch und maschinell weiterverwendbar sind. Verpflichtende Angaben, die bereits durch SHACL-Constraints geprüft werden, werden nicht als reine Vorhandenseinsindikatoren aufgenommen. Die formale DCAT-AP.de-Konformität geht jedoch als aggregierter Indikator N7 in diese Dimension ein, da Standardverletzungen die maschinelle Weiterverwendung unmittelbar beeinträchtigen. Die Lizenzprüfung erfolgt je Distribution und unterliegt dem Malus-Prinzip, da eingeschränkte, unklare oder fehlende Lizenzen die Nachnutzung rechtlich unsicher machen und deshalb aktiv negativ bewertet werden.

Kürzel	Indikatorname	Typ	Messung	Geprüfte Elemente	Herleitung
N1	Freie Lizenz aus DCAT-AP.de-Lizenzliste	FI	graduell	dct:license	KONV 32; MQA; NEU; INT-K1
N2	Herausgeber als strukturierter Agent mit Namen	FI	ternär	dct:publisher (foaf:Agent, foaf:name)	MQA; NEU; ZAV
N3	Kontaktpunkt mit nutzbarer E-Mail oder URL	FI	ternär	dcat:contactPoint	KONV 01; NEU; INT-K5
N4	Geplante Verfügbarkeit aus kontrolliertem Vokabular	FI	graduell	dcatap:availability	SPEC
N5	ContributorID aus Contributor-Vokabular	FI	ternär	dcatde:contributorID	KONV 12, KONV 13
N6	DCAT-AP.de-Konformität (SHACL-Validierung)	FI	ternär	gesamter Metadatensatz	SPEC; MQA; INT-K3

Tabelle 3.10: Nachnutzbarkeitsindikatoren

3.5.5 Aussagekraftsindikatoren

Aussagekraftsindikatoren prüfen, ob vorhandene Metadaten inhaltlich verständlich, aussagekräftig und kontextangemessen sind. Da Titel und Beschreibung bereits verpflichtend sind, wird nicht ihr Vorhandensein, sondern ihr Informationswert bewertet. Diese Eigenschaften sind regelbasiert nicht prüfbar. Ob ein Titel für sich genommen verständlich ist, eine Beschreibung inhaltlichen Mehrwert liefert oder Schlagwörter zum beschriebenen Datensatz passen, lässt sich weder über Feldexistenz noch über syntaktische Muster entscheiden (INT-K4). Das Bewertungsmodell sieht daher für diese Dimension ein sprachverstehendes Verfahren als Messinstrument vor. Konzeptionell gelten dabei zwei Anforderungen. Erstens werden die Bewertungskriterien nicht frei definiert, sondern aus den Qualitätsanforderungen des DCAT-AP.de-Konventionenhandbuchs sowie der Handreichung zur Verbesserung der Metadatenqualität von offenen Daten abgeleitet [13, 38]. Zweitens muss jedes semantische Urteil nachvollziehbar sein und auf benennbare Befunde im Metadaten text gestützt sowie im Reporting begründet werden (INT-K9, INT-K10). Alle Aussagekraftsindikatoren sind graduell, da semantische Qualität keine scharfe Erfüllungsgrenze besitzt. Für kontextabhängige Kriterien ist die in Abschnitt 3.5.1 definierte Ergebnisstufe *nicht anwendbar* vorgesehen.

Kürzel	Indikatorname	Typ	Messung	Geprüfte Elemente	Herleitung
S1	Aussagekraft des Titels	SI	graduell	dct:title	INT-K4; HMQ
S2	Aussagekraft der Beschreibung	SI	graduell	dct:description	INT-K4; HMQ
S3	Kohärenz von Titel und Beschreibung	SI	graduell	dct:title; dct:description	INT-K4
S4	Qualität der Schlagwörter	SI	graduell	dcat:keyword	INT-K4; HMQ
S5	Thematische Konsistenz	SI	graduell	dcat:theme; dcat:keyword; dct:title; dct:description	INT-K4
S6	Kontextuelle Qualifizierer (Stichtag, Bezugszeitraum, Vorläufigkeit)	SI	graduell	dct:description; dct:issued; dct:modified	INT-K2, INT-K7; HMQ

Tabelle 3.11: Aussagekraftsindikatoren

4 Prototypische Operationalisierung

Mit dem konzeptionellen Bewertungsmodell ist festgelegt, welche Qualitätsaspekte geprüft werden und nach welchen Prinzipien die Prüfergebnisse zu einem Gesamturteil verdichtet werden. Im folgenden Kapitel wird beschrieben, wie diese Prinzipien prototypisch operationalisiert werden. Die Umsetzung erfolgt in einer modularen Architektur, die die einzelnen Verarbeitungsschritte klar voneinander trennt und eine nachvollziehbare Bewertungskette von der Metadateneingabe bis zum Ergebnisreport abbildet.

4.1 Zielsetzung und Funktionsumfang des Prototyps

Der Prototyp überführt das in Kapitel 3 entwickelte Bewertungsmodell in ein lauffähiges System und setzt damit den operationalisierenden Teil der Zielsetzung dieser Arbeit um. Sein Ziel ist es, die Qualität von DCAT-AP.de-Metadaten im GovData-Kontext automatisiert, aussagekräftig und nachvollziehbar zu bewerten und die rein formale RDF-/SHACL-Validierung um kontext- und semantikbezogene Prüfungen sowie ein interpretierbares Reporting zu erweitern. Die Nachvollziehbarkeit der Bewertung ist dabei durchgängiges Entwurfsziel: Jedes Teilergebnis ist auf eine dokumentierte Prüffregel zurückführbar, und identische Eingaben führen bei den regelbasierten und technischen Prüfungen zu identischen Ergebnissen. Damit bildet der Prototyp zugleich die Grundlage für die Evaluation in Kapitel 5.

Aus Nutzungssicht bewertet der Prototyp einzelne DCAT-AP.de-Metadatenätze, die als RDF/XML-Dateien vorliegen. Die Verarbeitung erfolgt wahlweise für einzelne Dateien oder gebündelt für ein Verzeichnis, sodass sowohl Einzelbewertungen als auch Stichprobenläufe möglich sind. Für jeden Datensatz werden die Indikatoren des Bewertungsmodells ausgewertet und zu einem vollständigen, maschinenlesbaren Bewertungsergebnis zusammengeführt. Dieses enthält je Indikator die Ergebnisstufe, den Erfüllungsgrad, eine deutsch- und englischsprachige Ergebnismeldung sowie indikatorspezifische Detailbefunde, darüber hinaus die aggregierten Dimensionswerte, den gewichteten Gesamtscore und eine daraus abgeleitete Gesamtnote. Auf Ebene eines Bewertungslaufs werden zusätzlich aggregierte Kennzahlen und Visualisierungen über alle verarbeiteten Datensätze erzeugt. Welche Dimensionen und Indikatoren ausgewer-

tet werden und mit welchen Gewichten sie in die Aggregation eingehen, ist konfigurierbar, ohne dass Quellcode angepasst werden muss.

Ebenso bewusst ist der Funktionsumfang begrenzt. Der Prototyp harvestet keine Metadaten, sondern arbeitet auf bereits exportierten RDF-Dateien, wie sie die GovData-Infrastruktur bereitstellt. Er ist als Analysewerkzeug für Einzel- und Stichprobenbewertungen ausgelegt und nicht als dauerhaft betriebener Portaldienst mit kontinuierlichem Monitoring. Bewertet werden die Metadaten und ihre technische Einlösbarkeit, nicht die fachliche Qualität der beschriebenen Daten selbst.

4.2 Systemarchitektur und Verarbeitungspipeline

Die Architektur des Prototyps folgt drei Entwurfsprinzipien. Erstens ist die Verarbeitung in Schichten mit strikt einwärts gerichteten Abhängigkeiten organisiert, sodass die Domänenlogik von Ein- und Ausgabe entkoppelt bleibt. Zweitens ist das Indikatorensystem über eine Registrierung erweiterbar, sodass neue Indikatoren hinzugefügt werden können, ohne die Verarbeitungskette anzupassen. Drittens werden alle Fakten über einen Datensatz genau einmal erhoben und anschließend von allen Indikatoren gemeinsam genutzt. Abbildung 4.1 zeigt den Aufbau des Prototyps und den Datenfluss durch die Verarbeitungskette.




Abbildung 4.1: Systemarchitektur und Datenfluss des Prototyps

Der Verarbeitungsweg eines Metadatensatzes folgt den drei Schichten der Abbildung. In der *extraction*-Schicht wird ein RDF-Graph als RDF/XML-Datei eingelesen und in eine typisierte Faktenbasis überführt. Darauf folgen zwei bedarfsgesteuerte Anreiche-

rungsschritte, die technische Erreichbarkeitsprüfung der Distributionen und die semantische Bewertung der Freitextfelder. Um sich Netzwerkzugriffe und Sprachmodellaufrufe zu sparen, werden diese nur ausgeführt, wenn nach der aktiven Konfiguration mindestens ein Indikator ihre Ergebnisse tatsächlich konsumiert. In der Schicht `scoring` werden anschließend die Indikatoren je Qualitätsdimension ausgeführt und die Einzelergebnisse zu Dimensions- und Gesamtwerten aggregiert. Die Schicht `reporting` persistiert und visualisiert abschließend die fertigen Ergebnisse zusammen mit den Protokollen des Bewertungslaufs.

Die Indikatoren registrieren sich bei ihrer Instanziierung selbst in einer zentralen Registrierung, aus der die Bewertungsschicht die auszuführenden Prüfungen bezieht. Ein neuer Indikator besteht damit aus einer einzelnen Klasse, die eine Prüfmethode implementiert, und wird von der Verarbeitungskette automatisch berücksichtigt. Dieses Erweiterungsprinzip setzt die im Bewertungsmodell angelegte Offenheit des Indikatorenkatalogs technisch um.

Der Prototyp ist in Python implementiert und setzt Python 3.12 voraus. Die RDF-Verarbeitung erfolgt mit der Bibliothek `rdflib`¹, die Erreichbarkeitsprüfungen nutzen `requests`². Die strukturierte Ausgabe des Sprachmodells wird über `Pydantic`³ schemavalidiert, die Anbindung des Modells erfolgt über `LangChain`⁴. Die Konfiguration der Bewertungsläufe wird mit `Hydra`⁵ verwaltet, die Visualisierungen werden mit `matplotlib`⁶ erzeugt. Die exakten Versionsstände aller Abhängigkeiten sind im Quellcode-Repository⁷ festgeschrieben.

4.3 Extraktion und Anreicherung der Metadaten

Die in der Verarbeitungspipeline aufgebaute Faktenbasis hält je Datensatz alle bewertungsrelevanten Angaben, darunter Titel, Beschreibung, Schlagwörter, Themen sowie Datums- und Frequenzangaben, und für jede Distribution ein eigenes Faktenobjekt mit Format-, Medientyp-, Lizenz- und URL-Angaben. Häufig benötigte abgeleitete Größen wie die Anzahl der Distributionen mit Download-URL werden als berechnete Eigenschaften bereitgestellt.

Ihre Einführung als eigene Zwischenschicht zwischen RDF-Graph und Indikatoren ist

¹<https://rdflib.readthedocs.io/>

²<https://requests.readthedocs.io/>

³<https://docs.pydantic.dev/>

⁴<https://www.langchain.com/>

⁵<https://hydra.cc/>

⁶<https://matplotlib.org/>

⁷https://github.com/LarsBuerger/master_thesis_prototype/tree/v3_prototype_freeze

eine bewusste Entwurfsentscheidung. Sie stellt erstens Konsistenz sicher, da alle Indikatoren über dieselben, an genau einer Stelle extrahierten Fakten urteilen und Interpretationsfragen der RDF-Struktur nicht je Indikator unterschiedlich beantwortet werden können. Desweiteren wird redundante Arbeit vermieden, da der Graph nur einmal traversiert wird. Zudem wird die Prüflogik vom Datenmodell entkoppelt, denn die Indikatoren operieren auf typisierten Werten und enthalten keine RDF-spezifische Logik, was ihre Implementierung und Erweiterung wesentlich vereinfacht.

```

DatasetContext(
    titles=["Radverkehrsnetz Brandenburg"],
    keywords=["Radverkehr", "Radwege", "Infrastruktur"],
    themes=[".../data-theme/TRAN"],
    themes_in_vocab=[True],
    distributions=[
        DistributionContext(
            download_url="https://geoportal.example.de/radnetz.csv",
            formats=[".../file-type/CSV"],
            formats_in_vocab=[True],
            licenses_open=[True],
            probe=DistributionProbe(          # technische Anreicherung
                fetched=True,
                download_status_code=200,
                coalesced_mime="text/csv",
                machine_readable_tier="high",
                is_non_proprietary=True,
            ),
        ),
    ],
    semantic_assessment=ExpressivenessAssessment( # semantische Anreicherung
        title_quality=ExpressivenessCriterion(
            findings=["Titel nennt Thema und Raumbezug", ...],
            reasoning="...",
            applicable=True,
            score=0.8,
        ),
        ..., # weitere Kriterien
    ),
)

```

Listing 1: Exemplarisch gefüllte Faktenbasis nach beiden Anreicherungsstufen, gekürzt

Listing 1 zeigt exemplarisch eine gekürzte Faktenbasis nach Abschluss beider Anreicherungsstufen. Neben den extrahierten Rohwerten sind die vorberechneten Vokabularprüfungen wie `themes_in_vocab` sichtbar sowie die angehängten Prüfsignale: Das Ergebnis der Erreichbarkeitsprüfung liegt je Distribution im Feld `probe`, die semanti-

sche Bewertung datensatzweit im Feld `semantic_assessment`.

Prüfungen gegen kontrollierte Vokabulare stützen sich auf lokal mitgelieferte Kopien der Referenzlisten, die einmalig beim Start geladen werden. Dazu gehören die Vokabulare des Publications Office der Europäischen Union für Themen, Dateitypen und Aktualisierungsfrequenzen⁸, das Medientypregister der IANA⁹ sowie die Lizenzliste, die IDs der Datenbereitsteller und das Schlüsselverzeichnis der politischen Geokodierung aus DCAT-AP.de [13]. Die lokale Bündelung macht die Vokabularprüfungen deterministisch und unabhängig von der Verfügbarkeit externer Dienste.

Die technische Anreicherung prüft die Erreichbarkeit der in den Distributionen angegebenen Zugriffs- und Download-URLs. Jede eindeutige URL wird höchstens einmal je Bewertungslauf angefragt, zunächst über eine HEAD-Anfrage und bei deren Fehlschlag über eine GET-Anfrage mit abgebrochenem Inhaltsbezug. Erfasst werden unter anderem der HTTP-Statuscode, der zurückgelieferte Medientyp und die Fehlerklasse fehlgeschlagener Anfragen. Die Ergebnisse werden als Prüfsignale an die Faktenbasis angehängt und von allen konsumierenden Indikatoren gemeinsam genutzt.

Die semantische Anreicherung erzeugt bei aktivierten Aussagekraftsindikatoren eine strukturierte Bewertung der Freitextfelder und hängt sie ebenfalls an die Faktenbasis an. Sie folgt demselben Prinzip wie die technische Anreicherung: Die Bewertung wird genau einmal je Datensatz erstellt und anschließend von allen sechs Aussagekraftsindikatoren gemeinsam ausgewertet.

4.4 Implementierung der Einzelindikatoren

Alle Indikatoren folgen derselben Implementierungsstruktur. Ein Indikator ist eine Klasse mit einer einzelnen Prüfmethode, die die Faktenbasis liest und ein Ergebnisobjekt zurückgibt. Das Ergebnisobjekt enthält die Ergebnisstufe, den Erfüllungsgrad, eine deutsch- und englischsprachige Ergebnismeldung sowie ein Detailobjekt mit den geprüften Werten, aus dem sich das Urteil im Reporting nachvollziehen lässt. Listing 2 zeigt das Muster in vereinfachter Form am Beispiel der Themenkategorie. Da die Faktenbasis die Vokabularzugehörigkeit bereits vorberech-

```
class ThemeIndicator(Indicator):
    def validate(self, context):
        if not context.themes:
            return self.result(FAIL)
        if all(context.themes_in_vocab):
            return self.result(PASS)
        return self.result(PARTIAL)
```

Listing 2: Implementierungsmuster eines ternären Indikators, vereinfacht

⁸<https://op.europa.eu/en/web/eu-vocabularies/authority-tables>

⁹<https://www.iana.org/assignments/media-types/>

net bereitstellt, reduziert sich die Prüflogik der meisten formalen Indikatoren auf wenige Fallunterscheidungen.

Die folgenden Abschnitte dokumentieren je Dimension die gemeinsame Prüfmechanik und die konkreten Prüfregeln einschließlich der gewählten Schwellwerte. Die konzeptionelle Herleitung der Indikatoren wird nicht wiederholt, referenziert wird ausschließlich über die Kürzel aus Kapitel 3.

4.4.1 Abbildung des konzeptionellen Modells auf implementierte Indikatoren

Da das konzeptionelle Modell bereits auf operationalisierbare Indikatoren zugeschnitten ist, bilden die implementierten Indikatoren die Konzept-Kürzel eins zu eins ab. Von den im Konzept abgeleiteten Indikatoren werden in der evaluierten Modellkonfiguration 27 aktiviert. Tabelle 4.1 dokumentiert deren Zuordnung zu den Indikator-Bezeichnern der Implementierung. Diese Bezeichner erscheinen in den Bewertungsergebnissen, den Reports und den Auswertungen der Evaluation. Die Tabelle dient damit als durchgängige Referenz zwischen Konzept, Quellcode und Ergebnisdarstellung.

Kürzel	Indikator-Bezeichner	Kürzel	Indikator-Bezeichner
A1	find_keywords_count	Z1	acc_download_url
A2	find_theme_valid	Z2	acc_format
A3	find_locn_geometry	Z3	acc_media_type
A4	find_political_geocoding	Z4	acc_format_non_proprietary
A5	find_geocoding_level	Z5	acc_download_url_response
A6	find_temporal_coverage	Z6	acc_access_url_response
A7	find_issued_datetime	Z7	acc_machine_readable_access
A8	find_modified_datetime	N1	reuse_license
S1	expr_title_quality	N2	reuse_publisher
S2	expr_description_quality	N3	reuse_contact
S3	expr_title_description_coherence	N4	reuse_availability
S4	expr_keyword_quality	N5	reuse_contributor_id
S5	expr_thematic_consistency	N6	reuse_dcat_ap_de_compliance
S6	expr_contextual_qualifiers		

Tabelle 4.1: Zuordnung der Konzept-Kürzel zu den implementierten Indikator-Bezeichnern

4.4.2 Auffindbarkeitsindikatoren

Die Auffindbarkeitsindikatoren prüfen datensatzweite Angaben direkt auf der Faktenbasis und benötigen weder Netzwerkzugriffe noch das Sprachmodell. Mit Ausnahme von A7 und A8 sind alle ternär. Die beiden Datumsindikatoren messen graduell den Anteil

der vorhandenen Datumswerte mit validem `xsd:date`- oder `xsd:dateTime`-Typ, wobei Angaben auf Datensatz- und Distributionsebene gemeinsam betrachtet werden. Fehlt die jeweilige Angabe vollständig, gilt der Indikator als nicht erfüllt. Tabelle 4.2 fasst die Prüfregeln zusammen.

Kürzel	Prüfregel
A1	Erfüllt bei 3 bis 15 Schlagwörtern, teilweise erfüllt bei 1 bis 2 oder 16 bis 25, nicht erfüllt bei 0 oder mehr als 25
A2	Erfüllt, wenn alle Themenkategorien aus dem EU-Vokabular stammen, teilweise erfüllt, wenn nur ein Teil daraus stammt, nicht erfüllt ohne Themenkategorie
A3	Erfüllt, wenn eine Geometrieangabe vorhanden ist, sonst nicht erfüllt
A4	Erfüllt, wenn die Geokodierungs-URI im DCAT-AP.de-Vokabular liegt, teilweise erfüllt bei einer Angabe außerhalb des Vokabulars oder bei ausschließlicher Nutzung des Rückfallwerts <code>locn:adminUnitL2</code> , nicht erfüllt ohne Angabe
A5	Erfüllt, wenn die Ebenenangabe im Vokabular liegt, teilweise erfüllt bei einer Angabe außerhalb des Vokabulars, nicht erfüllt ohne Angabe
A6	Erfüllt, wenn ein valider Start- oder Endwert der zeitlichen Abdeckung vorliegt, sonst nicht erfüllt
A7	Graduell: Anteil der vorhandenen <code>dct:issued</code> -Werte mit validem Datumstyp, nicht erfüllt ohne Angabe
A8	Graduell: Anteil der vorhandenen <code>dct:modified</code> -Werte mit validem Datumstyp, nicht erfüllt ohne Angabe

Tabelle 4.2: Prüfregeln der Auffindbarkeitsindikatoren

Die Schlagwortspanne von 3 bis 15 ist direkt aus der Handreichung zur Verbesserung der Metadatenqualität des open bydata competence center übernommen, die für einen Datensatz mindestens drei relevante Schlagwörter empfiehlt und je nach Dateninhalt maximal 15 Begriffe als ausreichend ansieht [38]. Werte innerhalb dieser Spanne gelten als erfüllt, ein bis zwei oder 16 bis 25 Schlagwörter als Teilerfüllung und darüber hinausgehende Werte als nicht erfüllt. Die Abstufung bei der politischen Geokodierung folgt der Konventionstreue. Die dedizierte Eigenschaft `dcatde:politicalGeocodingURI` ist gemäß Konvention 08 des DCAT-AP.de-Konventionenhandbuchs der vorgesehene Weg, den verwaltungspolitischen Geobezug als URI aus dem zugehörigen kontrollierten Vokabular auszudrücken [13]. Der Rückfall auf `locn:adminUnitL2` transportiert dieselbe Information in schwächer standardisierter Form und wird daher nur als Teilerfüllung gewertet.

4.4.3 Zugänglichkeitsindikatoren

Alle Zugänglichkeitsindikatoren messen graduell je Distribution und mitteln die Einzelbeiträge zum Datensatzergebnis. Listing 3 zeigt das gemeinsame Bewertungsmuster in vereinfachter Form. Die Indikatoren unterscheiden sich ausschließlich in der Beitrags-

funktion, die einer einzelnen Distribution ihren Wert zuweist. Tabelle 4.3 definiert diese Beitragsfunktionen. Die Erreichbarkeitsprüfungen stützen sich auf die zuvor erhobenen Prüfsignale und werten einen HTTP-Statuscode unter 400 als erreichbar.

```
def score(distributions, contribution) -> float:
    if not distributions:
        return NOT_APPLICABLE
    return mean(contribution(d) for d in distributions)

# Beitragsfunktion Z5 (Erreichbarkeit der Download-URL):
def contribution(dist) -> float:
    if dist.probe.download_status_code < 400:
        return 1.0
    return -0.5 # Malus
```

Listing 3: Gemeinsames Bewertungsmuster der distributionsbezogenen Indikatoren, vereinfacht

Kürzel	Beitrag je Distribution
Z1	1 bei vorhandener Download-URL, sonst 0
Z2	1 bei Formatangabe aus dem EU-Dateitypvokabular, sonst 0
Z3	1 bei Medientyp als IANA-URI aus dem Register, sonst 0
Z4	1 bei nicht-proprietärem Format laut EU-Dateitypvokabular, sonst 0
Z5	1 bei erreichbarer Download-URL, –0,5 bei nicht erreichbarer
Z6	1 bei erreichbarer Access-URL, –0,5 bei nicht erreichbarer
Z7	1 bei Stufe <i>high</i> , 0,5 bei Stufe <i>mid</i> , 0 bei Stufe <i>none</i>

Tabelle 4.3: Beitragsfunktionen der Zugänglichkeitsindikatoren

Die Stufenzuordnung von Z7 orientiert sich an der Klassifikation maschinenlesbarer Dateitypen der Data Quality Guidelines von data.europa.eu [39]. Deren Tabelle unterscheidet drei Grade der Maschinenlesbarkeit, die unmittelbar auf die drei Stufen des Indikators abgebildet werden. Vollständig maschinenlesbare Formate wie CSV, JSON, XML oder RDF sowie deklarierte Datenservice-Endpunkte werden als *high* eingestuft, überwiegend maschinenlesbare Formate wie XLSX, ODS, XLS, HTML oder reine Textdateien als *mid* und nicht maschinenlesbare Auslieferungen wie PDF, Office-Dokumente oder Bildformate als *none*. Da die zugrunde liegende Klassifikation geospezifische Datentypen nicht berücksichtigt, wurde sie um solche Formate ergänzt, etwa Shapefile, die entsprechend ihrer Maschinenlesbarkeit eingeordnet werden. Anders als die Erreichbarkeitsprüfungen Z5 und Z6 wendet Z7 das Malus-Prinzip nicht an, die Stufe *none* geht mit 0 in die Distributionsmittelung ein. Eine nicht maschinenlesbare Distribution täuscht, anders als eine tote URL, keine Verfügbarkeit vor, sondern liefert, was

sie deklariert. Zudem ist es verbreitete Bereitstellungspraxis, neben einem maschinenlesbaren Zugriffsweg ergänzende, nicht maschinenlesbare Distributionen anzubieten, etwa begleitende PDF-Dokumente oder bei Geodaten Kartenansichten und Bildvorschauen. Ein Malus würde solche ergänzenden Angebote den Beitrag der maschinenlesbaren Distribution aktiv aufzehren lassen, obwohl ein maschinenlesbarer Zugriff auf die Daten besteht.

4.4.4 Nachnutzbarkeitsindikatoren

Die Nachnutzbarkeitsindikatoren kombinieren beide Messformen. N1 und N5 messen graduell je Distribution nach dem Muster aus Listing 3, die übrigen Indikatoren prüfen ternär auf Datensatzebene. Tabelle 4.4 fasst die Prüfregeln zusammen.

Kürzel	Prüfregel
N1	Graduell je Distribution: 1 bei freier Lizenz aus der DCAT-AP.de-Lizenzliste, –0,5 bei eingeschränkter, unbekannter oder fehlender Lizenz
N3	Erfüllt, wenn der Herausgeber als <code>foaf:Agent</code> typisiert ist und einen <code>foaf:name</code> trägt, teilweise erfüllt bei nur einem der beiden Merkmale, sonst nicht erfüllt
N4	Erfüllt, wenn der Kontaktpunkt eine valide E-Mail-Adresse oder URL enthält, teilweise erfüllt bei Kontaktpunkt ohne nutzbaren Kanal, nicht erfüllt ohne Kontaktpunkt
N5	Graduell je Distribution: 1 bei Verfügbarkeitsangabe aus dem Planned-Availability-Vokabular, sonst 0
N6	Erfüllt, wenn genau eine <code>dcate:contributorID</code> als IRI aus dem Contributor-Vokabular vorliegt, sonst nicht erfüllt
N7	Erfüllt bei null SHACL-Verletzungen gegen das DCAT-AP.de-Regelwerk, nicht erfüllt bei mindestens einer Verletzung

Tabelle 4.4: Prüfregeln der Nachnutzbarkeitsindikatoren

Der Lizenzindikator N1 wendet als einziger Indikator dieser Dimension das Malus-Prinzip an. Die Gleichbehandlung von eingeschränkten, unbekannten und fehlenden Lizenzen folgt der Nutzendenperspektive, denn in allen drei Fällen ist die Rechtslage ungeklärt und die Nachnutzung damit gleichermaßen blockiert.

Die Konformitätsprüfung N7 validiert den Metadatensatz nicht mit einer lokalen Kopie der SHACL-Shapes, sondern über den öffentlich betriebenen SHACL-Validierungsdienst des Interoperability Test Bed der Europäischen Kommission¹⁰. Dadurch wird stets gegen das offiziell gepflegte DCAT-AP.de-Regelwerk geprüft und die Urteile bleiben deckungsgleich mit dem Referenzvalidator, ohne dass der Prototyp eine eigene Regelwerkskopie aktuell halten muss. Geprüft wird gegen das Profil in der Version 2.0. Diese Version bildet ein vollständig abgeschlossenes Profil, das neben der Spezifikation

¹⁰<https://www.itb.ec.europa.eu/shacl/dcat-ap.de/api/validate>

auch ein zugehöriges Konventionenhandbuch bereitstellt [10, 13] und damit die Grundlage des in Kapitel 3 abgeleiteten Bewertungsmodells bildet. Die im Dezember 2024 veröffentlichte Version 3.0 wird bewusst nicht verwendet, da für sie kein geschlossenes Konventionenhandbuch mehr vorgesehen ist; die Konventionen werden stattdessen in die Spezifikation überführt, in Guidelines umgewandelt oder gestrichen, wobei entsprechende Guidelines bislang nicht vorliegen [11]. Die Bewertung ist binär, da Standardkonformität keine sinnvolle Teilerfüllung kennt. Als einziger Indikator hängt N7 von der Verfügbarkeit eines externen Dienstes ab. Ist der Dienst nicht erreichbar, wird der Indikator als Fehler ausgewiesen.

4.5 LLM-gestützte Bewertung der Aussagekraft

Die Aussagekraft ist die einzige Qualitätsdimension, die sich nicht regelbasiert bestimmen lässt. Kapitel 3 hat begründet, dass ihre Kriterien ein sprachverstehendes Verfahren als Messinstrument erfordern. Der vorliegende Abschnitt beschreibt, wie dieses Instrument im Prototyp umgesetzt ist, und behandelt damit den für Forschungsfrage 3 zentralen Baustein.

4.5.1 Ein-Aufruf-Architektur

Für das Sprachmodell verfolgt der Prototyp eine Ein-Aufruf-Architektur. Statt die sechs Kriterien einzeln abzufragen, wird der gesamte Datensatz in einem einzigen Aufruf bewertet. Das Ergebnis wird an die Faktenbasis angehängt, und jeder Indikator liest daraus seinen Teil. Damit folgt die semantische Anreicherung demselben Muster wie die technische Erreichbarkeitsprüfung, bei der die geteilte Ressource einmal berechnet und von allen Konsumenten gemeinsam genutzt wird. Zum einen werden durch dieses Vorgehen Kosten reduziert, da statt sechs Aufrufen nur einer je Datensatz anfällt. Zum anderen erhöht der gemeinsame Aufruf die Konsistenz der Bewertung. Alle sechs Kriterien gehen aus derselben ganzheitlichen Betrachtung des Datensatzes hervor und beruhen damit auf einem einheitlichen Verständnis der Metadaten. Widersprüche zwischen den Einzelurteilen, wie sie bei sechs voneinander unabhängigen Aufrufen entstehen könnten, werden dadurch unwahrscheinlich. Schlägt der Aufruf fehl oder ist kein Modell konfiguriert, bleibt die Bewertung leer und die Aussagekraftsindikatoren melden *nicht anwendbar*, statt den Bewertungslauf abubrechen.

4.5.2 Strukturierte Ausgabe

Die Ausgabe des Sprachmodells ist kein Freitext, sondern ein schemavalidiertes Objekt. Das Schema wird mit Pydantic definiert und dem Modell als verbindliche Ausgabestruktur vorgegeben, sodass die Antwort nicht nachträglich geparkt werden muss, sondern typgeprüft vorliegt. Jedes der sechs Kriterien entspricht einem Feld des Schemas und ist damit eins zu eins einem Aussagekraftsindikator (S1 bis S6) zugeordnet. Ein einzelnes Kriterium besteht aus vier Feldern in fester Reihenfolge: zunächst ein bis drei beobachtbare `findings`, daraus abgeleitet eine kurze `reasoning`-Begründung, anschließend ein `applicable`-Flag und erst zuletzt ein kontinuierlicher `score` zwischen 0 und 1. Diese Reihenfolge erzwingt, dass das Modell zuerst die beobachtbare Evidenz benennt und sein Urteil daraus herleitet, bevor es einen Zahlenwert festlegt. Listing 4 zeigt das Schema in vereinfachter Form.

```

class ExpressivenessCriterion(BaseModel):
    findings: list[str] = Field(
        default_factory=list,
        max_length=3,
        description=(
            "Zuerst ausfüllen: 1-3 konkrete, beobachtbare Stärken/Schwächen für "
            "dieses Kriterium."
        ),
    )
    reasoning: str = Field(...)
    applicable: bool = Field(...)
    score: float = Field(...)

    @property
    def status(self) -> str:      # Label, aus score abgeleitet
        if not self.applicable:
            return "not_applicable"
        if self.score >= 0.8:
            return "pass"
        if self.score >= 0.5:
            return "partial"
        return "fail"

class ExpressivenessAssessment(BaseModel):
    title_quality: ExpressivenessCriterion
    description_quality: ExpressivenessCriterion
    title_description_coherence: ExpressivenessCriterion
    keyword_quality: ExpressivenessCriterion
    thematic_consistency: ExpressivenessCriterion
    contextual_qualifiers: ExpressivenessCriterion

```

Listing 4: Pydantic-Schema der Aussagekraftsbewertung, vereinfacht

Zwei Eigenschaften des Schemas sind für die Nachvollziehbarkeit entscheidend. Erstens wird die diskrete Ergebnisstufe nicht vom Modell erfragt, sondern deterministisch aus dem `score` abgeleitet. Das Modell liefert ausschließlich den kontinuierlichen Wert samt Begründung, sodass Stufe und Wert einander nicht widersprechen können. Zweitens setzt das `applicable`-Flag die im Messmodell vorgesehene Nicht-Anwendbarkeit um: Ein Kriterium, das der Datentyp nicht erfordert, etwa ein kontextueller Qualifizierer bei einem statischen Datensatz, wird neutral übersprungen statt abgewertet. Jeder Aussagekraftswert ist damit auf benennbare Befunde und eine Begründung zurückführbar.

4.5.3 Eingabe und Prompt

Der Aufruf trennt Systemanweisung und Nutzereingabe. Die Systemanweisung legt die Rolle des Modells als Auditor ausschließlich für die Aussagekraft fest und grenzt technische Zugänglichkeit, Lizenzierung und Auffindbarkeit ausdrücklich aus. Sie enthält die schrittweise Vorgehensweise je Kriterium, die aus dem DCAT-AP.de-Konventionenhandbuch v2.0 (Kapitel 1.7 und 3.4) sowie der Handreichung zur Verbesserung der Metadatenqualität abgeleiteten Bewertungsregeln [13, 38] und eine Ankerskala, die Wertebereiche verbal an Qualitätsniveaus bindet. Die Nutzereingabe enthält die zu bewertenden Metadaten. Übergeben wird dabei nicht der vollständige RDF-Graph, sondern die bereits in Abschnitt 4.3 aufgebaute, auf die bewertungsrelevanten Freitext- und Klassifikationsfelder reduzierte Sicht der Faktenbasis. Das begrenzt den Tokenverbrauch und fokussiert das Modell auf den Bewertungsgegenstand. Listing 5 zeigt den Aufbau des Aufrufs.

```
def assess(context, llm) -> ExpressivenessAssessment:
    payload = context.to_agent_json()    # gekuerzte Faktenbasis
    messages = [
        ("system", SYSTEM_PROMPT),      # Rolle, Rubrik, Ankerskala
        ("human", USER_PROMPT.format(context=payload)),
    ]
    # Schema als verbindliche Ausgabestruktur erzwingen
    structured = llm.with_structured_output(ExpressivenessAssessment)
    return structured.invoke(messages)
```

Listing 5: Aufbau des Sprachmodellaufrufs mit gekürztem Kontext und erzwungenem Schema, vereinfacht

Zwei Vorkehrungen erhöhen die Robustheit der Bewertung. Zum einen wird das Modell angewiesen, die reine Feldpräsenz nicht als Qualität zu werten, sondern generische, kryptische oder widersprüchliche Angaben trotz Vorhandensein abzuwerten. Zum anderen wird der Metadateninhalt durch Trennmarken abgegrenzt und ausdrücklich als reiner Bewertungsgegenstand deklariert, den das Modell niemals als Anweisung behandeln darf. Damit wird verhindert, dass in Metadatenfeldern eingebetteter Text die Bewertung manipuliert. Der vollständige Wortlaut von System- und Nutzeranweisung sowie die Pydantic-Schemata sind im Anhang H dokumentiert.

4.5.4 Determinismus und Konfiguration

Der Aufruf erfolgt mit einer Temperatur von 0. Für ein Bewertungsinstrument ist Reproduzierbarkeit wichtiger als sprachliche Variation, und eine Temperatur von 0 maximiert die Bestimmtheit der Ausgabe, sodass identische Eingaben möglichst identische Bewertungen ergeben. Das stützt unmittelbar das Nachvollziehbarkeitsziel des Prototyps und die Anforderung einer reproduzierbaren Evaluation. Die Ausgabelänge ist auf 10.000 Tokens begrenzt. Diese Grenze lässt der strukturierten Antwort ausreichend Raum, sodass sie nicht abgeschnitten wird, und deckelt zugleich die Kosten eines einzelnen Aufrufs. Als Modell wird Claude Sonnet 4.5 verwendet, angebunden über den Dienst OpenRouter.

4.6 Scoring-, Gewichtungs- und Aggregationslogik

Wie in Sektion 2.5.1 erläutert, ist Datenqualität kein eindimensionales Konstrukt, sondern setzt sich aus mehreren, getrennt zu messenden Dimensionen zusammen [21]. Das Bewertungsmodell folgt dieser Auffassung mit einer zweistufigen Aggregation. Die Indikatorergebnisse werden zunächst je Dimension zu einem Dimensionswert verdichtet, und die Dimensionswerte anschließend zu einem Gesamtscore. Beide Stufen sind gewichtete Mittelwerte, deren Gewichte konfigurierbar sind und nicht im Quellcode festgelegt werden. Die folgenden Angaben beschreiben die in der Evaluation verwendete Konfiguration.

4.6.1 Punktevergabe je Indikator

Ternäre Indikatoren werden über ihre Ergebnisstufe in einen Punktwert überführt. Ein erfülltes Kriterium erhält den Wert 1,0, ein teilweise erfülltes 0,5 und ein nicht erfülltes 0,0. Der Wert 0,5 für die Teilerfüllung entspricht dem Mittelpunkt der Skala und behandelt die Zwischenstufe damit als genau halb erfülltes Kriterium, ohne eine Richtung zu bevorzugen. Graduelle Indikatoren tragen unmittelbar ihren kontinuierlichen Erfüllungsgrad bei. Ihre Ergebnisstufe hat, wie in Abschnitt 4.4 beschrieben, keinen Einfluss auf die Punktevergabe. Innerhalb der graduellen Indikatoren wirkt der Malus: Eine nicht erreichbare URL und eine eingeschränkte, unbekannte oder fehlende Lizenz gehen mit $-0,5$ statt mit 0 in die Distributionsmittelung ein. Als *nicht anwendbar* oder als Fehler ausgewiesene Indikatoren werden neutral behandelt und gehen weder in den Zähler noch in den Nenner der Aggregation ein.

Die konkreten Punktwerte sind normative Setzungen. Ein empirisch optimaler Wert existiert für solche Größen nicht, und auch etablierte Bewertungsmodelle legen ihre Punktwerte per Konvention fest, wie die Punkteverteilung der MQA zeigt (vgl. Tabelle 2.5) [27]. Die Literatur zu zusammengesetzten Indikatoren behandelt die Gewichts- und Punktwahl entsprechend als transparent zu dokumentierende Entwurfsentscheidung, die sich auf Experten- und Konstrukteursurteile stützt [40]. Kubler et al. zeigen mit ihrem AHP-basierten Ansatz zudem, dass Qualitätsgewichte grundsätzlich präferenzabhängig sind und je nach Stakeholderperspektive unterschiedlich ausfallen [26]. Maßgeblich für das Modell sind daher weniger die Absolutwerte als die durch sie ausgedrückten Relationen: Teilerfüllung zählt halb, und ein irreführender Defekt wiegt schwerer als eine fehlende Angabe. Für die Malus-Höhe von $-0,5$ bedeutet das konkret, dass zwei defekte Distributionen den Beitrag einer funktionierenden vollständig aufheben.

4.6.2 Aggregation zum Gesamtscore

Der Wert einer Dimension d ergibt sich als gewichteter Mittelwert über die Menge A_d ihrer aktiven und anwendbaren Indikatoren, wobei p_i den Punktwert und w_i das Gewicht eines Indikators bezeichnet. Da der Malus einzelne Beiträge negativ werden lässt, wird der Dimensionswert bei 0 nach unten begrenzt:

$$s_d = \max \left(0, \frac{\sum_{i \in A_d} w_i \cdot p_i}{\sum_{i \in A_d} w_i} \right) \quad (4.1)$$

Der Gesamtscore S ist der mit den Dimensionsgewichten W_d gewichtete Mittelwert der Dimensionswerte:

$$S = \frac{\sum_d W_d \cdot s_d}{\sum_d W_d} \quad (4.2)$$

Aus dem Gesamtscore wird abschließend eine Gesamtnote abgeleitet, die das Ergebnis für das Reporting verdichtet. Ab 0,9 wird die Note A vergeben, ab 0,75 die Note B, ab 0,6 die Note C, ab 0,4 die Note D und darunter die Note F. Die Notenstufen sind wie bei den graduellen Indikatoren rein konventionell gewählt und dienen der intuitiven Ergebnisinterpretation. Sie haben keinen Einfluss auf die Berechnung des Gesamtscores.

4.6.3 Gewichtung der Indikatoren und Dimensionen

Tabelle 4.5 zeigt die Gewichte der evaluierten Konfiguration auf beiden Ebenen. Auf Indikatorebene bleibt das Modell bewusst nah am Standardgewicht 1,0 und hebt ausschließlich vier Indikatoren an: die drei datenbrechenden Prüfungen Z5, Z6 und N1 auf das Gewicht 2,0 sowie den maschinenlesbaren Zugriffsweg Z7 auf das Gewicht 1,5.

Dimension / Indikator		Gewicht
Zugänglichkeit		2,0
Z5	Download-URL technisch erreichbar	2,0
Z6	Access-URL technisch erreichbar	2,0
Z7	Maschinenlesbarer Zugriffsweg	1,5
Aussagekraft		2,0
Nachnutzbarkeit		1,5
N1	Freie Lizenz aus DCAT-AP.de-Lizenzliste	2,0
Auffindbarkeit		1,0
<i>Alle übrigen Indikatoren</i>		<i>1,0</i>

Tabelle 4.5: Dimensions- und Indikatorgewichte der evaluierten Konfiguration

Die drei auf das Gewicht 2,0 angehobenen Indikatoren teilen eine Eigenschaft: Ein Defekt an ihnen macht den Datensatz faktisch unbrauchbar, unabhängig davon, wie gut die übrigen Metadaten sind. Eine nicht erreichbare Zugriffs-URL bedeutet, dass keine Daten vorliegen. Eine fehlende oder eingeschränkte Lizenz blockiert die Nachnutzung rechtlich. Damit prüfen genau diese Indikatoren definierende Merkmale offener Daten, die in Kapitel 2 eingeführt wurden: Bereitstellung ohne Zugangsbeschränkungen unter Bedingungen, die die Wiederverwendung erlauben [4, 5]. Die Experteninterviews benennen dieselben Defekte als zentrale Praxisprobleme (INT-K5). Es sind zugleich die Indikatoren, die den Malus tragen. Die Anhebung des Gewichts verstärkt diese Koppelung gezielt: Ein Datensatz, der an einem datenbrechenden Kriterium scheitert, soll sich im Ergebnis deutlich von einem Datensatz unterscheiden, der lediglich optionale Angaben schuldig bleibt. Der maschinenlesbare Zugriffsweg Z7 wird mit dem Gewicht 1,5 bewusst zwischen den datenbrechenden Indikatoren und dem Standardgewicht eingeordnet. Maschinenlesbarkeit zählt ebenfalls zu den definierenden Merkmalen offener Daten, und ein Datensatz ganz ohne maschinenlesbaren Zugriffsweg entzieht sich der automatisierten Verarbeitung. Anders als eine tote URL oder eine ungeklärte Lizenz

wirkt eine einzelne nicht maschinenlesbare Distribution jedoch nicht zwingend datenbrechend, da sie in der Bereitstellungspraxis häufig als ergänzendes Angebot neben einem maschinenlesbaren Zugriffsweg steht. Diese Priorisierung deckt sich mit der MQA, in der die Erreichbarkeit der Access-URL mit 50 Punkten das höchste Einzelgewicht aller Metriken trägt und die Lizenzangaben den am stärksten gewichteten Block der Wiederverwendbarkeit bilden, während die Maschinenlesbarkeit dort mit 20 Punkten im Mittelfeld liegt und damit dieselbe Zwischenstellung einnimmt (vgl. Tabelle 2.5) [27]. Die Dimensionsgewichte folgen derselben Logik auf der übergeordneten Ebene: Die Dimensionen tragen nicht gleich viel zur Nutzbarkeit eines Datensatzes bei. Zugänglichkeit und Aussagekraft erhalten das höchste Gewicht, weil ein Versagen in diesen Dimensionen den Datensatz vollständig entwertet. Sind die Daten nicht erreichbar, existiert faktisch kein nutzbares Angebot. Sind Titel, Beschreibung und Schlagwörter nichtsagend, bleibt der Datensatz für Nutzende unverständlich, auch wenn die Metadaten vollständig sind, worauf auch die Handreichung zur Verbesserung der Metadatenqualität ihren Schwerpunkt legt [38]. Die Nachnutzbarkeit wird über der Auffindbarkeit gewichtet, da selbst vollständig vorhandene und erreichbare Daten ohne geklärte rechtliche und organisatorische Rahmenbedingungen ihren Nutzen verlieren. Die Auffindbarkeit erhält das Standardgewicht, da ihre Indikatoren überwiegend Präsenz- und Strukturprüfungen einzelner Suchmerkmale sind. Ihr Beitrag zur Nutzbarkeit hängt zudem stärker als bei den übrigen Dimensionen von deren Erfüllung ab, insbesondere von den datenbrechenden Indikatoren der anderen Dimensionen: Ein auffindbarer Datensatz bleibt nutzlos, wenn die Lizenz fehlt, auf die Daten nicht zugegriffen werden kann oder die Freitextfelder trotz formaler Vollständigkeit widersprüchliche oder zusammenhanglose Inhalte aufweisen. Das Modell weicht damit bewusst von der MQA ab, die die Auffindbarkeit zu den am höchsten gewichteten Dimensionen zählt, dies allerdings auf Basis reiner Präsenzmetriken (vgl. Tabelle 2.5).

4.7 Maschinenlesbare Ergebnisreports

Der Prototyp erzeugt für jede bewertete Metadaten-datei einen vollständigen maschinenlesbaren Report, der jedes Einzelergebnis mit Begründung und allen verwendeten Parametern dokumentiert. Dieser Report ist zugleich die einzige Datengrundlage der menschenlesbaren Aufbereitung, die Section 4.8 beschreibt. Jeder Bewertungslauf legt ein eigenes Ausgabeverzeichnis an. Innerhalb dieses Verzeichnisses erhält jede bewertete Datei ein Unterverzeichnis mit drei Artefakten: dem Ergebnisreport als `json` Objekt sowie zwei Protokolldateien. Listing 6 zeigt den Ergebnisreport in gekürzter Form.

```

{
  "by_dimension": {
    "accessibility": {
      "dimension": "accessibility",
      "score": 0.684,
      "dimension_weight": 2.0,
      "total_indicator_weight": 9.5,
      "indicator_count": 7, "pass_count": 4, "pass_rate": 0.571,
      "indicators": [
        {
          "indicator_id": "acc_format",
          "name_de": "Format aus kontrolliertem Vokabular (je Distribution)",
          "dimension": "accessibility",
          "status": "fail",
          "score": 0.0,
          "message_de": "0/1 Distribution(en) mit Format aus dem Vokabular",
          "message_en": "0/1 distribution(s) with a format from the vocabulary",
          "details": {
            "total_distributions": 1,
            "passing_count": 0,
            "per_distribution": [{"uri": ".../distributions/a675922c-...",
                                "formats": [], "passes": false}]
          },
          "error": null,
          "timestamp": "2026-07-16T11:27:02.637627",
          "finding": {
            "headline": "Keine der 1 Distribution hat ein Format aus dem
                        EU-Vokabular.",
            "current": [{"label": "Distribution 1",
                          "value": "kein Format angegeben", "tone": "bad",
                          "where": ".../distributions/a675922c-..."}],
            "target": "Setzen Sie je Distribution eine Format-URI, z. B.
                      http://publications.europa.eu/.../file-type/CSV.",
            "notes": []
          },
          "default_weight": 1.0,
          "effective_weight": 1.0,
          "raw_status": "fail",
          "raw_score": 0.0,
          "effective_score": 0.0
        },
        ... // weitere Indikatoren der Dimension
      ]
    },
    "findability": {...}, // weitere Dimensionen
  },
  "summary": {
    "overall_score": 0.650,
    "quality_grade": "C",
    "dimension_scores": {"accessibility": 0.684, "findability": 0.5, ...},
    "effective_dimension_weights": {"accessibility": 2.0, ...},
    "total_indicators": 27, "total_pass": 13, "total_fail": 14
  },
  "weights": {
    "dimension_weights": {"accessibility": 2.0, "findability": 1.0, ...},
    "indicator_weights": {"acc_format": 1.0, "reuse_license": 2.0, ...}
  },
  "errors": [],
  "llm_usage": [{"model": "openai/gpt-5.5", "total_tokens": 4445,
                  "cost_usd": 0.0334, "latency_seconds": 18.9}]
}

```

Listing 6: Ergebnisreport `result.json` einer einzelnen Metadaten-datei; vollständig gezeigt ist ein Indikator, die übrigen 26 sind ausgelassen

Der Block `by_dimension` gruppiert die Einzelergebnisse nach Qualitätsdimension und weist je Dimension den Dimensionswert, das Dimensionsgewicht, die Summe der Indikatorgewichte sowie die Zahl der geprüften und der bestandenen Indikatoren aus. Jeder Indikatoreintrag enthält neben Ergebnisstufe und Punktwert die Bezeichnung und eine Ergebnismeldung sowie im Feld `details` die indikatorspezifische Evidenz. Dazu zählen Zählwerte, Ergebnisse je Distribution und bei den semantischen Indikatoren die Befunde und die Begründung des Sprachmodells. Nicht oder nur teilweise erfüllte Indikatoren sowie Fehlerfälle tragen darüber hinaus das Feld `finding`, das der Bewertungskern aus dieser Evidenz ableitet; bei erfüllten Indikatoren bleibt es leer, weil dort nichts zu erklären ist.

Das Feld enthält den in Section 4.8.4 beschriebenen Befund in genau der Form, in der ihn die Oberfläche darstellt: `headline` als Kernaussage in einem Satz, `current` als Liste der vorgefundenen Angaben mit Bezeichnung, Wert, einer Bewertung des Werts (`tone`) und optionaler Fundstelle (`where`), `target` als Handlungsanweisung und `notes` für Einzelbefunde bei mehreren gleichartigen Verstößen. Diese Struktur ist über alle Indikatoren hinweg identisch, während `details` darunter indikatorspezifisch bleibt. Der Befund entsteht im Bewertungskern und nicht in der Oberfläche, sodass der Report auch die Erklärung eines Ergebnisses vollständig mitführt. Die Felder `raw_status` und `raw_score` halten das unveränderte Urteil des Indikators fest, während `status` und `score` das Ergebnis nach Anwendung der konfigurierten Punktevergabe wiedergeben. Analog dokumentiert das Paar aus `default_weight` und `effective_weight`, ob die Konfiguration das Standardgewicht des Indikators überschreibt. Der Einfluss der Konfiguration auf jedes Einzelergebnis bleibt damit im Report sichtbar.

Der Block `summary` verdichtet das Ergebnis zu Gesamtscore, Note und Dimensionswerten, der Block `weights` gibt die vollständige Gewichtskonfiguration beider Ebenen wieder. Der Report ist dadurch in sich abgeschlossen: Sämtliche Größen, die in die Gleichungen 4.1 und 4.2 eingehen, sind enthalten, sodass sich der Gesamtscore ohne Zugriff auf den Prototyp oder dessen Konfigurationsdateien nachträglich vollständig herleiten lässt. Ergänzend legt der Lauf auf oberster Ebene eine Metadatendatei ab, die die vollständig aufgelöste Konfiguration und den Commit-Hash des verwendeten Quellcodestands festhält. Der Block `llm_usage` dokumentiert je Sprachmodellaufruf das verwendete Modell, die verbrauchten Tokens, die entstandenen Kosten und die Antwortzeit und macht damit den nichtdeterministischen und kostenpflichtigen Teil der Bewertung transparent.

Der Report wird zusätzlich durch zwei weitere Protokolldateien ergänzt. Eine `logs` Datei zeichnet alle Verarbeitungsschritte der jeweiligen Datei auf, vom RDF-Parsing über die Erreichbarkeitsprüfungen mit ihren Einzelsignalen bis zur Entscheidung jedes Indikators. Zusätzlich wird eine `llm` spezifische Datei generiert, die die vollständige

Anfrage an das Sprachmodell einschließlich System-Prompt, übergebener Faktenbasis und Rohantwort enthält. Ein Bewertungslauf lässt sich damit auch nachträglich Schritt für Schritt nachvollziehen und bei Bedarf reproduzieren.

Auf Laufebene entstehen zusätzlich aggregierte Dateien, darunter eine Zusammenfassung aller Einzelergebnisse und eine Kostenübersicht der Sprachmodellaufrufe.

4.8 Menschenlesbares Qualitätsreporting

Der folgende Abschnitt beschreibt, wie der maschinenlesbare Report aus Section 4.7 in eine menschenlesbare Darstellung überführt wird, die ihre jeweiligen Adressaten handlungsfähig macht. Die Gestaltung folgt den in Section 4.8.1 beschriebenen Zielgruppen und Gestaltungszielen und beantwortet damit die fünfte Forschungsfrage.

4.8.1 Zielgruppen und Gestaltungsziele

Ein Qualitätsurteil hat mehr als einen Adressaten, und die Adressaten benötigen es in unterschiedlicher Auflösung. Tabelle 4.6 stellt die drei Gruppen gegenüber, an denen sich die Darstellung ausrichtet.

Zielgruppe	Leitfrage	Benötigte Auflösung
Datennutzende	Kann ich diesem Datensatz trauen und ihn ohne Rückfragen weiterverwenden?	Gesamtscore, ergänzend die vier Dimensionswerte
Datenbereitstellende	Was muss ich an meinem Metadatensatz konkret ändern?	Einzelergebnis je Indikator mit Befund, Fundstelle und Handlungsanweisung
Portalbetreibende	Wo liegen die systematischen Lücken im Bestand und wie entwickeln sie sich?	Aggregation über den Bestand: Mängelhäufigkeit je Indikator, Verlauf über die Zeit

Tabelle 4.6: Zielgruppen des Qualitätsreportings und ihr jeweiliger Auflösungsbedarf

Für Datennutzende ist die Bewertung ein Auswahlkriterium und kein Arbeitsauftrag. Sie treffen anhand des Ergebnisses eine Entscheidung darüber, ob ein Datensatz für ihr Vorhaben in Betracht kommt, und benötigen dafür einen verdichteten Wert. Die Dimensionswerte sind für sie insofern von Interesse, als sie unterschiedliche Nutzungshürden trennen. Ein Datensatz mit guter Auffindbarkeit, aber schwacher Zugänglichkeit ist für die automatisierte Weiterverarbeitung anders zu bewerten als umgekehrt. Eine Aufschlüsselung bis zum einzelnen Indikator ist für diese Gruppe ohne Nutzen, weil sie an den Metadaten nichts ändern kann.

Portalbetreibende am anderen Ende interessiert weniger der einzelne Datensatz als das Muster über den Bestand. Ein Indikator, den nahezu alle Datensätze verfehlen, verweist auf eine Lücke im Erfassungsprozess oder im Harvestingprozess und damit

auf eine Maßnahme, die viele Datensätze zugleich verbessert. Ebenso ist für diese Gruppe die Entwicklung über die Zeit aussagekräftiger als ein Einzelwert, weil sich erst daran ablesen lässt, ob eine getroffene Maßnahme gewirkt hat.

Der anspruchsvollste Fall sind die Datenbereitstellenden, weil sie als Einzige aus dem Ergebnis eine konkrete Handlung ableiten müssen. Die Gestaltung richtet sich deshalb an ihnen aus. Die beiden übrigen Sichten entstehen durch Verdichtung der gleichen Daten. Aus dieser Ausrichtung folgen drei Gestaltungsziele.

- **Vorrang des Befunds vor der Punktzahl:** Ein Zahlenwert ordnet ein, benennt aber nichts, weshalb zu jedem nicht erfüllten Indikator der zugrunde liegende Sachverhalt gezeigt wird.
- **Vorrang der Fundstelle vor dem Feldnamen:** Die Angabe, dass ein Feld fehlt, hilft nur, wenn erkennbar bleibt, an welcher Stelle des konkreten Metadatensatzes das gilt, gerade entscheidend bei mehreren Distributionen.
- **Vorrang der Handlungsanweisung vor der Fehlermeldung:** Aus jedem Befund muss hervorgehen, welche Änderung ihn auflösen würde.

Alle drei sind Ausprägungen desselben Prinzips, das bereits den maschinenlesbaren Report leitet: Nachvollziehbarkeit. Ein Qualitätsurteil, das sein Zustandekommen nicht offenlegt, ist nicht überprüfbar und damit nicht handlungsleitend.

4.8.2 Einbettung in eine Portalumgebung

Ein Qualitätsbefund entfaltet seine Wirkung dort, wo die Metadaten ohnehin gepflegt und betrachtet werden. Ein Analysewerkzeug, in das Metadaten gesondert hochgeladen werden, benötigt dagegen einen zusätzlichen Arbeitsschritt an einem zusätzlichen Ort. Die Bewertung wird deshalb als zusätzliche Ebene innerhalb der gewohnten Portalansichten dargestellt: In der Trefferliste erscheint je Datensatz ein kompakter Qualitätsindikator, die Detailansicht erhält einen Bewertungsabschnitt unterhalb der beschreibenden Metadaten. Die Aggregation über den Bestand liegt als eigener Menüpunkt daneben.

Um dies zeigen zu können, ohne Zugriff auf ein produktiv betriebenes Portal zu haben, bildet der Prototyp die Oberfläche des GovData-Portals nach [2] und übernimmt dessen Gestaltungssystem und Seitenaufbau. Diese Nachbildung ist ausdrücklich Mittel zum Zweck und nicht Gegenstand der Arbeit: Sie dient dem Nachweis, dass sich die Bewertungsergebnisse in eine bestehende Portalumgebung einfügen lassen, und wird selbst nicht bewertet. Die Anwendung umfasst demnach nur die für die Qualitätsdarstellung erforderlichen Ansichten, bildet die Redaktionsprozesse des Portals

nicht nach und schreibt nicht in die Metadaten zurück. Bewertungsergebnisse liegen als eigene Ebene neben dem Datenbestand und sind mit ihm allein über die Identität des Datensatzes verknüpft. Ein produktiv betriebenes Portal müsste sein Datenmodell also nicht um Bewertungsfelder erweitern. Dass die Oberfläche zwischen mehreren vorliegenden Bewertungsläufen umschalten lässt, ist dabei ein weiteres Demonstrationmittel. Im Regelbetrieb läge über einem Bestand genau eine Bewertung, die nach jedem Harvesting erneuert wird. Der Prototyp belegt damit die Einbettbarkeit, ersetzt aber keine Untersuchung der tatsächlichen Wirkung in der Praxis.




Abbildung 4.2: Suchseite mit Qualitätsfacette links und Qualitätsring je Treffer

Abbildung 4.2 zeigt die Suchseite dieser Nachbildung: Der Qualitätsring steht je Treffer rechts neben den beschreibenden Angaben, und die Qualitätsstufe tritt links als zusätzliche Facette neben die bestehenden Filter des Portals.

4.8.3 Anbindung an den Bewertungskern

Die Oberfläche greift nicht auf den Bewertungskern zu, sondern spricht mit ihm über eine dazwischenliegende Dienstschicht. Diese ist in Python umgesetzt und bindet den in Section 4.2 beschriebenen Bewertungsdienst als Bibliothek ein. Sie enthält selbst keine Bewertungslogik, sondern übersetzt zwischen Konfiguration, Ergebnisreport und Anzeigeform. Nach außen stellt sie eine HTTP-Schnittstelle bereit, über die sämtlicher Austausch in JSON erfolgt. Die Oberfläche ist eine im Browser laufende Anwendung in TypeScript und hält keinen eigenen Zustand über die dargestellten Ergebnisse hinaus.

Die Schnittstelle gliedert sich in vier Gruppen von Endpunkten: für die Datenbestände, für abgeschlossene Bewertungsläufe, zum Anstoßen neuer Läufe sowie für die Bewertungskonfiguration und den Klartext je Indikator. Auch Bezeichnung, betroffenes Feld, Handlungsanweisung und Vorlage stammen damit aus dem Bewertungskern und werden nicht in der Oberfläche gepflegt. Ein Lauf dauert wegen der Netzabfragen und des Sprachmodellaufrufs je Datei zu lange, um eine HTTP-Anfrage so lange offen zu halten. Die Anfrage legt deshalb nur einen Auftrag an und liefert dessen Kennung zurück, die Verarbeitung läuft im Hintergrund, und die Oberfläche fragt den Fortschritt zyklisch ab.

4.8.4 Vom Prüfergebnis zum Befund

Die Evidenz, die ein Indikator im Feld `details` des Reports hinterlegt, ist notwendigerweise indikatorspezifisch: Ein Erreichbarkeitsindikator hält Antwortstatus je Distribution fest, ein Konformitätsindikator die verletzten Regeln der Schemaprüfung, ein sprachmodellgestützter Indikator die Einzelbefunde und deren Begründung. Für die Darstellung ist diese Vielfalt hinderlich. Eine Oberfläche, die 27 unterschiedlich aufgebaute Evidenzstrukturen jeweils eigens darstellt, ist weder wartbar noch für den Leser erlernbar. Der Prototyp überträgt deshalb jedes negative Prüfergebnis in eine einheitliche Form, den *Befund*. Er besteht aus einer Kernaussage, die das Problem benennt, aus Ist-Angaben, die den vorgefundenen Zustand belegen und jeweils eine Fundstelle tragen können, aus einem Hinweis, der den geforderderten Zustand beschreibt, sowie aus Einzelbefunden für den Fall mehrerer gleichartiger Verstöße. Diese Form ist über alle Indikatoren hinweg identisch. Der Leser lernt sie einmal und kann sie danach auf jeden Indikator anwenden, unabhängig davon, ob dessen Urteil aus einer Feldprüfung, einer Netzabfrage oder einer Sprachmodellbewertung stammt. Als Fundstelle dient je nach Indikator die betroffene Distribution, der verletzte Pfad der Schemaprüfung oder das Feld. Der Hinweis ist bewusst als Handlungsanweisung und nicht als Zustandsbeschreibung formuliert. Er benennt, was zu tun ist, statt zu wiederholen, wie das Ergebnis aussähe, wenn es richtig wäre. Die Auflistung der nicht bestandenen Prüfungen mit Fundstelle und, wo möglich, Quelltextbeleg orientiert sich damit an der Form, die die Konformitätsprüfdienste des W3C für Markup und Stylesheets etabliert haben [41, 42]: Deren Meldungen bestehen ebenfalls aus einem Schweregrad, einer natürlichsprachlichen Kernaussage, der Position in der Quelle und einem Auszug des Quelltexts um diese Position. Der Befund überträgt dieses Muster von der Syntaxprüfung eines Dokuments auf die Qualitätsprüfung eines Metadatensatzes. Abbildung 4.3 zeigt einen aufgeklappten Befund am Beispiel des Indikators zum Dateiformat: links die vorgefundenen Werte mit der jeweils betroffenen Distribution als Fundstelle,

rechts der Hinweis mit dem Verweis auf das maßgebliche Vokabular.

Format aus EU-Vokabular

dct:format

0/2 Distribution(en) mit Format aus dem Vokabular

Hinweise ausblenden

× nicht erfüllt

0.00

1.00

SO STEHT ES IM METADATENSATZ

Distribution 1

https://example.org/vokabular/dateiformat/PDF-DOKUMENT

https://example.org/testfall/falsche-werte/verteilung-1

Distribution 2

https://example.org/vokabular/dateiformat/EXCEL-TABELLE

https://example.org/testfall/falsche-werte/verteilung-2

HINWEISE

Setzen Sie je Distribution eine Format-URI, z. B. http://publications.europa.eu/resource/authority/file-type/CSV.

Zugelassene Werte: **EU-Dateiformate**

SO SOLLTE ES AUSSEHEN

```
<dc:Distribution rdf:about="...">
  <dct:format rdf:resource="http://publications.europa.eu/resource/authority/file-type/CSV"/>
</dc:Distribution>
```

Abbildung 4.3: Aufgeklappter Befund zu einem nicht erfüllten Indikator

Der Befund entsteht im Bewertungskern und nicht in der Oberfläche. Die Übersetzung von Evidenz in eine Aussage über den Metadatensatz setzt Kenntnis des jeweiligen Indikators voraus und ist damit eine fachliche, keine gestalterische Entscheidung. Läge sie in der Oberfläche, entstünde eine zweite Interpretationsschicht neben dem Bewertungsmodell, Änderungen an einem Indikator müssten an zwei Stellen nachgezogen werden, und der maschinenlesbare Report wäre nicht mehr die einzige Quelle der Darstellung. Erzeugt wird ein Befund nur für nicht oder teilweise erfüllte Indikatoren sowie für Fehlerfälle – bei einem erfüllten Indikator gibt es nichts zu erklären.

4.8.5 Von der Meldung zur Handlungsanweisung

Der Befund benennt das Problem und den Weg zu seiner Auflösung, beides jedoch in Prosa. Was er nicht leistet, ist die Übersetzung dieser Anweisung in die Schreibweise, die der Metadatensatz verlangt: Ein Datenbereitsteller ohne DCAT-Kenntnisse weiß nach dem Hinweis, dass eine Kategorie aus dem EU-Vokabular zu setzen ist, aber nicht, wie das im RDF/XML seines Datensatzes auszusehen hat. Die zweite Aufbereitungsstufe schließt diese Lücke.

Der Prototyp zeigt dafür eine **Vorlage**: ein kurzes RDF/XML-Fragment, dass das betroffene Feld in korrekter Schreibweise mit einem Beispielwert enthält. Damit entfällt die Hürde, erst nachschlagen zu müssen, wie die geforderte Angabe zu notieren ist – welches Feld, welche Verschachtelung, welche Schreibweise steht unmittelbar vor dem Adressaten. Geht es um ein Feld mit kontrolliertem Vokabular, stehen im Hinweis daneben zusätzlich die Bezeichnung des Vokabulars und der Verweis auf dessen

Übersichtsseite, sodass sich der inhaltlich passende Wert dort auswählen lässt. Abbildung 4.4 (a) zeigt eine solche Vorlage für die Geometrieangabe eines Datensatzes. Entscheidend für den Nutzen der Vorlage ist, dass sie unabhängig vom vorgefundenen Zustand ist. Sie sieht identisch aus, ob das Feld falsch belegt ist oder ganz fehlt. Gerade der zweite Fall ist der, in dem sie gebraucht wird, denn dort gibt es im Metadatensatz nichts, worauf sich zeigen ließe.

SO STEHT ES IM METADATENSATZ locn:geometry nicht gesetzt	HINWEISE Hinterlegen Sie eine Bounding Box oder ein Polygon als WKT oder GeoJSON, z. B. POLYGON ((9.25 52.16, ...)).
SO SOLLTE ES AUSSEHEN <pre>< dct:spatial> < dct:Location> < locn:geometry rdf:datatype="http://www.opengis.net/ont/geosparql#wktLiteral" >POLYGON ((9.25 52.16, 9.95 52.16, 9.95 52.52, 9.25 52.52, 9.25 52.16))</locn:geometry> </dct:Location> </dct:spatial></pre>	

(a) Vorlage („So sollte es aussehen“) für ein Feld mit vorgegebener Schreibweise

SO STEHT ES IM METADATENSATZ HTTP keine Antwort https://nicht-aufloesbar.invalid/daten/bericht https://example.org/testfall/falsche-werte/verteilung-1 HTTP keine Antwort https://nicht-aufloesbar.invalid/daten/tabelle https://example.org/testfall/falsche-werte/verteilung-2	HINWEISE Alle Links müssen mit einem Statuscode im Bereich 200–299 antworten.
BETROFFENE STELLE IN DER METADATENDATEI <pre>119 <dc:accessURL rdf:resource="https://nicht-aufloesbar.invalid/daten/bericht"/> 132 <dc:accessURL rdf:resource="https://nicht-aufloesbar.invalid/daten/tabelle"/></pre>	

(b) Fundstelle („Betroffene Stelle in der Metadatendatei“) für einen inhaltsabhängigen Indikator

Abbildung 4.4: Die beiden Formen des Detailblocks: Vorlage und Fundstelle im Quelltext

Nicht jeder Indikator lässt eine solche Vorlage zu. Wenn die richtige Angabe vom Inhalt abhängt und nicht von der Schreibweise, wie beispielsweise bei den Schlagwörtern oder sprachmodellgestützten Indikatoren, gäbe eine Vorlage nur eine Syntax vor, die ohnehin nie das Problem war. Das selbe gilt auch für Indikatoren, wo das Problem

außerhalb des Metadatensatzes liegt, etwa bei einem Verweis, der ins Leere führt. Für diese Indikatoren tritt an die Stelle der Vorlage die **Fundstelle**: die einschlägigen Zeilen des RDF-Quelltexts mit Zeilennummer, sodass sich die Kette von der Punktzahl bis zur konkreten Stelle im Metadatensatz schließt. Abbildung 4.4 (b) zeigt dies für zwei nicht auflösbare Verweise. Für eine dritte Gruppe schließlich entfällt der Detailblock ganz, weil Befund und Hinweis bereits alles tragen.

Welche der drei Formen ein Indikator führt, ist damit keine Eigenschaft des Einzelergebnisses, sondern des Indikators, und liegt entsprechend als feste Angabe neben Klarnamen, Feldbezeichnung und Handlungsanweisung im Bewertungskern. Der Detailblock trägt in jedem Fall genau eine dieser Formen.

4.8.6 Darstellung und Bedienung

Den drei Zielgruppen aus Tabelle 4.6 entsprechen drei Auflösungsstufen der Darstellung. Sie folgen dem Ordnungsprinzip *Überblick zuerst, dann Filtern, dann Details auf Anforderung*, das Shneiderman als Grundmuster informationsvisualisierender Oberflächen beschreibt [43]: Jede Stufe zeigt so viel, wie die Entscheidung auf dieser Ebene erfordert, und macht die nächste Detailtiefe erst auf Anforderung sichtbar. Die Trefferliste zeigt je Datensatz allein den Gesamtscore als Ring mit Note und bedient damit die Auswahlentscheidung der Datennutzenden, ohne die Liste mit Bewertungsdetails zu überfrachten.

Die Detailsicht eines Datensatzes richtet sich an die Datenbereitstellenden. Sie zeigt den Gesamtscore, das Profil über die vier Qualitätsdimensionen als Netzdiagramm und darunter je Dimension eine Übersicht ihrer Indikatoren mit Ergebnisstufe, Punktwert und Gewicht; jeder nicht erfüllte Indikator lässt sich zu dem in Section 4.8.4 beschriebenen Befund aufklappen. Zwei Bedienelemente steuern den Umfang der Ansicht: Ein Schalter blendet die erfüllten Indikatoren aus und reduziert sie auf das, was zu bearbeiten ist. Ein weiterer Knopf klappt Dimensionen und Befunde gemeinsam auf oder zu und macht damit den vollständigen Bearbeitungsbedarf eines Datensatzes in einem Schritt sichtbar, statt ihn Dimension für Dimension und darin Befund für Befund erschließen zu lassen. Abbildung 4.5 zeigt diesen Bewertungsabschnitt im eingeklappten Zustand: Note, Gesamtscore und Dimensionsprofil als Einstieg, darunter je Dimension eine Zeile, die neben Score und Gewicht ausweist, wie viele ihrer Indikatoren erfüllt sind und wie viele Handlungsbedarf auslösen.




Abbildung 4.5: Detailsicht eines Datensatzes mit Dimensionsprofil und Indikatorübersicht

Die Aggregationsansicht in Abbildung 4.6 bedient die Portalbetreibenden. Sie weist die Zahl der bewerteten Datensätze, den mittleren Gesamtscore mit Spannweite und den Anteil erfüllter Prüfungen aus und ergänzt diese Kennzahlen um die Verteilung der Gesamtbewertung, die Mittelwerte je Dimension, die häufigsten Mängel als Anteil der Datensätze, die einen Indikator nicht oder nur teilweise erfüllen, sowie den Verlauf über die vorliegenden Bewertungsläufe. Die Zusammenstellung folgt dem für Übersichtsdarstellungen formulierten Grundsatz, die zur Beurteilung erforderlichen Größen gemeinsam und nach ihrem Informationswert geordnet zu zeigen, statt sie auf mehrere Ansichten zu verteilen [44]. Die Verlaufsdarstellung ist bewusst zurückhaltend beschriftet, weil ihre Punkte Bewertungsläufe und keine Erhebungszeitpunkte sind: Sie zeigt zunächst die Streuung des Verfahrens und wird erst dann zu einer Qualitätsentwicklung, wenn der Bestand wiederholt geharvestet und bewertet wird.




Abbildung 4.6: Aggregatsicht über einen Datenbestand

Für die aus der Oberfläche angestoßenen Bewertungsläufe gilt eine Vorgabe, die für die Belastbarkeit der dargestellten Werte wesentlich ist: Die Oberfläche führt keine eigenen Voreinstellungen, sondern lädt zur Laufzeit dieselbe Konfigurationsdatei, die auch der Evaluation dieser Arbeit zugrunde liegt. Gewichte, Punktevergabe und Indikatormenge sind damit nicht nur ähnlich, sondern identisch. Als einzige Wahl bleibt, ob die sprachmodellgestützte Dimension der Aussagekraft einbezogen wird. Eine Unterscheidung, die auf Zeit- und Kostenaufwand des Laufs durchschlägt.

Für die Gestaltung gelten durchgängig zwei Regeln der Barrierefreiheit, die den Web Content Accessibility Guidelines entnommen sind [45]. Farbe ist nie alleiniger Bedeutungsträger (Erfolgskriterium 1.4.1): Jede Ergebnisstufe trägt neben ihrer Farbe ein Symbol und eine ausgeschriebene Bezeichnung, jede Diagrammreihe ist beschriftet. Sämtliche Farbwerte stammen aus dem Gestaltungssystem des Portals; ihre Kontraste wurden für die verwendeten Kombinationen gegen die Schwellen der Erfolgskriterien 1.4.3 und 1.4.11 nachgerechnet, statt sie nach Augenmaß zu wählen. Ergänzend wurden die Diagrammfarben mit einem physiologisch begründeten Simulationsmodell

für Farbfehlsichtigkeit [46] auf ihre Unterscheidbarkeit geprüft.

5 Evaluation

5.1 Evaluationsdesign und Hypothesen

Die Evaluation stützt sich auf zwei komplementäre Argumentationsstränge, die auf identischem RDF-Input erhoben werden. Der erste vergleicht den Prototyp mit einem externen menschlichen Qualitätsurteil und beantwortet die Frage, ob er *korrekt* bewertet. Der zweite vergleicht ihn mit der Metadata Quality Assessment (MQA) von data.europa.eu als etablierter Baseline und beantwortet die Frage, was er *ergänzend* sieht. Beide Stränge sind aufeinander aufbauend: Der Baseline-Vergleich allein kann lediglich zeigen, dass sich die Bewertungen unterscheiden, nicht aber, welche der beiden näher an der tatsächlichen Qualität liegt. Erst der Ground-Truth-Vergleich erlaubt diese Aussage.

Daraus ergeben sich drei Hypothesen:

1. **H1 (Konvergenz):** Die Scores beider Verfahren konvergieren stark auf denjenigen Indikatoren, die äquivalent geprüft werden.
2. **H2 (Mehrwert):** Die Scores divergieren systematisch auf denjenigen Indikatoren, bei denen der Prototyp tiefer prüft als die MQA oder bei denen die MQA über kein Pendant verfügt.
3. **H3 (Korrektheit):** Auf denjenigen Indikatoren, auf denen beide Verfahren divergieren, stimmt der Prototyp stärker mit dem externen Qualitätsurteil überein als die MQA.

H1 (Konvergenz) besagt, dass die Scores beider Verfahren auf den äquivalenten Prüfungen stark konvergieren, der Prototyp die etablierte MQA-Logik also korrekt abbildet; methodisch entspricht dies dem Nachweis konvergenter Validität [47]. **H2 (Mehrwert)** besagt, dass die Scores auf denjenigen Indikatoren systematisch divergieren, bei denen der Prototyp tiefer prüft als die MQA oder bei denen die MQA über kein Pendant verfügt. Hier ist eine Divergenz kein Fehler, sondern der erwartete Effekt des verifizierenden statt lediglich prüfenden Ansatzes. **H3 (Korrektheit)** besagt, dass der Prototyp dort, wo beide Verfahren divergieren, stärker mit dem externen Qualitätsurteil übereinstimmt als die MQA. H3 verbindet beide Stränge und trägt die eigentliche Überlegenheitsaussage. Ohne sie belegt H2 nur, dass anders gemessen wird, nicht dass besser gemessen wird.

5.2 Datengrundlage und Stichprobe

Grundlage der Evaluation ist ein vollständiger Auszug des GovData-CKAN-Katalogs vom 15. Mai 2026 mit 151.579 Datensätzen. Aus diesem wurden zunächst alle Datensätze entfernt, die mindestens eine NetCDF-Distribution enthalten (1.793 Datensätze, verbleibend 149.786). NetCDF-Ressourcen sind typischerweise sehr große Klima- und Umweltdatenreihen, deren Abruf im Rahmen der technischen Erreichbarkeitsprüfung Laufzeit und Datenvolumen dominiert hätte, ohne inhaltlich zusätzliche Erkenntnisse zu liefern. Der verbleibende Katalog wurde anhand von Formatangaben, Medientypen und Service-Kennungen in 25.416 Geo-Datensätze und 124.370 Nicht-Geo-Datensätze unterteilt.

Aus dieser Grundgesamtheit wurde am 25. Juni 2026 eine **stratifizierte Zufallsstichprobe** von $n = 50$ Datensätzen gezogen (Seed 67, reproduzierbar über Notebook 12). Die Gruppierung erfolgt zweistufig: primär nach der Unterscheidung Geo/Nicht-Geo, sekundär innerhalb beider Gruppen nach den vier jeweils aufkommensstärksten Datenbereitstellern zuzüglich einer Restkategorie für alle übrigen Bereitsteller. Aus jedem der so entstehenden zehn Straten werden fünf Datensätze gezogen. Die Schichtung stellt sicher, dass die Stichprobe die für die Metadatenqualität relevanten Unterschiede der Grundgesamtheit abbildet, statt von den wenigen aufkommensstärksten Portalen dominiert zu werden, die bei einer einfachen Zufallsziehung den Großteil der Stichprobe stellen würden. Die gezogenen Datensätze wurden anschließend als RDF/XML von GovData abgerufen und bilden damit denselben Input, auf dem der Prototyp und die MQA-Reimplementierung arbeiten.

Ergänzend zur Kernstichprobe steht ein Satz von zwanzig **kuratierten Extremfällen** zur Verfügung, je zehn mit erwartbar hoher und erwartbar niedriger Metadatenqualität. Erstere zeichnen sich durch eine aussagekräftige Beschreibung, erreichbare Ressourcen, maschinenlesbare Formate sowie vorhandene Lizenz- und Kontaktangaben aus, letztere durch generische Titel, nichtssagende Beschreibungen, defekte Verweise, unklare Lizenzen und fehlerhafte Formatangaben. Beide Schichten verfolgen unterschiedliche Zwecke und werden getrennt ausgewertet: Die Extremfälle belegen den Wirkmechanismus per Konstruktion, da bei ihnen bekannt ist, welches Ergebnis zu erwarten ist. Die Kernstichprobe kontrolliert die Selektionsverzerrung, die einer kuratierten Auswahl notwendigerweise anhaftet, und zeigt das Verhalten unter realistischen Bedingungen. Da die Extremfälle konstruiert und nicht randomisiert selektiert sind, erlauben sie keine Verallgemeinerung auf die Grundgesamtheit. Alle quantitativen Aussagen dieser Arbeit stützen sich daher durchgehend auf die Kernstichprobe.

5.3 Ground-Truth-Erhebung

Als externer Maßstab dient eine manuelle Bewertung aller 50 Datensätze der Kernstichprobe und der Extremfälle, entlang derselben vier Qualitätsdimensionen, die auch der Prototyp verwendet. Bewertet wird jede Dimension auf einer sechsstufigen Skala von 0 bis 5 entlang je einer ausformulierten Ankerfrage; Tabelle 5.1 führt die vier Fragen auf. Die Stufenzahl folgt dem Befund von Preston und Colman [48], wonach Reliabilität, Validität und Diskriminierungsfähigkeit von Ratingskalen bis etwa fünf bis sieben Kategorien zunehmen und vierstufige Skalen suboptimal sind. Auf einen expliziten Skalenmittelpunkt wird verzichtet; das gegen Mittelpunkte vorgebrachte Argument des Central-Tendency-Bias betrifft primär Einstellungsskalen ohne inhaltliche Anker, während bei einer kriteriengeleiteten Bewertung mit definierten Ankerformulierungen kein Ausweichverhalten zu erwarten ist [49].

Dimension	Ankerfrage
Auffindbarkeit	Ist der Datensatz über Titel, Beschreibung, Schlagwörter, Kategorien sowie räumliche und zeitliche Angaben gut auffindbar und einordenbar?
Zugänglichkeit	Ist die beschriebene Ressource erreichbar, abrufbar, maschinenlesbar und technisch plausibel beschrieben?
Nachnutzbarkeit	Sind Lizenz, Rechte, Kontakt, Herausgeber und verwendete Vokabulare für eine Weiterverwendung ausreichend klar?
Aussagekraft	Sind Titel, Beschreibung, Schlagwörter und Kontextangaben verständlich, plausibel und informationshaltig?

Tabelle 5.1: Ankerfragen der manuellen Ground-Truth-Bewertung je Qualitätsdimension

Methodisch entscheidend ist, dass die Anker die *nutzerseitige Qualitätserfahrung* beschreiben und nicht die Indikatorlogik des Prototyps. Ein Anker der Dimension Auffindbarkeit formuliert beispielsweise, ob ein Nutzer den Datensatz über seine Metadaten finden und thematisch einordnen kann, nicht ob ein bestimmtes DCAT-Feld belegt ist. Damit misst die Ground Truth dasselbe Konstrukt aus methodisch unabhängiger Perspektive, statt die Prüflogik des Prototyps manuell nachzuvollziehen [47].

Aus den vier Dimensionswerten wird ein Gesamturteil in den Stufen *gut*, *mittel* und *schlecht* abgeleitet; Tabelle 5.2 führt die Schwellen auf.

Gesamturteil	Durchschnitt der vier Dimensionen	Zusätzliche Bedingung
gut	mindestens 4,0	keine Dimension unter 3
schlecht	höchstens 2,0	–
	oder unter 3,5	mindestens zwei Dimensionen unter 2
mittel	alle übrigen Fälle	

Tabelle 5.2: Ableitung des Gesamturteils der Ground Truth aus den vier Dimensionswerten

Die Schwellen sind kriteriumsorientiert gesetzt [50]: Sie repräsentieren inhaltlich definierte Qualitätsniveaus und nicht die relative Lage innerhalb der Stichprobenverteilung. Die Aggregation ist bewusst hybrid – primär kompensatorisch über den Durchschnitt, abgesichert durch eine konjunktive Klausel – damit ein hoher Wert in einer Dimension eine gravierende Lücke in einer anderen nicht vollständig ausgleichen kann [51]. In der Tabelle entspricht die mittlere Spalte dem kompensatorischen, die rechte dem konjunktiven Teil dieser Regel.

Die Bewertung erfolgte blind gegenüber den Ergebnissen des Prototyps: Die Bewertungsvorlage enthält ausschließlich den Inhalt der zu bewertenden Metadatendatei nicht jedoch dessen Scores. Damit wird ein Anchoring-Bias ausgeschlossen, der die gemessene Übereinstimmung künstlich erhöhen würde.

Als Limitation ist festzuhalten, dass die Bewertung von einer einzelnen Person vorgenommen wurde und eine Inter-Rater-Reliabilität daher nicht bestimmt werden kann. Der internen Konsistenz wurde durch eine vorherige Kalibrierung an fünf Beispieldatensätzen, kompakte Bewertungssitzungen und die explizite Markierung von Zweifelsfällen Rechnung getragen.

5.4 Vergleichsbaseline: MQA-Reimplementierung und A/B/C-Klassifikation

Als Vergleichsmaßstab dient die Metadata Quality Assessment Implementierung von data.europa.eu. Sie eignet sich als Baseline, weil sie im europäischen Open-Data-Kontext etabliert ist, ihre Methodik offengelegt ist und sie denselben DCAT-AP-Input bewertet wie der Prototyp. Um beide Verfahren auf exakt derselben Datengrundlage vergleichen zu können, wurde die MQA-Bewertungslogik nach der offiziellen Methodik [52] reimplementiert und gegen die veröffentlichten Berichte von data.europa.eu validiert. Die Reimplementierung ist dabei lediglich Evaluationsinstrument und nicht Bestandteil des Artefakts. Da beide Verfahren unterschiedliche Punkteskalen verwenden, werden die Ergebnisse vor dem Vergleich auf einen gemeinsamen Wertebereich normalisiert.

Der inhaltliche Kern des Vergleichs ist die Unterscheidung zweier Prüfparadigmen. Die MQA bewertet überwiegend, *ob* ein Feld vorhanden, in einem kontrollierten Vokabular gelistet oder eine URL auflösbar ist. Sie nimmt Qualität bei Vorhandensein weitgehend an. Der Prototyp prüft darüber hinaus, ob die vorhandenen Angaben gültig, untereinander kongruent und inhaltlich tragfähig sind. Um diesen Unterschied systematisch auswertbar zu machen, wird jeder Indikator des Prototyps einer von drei Klassen zugeordnet.

- **Klasse A** umfasst Indikatoren, die im Kern dasselbe prüfen wie eine MQA-Metrik. Hier ist hohe Übereinstimmung zu erwarten (H1).
- **Klasse B** umfasst Indikatoren, bei denen die MQA bereits das Vorhandensein honoriert, während der Prototyp Gültigkeit oder Kongruenz verifiziert. Eine Kombination aus MQA-PASS und Prototyp-FAIL ist hier der Nachweis einer Überschätzung durch die MQA (H2).
- **Klasse C** umfasst Indikatoren ohne MQA-Pendant – darunter die gesamte Dimension der Aussagekraft – bei denen die MQA strukturell blind bleibt, der Prototyp aber variiert (H2).

Diese Partitionierung entspricht klassischen Validitätsbegriffen der Messtheorie [53]: Klasse A adressiert konvergente Validität, Klasse B und C die inkrementelle Validität des Prototyps gegenüber der Baseline. Die Zuordnung ist vollständig dokumentiert und enthält je Indikator die zugeordneten MQA-Metriken, die Aggregationsregel und die Begründung. Die vollständige Zuordnungstabelle findet sich in Anhang J.

Damit der Vergleich nicht einseitig zugunsten des Prototyps ausfällt, sind umgekehrt auch die MQA-Metriken zu nennen, für die der Prototyp keine Entsprechung vorsieht: `rights_availability` (dct:rights) und `byte_size_availability` (dcat:byteSize). Beide Felder sind nach DCAT-AP.de weder verpflichtend noch empfohlen. Bereits die Experteninterviews ordneten wenig aussagekräftige Zusatzfelder dieser Art unter dem Prinzip „Qualität statt Quantität“ als für die Bewertung verzichtbar ein (Anhang C, Kategorie K1.2), weshalb der Prototyp hierfür keinen eigenen Indikator vorsieht.

5.5 Auswertungsverfahren und Kennzahlen

Für den Ground-Truth-Vergleich ist die **Spearman-Rangkorrelation** ρ die Primärmetrik, berichtet als Gesamtwert und je Dimension. Diese Festlegung hat drei Gründe. Erstens ist die Forschungsfrage ordinal: Zu prüfen ist, ob der Prototyp dieselbe Rangordnung

erzeugt wie ein menschlicher Bewerter. Der kontinuierliche Score ist das eigentliche Ergebnis des Verfahrens, das dreistufige Urteil lediglich eine daraus abgeleitete Diskretisierung. Zweitens ist Cohens κ auf dieser Stichprobe strukturell nach oben begrenzt: Die Urteilsverteilung der Ground Truth ist mit rund 87 % der Datensätze in der Kategorie *mittel* stark konzentriert, wodurch die zufällig zu erwartende Übereinstimmung bereits bei etwa 0,79 liegt. Selbst ein nahezu perfektes Verfahren könnte unter diesen Randbedingungen kein hohes κ erreichen — ein bekanntes Phänomen, das als Kappa-Paradox beschrieben ist [54]. Dass eine reale, stratifiziert gezogene GovData-Stichprobe überwiegend mittelmäßige Metadaten enthält, ist ein Befund über die Datenlage, kein Mangel des Prototyps. Drittens ist der κ -Punktschätzer bei so wenigen Fällen außerhalb der mittleren Kategorie instabil; das entsprechend breite Bootstrap-Konfidenzintervall ist das stärkste Einzelargument gegen seine Verwendung als Entscheidungsgrundlage.

Ergänzt wird die Rangkorrelation durch Kendalls τ sowie durch eine Ceiling-Analyse. Diese berechnet, welches ρ bei der vorliegenden Ground-Truth-Verteilung überhaupt erreichbar wäre, und zeigt damit, wie nah der Prototyp an dieses Maximum herankommt. Da Rangkorrelationen ausschließlich die Reihenfolge und nicht das Niveau bewerten, treten mittlerer absoluter Fehler (MAE) und Bias als Kalibrierungsmaße hinzu. Auf der Urteilebene werden als **Sekundärmetriken** Accuracy, gewichtetes κ mit Bootstrap-Konfidenzintervall, PABAK sowie die schwellenfreie AUC für die Trennung *gut* gegen den Rest und die Konfusionsmatrix berichtet. PABAK bereinigt das Prävalenzproblem rechnerisch [55] und macht damit sichtbar, dass eine niedrige κ -Punktschätzung hier ein Verteilungs- und kein Qualitätsbefund ist.

Naheliegender wäre der Einwand, eine feiner gestufte Urteilsskala könne das Problem beheben. Kontrollrechnungen mit abweichenden Klasseneinteilungen zeigen jedoch, dass nicht die Stufenzahl entscheidend ist, sondern die Lage der Schwellen relativ zur Stichprobenverteilung. Zudem konvergiert fein gestuftes, quadratisch gewichtetes κ gegen eine Korrelation und misst damit dasselbe wie ρ , nur abhängig von zwei zusätzlichen willkürlichen Festlegungen. Auf eine nachträgliche Anpassung der Schwellen wurde verzichtet, da günstig gewählte Schnittpunkte eine Optimierung der Kennzahl statt einer Messung darstellen würden.

Für den MQA-Vergleich werden je Indikatorklasse eigene Kennzahlen berichtet: die Übereinstimmungsrate für Klasse A, die Überschätzungsrate für Klasse B, die Score-Varianz des Prototyps bei flacher MQA-Bewertung für Klasse C sowie eine Bland-Altman-Darstellung der Score-Differenzen über den gesamten Wertebereich.

5.6 Modellauswahl für die LLM-gestützte Bewertung

Die semantische Bewertung der Aussagekraft ist der einzige Bestandteil des Prototyps, der auf ein Sprachmodell zurückgreift. Die übrigen drei Dimensionen werden deterministisch aus dem RDF-Graphen berechnet und sind vom gewählten Modell vollständig unabhängig. Bevor die eigentlichen Evaluationsergebnisse berichtet werden, ist deshalb zu klären, welches Modell dieser Bewertung zugrunde liegt und wie stark diese Wahl das Gesamtergebnis überhaupt beeinflusst.

Als Kandidaten wurden GPT-5.5, Claude Opus 4.8 und Claude Sonnet 4.6 gewählt. Die Auswahl orientiert sich an der Nutzungsstatistik von OpenRouter, über die auch die Modellaufrufe des Prototyps abgewickelt werden: Die Plattform weist aus, welche Modelle je Aufgabentyp den größten Anteil der abgerechneten Nutzung auf sich vereinen, und die drei genannten Modelle führen dort die Kategorie der Klassifikationsaufgaben an [56]. Da die Bewertung der Aussagekraft im Kern eine Klassifikationsaufgabe auf Freitextfeldern ist, bildet diese Rangliste einen sachnahen und nachvollziehbaren Auswahlmaßstab, der zugleich verhindert, dass die Auswahl als beliebig oder anbietergebunden erscheint. Ein erschöpfender Modellvergleich ist damit ausdrücklich nicht beabsichtigt. Die Auswahl deckt die in der Praxis dominierenden Kandidaten ab.

Verglichen werden die drei Kandidaten auf identischer Datenbasis: der Kernstichprobe ($n = 50$) unter der Konfiguration `state_evaluation_final`, jeweils mit demselben Prompt und derselben Bewertungsrubrik. Abbildung 5.1 zeigt die Rangkorrelation zur Ground Truth je Dimension und Modell.




Abbildung 5.1: Spearman-Rangkorrelation zur Ground Truth je Qualitätsdimension und Sprachmodell (Kernstichprobe, $n = 50$)

Der Befund ist eindeutig: In den Dimensionen Auffindbarkeit, Zugänglichkeit und Wiederverwendbarkeit sind die Werte über alle drei Modelle bitgenau identisch ($\rho = 0,524$, $0,712$ und $0,739$). Die Modellwahl berührt ausschließlich die Aussagekraft. Für den Vergleich folgt daraus, dass die Aussagekraft die einzige Dimension ist, auf der die Kandidaten überhaupt sinnvoll gegeneinander zu bewerten sind. Zudem sind Gesamtkennzahlen für diesen Zweck nur eingeschränkt aussagekräftig, weil sie den identischen deterministischen Anteil mitmitteln und die tatsächlichen Unterschiede dadurch verwässern. Die Gesamtwerte werden im Folgenden dennoch berichtet, da sie die praktische Auswirkung der Modellwahl auf das Endergebnis sichtbar machen.

5.6.1 Auswahl des Sprachmodells

Tabelle 5.3 stellt die Kandidaten gegenüber. Die Kennzahlen sind nach der in Abschnitt 5.5 festgelegten Hierarchie geordnet: zuerst die Primärmetrik, dann die Kalibrierungsmaße, zuletzt die Urteilstebene als Sekundärmetrik.

Kennzahl	GPT-5.5	Opus 4.8	Sonnet 4.6
<i>Primärmetrik</i>			
Spearman ρ Aussagekraft	0,569	0,608	0,598
Spearman ρ gesamt	0,765	0,770	0,745
<i>Kalibrierung</i>			
MAE (Skala 0–5)	0,289	0,275	0,308
Bias gesamt	+0,018	−0,018	−0,144
Bias Aussagekraft	−0,077	−0,220	−0,723
<i>Urteilstebene (Sekundärmetrik)</i>			
Accuracy	0,92	0,90	0,88
Cohen κ (gewichtet)	0,635	0,508	0,359
PABAK	0,88	0,85	0,82
AUC gut-vs-rest	0,907	0,902	0,876
Als „gut“ erkannt (von 5)	3	2	1
<i>Aufwand</i>			
Kosten je 50 Datensätze (USD)	1,79	4,10	2,02

Tabelle 5.3: Kennzahlenvergleich der Kandidatenmodelle auf der Kernstichprobe ($n = 50$), je ein Lauf pro Modell.

Opus 4.8 scheidet am Aufwand aus. Das Modell verursacht mit 4,10 USD je 50 Datensätzen etwa doppelt so hohe Kosten wie die beiden anderen Kandidaten, ohne dass dem ein belastbarer Qualitätsvorsprung gegenüberstünde: Auf der Primärmetrik liegt es lediglich 0,010 vor Sonnet 4.6 und 0,040 vor GPT-5.5 – Abstände, die, wie Abschnitt 5.6.2 zeigt, kleiner sind als die Schwankung eines einzelnen Modells zwischen Wiederholungsläufen.

Zwischen **GPT-5.5** und **Sonnet 4.6** trennt die Primärmetrik die Kandidaten nicht. Der Abstand auf der Aussagekraft beträgt in obiger Tabelle 0,029; auf der Wiederholungstichprobe, auf der auch die Streuung bestimmt ist ($n = 30$, Abschnitt 5.6.2), sind es 0,028 zugunsten von Sonnet 4.6, während die Streuung desselben Modells zwischen Wiederholungsläufen dort bei $\sigma = 0,023$ liegt. Der Unterschied entspricht damit dem 1,2-fachen der Streuung, und die Wertebereiche beider Modelle überlappen einander. Ein Vorsprung dieser Größenordnung ist auf dieser Stichprobe nicht von Zufallsschwankung zu unterscheiden.

Damit fällt die Entscheidung auf den nachgeordneten Kriterien, und diese weisen übereinstimmend auf GPT-5.5. Am deutlichsten ist der Befund zur *Kalibrierung*: Sonnet 4.6 unterschätzt die Aussagekraft systematisch um 0,723 Skalenpunkte, also rund 15 % der Skalenbreite, GPT-5.5 dagegen nur um 0,077. Diese Niveauverschiebung ist für die Rangkorrelation folgenlos – ρ misst ausschließlich die Reihenfolge – wirkt sich auf der Urteilebene aber unmittelbar aus, weil die Urteilsregel feste Schwellen auf die gerundeten Dimensionswerte anwendet. Sonnet 4.6 drückt dadurch 19 der 50 Datensätze unter die konjunktive Sperrklausel „keine Dimension unter 3“ (Ground Truth: 7) und erkennt in der Folge nur einen der fünf tatsächlich guten Datensätze als „gut“, gegenüber drei bei GPT-5.5. Für ein Werkzeug, das Datenbereitstellern eine Qualitätsrückmeldung geben soll, ist eine systematische Abwertung guter Metadaten ein praktisch relevanter Mangel.

Dieser Zusammenhang erklärt zugleich den auf den ersten Blick widersprüchlichen Befund, dass GPT-5.5 auf der Primärmetrik hinten liegt, auf der Urteilebene jedoch durchgängig vorn: Rangkorrelation und Urteilsregel messen unterschiedliche Eigenschaften. Erstere ist niveaublind und bewertet allein die Reihenfolge, letztere ist niveauempfindlich und bewertet die absolute Lage relativ zu festen Schwellen. GPT-5.5 ordnet die Datensätze geringfügig schlechter, verortet sie aber auf dem zutreffenden Niveau. Sonnet 4.6 hingegen ordnet minimal besser ein, verschiebt jedoch das gesamte Niveau nach unten.

Die Unterschiede auf der Urteilebene sind allerdings mit Zurückhaltung zu lesen. Die Konfusionsmatrizen der drei Modelle sind in zwei von drei Zeilen identisch; der gesamte Unterschied entsteht in den fünf Datensätzen mit dem Ground-Truth-Urteil „gut“. Aus einer Differenz von zwei Datensätzen resultiert bereits die κ -Spanne von 0,635 bis 0,359 — eine Sensitivität, die den in Abschnitt 5.5 dargelegten Prävalenzbefund bestätigt und begründet, warum diese Kennzahlen als Sekundärmetrik geführt werden. Sie stützen die Entscheidung, tragen sie aber nicht allein.

Gewählt wird daher **GPT-5.5**. Es ist auf der Primärmetrik von Sonnet 4.6 nicht unterscheidbar, deutlich besser kalibriert, auf der Urteilebene durchgängig genauer, reproduzierbarer (Abschnitt 5.6.2) und zugleich das kostengünstigste der drei Modelle. Alle folgenden Ergebnisse dieses Kapitels beruhen auf diesem Modell.

5.6.2 Reproduzierbarkeit der Bewertung

Da die Bewertung der Aussagekraft auf einem generativen Sprachmodell beruht, ist sie anders als die übrigen Dimensionen nicht deterministisch. Wie stark die Ergebnisse zwischen zwei Läufen desselben Modells schwanken, ist deshalb sowohl ein eigenständiges Gütekriterium als auch die Voraussetzung dafür, Unterschiede zwischen Modellen überhaupt beurteilen zu können: Ein Abstand, der kleiner ist als die Schwankung eines einzelnen Modells, trägt keine Aussage.

Erhoben wurden je drei Läufe für GPT-5.5 und Sonnet 4.6 auf einer identischen Teilstichprobe von 30 Datensätzen. Abbildung 5.2 zeigt die Einzelergebnisse sowie die Spanne je Modell.




Abbildung 5.2: Spearman ρ der Aussagekraft über je drei Wiederholungsläufe, identische Teilstichprobe ($n = 30$)

Beide Modelle streuen in vergleichbarer Größenordnung: Sonnet 4.6 erreicht im Mittel $\rho = 0,558$ bei einer Spanne von 0,043 ($\sigma = 0,022$), GPT-5.5 im Mittel $\rho = 0,530$ bei einer Spanne von 0,047 ($\sigma = 0,024$). Dass die Streuung bei beiden nahezu identisch ausfällt, legt nahe, dass sie weniger eine Eigenschaft des einzelnen Modells als der Bewertungsaufgabe selbst ist. Die Wertebereiche überlappen einander deutlich, da der beste Lauf von GPT-5.5 ($\rho = 0,557$) über dem schwächsten von Sonnet 4.6 ($\rho = 0,539$) liegt. Dies ist die in Abschnitt 5.6.1 herangezogene Grundlage für die Feststellung, dass die Primärmetrik die beiden Kandidaten nicht trennt.

Auf der Ebene der Scores, statt der aus ihnen abgeleiteten Rangkorrelation, fällt der Vergleich klarer aus. Tabelle 5.4 stellt die Reproduzierbarkeitskennzahlen beider Modelle gegenüber.

Kennzahl	GPT-5.5	Sonnet 4.6
Spanne der Run-Mittelwerte	0,0004	0,0063
Ø Standardabweichung je Datensatz	0,0046	0,0082
Ø Standardabweichung Aussagekraft	0,0150	0,0268
MAE zwischen zwei Läufen	0,0059	0,0107
Spearman ρ zwischen zwei Läufen	0,993	0,991
Höchster Anteil an Statuswechseln je Kriterium	17 %	47 %

Tabelle 5.4: Reproduzierbarkeit über je drei Wiederholungsläufe auf identischer Teilstichprobe ($n = 30$)

GPT-5.5 reproduziert seine Bewertungen durchgehend stabiler, auf Ebene der Run-Mittelwerte um mehr als eine Größenordnung. Dass die Streuung der Rangkorrelation dennoch minimal höher ausfällt, ist kein Widerspruch: ρ ist eine Rangstatistik, und bei eng beieinanderliegenden Werten genügen geringe Score-Änderungen, um Ränge zu vertauschen. Die zugrunde liegenden Scores selbst sind bei GPT-5.5 klar reproduzierbarer.

Drei Befunde sind darüber hinaus festzuhalten. Erstens sind die drei deterministischen Dimensionen über sämtliche Läufe hinweg bitgenau identisch. Die gesamte beobachtete Streuung stammt somit aus der LLM-gestützten Bewertung, während die übrige Verarbeitungskette exakt reproduziert – ein Validitätsnachweis für die Pipeline als Ganzes. Zweitens ergibt sich aus der Spanne der Run-Mittelwerte eine Auflösungsgrenze für alle weiteren Vergleiche: Unterschiede zwischen Konfigurationen oder Modellen, die kleiner sind als 0,0004 (GPT-5.5), sind nicht interpretierbar. Drittens verteilt sich die Instabilität nicht gleichmäßig über die Bewertungskriterien, sondern konzentriert sich auf einzelne von ihnen; bei GPT-5.5 wechselt der diskrete Status im ungünstigsten Fall bei 17 % der Datensätze, bei Sonnet 4.6 dagegen bei 47 %. Die betroffenen Kriterien sind damit als Ansatzpunkt für eine Schärfung der Bewertungsrubrik identifiziert.

5.7 Ergebnisse: Prototyp und Ground Truth

Dieser Abschnitt berichtet die in Abschnitt 5.5 festgelegten Kennzahlen für beide Stichproben getrennt: zuerst die Kernstichprobe, die die quantitativen Aussagen dieser Arbeit trägt, dann die Extremfälle, die den Wirkmechanismus per Konstruktion belegen (Abschnitt 5.2). Beide Auswertungen verwenden durchgängig GPT-5.5.

5.7.1 Kernstichprobe (n=50)

Primär- und Sekundärmetrik für die Kernstichprobe wurden bereits in Abschnitt 5.6.1 im Rahmen der Modellauswahl vollständig berichtet (Tabelle 5.3, Spalte GPT-5.5): Spearman ρ gesamt = 0,765, Genauigkeit 92 %, gewichtetes κ = 0,635, PABAK = 0,88, AUC = 0,907. Sie bilden zugleich das Hauptergebnis dieses Abschnitts, da GPT-5.5 das für die gesamte übrige Auswertung verwendete Modell ist, und werden hier nicht wiederholt, sondern um die noch offene Ceiling-Einordnung sowie eine visuelle Aufbereitung ergänzt.

Abbildung 5.3 stellt die vier Dimensions- ρ ihrem jeweiligen Ceiling gegenüber – dem bei gegebener Ground-Truth-Verteilung maximal erreichbaren ρ (Abschnitt 5.5). Tabelle 5.5 listet die Werte vollständig, einschließlich der tatsächlich genutzten GT-Stufenzahl je Dimension.




Abbildung 5.3: Spearman ρ je Qualitätsdimension, beobachtet vs. Ceiling (Kernstichprobe, $n = 50$)

Dimension	ρ beobachtet	ρ Ceiling	Anteil	GT-Stufen
Auffindbarkeit	0,524	0,768	68,3 %	4
Zugänglichkeit	0,712	0,952	74,8 %	6
Wiederverwendbarkeit	0,739	0,928	79,6 %	6
Aussagekraft	0,569	0,851	66,8 %	4

Tabelle 5.5: Ceiling-Analyse je Dimension (Kernstichprobe, $n = 50$): beobachtetes ρ , maximal erreichbares ρ bei gegebener GT-Verteilung, Anteil vom Ceiling, Anzahl tatsächlich genutzter GT-Stufen.

Dass Auffindbarkeit das niedrigste rohe ρ aufweist, ist damit nur zur Hälfte ein Skalenartefakt: Das Ceiling liegt mit 0,768 selbst unter dem der übrigen drei Dimensio-

nen, weil die Ground Truth hier nur vier der sechs Stufen tatsächlich nutzt. Die verbleibende Lücke zum Ceiling (68,3 % ausgeschöpft) ist aber real und kleiner als bei Zugänglichkeit oder Wiederverwendbarkeit (74,8 % bzw. 79,6 %). Aussagekraft liegt mit 66,8 % auf ähnlichem Niveau wie Auffindbarkeit – ein erster Hinweis auf die in Abschnitt 5.7.2 vertiefte Schwäche dieser Dimension, die auf den Extremfällen deutlich stärker hervortritt.

Die Disattenuationskorrektur (Abschnitt 5.5) liefert für die Kernstichprobe keinen brauchbaren Punktschätzer: Cronbachs α liegt auf der Modellseite bei nur 0,294, weil die vier Dimensionen absichtlich verschiedene Konstrukte messen; die Korrektur $r_{\text{latent}} = \rho / \sqrt{\alpha_{GT} \cdot \alpha_{\text{Modell}}}$ überschreitet den zulässigen Wertebereich und wird bei 1,0 gekappt. Dies bestätigt die in Abschnitt 5.5 vorab benannte methodische Grenze – nicht eine besonders hohe latente Übereinstimmung – und wird deshalb nicht als Kennzahl weiterverwendet.

Abbildung 5.4 zeigt den Gesamtscore-Vergleich nach GT-Urteil eingefärbt. Die Konfusionsmatrix in Abbildung 5.5 macht sichtbar, dass beide Fehlklassifikationen an der Schwelle *gut/mittel* liegen, keine an der Schwelle *mittel/schlecht* – der Prototyp verwechselt auf der Kernstichprobe ausschließlich benachbarte Qualitätsstufen.




Abbildung 5.4: Modell- vs. Ground-Truth-Gesamturteil, eingefärbt nach GT-Urteil (Kernstichprobe, $n = 50$)

Ground-Truth-Urteil	schlecht -	1	0	0
	mittel -	0	42	2
	gut -	0	2	3
		schlecht	mittel	gut
		Modell-Urteil		

Abbildung 5.5: Konfusionsmatrix des Gesamturteils (Kernstichprobe, $n = 50$)

5.7.2 Extremfälle (n=20)

Auf den konstruierten Extremfällen liegt die Gesamtkorrelation mit $\rho = 0,827$ über der Kernstichprobe (0,765) – erwartbar, da die Stichprobe bewusst auf maximale Trennschärfe

zwischen guten und schlechten Datensätzen angelegt ist (Abschnitt 5.2). Auffindbarkeit und Wiederverwendbarkeit erreichen hier 90,3 % bzw. 91,0 % ihres jeweiligen Ceilings – praktisch das bei dieser Skalengranularität Erreichbare. Zugänglichkeit bleibt mit $\rho = 0,713$ nahezu identisch zur Kernstichprobe (0,712) und zeigt damit eine über beide Stichproben stabile Bewertungsgüte (Abbildung 5.6, Tabelle 5.6).




Abbildung 5.6: Spearman ρ je Qualitätsdimension, beobachtet vs. Ceiling (Extremfälle, $n = 20$)

Dimension	ρ beobachtet	ρ Ceiling	Anteil	GT-Stufen
Auffindbarkeit	0,874	0,967	90,3 %	5
Zugänglichkeit	0,713	0,978	72,9 %	5
Wiederverwendbarkeit	0,872	0,957	91,0 %	6
Aussagekraft	0,321	0,942	34,1 %	4

Tabelle 5.6: Ceiling-Analyse je Dimension (Extremfälle, $n = 20$).

Aussagekraft fällt dagegen auf $\rho = 0,321$ – deutlich unter den Wert der Kernstichprobe (0,569) und mit nur 34,1 % des eigenen Ceilings (0,942) der mit Abstand am wenigsten ausgeschöpfte Wert der gesamten Auswertung. Die Ceiling-Analyse schließt Skalen- oder Stichprobenartefakte hier explizit aus: Selbst ein perfekt monotones Modell könnte auf dieser Ground-Truth-Verteilung ein ρ von 0,942 erreichen.

Der Blick auf die Indikatorebene liefert die Erklärung. Die Aussagekraft wird als ungewichteter Mittelwert aus sechs vom Sprachmodell bewerteten Teilkriterien gebildet (Abschnitt 4.5). Bei dem Metadatensatz `bad_09.rdf` etwa bewertet das Modell die Beschreibungsqualität als FAIL (0,15) mit der Begründung, die Beschreibung bestehe nur aus dem einzelnen Wort „Justizblatt“ und erkläre weder Inhalt noch Struktur der Ressource. Die übrigen fünf Teilkriterien liegen bei 0,65 bis 0,95, sodass der ge-

mittelte Dimensionswert bei 0,72 landet – ein einzelnes hartes Defizit wird durch fünf unauffällige Werte praktisch neutralisiert. Bei zehn der zwanzig Extremfälle weicht das resultierende dreistufige Urteil deshalb vom menschlichen ab (Genauigkeit 50 %), wobei sich die Fehlklassifikationen auf einen wiederkehrenden Effekt zurückführen lassen: Der Modell-Aussagekraftswert bewegt sich in praktisch allen Fällen in einem schmalen Band zwischen 3,3 und 4,3 auf der 0–5-Skala, unabhängig davon, ob die menschliche Bewertung bei 1 oder bei 4 liegt – etwa bei `bad_09.rdf` selbst (GT = 1, Modell = 3,6) oder `good_02.rdf` (GT = 2, Modell = 3,8). Die flache Mittelung komprimiert damit die tatsächliche Streubreite der Aussagekraft in einen Bereich, der weder erkennbar schlechte noch erkennbar gute Texte klar heraushebt.

Trotz dieser Schwäche auf Dimensionsebene trennt der Gesamtscore die beiden Konstruktionsgruppen deutlich: Datensätze mit der Konstruktionsabsicht *gut* erreichen im Mittel 4,06 (Skala 0–5), solche mit der Absicht *schlecht* 2,10 (Abbildung 5.7) – der Wirkmechanismus funktioniert also auf Ebene des Gesamturteils, weil die drei übrigen, überwiegend gut funktionierenden Dimensionen das einzelne schwache Signal im Gesamtmix aus vier gleich gewichteten Eingangsdimensionen abfedern. Die Disattenuationskorrektur bestätigt dieses Bild mit einem plausiblen, nicht gekappten Wert von 0,959 bei Cronbachs α von 0,890 (GT) bzw. 0,837 (Modell) – anders als bei der Kernstichprobe korrelieren die vier Dimensionen hier stark genug untereinander, um eine belastbare Korrektur zuzulassen, weil konstruiert gute bzw. schlechte Datensätze tendenziell in allen vier Dimensionen gemeinsam ausschlagen.




Abbildung 5.7: Modell-Gesamtscore nach Konstruktionsabsicht (Extremfälle, $n = 20$)

Für das Aussagekraftskriterium folgt daraus eine Limitation der Aggregationslogik, nicht des zugrunde liegenden Sprachmodellurteils selbst: Die einzelnen Teilkriterien differenzieren sichtbar, der Boxplot in Abbildung 5.10 zeigt das für dieselbe Kernstichprobe, ihre ungewichtete Mittelung verschluckt jedoch punktuelle harte Defizite.

5.8 Ergebnisse: Prototyp und MQA im Vergleich

Dieser Abschnitt prüft die in Abschnitt 5.1 formulierten Hypothesen H1 und H2 anhand der A/B/C-Klassifikation aus Abschnitt 5.3 und schließt mit der Triangulation gegen die Ground Truth (H3), die beide Evidenzstränge dieses Kapitels zusammenführt. Die MQA-Seite ist rein deterministisch und probe-basiert und daher vom Prototyp-Modell unabhängig; die Prototyp-Seite verwendet – wie in Abschnitt 5.7 – durchgängig GPT-5.5.

5.8.1 Kernstichprobe (n=50)

Auf den 9 Klasse-A-Indikatoren, die im Kern dasselbe prüfen wie eine MQA-Metrik, stimmen beide Verfahren in 96,0 % der 450 Datei-Indikator-Paare überein (Abbildung 5.8): 298-mal sind beide PASS, 134-mal beide FAIL. Die verbleibenden 18 Fälle sind mit 17 gegen 1 stark asymmetrisch verteilt – MQA vergibt deutlich häufiger einen Pass, den der Prototyp verweigert, als umgekehrt. Diese hohe Konvergenz bei gleichzeitig asymmetrischer Restabweichung stützt H1 (konvergente Validität auf äquivalenten Prüfungen) und deutet zugleich bereits die in H2 erwartete Richtung an.




Abbildung 5.8: Konvergenz auf Klasse-A-Indikatoren (Kernstichprobe, $n = 450$ Datei-Indikator-Paare)

Auf den 9 Klasse-B-Indikatoren, bei denen die MQA Vorhandensein honoriert und der Prototyp zusätzlich Gültigkeit oder Kongruenz prüft, überschätzt die MQA in 71 von 450 Fällen (15,8 %) die tatsächliche Qualität (Abbildung 5.9). Der stärkste Einzelbefund be-

trifft die politische Geokodierung: Bei 56 % der Datensätze (28 von 50) vergibt die MQA einen PASS wegen bloßer Existenz, während der Prototyp die tatsächliche Gültigkeit prüft und verweigert. Auf den Klasse-C-Indikatoren, für die die MQA strukturell keine Metrik besitzt, streut der Prototyp-Score sichtbar (Abbildung 5.10): Die Beschreibungsqualität etwa variiert von 0 bis 0,9 (Mittelwert 0,46, Standardabweichung 0,22) – ein Beleg, dass der Prototyp hier tatsächlich differenziert, statt konstruktiv flach zu bleiben, wie es die MQA an dieser Stelle per Design ist.




Abbildung 5.9: Überschätzungsrate je Klasse-B-Indikator: Anteil MQA PASS & Prototyp FAIL (Kernstichprobe)




Abbildung 5.10: Prototyp-Score-Verteilung auf Klasse-C-Indikatoren, für die die MQA keine Metrik besitzt (Kernstichprobe)

Auf Ebene der Gesamtscores korrelieren beide Systeme mit $\rho = 0,829$ stark (Ab-

bildung 5.11); die mittlere Differenz beträgt nur $-0,022$ Skalenpunkte zwischen Prototyp und MQA. Diese geringe Niveauverschiebung bei gleichzeitig hoher Rangkorrelation ist konsistent mit dem Befund aus Klasse A und B: Der Prototyp bewertet überwiegend dieselben Datensätze strenger, nicht andere Datensätze anders – eine Rangvertauschung, die ρ senken würde, findet kaum statt. Die B- und C-Befunde zeigen jedoch, dass diese Ähnlichkeit im Aggregat reale Messunterschiede auf Indikatorebene überdeckt, die erst im nächsten Abschnitt (H3) sichtbar werden.




Abbildung 5.11: Gesamtscore Prototyp vs. MQA (Kernstichprobe, $n = 50$)

5.8.2 Extremfälle ($n=20$)

Auf den Extremfällen fällt die Konvergenz mit 95,6 % ($n = 180$) ähnlich hoch aus wie auf der Kernstichprobe, die Asymmetrie ist hier jedoch vollständig einseitig (Abbildung I.1): In 8 Fällen vergibt die MQA einen Pass, den der Prototyp verweigert, in keinem einzigen Fall ist es umgekehrt. Die Überschätzungsrate steigt auf 20,0 % (36 von 180 Klasse-B-Fällen); dominierend ist hier die Lizenz: Bei 50 % der Datensätze (10 von 20) bewertet die MQA die Lizenzangabe als ausreichend, während der Prototyp sie als ungültig oder unfrei einstuft – naheliegend, da unter den Extremfällen gezielt Datensätze mit unter anderem fehlerhaften oder unklaren Lizenzangaben gewählt wurden (Abschnitt 5.2). Die Klasse-C-Indikatoren zeigen auch hier durchgängige Streuung, etwa bei der Verfügbarkeitsangabe (Standardabweichung 0,36) und der Geokodierungs-

stufe (0,48). Auf Ebene der Gesamtscores liegt die Rangkorrelation beider Verfahren bei $\rho = 0,820$ und die mittlere Differenz bei $-0,036$ Skalenpunkten – beides nahe an den Werten der Kernstichprobe.

Die zugehörigen Abbildungen finden sich vollständig in Anhang I.

5.8.3 Triangulation gegen die Ground Truth (H3)

Die bisherigen Befunde belegen, dass Prototyp und MQA unterschiedlich messen (H2), nicht aber, welches Verfahren näher an der tatsächlichen Qualität liegt. Dafür werden beide Gesamtscores, unabhängig voneinander, gegen dieselbe Ground Truth korreliert. Anders als in Abschnitt 5.7, wo je Dimension die *eigene* Modell-Teilbewertung gegen die gleichnamige GT-Dimension korreliert wird (Abbildung 5.3), steht auf der Prototyp-Seite in diesem Abschnitt durchgehend der *globale* Gesamtscore. Dieselbe eine Zahl, die auch dem Scatter in Abbildung 5.11 zugrunde liegt. Die Zeile „Auffindbarkeit“ misst hier also nicht die Güte der Auffindbarkeits-Teilbewertung selbst, sondern wie gut der *Gesamtscore* die menschliche Auffindbarkeits-Einschätzung vorhersagt. Diese Wahl ist notwendig, weil die MQA über keine mit den Prototyp-Dimensionen vergleichbaren Teilscores verfügt und ein fairer Vergleich beider Systeme deshalb nur auf Ebene des jeweiligen Gesamtscores möglich ist.

Auf der Kernstichprobe liegt der Prototyp-Gesamtscore bei fünf von sechs Zielen vorn: gesamt (0,779 vs. 0,740), ohne Aussagekraft (0,695 vs. 0,671), Zugänglichkeit (0,591 vs. 0,569), Wiederverwendbarkeit (0,457 vs. 0,426) und Aussagekraft (0,682 vs. 0,611) – Abstände von durchweg 0,02 bis 0,07 (Abbildung 5.12). Einzige Ausnahme ist die Auffindbarkeit, auf der die MQA vorn liegt (0,252 vs. 0,134). Ein naheliegender Grund liegt in der Gewichtung des Gesamtscores (Abschnitt 4.6.3, Tabelle 4.5): Auffindbarkeit geht mit dem niedrigsten Dimensionsgewicht (1,0 gegenüber 1,5 bis 2,0 bei den übrigen drei Dimensionen) in den Gesamtscore ein und prägt ihn folglich am wenigsten. Damit ist der Gesamtscore strukturell ein schwächerer Prädiktor gerade für diese GT-Dimension, unabhängig von der inhaltlichen Prüfgüte der Auffindbarkeitsindikatoren selbst. Diese liegt laut Abbildung 5.3 mit $\rho = 0,524$ im Mittelfeld der vier Dimensionen.

Auf den Extremfällen fällt der Befund eindeutiger aus: Der Prototyp liegt hier auf *allen sechs* Zielen vorn, mit deutlich größeren Abständen als auf der Kernstichprobe (+0,08 bis +0,15. Auch bei der Auffindbarkeit, wo die Kernstichprobe die einzige Ausnahme zugunsten der MQA zeigte (0,755 vs. 0,671). Das ist plausibel da die Extremfälle gezielt so selektiert wurden, dass sich Feldpräsenz und tatsächliche Validität auseinanderentwickeln (Abschnitt 5.2). Damit genau die Fälle, in denen sich der Vorteil vertiefender Prüfung am stärksten auszahlen sollte. Abbildung 5.12 und Abbildung 5.13 stellen beide Stichproben nebeneinander dar.




Abbildung 5.12: Triangulation gegen die Ground Truth: Spearman ρ von Prototyp und MQA je Zieldimension (Kernstichprobe, $n = 50$)




Abbildung 5.13: Triangulation gegen die Ground Truth: Spearman ρ von Prototyp und MQA je Zieldimension (Extremfälle, $n = 20$)

Ergänzend zeigt Abbildung 5.14 beide Systeme auf derselben Trennschärfe-Darstellung wie Abbildung 5.7, diesmal auf der gemeinsamen normalisierten 0–1-Skala. Bei den selektiert schlechten Datensätzen liegen beide Systeme mit 0,45 (MQA) und 0,44 (Prototyp) fast gleichauf. Bei den selektiert guten bewertet die MQA mit 0,88 etwas großzügiger als der Prototyp mit 0,82. Die absolute Spreizung zwischen den Gruppen fällt bei der MQA mit 0,44 Punkten sogar geringfügig größer aus als beim Prototyp (0,38). MQA ist auf den Extremfällen also nicht per se weniger trennscharf im Sinne der Score-Spannweite. Der entscheidende Unterschied liegt nicht in der Breite der Spreizung, sondern in ihrer Richtung relativ zur menschlichen Bewertung: Die Triangulation zeigt, dass die MQA-Scores trotz vergleichbarer oder sogar größerer Spreizung schlechter mit der Ground Truth rangkorrelieren als die des Prototyps. Das ist ein Beleg dafür, dass hohe Streuung allein noch keine korrekte Rangordnung garantiert.




Abbildung 5.14: Score-Trennschärfe von MQA und Prototyp nach Konstruktionsabsicht (Extremfälle, $n = 20$, normalisierte 0–1-Skala)

Zusammengenommen stützen die drei Evidenzstränge dieses Kapitels die eingangs formulierten Hypothesen konsistent: Auf äquivalenten Prüfungen konvergieren Proto-

typ und MQA mit über 95 % Übereinstimmung (H1). Indikatoren, die der Prototyp tiefer prüft, überschätzt die MQA in 16 bis 20 % der Fälle eine Qualität, die nicht gegeben ist, und differenziert dort, wo die MQA strukturell blind bleibt (H2). An Stellen wo beide Verfahren divergieren, liegt der Prototyp auf der Kernstichprobe in fünf von sechs, auf den Extremfällen in allen sechs Zielgrößen näher an der menschlichen Bewertung (H3). Die einzige Ausnahme, Auffindbarkeit auf der Kernstichprobe, relativiert diesen Befund, ohne ihn zu widerlegen: Sie zeigt, dass zusätzliche Prüftiefe nicht in jeder Dimension automatisch mit besserer menschlicher Übereinstimmung einhergeht.

5.9 Limitationen der Evaluation

6 Diskussion

6.1 Beitrag der Arbeit zur Metadatenqualitätsbewertung im GovData-Kontext

6.2 Bedeutung kontext- und semantikbezogener Prüfungen

6.3 Potenziale und Grenzen KI-gestützter Verfahren

6.4 Nachvollziehbarkeit als Gestaltungsziel des Qualitätsreportings

7 Fazit und Ausblick

7.1 Zusammenfassung der zentralen Ergebnisse

7.2 Beantwortung der Forschungsfragen

7.3 Limitationen

7.4 Weiterer Forschungs- und Entwicklungsbedarf

Abkürzungsverzeichnis

AD Aggregation Derivation.

AHP Analytic Hierarchy Process.

AI Artificial Intelligence.

CKAN Comprehensive Knowledge Archive Network.

CSV Comma-Separated Values.

DCAT Data Catalog Vocabulary.

DCAT-AP Data Catalog Vocabulary Application Profile.

DCAT-AP.de Data Catalog Vocabulary Application Profile for Germany.

DQV Data Quality Vocabulary.

FAIR Findable, Accessible, Interoperable, and Reusable.

FITKO Föderale IT-Kooperation.

GND Gemeinsame Normdatei.

HTTP Hypertext Transfer Protocol.

IANA Internet Assigned Numbers Authority.

IEC International Electrotechnical Commission.

ISO International Organization for Standardization.

KI Künstliche Intelligenz.

LOD Linked Open Data.

MQA Metadata Quality Assessment.

NISO National Information Standards Organization.

ODP Open Data Portal.

ODPQ Open Data Portal Quality.

OECD Organisation for Economic Co-operation and Development.

OGD Open Government Data.

RDF Resource Description Framework.

SHACL Shapes Constraint Language.

SKOS Simple Knowledge Organization System.

SPARQL SPARQL Protocol and RDF Query Language.

URI Uniform Resource Identifier.

URL Uniform Resource Locator.

W3C World Wide Web Consortium.

XML Extensible Markup Language.

Abbildungsverzeichnis

2.1	Schematische Darstellung inhärenter und systemabhängiger Datenqualitätsmerkmale in Anlehnung an ISO/IEC 25012.	17
4.1	Systemarchitektur und Datenfluss des Prototyps	53
4.2	Suchseite mit Qualitätsfacette links und Qualitätsring je Treffer	73
4.3	Aufgeklappter Befund zu einem nicht erfüllten Indikator	75
4.4	Die beiden Formen des Detailblocks: Vorlage und Fundstelle im Quelltext	76
4.5	Detailsicht eines Datensatzes mit Dimensionsprofil und Indikatorübersicht	78
4.6	Aggregatsicht über einen Datenbestand	79
5.1	Spearman-Rangkorrelation zur Ground Truth je Qualitätsdimension und Sprachmodell (Kernstichprobe, $n = 50$)	86
5.2	Spearman ρ der Aussagekraft über Wiederholungsläufe	89
5.3	Spearman ρ je Qualitätsdimension, beobachtet vs. Ceiling (Kernstichprobe, $n = 50$)	91
5.4	Modell- vs. Ground-Truth-Gesamturteil, eingefärbt nach GT-Urteil (Kernstichprobe, $n = 50$)	92
5.5	Konfusionsmatrix des Gesamturteils (Kernstichprobe, $n = 50$)	92
5.6	Spearman ρ je Qualitätsdimension, beobachtet vs. Ceiling (Extremfälle, $n = 20$)	93
5.7	Modell-Gesamtscore nach Konstruktionsabsicht (Extremfälle, $n = 20$)	94
5.8	Konvergenz auf Klasse-A-Indikatoren (Kernstichprobe, $n = 450$ Datei-Indikator-Paare)	95
5.9	Überschätzungsrate je Klasse-B-Indikator: Anteil MQA PASS & Prototyp FAIL (Kernstichprobe)	96
5.10	Prototyp-Score-Verteilung auf Klasse-C-Indikatoren, für die die MQA keine Metrik besitzt (Kernstichprobe)	96
5.11	Gesamtscore Prototyp vs. MQA (Kernstichprobe, $n = 50$)	97
5.12	Triangulation gegen die Ground Truth: Spearman ρ von Prototyp und MQA je Zieldimension (Kernstichprobe, $n = 50$)	99
5.13	Triangulation gegen die Ground Truth: Spearman ρ von Prototyp und MQA je Zieldimension (Extremfälle, $n = 20$)	99

5.14	Score-Trennschärfe von MQA und Prototyp nach Konstruktionsabsicht (Extremfälle, $n = 20$, normalisierte 0–1-Skala)	99
I.1	Konvergenz auf Klasse-A-Indikatoren (Extremfälle, $n = 180$ Datei-Indikator- Paare)	153
I.2	Überschätzungsrate je Klasse-B-Indikator: Anteil MQA PASS & Prototyp FAIL (Extremfälle)	153
I.3	Prototyp-Score-Verteilung auf Klasse-C-Indikatoren, für die die MQA kei- ne Metrik besitzt (Extremfälle)	154
I.4	Gesamtscore Prototyp vs. MQA (Extremfälle, $n = 20$)	154

Tabellenverzeichnis

2.1	Metadatatypen in Anlehnung an NISO, eigene Übersetzung und Para- phrase	12
2.2	FAIR-Prinzipien nach Wilkinson et al.	19
2.3	Qualitätsdimensionen und Metriken für Linked Data nach Zaveri et al.	21
2.4	Qualitätsdimensionen auf DCAT-Schlüsseln nach Neumaier et al.	22
2.5	MQA-Qualitätsmetriken und Gewichtungen nach Wentzel et al.	24
2.6	Modellierung von Quality Measurements und Quality Annotations nach Wentzel et al.	25
2.7	Kombinierte Übersicht der ISO-19157-Qualitätselemente, Scopes, Mea- sures und Evaluationsarten nach Noguera-Iso et al.	26
3.1	Deduktiv abgeleitete Hauptkategorien der Interviewauswertung	33
3.2	Auszug aus den induktiv entwickelten Unterkategorien	34
3.3	Auszug aus dem Kodierleitfaden	35
3.4	Zentrale Ergebnisse der Interviewauswertung	36
3.5	Longlist gebündelter Kandidatendimensionen	41
3.6	Verdichtung der Kandidatendimensionen zu finalen Qualitätsdimensionen	42
3.7	Kurzzeichen der Herleitungssignale in den Indikatortabellen	47
3.8	Auffindbarkeitsindikatoren	48
3.9	Zugänglichkeitsindikatoren	49
3.10	Nachnutzbarkeitsindikatoren	49
3.11	Aussagekraftsindikatoren	50

4.1	Zuordnung der Konzept-Kürzel zu den implementierten Indikator-Bezeichnern	57
4.2	Prüfregeln der Auffindbarkeitsindikatoren	58
4.3	Beitragsfunktionen der Zugänglichkeitsindikatoren	59
4.4	Prüfregeln der Nachnutzbarkeitsindikatoren	60
4.5	Dimensions- und Indikatorgewichte der evaluierten Konfiguration	67
4.6	Zielgruppen des Qualitätsreportings und ihr jeweiliger Auflösungsbedarf	71
5.1	Ankerfragen der manuellen Ground-Truth-Bewertung je Qualitätsdimension	82
5.2	Ableitung des Gesamturteils der Ground Truth aus den vier Dimensions- werten	83
5.3	Kennzahlenvergleich der Kandidatenmodelle	87
5.4	Reproduzierbarkeit über drei Wiederholungsläufe	90
5.5	Ceiling-Analyse der Kernstichprobe	91
5.6	Ceiling-Analyse der Extremfälle	93
G.1	Codierte Auswertungsmatrix der Experteninterviews	145

Literatur

- [1] Lnenicka et al. „Identifying patterns and recommendations of and for sustainable open data initiatives: a benchmarking-driven analysis of open government data initiatives among European countries“. In: *Government Information Quarterly* (2024). DOI: [10.1016/j.giq.2023.101898](https://doi.org/10.1016/j.giq.2023.101898).
- [2] FITKO. *GovData – Das Datenportal für Deutschland*. 2024. URL: <https://www.govdata.de/> (besucht am 05.03.2026).
- [3] FITKO. *GovData | FITKO*. Apr. 2026. URL: <https://www.fitko.de/produktmanagement/govdata> (besucht am 20.04.2026).
- [4] Barbara Ubaldi. *Open Government Data: Towards Empirical Analysis of Open Government Data Initiatives*. Techn. Ber. 22. OECD Publishing, 2013. DOI: [10.1787/5k46bj4f03s7-en](https://doi.org/10.1787/5k46bj4f03s7-en). URL: <https://dx.doi.org/10.1787/5k46bj4f03s7-en>.
- [5] OECD. *Open, Useful and Re-usable Data (OURdata) Index: 2019*. Techn. Ber. 1. OECD Publishing, 2020. DOI: [10.1787/45f6de2d-en](https://doi.org/10.1787/45f6de2d-en). URL: <http://dx.doi.org/10.1787/45f6de2d-en>.
- [6] Bundesministerium für Digitales und Staatsmodernisierung. *Open Data*. [Online; accessed 20. Apr. 2026]. Apr. 2026. URL: <https://bmds.bund.de/themen/digitale-wirtschaft/daten/open-data> (besucht am 20.04.2026).
- [7] Jenn Riley. *Understanding Metadata: What is Metadata, and What is it For? A Primer*. Baltimore: NISO, 2017. URL: <https://www.niso.org/publications/understanding-metadata-2017>.
- [8] World Wide Web Consortium. *Data Catalog Vocabulary (DCAT) – Version 3*. Techn. Ber. W3C, 2024. URL: <https://www.w3.org/TR/vocab-dcat-3/>.
- [9] DCAT-AP.de. *DCAT-AP.de – Start*. n.d. URL: <https://www.dcat-ap.de/> (besucht am 21.04.2026).
- [10] DCAT-AP.de. *DCAT-AP.de Spezifikation 2.0*. 2022. URL: <https://www.dcat-ap.de/def/dcatde/2.0/spec/> (besucht am 21.04.2026).
- [11] DCAT-AP.de. *DCAT-AP.de Spezifikation 3.0*. 2024. URL: <https://www.dcat-ap.de/def/dcatde/3.0/spec/> (besucht am 21.04.2026).

- [12] FITKO. *GovData – Föderales Entwicklungsportal*. n.d. URL: <https://docs.fitko.de/resources/govdata/> (besucht am 21. 04. 2026).
- [13] DCAT-AP.de. *DCAT-AP.de Konventionenhandbuch 2.0*. 2022. URL: <https://www.dcat-ap.de/def/dcatde/2.0/implRules/> (besucht am 21. 04. 2026).
- [14] World Wide Web Consortium. *RDF 1.1 Concepts and Abstract Syntax*. Techn. Ber. W3C, 2014. URL: <https://www.w3.org/TR/rdf11-concepts/> (besucht am 21. 04. 2026).
- [15] World Wide Web Consortium. *RDF 1.1 Concepts and Abstract Syntax*. Techn. Ber. W3C, 2014. URL: <https://www.w3.org/TR/rdf11-concepts/> (besucht am 06. 05. 2026).
- [16] World Wide Web Consortium. *SPARQL 1.1 Query Language*. Techn. Ber. W3C, 2013. URL: <https://www.w3.org/TR/sparql11-query/> (besucht am 06. 05. 2026).
- [17] World Wide Web Consortium. *Shapes Constraint Language (SHACL)*. Techn. Ber. W3C, 2017. URL: <https://www.w3.org/TR/shacl/> (besucht am 21. 04. 2026).
- [18] Jose Emilio Labra Gayo. *Linked Data Validation and Quality*. Topic Report. European Public Sector Information Platform, 2015. URL: https://data.europa.eu/sites/default/files/report/2015_linked_data_validation_and_quality.pdf.
- [19] Sebastian Neumaier, Jürgen Umbrich und Axel Polleres. „Automated Quality Assessment of Metadata Across Open Data Portals“. In: *Journal of Data and Information Quality* 8.1 (2016). DOI: [10.1145/2964909](https://doi.org/10.1145/2964909).
- [20] Amrapali Zaveri u. a. „Quality Assessment for Linked Data: A Survey“. In: *Semantic Web* 7.1 (2016), S. 63–93. DOI: [10.3233/SW-150175](https://doi.org/10.3233/SW-150175).
- [21] Richard Y. Wang und Diane M. Strong. „Beyond Accuracy: What Data Quality Means to Data Consumers“. In: *Journal of Management Information Systems* 12.4 (1996), S. 5–33.
- [22] Diane M. Strong, Yang W. Lee und Richard Y. Wang. „Data quality in context“. In: *Communications of the ACM* 40.5 (1997), S. 103–110.
- [23] Yair Wand und Richard Y. Wang. „Anchoring Data Quality Dimensions in Ontological Foundations“. In: *Communications of the ACM* 39.11 (1996), S. 86–95.
- [24] *ISO/IEC 25012:2008 Data Quality Model*. International Organization for Standardization, 2008.
- [25] Mark D. et al. Wilkinson. „The FAIR Guiding Principles for scientific data management and stewardship“. In: *Scientific Data* 3 (2016).

- [26] Sylvain Kubler u. a. „Comparison of Metadata Quality in Open Data Portals Using the Analytic Hierarchy Process“. In: *Government Information Quarterly* 35.1 (2018), S. 13–29. DOI: [10.1016/j.giq.2017.11.003](https://doi.org/10.1016/j.giq.2017.11.003).
- [27] data.europa.eu. *Metadata Quality Assessment Methodology: How data.europa.eu Measures the Quality of Harvested Metadata*. Accessed April 29, 2026. 2026. URL: <https://data.europa.eu/mqa/methodology?locale=en> (besucht am 29.04.2026).
- [28] Bianca Wentzel u. a. „An Extensive Methodology and Framework for Quality Assessment of DCAT-AP Datasets“. In: *Electronic Government*. Hrsg. von Ida Lindgren u. a. Bd. 14130. Lecture Notes in Computer Science. Cham: Springer, 2023, S. 262–278. DOI: [10.1007/978-3-031-41138-0_17](https://doi.org/10.1007/978-3-031-41138-0_17). URL: https://doi.org/10.1007/978-3-031-41138-0_17.
- [29] Javier Noguerras-Iso u. a. „Quality of Metadata in Open Data Portals“. In: *IEEE Access* 9 (2021), S. 60364–60382. DOI: [10.1109/ACCESS.2021.3073455](https://doi.org/10.1109/ACCESS.2021.3073455).
- [30] Thorsten Dresing und Thorsten Pehl. *Praxisbuch Interview, Transkription und Analyse: Anleitungen und Regelsysteme für qualitativ Forschende*. 8. Aufl. Marburg: Eigenverlag, 2018. URL: https://www.audiotranskription.de/wp-content/uploads/2020/11/Praxisbuch_08_01_web.pdf.
- [31] Philipp Mayring. *Qualitative Content Analysis: Theoretical Foundation, Basic Procedures and Software Solution*. Klagensfurt: GESIS Leibniz Institute for the Social Sciences, 2014. URL: <https://www.ssoar.info/ssoar/handle/document/39517>.
- [32] Philipp Mayring. *Qualitative Inhaltsanalyse: Grundlagen und Techniken*. 12. Aufl. Weinheim: Beltz, 2015.
- [33] Riccardo Albertoni und Antoine Isaac. *Data on the Web Best Practices: Data Quality Vocabulary*. W3C Working Group Note. World Wide Web Consortium, Dez. 2016. URL: <https://www.w3.org/TR/vocab-dqv/> (besucht am 04.05.2026).
- [34] International Organization for Standardization. *ISO 19157-1:2023 Geographic Information – Data Quality – Part 1: General Requirements*. International Organization for Standardization, 2023. URL: <https://www.iso.org/standard/78900.html> (besucht am 04.05.2026).
- [35] Carolina Cortés Lasalle u. a. „Is SHACL Suitable for Data Quality Assessment?“. In: *Proceedings of the Workshop on Knowledge Graphs and Data Quality*. Verify venue and year before submission. 2025.

- [36] Tim Berners-Lee. *Linked Data. Design Issues*. 2006. URL: <https://www.w3.org/DesignIssues/LinkedData.html> (besucht am 04.05.2026).
- [37] Piveau. *piveau-metrics-score: Scoring.kt*. Quellcode des MQA-Scoring-Dienstes, Commit df994a17. URL: <https://gitlab.com/piveau/metrics/piveau-metrics-score/-/blob/df994a1764462b48bf96dfe54f20e2ad2d26011e/src/main/kotlin/io/piveau/metrics/Scoring.kt> (besucht am 07.07.2026).
- [38] oc.bydata – open bydata competence center. *Handreichung zur Verbesserung der Metadatenqualität von offenen Daten*. Stand 12/2025, herausgegeben von der byte – Bayerische Agentur für Digitales GmbH. 2025. URL: <https://open.bydata.de/> (besucht am 06.07.2026).
- [39] data.europa.eu. *Data Quality Guidelines*. Publications Office of the European Union; Klassifikation maschinenlesbarer Dateitypen (Table 5). 2024. URL: <https://op.europa.eu/webpub/op/data-quality-guidelines/en/> (besucht am 08.07.2026).
- [40] Michela Nardo u. a. *Handbook on Constructing Composite Indicators: Methodology and User Guide*. Paris: OECD Publishing, 2008. DOI: [10.1787/9789264043466-en](https://doi.org/10.1787/9789264043466-en).
- [41] World Wide Web Consortium. *The Nu Html Checker*. Konformitätsprüfdienst des W3C für HTML; Meldungsformat dokumentiert unter <https://github.com/validator/validator/wiki/Output-%C2%BB-JSON>. 2026. URL: <https://validator.w3.org/nu/> (besucht am 28.07.2026).
- [42] World Wide Web Consortium. *W3C CSS Validation Service*. 2026. URL: <https://jigsaw.w3.org/css-validator/> (besucht am 28.07.2026).
- [43] Ben Shneiderman. „The Eyes Have It: A Task by Data Type Taxonomy for Information Visualizations“. In: *Proceedings of the 1996 IEEE Symposium on Visual Languages*. Boulder, CO: IEEE Computer Society, 1996, S. 336–343. DOI: [10.1109/VL.1996.545307](https://doi.org/10.1109/VL.1996.545307).
- [44] Stephen Few. *Information Dashboard Design: The Effective Visual Communication of Data*. Sebastopol, CA: O'Reilly Media, 2006. ISBN: 978-0-596-10016-2.
- [45] World Wide Web Consortium. *Web Content Accessibility Guidelines (WCAG) 2.2*. W3C Recommendation. W3C, 2023. URL: <https://www.w3.org/TR/WCAG22/> (besucht am 28.07.2026).
- [46] Gustavo M. Machado, Manuel M. Oliveira und Leandro A. F. Fernandes. „A Physiologically-Based Model for Simulation of Color Vision Deficiency“. In: *IEEE Transactions on Visualization and Computer Graphics* 15.6 (2009), S. 1291–1298. DOI: [10.1109/TVCG.2009.113](https://doi.org/10.1109/TVCG.2009.113).

- [47] Donald T. Campbell und Donald W. Fiske. „Convergent and Discriminant Validation by the Multitrait-Multimethod Matrix“. In: *Psychological Bulletin* 56.2 (1959), S. 81–105. DOI: [10.1037/h0046016](https://doi.org/10.1037/h0046016).
- [48] Carolyn C. Preston und Andrew M. Colman. „Optimal Number of Response Categories in Rating Scales: Reliability, Validity, Discriminating Power, and Respondent Preferences“. In: *Acta Psychologica* 104.1 (2000), S. 1–15. DOI: [10.1016/S0001-6918\(99\)00050-5](https://doi.org/10.1016/S0001-6918(99)00050-5).
- [49] Anders Jonsson und Gunilla Svingby. „The Use of Scoring Rubrics: Reliability, Validity and Educational Consequences“. In: *Educational Research Review* 2.2 (2007), S. 130–144. DOI: [10.1016/j.edurev.2007.05.002](https://doi.org/10.1016/j.edurev.2007.05.002).
- [50] Robert Glaser. „Instructional Technology and the Measurement of Learning Outcomes: Some Questions“. In: *American Psychologist* 18.8 (1963), S. 519–521. DOI: [10.1037/h0049294](https://doi.org/10.1037/h0049294).
- [51] Hillel J. Einhorn. „Use of Nonlinear, Noncompensatory Models as a Function of Task and Amount of Information“. In: *Organizational Behavior and Human Performance* 6.1 (1971), S. 1–27. DOI: [10.1016/0030-5073\(71\)90031-6](https://doi.org/10.1016/0030-5073(71)90031-6).
- [52] data.europa.eu. *Metadata Quality Assessment (MQA) — Data Quality Guidelines*. <https://op.europa.eu/webpub/op/data-quality-guidelines/en/>. Publications Office of the European Union, accessed 2026-06-16. 2024.
- [53] Lee J. Cronbach und Paul E. Meehl. „Construct Validity in Psychological Tests“. In: *Psychological Bulletin* 52.4 (1955), S. 281–302. DOI: [10.1037/h0040957](https://doi.org/10.1037/h0040957).
- [54] Alvan R. Feinstein und Domenic V. Cicchetti. „High Agreement but Low Kappa: I. The Problems of Two Paradoxes“. In: *Journal of Clinical Epidemiology* 43.6 (1990), S. 543–549. DOI: [10.1016/0895-4356\(90\)90158-L](https://doi.org/10.1016/0895-4356(90)90158-L).
- [55] Ted Byrt, Janet Bishop und John B. Carlin. „Bias, Prevalence and Kappa“. In: *Journal of Clinical Epidemiology* 46.5 (1993), S. 423–429. DOI: [10.1016/0895-4356\(93\)90018-V](https://doi.org/10.1016/0895-4356(93)90018-V).
- [56] OpenRouter. *AI Model Rankings – Top models by task*. Rangliste der je Aufgabentyp meistgenutzten Modelle, gemessen am Anteil an den auf der Plattform abgerechneten Ausgaben. Die Seite wird fortlaufend aktualisiert; der angegebene Stand bezieht sich auf das Abrufdatum. 2026. URL: <https://openrouter.ai/rankings#task-spend> (besucht am 16.07.2026).

A Interviewleitfaden

Experteninterview-Leitfaden zum Thema

Qualitätsmessung von Metadaten nach DCAT-AP.de Standard

Ziel dieses Interviews ist es, ergänzend zur Fachliteratur Antworten auf Fragen aus der Perspektive von Experten zu erhalten.

Zum anderen soll das Interview dazu beitragen, diese Masterarbeit inhaltlich zu schärfen und mögliche Ansätze für die weitere Vertiefung zu identifizieren.

Da Sie sich intensiv mit Metadaten im Open-Data-Bereich beschäftigen, sind Sie aufgrund Ihrer Expertise eine besonders geeignete Ansprechperson für dieses Interview.

Geplante Dauer des Interviews: 40 – 60 Minuten

Das Interview wird aufgezeichnet, um die Aussagen möglichst präzise transkribieren und auswerten zu können.

Dem Leitfaden beigelegt ist außerdem eine Datenschutzerklärung, die die pseudonymisierte Weiterverarbeitung der erhobenen Daten regelt.

In dieser Masterarbeit werden bestehende Ansätze zur Qualitätsmessung von Metadaten nach dem Standard DCAT AP.de analysiert. Darauf aufbauend soll ein innovativer Ansatz entwickelt und prototypisch implementiert werden, der erkannte Schwächen bestehender Verfahren adressiert und eine präzisere sowie aussagekräftigere Qualitätsanalyse ermöglicht.

Ein besonderer Fokus liegt auf der Frage, inwiefern Agentive AI zur Weiterentwicklung solcher Ansätze beitragen kann.

Die zentrale Forschungsfrage lautet, wie ein transparentes und praxisrelevantes Bewertungsmodell für Metadaten nach DCAT AP.de im GovData Kontext entwickelt werden kann, das formale Validierungsergebnisse mit KI gestützten Analyseverfahren kombiniert.

Das Interview dient nicht nur dazu, die inhaltliche Ausrichtung der Masterarbeit weiter zu schärfen. Es soll auch aktuelle Herausforderungen bei der Qualitätsmessung von Metadaten identifizieren und das Verbesserungspotenzial bestehender Methoden sowie möglicher KI-gestützter Ansätze besser einordnen.

Einleitung

Wie lange arbeiten Sie bereits im OpenData Umfeld und was ist Ihre genaue Berufsbezeichnung?

Was gehört zu Ihren täglichen Aufgaben?

Die perfekten Metadaten

1. Wie sieht Ihrer Meinung nach der perfekte Metadatensatz aus? Bringen Sie gerne einen Beispieldatensatz mit.

- a. An welchen Kriterien bewerten Sie einen Metadatensatz als perfekt?
- b. Haben Sie konkrete Beispiele von schlechten Metadaten auf GovData, die sich eventuell für das Testen eines Prototyps eignen würden? Bringen Sie gerne einen Beispieldatensatz mit.

Bestehende Ansätze für Metadata-Quality-Scores und die Rolle von SHACL

2. Was fehlt Ihrer Meinung nach in den aktuellen Ansätzen der Metadata-Quality-Scores?

- a. Können Sie die aktuellen Ansätze kurz einordnen, zum Beispiel den Ansatz von Piveau welcher im Datenportal “data.europa.eu” genutzt wird und den darauf aufbauenden Schweizer Ansatz?
- b. Welche Qualitätskriterien sollte ein Scoring auf jeden Fall enthalten, damit es vollständiger und aussagekräftiger ist?
- c. Inwiefern kann das DCAT-AP.de-SHACL-Validationsergebnis in einem Qualitätsscoring wertvoll sein?
- d. Wie kann man das Validation Result am besten in ein Scoring integrieren, und welche Regeln beziehungsweise Teile der Ergebnisse halten Sie dabei für besonders wichtig?

Relevanz des eigentlichen Datensatzes

3. Inwiefern halten Sie den eigentlichen Datensatz für relevant für die Bewertung der Metadaten?

Potenziale von AI Agents

- 4. Inwiefern halten Sie Ansätze, die AI Agents in den Vordergrund rücken, für sinnvoll, um einen neuen Ansatz zu entwickeln oder bestehende Ansätze zu verbessern, zum Beispiel durch eine kontextsensitive Analyse der Metadaten?**
- a. Was wären Ihrer Meinung nach wichtige kontextsensitive Informationen, die ein Agent überprüfen sollte?
 - b. Gibt es Ihrer Meinung nach auch noch andere Anwendungsfälle, in denen AI Agents bei einem Scoring helfen könnten? (Abseits von kontextsensitivem Wissen)

Abschluss

- 5. Gibt es aus Ihrer Sicht einen wichtigen Aspekt zur Qualitätsmessung von Metadaten nach DCAT-AP.de, den wir bisher noch nicht angesprochen haben?
- 6. Welche Empfehlungen würden Sie mir für die weitere Ausarbeitung und Schwerpunktsetzung der Masterarbeit mitgeben?

Ich bedanke mich ganz herzlich bei Ihnen für das Interview.

B Induktiv entwickelte Unterkategorien

Code	induktive Unterkategorie	Belegstellen
K1 Qualitätsverständnis und ideale Metadaten		
K1.1	Mindestvalidität und Best Practice	I1.002–I1.004
K1.2	Qualität statt Quantität	I3.002–I3.003
K1.3	Metadaten als Inhalts- und Nutzungsvorschau	I3.005
K1.4	semantischer Graph als Idealform	I2.003–I2.006
K2 Vollständigkeit, Reichhaltigkeit und Feldrelevanz		
K2.1	relative Vollständigkeit	I2.026
K2.2	empfohlene Felder über Pflichtfelder hinaus	I1.007–I1.010; I3.013
K2.3	fachlich vorhandene Informationen übernehmen	I2.004–I2.005
K2.4	relevante Felder statt maximale Feldanzahl	I3.002–I3.003
K3 Formale und syntaktische Qualität		
K3.1	DCAT-AP.de-Mindestvalidität	I1.002
K3.2	SHACL-Konformität als Basisdimension	I1.027–I1.029; I3.015
K3.3	URI- und Vokabularkorrektheit	I3.003; I3.018
K3.4	Trennung von fehlendem Feld und syntaktischem Fehler	I3.017
K3.5	XML/RDF-Validität und Datentypprüfung	I3.018
K4 Semantische und inhaltliche Qualität		
K4.1	nichtssagende oder zu kurze Titel	I2.008
K4.2	Titel-Beschreibung-Redundanz	I2.008
K4.3	regionale Begriffe und Fachsprache	I2.009–I2.010; I1.043
K4.4	verständliche und erklärende Beschreibung	I2.027; I3.005
K4.5	inhaltliche Widersprüche zwischen Metadatenfeldern	I2.011; I2.047
K4.6	Keywords, Themenfeld und Kategorie als semantische Prüffelder	I1.041; I3.028
K5 Technische Zugänglichkeit, Aktualität und Nutzbarkeit		
K5.1	Dead Links und Linkrot	I1.015; I2.011
K5.2	funktionierende Distributions-, Download- und Servicelinks	I1.015; I2.028
K5.3	Aktualität und Harvesting-Zeitpunkt	I1.019; I1.024–I1.025
K5.4	Maschinenlesbarkeit und nicht-proprietäre Formate	I3.021
K6 Interoperabilität und Linked-Data-Qualität		
K6.1	URI statt Literal	I1.020–I1.022
K6.2	externe Referenzsysteme, Wikidata und GND	I2.005; I1.022
K6.3	kontrollierte Vokabulare und Thesauri	I2.005; I2.055; I3.018
K6.4	Querverbindungen zwischen vergleichbaren Datensätzen	I2.006; I2.056
K6.5	Organisationsgraph und Vermeidung von Blank Nodes	I2.029
K7 Kontextsensitivität und Fit for Purpose		
K7.1	domänenspezifische Feldrelevanz	I1.006; I1.009–I1.010
K7.2	Geodaten und Normierungsgrad	I1.031–I1.033; I3.022
K7.3	föderale Vergleichbarkeit	I1.040
K7.4	Stakeholder-spezifische Qualitätsfragen	I1.047–I1.049
K7.5	unterschiedliche Perspektiven von Bereitstellenden und Nutzenden	I1.019
K8 Rohdatenbezug und Metadaten-Daten-Kongruenz		
K8.1	Formatkongruenz zwischen Metadaten und Ressource	I2.045; I3.020
K8.2	Serviceverhalten und tatsächliche Nutzbarkeit	I2.046
K8.3	Dateninhalt gegen Titel und Beschreibung prüfen	I2.047
K8.4	Bounding Box und Flächendeckung aus Daten ableiten	I2.013; I2.059
K8.5	fachliche Grenzen der Rohdatenbewertung	I3.022
K9 Scoring, Gewichtung, Reporting und Verbesserungshinweise		
K9.1	wissenschaftlich begründete Metriken	I2.021–I2.024
K9.2	SHACL als Teildimension statt Gesamtscore	I1.028–I1.029
K9.3	Teil-Scores zur Problemlokalisierung	I2.039–I2.040
K9.4	Ranking als Verbesserungsanreiz	I2.034–I2.037
K9.5	verständliche Fehlermeldungen und Handlungshinweise	I2.040–I2.041; I3.017
K10 KI-gestützte Analyseverfahren und Automatisierungsgrenzen		
K10.1	Metadaten-Linter	I1.039
K10.2	Freitextprüfung und Beschreibungsgüte	I1.035; I1.043–I1.044
K10.3	Keyword-Mapping und Assisted Learning	I1.041; I2.055–I2.056
K10.4	SPARQL- und Analyseunterstützung	I1.047–I1.049
K10.5	semantischer Graph als bessere KI-Grundlage	I2.052–I2.056
K10.6	Rohdatenanalyse durch KI	I2.058–I2.061; I3.024
K10.7	Datenhoheit bei automatisierter Verbesserung	I2.032; I3.026
K10.8	Halluzination, stochastische Ausreißer und fachliche Fehlinterpretation	I1.037; I1.046; I2.052
K10.9	Ressourcenaufwand und Betriebslast	I1.046; I2.062–I2.063

C Kodierleitfaden der Interviewauswertung

Code	Kategorie	Definition	Kodierregel	Ankerbeispiel / Modellbezug
K1 Qualitätsverständnis und ideale Metadaten				
K1.1	Mindestvalidität und Best Practice	Aussagen, die zwischen Mindestanforderungen und höherer Qualitätsstufe unterscheiden.	Codieren, wenn DCAT-AP.de-Validität, Pflichtenforderungen oder Best-Practice-Empfehlungen als Qualitätsstufen beschrieben werden.	Valide DCAT-AP.de-Lieferung als Minimalvoraussetzung; Best Practice als höhere Qualitätsstufe. Modellbezug: Trennung von Basiskonformität und Zusatzqualität.
K1.2	Qualität statt Quantität	Aussagen, die betonen, dass nicht möglichst viele, sondern die relevanten Felder in guter Qualität ausgefüllt sein sollten.	Codieren, wenn ein pragmatisches Qualitätsverständnis beschrieben wird, das relevante und sorgfältig gepflegte Felder höher bewertet als maximale Feldanzahl.	„Lieber Qualität statt Quantität.“ Modellbezug: keine reine Feldzählung als Qualitätsmaß.
K1.3	Metadaten als Inhalts- und Nutzungsvorschau	Aussagen, nach denen Metadaten Nutzenden vor dem Öffnen des Datensatzes eine fachliche und technische Einschätzung ermöglichen sollen.	Codieren, wenn Metadaten als Vorschau auf Inhalt, technische Verarbeitbarkeit oder Nutzungseignung beschrieben werden.	Metadaten sollen zeigen, was die Daten enthalten und ob sie technisch oder inhaltlich nutzbar sind. Modellbezug: Nutzendenorientierung als Qualitätsanforderung.
K1.4	Semantischer Graph als Idealform	Aussagen, die einen semantischen Graphen oder Linked-Data-Strukturen als Ideal hochwertiger Metadaten beschreiben.	Codieren, wenn Graphstruktur, Erweiterbarkeit, Entitäten oder semantische Modellierung als Ideal hochwertiger Metadaten genannt werden.	Ein perfekter Metadatensatz basiert auf DCAT-AP.de beziehungsweise einem semantischen Graphen. Modellbezug: Graphfähigkeit als übergeordnete Qualitätsanforderung.
K2 Vollständigkeit, Reichhaltigkeit und Feldrelevanz				
K2.1	Relative Vollständigkeit	Aussagen, die Vollständigkeit nicht absolut, sondern relativ zum fachlichen Kontext und zu grundlegenden Anforderungen verstehen.	Codieren, wenn gefragt wird, ob grundlegende Anforderungen und thematisch relevante Informationen vorhanden sind.	Metadaten können in einem Graphen nie vollständig sein; sinnvoll ist relative Vollständigkeit. Modellbezug: Vollständigkeit kontextsensitiv operationalisieren.
K2.2	Empfohlene Felder über Pflichtfelder hinaus	Aussagen, die betonen, dass DCAT-AP.de-Pflichtfelder allein für gute Metadaten nicht ausreichen.	Codieren, wenn empfohlene Felder, Soll-Kriterien oder optionale Angaben als qualitätssteigernd beschrieben werden.	Die Möglichkeiten von DCAT-AP.de sollten möglichst umfassend genutzt werden. Modellbezug: empfohlene Felder im Score berücksichtigen.
K2.3	Fachlich vorhandene Informationen übernehmen	Aussagen, die fordern, dass bereits vorhandene fachliche Informationen nicht verworfen werden.	Codieren, wenn vorhandene Ansprechpartner, fachliche Rollen, ergänzende Informationen oder domänenspezifische Angaben in Metadaten übernommen werden sollen.	Fachlich vorhandene Informationen, etwa mehrere Ansprechpartner im Geobereich, sollten nicht entfernt werden. Modellbezug: Reichhaltigkeit ohne Informationsverlust.
K2.4	Relevante Felder statt maximale Feldanzahl	Aussagen, die eine gezielte Auswahl relevanter Felder gegenüber vollständiger Befüllung aller DCAT-Felder bevorzugen.	Codieren, wenn nicht alle möglichen Felder, sondern die wichtigen Felder korrekt und sorgfältig ausgefüllt werden sollen.	Nicht alle circa 70 DCAT-Felder sind für jeden Datensatz sinnvoll. Modellbezug: Gewichtung nach Relevanz statt bloßer Feldanzahl.
K3 Formale und syntaktische Qualität				
K3.1	DCAT-AP.de-Mindestvalidität	Aussagen zur Erfüllung der Mindest- oder Pflichtenforderungen des DCAT-AP.de-Standards.	Codieren, wenn Standardkonformität als Basiskriterium oder Mindestvoraussetzung beschrieben wird.	DCAT-AP.de-Validität als Minimalvoraussetzung. Modellbezug: Basiskriterium formaler Qualität.
K3.2	SHACL-Konformität als Basisdimension	Aussagen zur Bedeutung von SHACL-Validierung für formale Qualitätsprüfung.	Codieren, wenn SHACL als Prüfung der Standardkonformität, Fehlerfreiheit oder syntaktischen Korrektheit beschrieben wird.	SHACL verbindet Feldvorhandensein und syntaktisch korrekte Ausfüllung. Modellbezug: formale Validierungsdimension.
K3.3	URI- und Vokabularkorrektheit	Aussagen zur korrekten Verwendung von URIs, kontrollierten Vokabularen und standardisierten Werten.	Codieren, wenn richtige URIs, Vokabulare oder normierte Wertelisten als formale Qualitätsanforderung genannt werden.	Korrekte URIs und Vokabulare als grundlegende Prüfung. Modellbezug: syntaktisch-formaler Indikator.
K3.4	Trennung von fehlendem Feld und syntaktischem Fehler	Aussagen, die unterschiedliche formale Fehlerarten voneinander trennen.	Codieren, wenn gefordert wird, dass fehlende Felder und falsch ausgefüllte Felder getrennt ausgewiesen werden.	Es soll klar sein, ob ein Problem syntaktisch ist oder ob ein Feld fehlt. Modellbezug: differenzierte Fehlerklassen.
K3.5	XML/RDF-Validität und Datentypprüfung	Aussagen zur technischen Validität von XML, RDF, Datentypen oder strukturellen Formaten.	Codieren, wenn valides XML, RDF-Struktur, Datumsformate, Datentypen oder technische Formatvalidität thematisiert werden.	Valides XML, korrekte URIs und Vokabulare als grundlegende Prüfungen. Modellbezug: technisch-syntaktische Prüflogik.
K4 Semantische und inhaltliche Qualität				
K4.1	Nichtssagende oder zu kurze Titel	Aussagen zu Titeln, die vorhanden sind, aber den Datensatz nicht ausreichend beschreiben.	Codieren, wenn Titel als zu kurz, generisch, mehrdeutig oder unverständlich beschrieben werden.	„Los 1“ als Titel ohne erkennbare Aussage. Modellbezug: semantischer Titelindikator.

Fortsetzung auf der nächsten Seite

Code	Kategorie	Definition	Kodierregel	Ankerbeispiel / Modellbezug
K4.2	Titel-Beschreibung-Redundanz	Aussagen, in denen die Beschreibung keinen eigenständigen Informationswert gegenüber dem Titel hat.	Codieren, wenn Titel und Beschreibung identisch oder nahezu identisch sind.	Titel und Beschreibung sind identisch; die Beschreibung liefert keinen Mehrwert. Modellbezug: Redundanzprüfung.
K4.3	Regionale Begriffe und Fachsprache	Aussagen zu sprachlichen Ausdrücken, die für Außenstehende schwer verständlich sind.	Codieren, wenn regionale Begriffe, Fachsprache, domänenspezifische Terminologie oder fehlende allgemeinverständliche Synonyme genannt werden.	„I-Dötzchen“ oder „eulitoral“ als schwer verständliche Begriffe. Modellbezug: Verständlichkeitsprüfung von Freitext.
K4.4	Verständliche und erklärende Beschreibung	Aussagen zur inhaltlichen Erklärungskraft von Beschreibungen.	Codieren, wenn eine Beschreibung den Inhalt der Daten verständlich erklären und Nutzenden Orientierung geben soll.	Beschreibung soll erklären, was die Daten enthalten und ob sie nutzbar sind. Modellbezug: semantische Beschreibungsqualität.
K4.5	Inhaltliche Widersprüche zwischen Metadatenfeldern	Aussagen zu unplausiblen oder widersprüchlichen Angaben innerhalb eines Metadatenatzes.	Codieren, wenn Titel, Herausgeber, Ort, Beschreibung, Kategorie oder andere Metadatenfelder inhaltlich nicht zusammenpassen.	Titel verweist auf Nürnberg, Herausgeber ist Köln. Modellbezug: Plausibilitätsprüfung zwischen Feldern.
K4.6	Keywords, Themenfeld und Kategorie als semantische Prüffelder	Aussagen, die Schlagwörter, Themenfelder oder Kategorien als relevante semantische Qualitätsmerkmale behandeln.	Codieren, wenn Keywords, Kategorien, Themenfelder oder Schlagworte hinsichtlich Passung, Mehrwert oder Mapping bewertet werden.	Keywords und Kategorien sollen den Inhalt passend beschreiben. Modellbezug: semantischer Indikator für thematische Passung.
K5 Technische Zugänglichkeit, Aktualität und Nutzbarkeit				
K5.1	Dead Links und Linkrot	Aussagen zu nicht mehr erreichbaren Links oder veralteten Ressourcenverweisen.	Codieren, wenn defekte URLs, Linkrot, nicht funktionierende Downloads oder nicht erreichbare Services genannt werden.	Distributionslink, Download oder Datenservice funktioniert nicht mehr. Modellbezug: Verfügbarkeitsindikator.
K5.2	Funktionierende Distributions-, Download- und Servicelinks	Aussagen zur Erreichbarkeit und Nutzbarkeit von Zugriffspfaden.	Codieren, wenn funktionierende Download-URLs, Access-URLs, Datenservices oder Distributionen als Qualitätsanforderung genannt werden.	Nutzende sollen leicht zu den beschriebenen Datensätzen gelangen. Modellbezug: technische Zugänglichkeit.
K5.3	Aktualität und Harvesting-Zeitpunkt	Aussagen zu Alter, Aktualität, Harvesting-Datum oder Katalog-Metadaten.	Codieren, wenn Aktualität, letzter Harvesting-Zeitpunkt, Catalog Records oder Pflegezustand als Qualitätsindikator beschrieben werden.	Harvesting-Datum kann zeigen, dass ein Eintrag dem letzten Stand entspricht. Modellbezug: Aktualitäts- und Pflegeindikator.
K5.4	Maschinenlesbarkeit und nicht-proprietäre Formate	Aussagen zur technischen Weiterverarbeitbarkeit von Ressourcenformaten.	Codieren, wenn maschinenlesbare, offene, nicht-proprietäre oder gut lesbare Formate als Nutzbarkeitsanforderung genannt werden.	Bereitstellende fragen nach gut lesbaren und nicht-proprietären Dateiformaten. Modellbezug: Open-Data-Fitness.
K6 Interoperabilität und Linked-Data-Qualität				
K6.1	URI statt Literal	Aussagen, die maschineninterpretierbare Identifikatoren gegenüber Freitextangaben bevorzugen.	Codieren, wenn ein URI-, ID- oder Entitätsverweis als verlässlicher oder hochwertiger als ein Literal beschrieben wird.	Eine GND-ID ist verlässlicher als ein Organisationsname als Freitext. Modellbezug: Linked-Data-Reifegrad.
K6.2	Externe Referenzsysteme, Wikidata und GND	Aussagen zu externen Normdaten und Wissenssystemen als Verknüpfungsressourcen.	Codieren, wenn Wikidata, GND oder andere externe Referenzsysteme zur Anreicherung oder Identifikation genannt werden.	Verknüpfungen zu Wikidata oder Gemeinsamer Normdatei. Modellbezug: externe semantische Referenzierung.
K6.3	Kontrollierte Vokabulare und Thesauri	Aussagen zur Verwendung kontrollierter Vokabulare, Thesauri oder standardisierter Begriffssysteme.	Codieren, wenn Thesauri, EU-Vokabulare, UBA-Thesaurus oder kontrollierte Schlagwortssysteme genannt werden.	Thesauri können Fachbegriffe beschreiben und Kontext erschließen. Modellbezug: Interoperabilität und semantische Harmonisierung.
K6.4	Querverbindungen zwischen vergleichbaren Datensätzen	Aussagen zu Verknüpfungen zwischen ähnlichen oder gleichen Datensätzen.	Codieren, wenn gleiche, ähnliche oder vergleichbare Datensätze über Portale, Kommunen oder Domänen hinweg verknüpft werden sollen.	Querverbindungen zwischen vergleichbaren Datensätzen aus Kommunen. Modellbezug: graphbasierte Vergleichbarkeit.
K6.5	Organisationsgraph und Vermeidung von Blank Nodes	Aussagen zur strukturierten Modellierung von Organisationen und zur Vermeidung schwacher RDF-Strukturen.	Codieren, wenn Organisationsgraph, Agentenmodellierung, Blank Nodes oder strukturelle Linked-Data-Qualität genannt werden.	Organisationen sollten sinnvoll über einen Organisationsgraphen abgebildet werden. Modellbezug: strukturelle RDF-Qualität.
K7 Kontextsensitivität und Fit for Purpose				
K7.1	Domänenspezifische Feldrelevanz	Aussagen, nach denen bestimmte Metadatenfelder je nach Fachdomäne unterschiedlich relevant sind.	Codieren, wenn Rollen, Relationen, Media Types, Geolocation oder andere Felder abhängig von Geodaten, Statistikdaten oder Fachdomänen bewertet werden.	Creator und Maintainer sind bei Geodaten relevanter als bei Statistikdaten. Modellbezug: kontextsensitive Gewichtung.
K7.2	Geodaten und Normierungsgrad	Aussagen zum besonderen Normierungsgrad und zur spezifischen Qualitätslogik von Geodaten.	Codieren, wenn Geodaten, ISO-Kontext, INSPIRE, GIS, Bounding Boxes oder normierte Fachstandards als besondere Domäne genannt werden.	Geodaten sind stark normiert und erleichtern hochwertige Metadaten. Modellbezug: Domänenspezifik im Modell.
K7.3	Föderale Vergleichbarkeit	Aussagen zu Qualitätsvergleichen zwischen Ländern, Kommunen oder föderalen Datenbereitstellern.	Codieren, wenn Schleswig-Holstein, Niedersachsen, Bayern, Länder- oder Kommunalvergleiche als Kontext für Bewertung genannt werden.	Abweichung zwischen Küstenländern kann Qualitätsproblem sein, zwischen Küstenland und Bayern nicht zwingend. Modellbezug: föderaler Kontext.
K7.4	Stakeholder-spezifische Qualitätsfragen	Aussagen, nach denen unterschiedliche Akteure unterschiedliche Qualitätsinteressen haben.	Codieren, wenn Qualitätsmetriken für Länder, Bund, Kommunen, Fachpersonen oder andere Stakeholder zugeschnitten werden sollen.	Mindestens 17 relevante Stakeholder haben zugeschnittene Qualitätsfragen. Modellbezug: konfigurierbare Qualitätsansichten.

Fortsetzung auf der nächsten Seite

Code	Kategorie	Definition	Kodierregel	Ankerbeispiel / Modellbezug
K7.5	Unterschiedliche Perspektiven von Bereitstellenden und Nutzenden	Aussagen, die Unterschiede zwischen Datenbereitstellenden und Datennutzenden betonen.	Codieren, wenn dieselbe Metadatenqualität aus Bereitstellenden- und Nutzendenperspektive unterschiedlich bewertet wird.	Ein alter Datensatz kann für Bereitstellende valide sein, für Nutzende aber verdächtig wirken. Modellbezug: perspektivenabhängige Interpretation.
K8 Rohdatenbezug und Metadaten-Daten-Kongruenz				
K8.1	Formatkongruenz zwischen Metadaten und Ressource	Aussagen zum Abgleich zwischen angegebenem Format und tatsächlicher Ressource.	Codieren, wenn geprüft werden soll, ob das in den Metadaten angegebene Format mit Datei, Service oder Inhalt übereinstimmt.	Metadaten geben CSV an, aber der Inhalt ist kein CSV; oder CSV hängt an, während PDF angegeben ist. Modellbezug: Kongruenzindikator.
K8.2	Serviceverhalten und tatsächliche Nutzbarkeit	Aussagen zum Abgleich zwischen erwartetem und tatsächlichem Verhalten von Services.	Codieren, wenn etwa WMS-/WFS-Dienste, APIs, XML-Fehlermeldungen oder erwartete Kartenansichten als Prüfgegenstand genannt werden.	Mensch erwartet eine Karte, bekommt aber eine XML-Fehlermeldung. Modellbezug: praktische Ressourcenvalidierung.
K8.3	Dateninhalt gegen Titel und Beschreibung prüfen	Aussagen, nach denen tatsächliche Dateninhalte gegen Metadatenangaben geprüft werden.	Codieren, wenn Titel, Beschreibung oder Themenangaben mit tatsächlichem Inhalt der Datei oder Ressource verglichen werden.	Titel sagt „Vornamen“, Datensatz enthält hauptsächlich Zahlen. Modellbezug: semantischer Rohdatenabgleich.
K8.4	Bounding Box und Flächendeckung aus Daten ableiten	Aussagen zu geodatenbezogenen Informationen, die aus den Daten selbst berechnet oder geprüft werden können.	Codieren, wenn Bounding Box, Flächendeckung oder räumliche Abdeckung aus Daten statt manueller Metadateneingabe abgeleitet werden sollen.	Bounding Box ist menschlich eingetragen und fehleranfällig; besser wäre Berechnung aus Daten. Modellbezug: datenbasierte Kontextprüfung.
K8.5	Fachliche Grenzen der Rohdatenbewertung	Aussagen zu Grenzen einer Bewertung des eigentlichen Datensatzes durch ein Metadatenportal.	Codieren, wenn fachliche Zuständigkeit, domänenspezifische Standards oder begrenzte Beratungskompetenz beim Rohdateninhalt thematisiert werden.	Metadatenportal kann Rohdatenqualität nur eingeschränkt fachlich beurteilen. Modellbezug: Begrenzung des Prüfanspruchs.
K9 Scoring, Gewichtung, Reporting und Verbesserungshinweise				
K9.1	Wissenschaftlich begründete Metriken	Aussagen, die eine theoretische, wissenschaftliche oder methodische Begründung von Qualitätsmetriken fordern.	Codieren, wenn kritisiert wird, dass Scores Kriterien messen, ohne zu begründen, warum diese Kriterien relevant sind.	Ein Score sollte belegen, warum genau diese Kriterien verwendet werden. Modellbezug: begründete Indikatorauswahl.
K9.2	SHACL als Teildimension statt Gesamtscore	Aussagen, die SHACL- oder DCAT-AP.de-Konformität als Teil, aber nicht als vollständiges Qualitätsurteil verstehen.	Codieren, wenn formale Validierung als eigene Dimension im Gesamtscore beschrieben wird.	DCAT-AP.de-Qualität sollte als eine Dimension im Gesamtscore angezeigt werden. Modellbezug: separater formaler Teilschritt.
K9.3	Teil-Scores zur Problemlokalisierung	Aussagen zur Aufteilung eines Scores in Dimensionen oder Teilbewertungen.	Codieren, wenn Teil-Scores, Kategorien oder getrennte Bewertungsbereiche zur Diagnose von Problemen gefordert werden.	Teilbewertungen helfen zu erkennen, wo genau ein Problem liegt. Modellbezug: multidimensionaler Report.
K9.4	Ranking als Verbesserungsanreiz	Aussagen zur Nutzung von Rankings oder regelmäßigen Prüfungen zur Qualitätsverbesserung.	Codieren, wenn Länder, Kommunen oder Portale sich vergleichen und daraus Verbesserungsbedarf ableiten sollen.	Rankings können zeigen, wo Luft nach oben besteht. Modellbezug: Benchmarking, aber mit Vorsicht.
K9.5	Verständliche Fehlermeldungen und Handlungshinweise	Aussagen zur Verständlichkeit und praktischen Nutzbarkeit von Validierungs- oder Qualitätsreports.	Codieren, wenn Fehler erklärt, konkret lokalisiert oder mit Verbesserungshinweisen versehen werden sollen.	Eine reine Fehlermeldung ist wenig hilfreich; es braucht Erklärung und Behebungshinweis. Modellbezug: handlungsorientiertes Reporting.
K10 KI-gestützte Analyseverfahren und Automatisierungsgrenzen				
K10.1	Metadaten-Linter	Aussagen zu KI- oder regelgestützten Systemen, die Metadaten prüfen und Hinweise geben.	Codieren, wenn ein Linter, Prüfwerkzeug oder Vorschlagssystem auf Basis von DCAT-AP.de, SHACL oder Spezifikation beschrieben wird.	Agentische KI als Metadaten-Linter. Modellbezug: unterstützende Qualitätsprüfung.
K10.2	Freitextprüfung und Beschreibungsgüte	Aussagen zur KI-gestützten Bewertung oder Verbesserung natürlicher Sprache in Metadaten.	Codieren, wenn Titel, Beschreibungen, einfache Sprache, Synonyme, Fachsprache oder Style Guides mit KI-Unterstützung geprüft werden.	KI kann Beschreibungstexte oder die Güte von Beschreibungstexten bewerten. Modellbezug: semantische Freitextanalyse.
K10.3	Keyword-Mapping und Assisted Learning	Aussagen zu KI- oder ML-gestützter Zuordnung von Stichworten zu Kategorien, Vokabularen oder Schlagwortsystemen.	Codieren, wenn einfache Freitext-Stichworte auf Kategorien, echte Schlagworte oder EU-Vokabulare gemappt werden sollen.	Assisted Learning kann qualitativ hochwertigere Keywords schaffen. Modellbezug: KI-gestützte Harmonisierung.
K10.4	SPARQL- und Analyseunterstützung	Aussagen zur KI-Unterstützung bei technischen Abfragen oder Analysebausteinen.	Codieren, wenn KI zur Erstellung spezifischer SPARQL-Queries, Filter oder Analysebausteine eingesetzt werden soll.	KI könnte Fachpersonen helfen, hochspezifische SPARQL-Queries zu entwickeln. Modellbezug: technische Assistenz statt Bewertungsautomat.
K10.5	Semantischer Graph als bessere KI-Grundlage	Aussagen, nach denen KI zuverlässiger arbeitet, wenn sie auf einem semantischen Graphen statt auf unstrukturierter Textbasis arbeitet.	Codieren, wenn Graphdaten, semantische Verknüpfungen oder externe Graphen als Grundlage für KI-Nutzung beschrieben werden.	Auf einem semantischen Graphen kann KI datenbasierter arbeiten und weniger halluzinieren. Modellbezug: graphbasierte Kontextgrundlage.
K10.6	Rohdatenanalyse durch KI	Aussagen zur KI-gestützten Analyse der tatsächlichen Ressourcen oder großer Datenmengen.	Codieren, wenn KI in die Daten selbst hineinschauen, Muster erkennen, Strukturen vergleichen oder Rohdaten gegen Metadaten prüfen soll.	KI kann große Datenmengen analysieren und Muster ableiten. Modellbezug: optionale kontextbezogene KI-Prüfung.

Fortsetzung auf der nächsten Seite

Code	Kategorie	Definition	Kodierregel	Ankerbeispiel / Modellbezug
K10.7	Datenhoheit bei automatisierter Verbesserung	Aussagen zu Verantwortung, Schreibrechten oder Zuständigkeit bei automatisierter Veränderung von Metadaten.	Codieren, wenn gefragt wird, wer Metadaten ändern, korrigieren oder anreichern darf.	Wer hat die Hoheit über die Daten, wenn KI etwas verbessert oder verändert? Modellbezug: KI nur als Analyse- oder Empfehlungsebene.
K10.8	Halluzination, stochastische Ausreißer und fachliche Fehlinterpretation	Aussagen zu Unsicherheit, Fehleranfälligkeit, Halluzination oder fachlicher Fehlbewertung durch KI.	Codieren, wenn stochastische Ausreißer, Halluzinationen, Mehrdeutigkeiten oder falsche Vereinfachungen durch KI thematisiert werden.	KI kann „Watt“ nicht zuverlässig zwischen elektrischer Einheit und Wattenmeer unterscheiden. Modellbezug: keine autonome KI-Bewertungsinstanz.
K10.9	Ressourcenaufwand und Betriebslast	Aussagen zu Kosten, Rechenaufwand, Serverlast oder Betriebsvoraussetzungen KI-gestützter Verfahren.	Codieren, wenn KI-Bewertungen wegen Wiederholungen, Last, Betrieb oder Ressourcenaufwand problematisiert werden.	Wiederholte KI-Bewertungen können mehr Ressourcen kosten als sie Nutzen bringen. Modellbezug: Aufwand-Nutzen-Prüfung für KI-Komponenten.

D Transkript Interview I1

Transkript Experteninterview I1

Metadaten

- Interview-ID: I1
 - Institutioneller Kontext: FITKO
 - Transkriptart: inhaltlich geglättet
 - Sprecherkennzeichnung: INT = Interviewer, EXP = interviewte Person
 - Anonymisierung: pseudonymisiert
 - Bearbeitung: Einleitende Fragen und Abschlussfragen entfernt; Gliederung nach Hauptteilen des Leitfadens ergänzt
-

Die perfekten Metadaten

[I1_001] **INT:** Dann würde ich mit den Hauptfragen beginnen. Zunächst geht es um den perfekten Metadatensatz. Wie würdest du einen qualitativ hochwertigen Metadatensatz im GovData-Kontext beschreiben?

[I1_002] **EXP:** Für GovData gilt DCAT-AP.de als verpflichtend zu nutzender Standard. Die Minimalvoraussetzung ist daher, dass ein Datensatz valide geliefert wird. Das heißt, er erfüllt die Mindest- beziehungsweise Pflichtanforderungen aus DCAT-AP.de. Das ist ehrlich gesagt nicht immer der Fall, aber wir sind historisch bedingt auch gutmütig.

[I1_003] **EXP:** Ein perfekter oder qualitativ hochwertiger Metadatensatz erfüllt zusätzlich unsere Best-Practice-Empfehlungen. Einerseits gibt es Kriterien, die wir im Rahmen der Spezifikation empfehlen. Andererseits haben wir zusammen mit den zuständigen Expertinnen und Experten aus dem föderalen Umfeld eine Art Beispieldatensatz entworfen. Den gibt es auch zum Herunterladen auf der DCAT-AP.de-Seite. Er ist in der aktuellen Seitenstruktur etwas versteckt, findet sich aber unter „Tools und Beispiele“. Aus unserer Sicht bildet er eine Best Practice ab.

[I1_004] **EXP:** Das ist aber immer eine Mischung aus Aufwand und Nutzen. Man kann sicher noch detaillierter werden, bewegt sich dann aber in einem Long Tail: Der zusätzliche Nutzen wird geringer, während der Aufwand steigt.

[I1_005] **INT:** Welche Qualitätsmerkmale sind aus deiner Sicht grundsätzlich relevant?

[I1_006] **EXP:** Qualität, auch Datenqualität, hängt immer vom Betrachtungskontext ab. Man spricht hier von Kontextsensitivität beziehungsweise Fit for Purpose. Die Frage ist also: Was ist unser Purpose? Als Metadatenportal wollen wir einen möglichst gut durchsuchbaren Metadatenkatalog haben. Dieser Katalog soll möglichst vielen Nutzenden, also Menschen,

Maschinen und weiteren Beteiligten, möglichst leicht zeigen, welche Datensätze in unseren aggregierten Portalen verfügbar sind. Man soll möglichst leicht zu den Datensätzen gelangen, die durch unsere Metadaten beschrieben werden.

[I1_007] **EXP:** Dafür ist aus unserer Sicht der wichtigste Faktor die Reichhaltigkeit der Metadaten. Die Möglichkeiten von DCAT-AP.de sollten möglichst umfassend genutzt werden. Man sollte sich nicht auf die Minimalkriterien beschränken, sondern auch die empfohlenen Kriterien nutzen. Wenn man das mit klassischen Datenqualitätsmetriken erfasst, entspricht das der Vollständigkeit. In der klassischen Datenqualität gibt es Metriken wie Vollständigkeit, Aktualität und Ähnliches. Für uns ist Vollständigkeit der Datensätze das erste Qualitätskriterium.

[I1_008] **INT:** Welche Qualitätsmerkmale hängen in diesem Zusammenhang besonders stark vom jeweiligen Nutzungskontext ab?

[I1_009] **EXP:** Wir haben Pflichtkriterien, empfohlene Kriterien und Kriterien, die man optional nutzen kann. Letztere hängen besonders stark vom Nutzungskontext ab. Ein Beispiel sind spezielle Rollen innerhalb eines Metadatensatzes. Wenn wir nicht nur den Herausgeber als Publisher kennen, sondern auch Creator, Maintainer oder ähnliche Rollen, kann das je nach Kontext relevant sein. Für Geodaten ist das zum Beispiel ein wichtiger Faktor, weil solche Rollen dort im ISO-Standard vorgesehen sind. Für statistische Daten spielt das dagegen häufig keine Rolle.

[I1_010] **EXP:** Sehr spezifische Eigenschaften oder Relationen in DCAT-AP.de sind also nur für bestimmte Kontexte relevant. Allgemeinere Kriterien wie Datensatz, Datenservice, Dokumentation, Homepage, Publisher, zuständige Stelle oder Rechtsgrundlage sind dagegen für fast alle relevant. Auch sie sind kontextsensitiv, aber nicht in dem gleichen Maße wie beispielsweise Media Type oder Geolocation.

[I1_011] **INT:** Hast du konkrete Beispiele für Metadaten auf GovData, die sich für das Testen eines Prototyps eignen würden? Das können besonders gute oder auch besonders schlechte Metadaten sein.

[I1_012] **EXP:** Aus unserer Sicht gibt es im föderalen Raum leistungsfähigere und weniger leistungsfähige Portale. Man kann auch sagen, dass Bundesländer zu unterschiedlichen Zeitpunkten mit bestimmten Veröffentlichungsprozessen begonnen haben. Einen konkreten Datensatz kann ich hier nicht explizit benennen.

[I1_013] **EXP:** Für interne Beispiele oder öffentliche Präsentationen suchen wir uns oft kontextsensitive Datensätze aus, die Aufmerksamkeit erzeugen und die Vielfalt der Themen zeigen. Beispiele wären etwa Kartoffelernten aus Niedersachsen, eulitorale Muschelbänke im Watt oder die Anzahl bestimmter Fahrradparkplätze.

[I1_014] **EXP:** Für gute Datensätze würde ich tendenziell auf das Transparenzportal beziehungsweise Open-Data-Angebot aus Schleswig-Holstein schauen, weil dort ein Qualitätssicherungsprozess vorgeschaltet wird, bevor Daten zu uns geliefert werden. Das ist

insofern besonders, als dort relativ viel Arbeit investiert wird, um nicht nur valide DCAT-AP.de-Daten zu liefern, sondern auch Best-Practice-Anforderungen umzusetzen. Das machen nicht alle Länder. Andere tun es ebenfalls, aber Schleswig-Holstein ist ein naheliegender Ausgangspunkt.

[I1_015] **EXP:** Für schlechte Datensätze muss man vermutlich nicht lange suchen. Es gibt historisch viele Datensätze, die veraltet sind, nicht gut gepflegt wurden, einmal eingestellt wurden und dann Linkrot oder ähnlichen Problemen unterliegen. Mit einer kurzen Suche auf GovData findet man wahrscheinlich mehrere Datensätze, die Probleme aufweisen: schlecht beschriebene Datensätze, bei denen unklar ist, worum es geht, oder Datensätze mit defekten Links. Das ist ein Kernproblem. Wenn ein Datensatz auf einen Distributionslink, einen Download oder einen Datenservice verweist, der nicht mehr funktioniert, ist das besonders gravierend. Genau diese Verfügbarkeit ist für die Nutzung wichtig. Es erzeugt viel Feedback, wenn Menschen oder Maschinen etwas suchen, was angeblich verfügbar ist, dann aber nicht auffindbar ist.

Bestehende Quality Scores und SHACL

[I1_016] **INT:** Dann gehen wir weiter zu bestehenden Ansätzen für Quality Scores und zur Rolle von DCAT-AP.de und SHACL. Was fehlt deiner Meinung nach in aktuellen Ansätzen der Metadata Quality Scores, gerade mit Blick auf data.europa.eu, den MQA-Ansatz und den Schweizer Ansatz?

[I1_017] **EXP:** Grundsätzlich kenne ich diese Ansätze. MQA ist im weiteren Sinne der klassische Ansatz. Was mir fehlt, ist, dass aus meiner Sicht gerade im Bereich data.europa.eu nicht genug Mühe in die Recherche klassischer Datenqualitätskriterien investiert wurde. Diese Kriterien sind inhaltlich teilweise seit mehr als 20 Jahren etabliert. Wir gehen da bis in die 1990er- oder 1980er-Jahre zurück, teilweise sogar weiter. Dort wurden Metriken und Konzepte wie Fit for Purpose entwickelt. Dazu gibt es Standardliteratur, die Grunddimensionen wie Aktualität oder syntaktische Fehlerfreiheit beschreibt und erklärt, wie man sie misst.

[I1_018] **EXP:** Diese klassischen Kriterien kann man als ersten Ansatz sehr gut nutzen. Aus meiner Sicht ist das nicht umfassend genug geschehen. Das sind eigentlich Low-Hanging Fruits. Man sollte zunächst einen Schritt zurücktreten und diese Grundlagen in die Analysewerkzeuge integrieren.

[I1_019] **EXP:** Im GovData-Kontext reicht das allein aber nicht aus. Solche Dimensionen sollte man in der Basis erfassen: funktionierende Links, Fehlerfreiheit, Alter eines Datensatzes, Zeitpunkt der letzten Aktualisierung oder des letzten Harvestings. Dabei muss man bewerten, welche Aktualität für welchen Kontext relevant ist. Für Datenbereitstellende kann ein alter Datensatz weiterhin völlig valide sein. Für Datennutzende wirkt ein sehr alter Datensatz dagegen möglicherweise verdächtig, weil sie sich fragen, ob es aktuellere Daten

gibt. Ein Harvesting-Datum kann für einen Metadatenkatalog daher ein gutes Kriterium sein, weil es zeigt: Dieser Eintrag wurde gestern geharvestet und entspricht dem letzten Stand.

[I1_020] **EXP:** Danach müsste man tiefer in Richtung Linked Data schauen. Aus meiner Sicht sollte stärker bewertet werden, ob ein Metadatensatz die Möglichkeiten des RDF-Datenmodells intensiv nutzt. Eine Angabe, die auf ein konkretes Vokabular der EU oder auf ein von uns gepflegtes Vokabular verweist, ist besser als ein reines Literal. Wenn ich auf eine ID verweisen kann, ist das besser, als dieselbe Information nur als Freitext zu speichern. Das wird in den meisten Scoring-Ansätzen bisher nicht ausreichend berücksichtigt, ist aber für Linked Data zentral.

[I1_021] **INT:** Welche Dimensionen fehlen oder werden zu schwach berücksichtigt?

[I1_022] **EXP:** Die Dimensionen beziehen sich letztlich auf Qualitätskriterien. Für den gerade genannten Faktor gibt es meines Wissens kein explizites Kriterium. Man könnte ihn unter Richtigkeit oder Verlässlichkeit einordnen. Eine Verlässlichkeitsdimension müsste berücksichtigen, dass ein Verweis auf eine GND-ID zur Identifikation eines Agenten verlässlicher ist als derselbe Name als Freitext, zum Beispiel „Bundesministerium des Innern und für Heimat“. Diese Dimension der Verlässlichkeit müsste man nachziehen.

[I1_023] **INT:** Gibt es weitere Qualitätskriterien, die ein Scoring auf jeden Fall enthalten sollte, damit es möglichst vollständig und aussagekräftig ist?

[I1_024] **EXP:** Das kann man nicht allgemein beantworten. Für uns wäre zusätzlich relevant, ob wir Metadaten über das Harvesting haben. Das ist ein internes Qualitätskriterium. Für GovData wäre es wichtig, neben öffentlichen Qualitätskriterien, die für Nutzende oder den Katalog relevant sind, getrennt auf das Thema Harvesting-Metadaten oder Katalog-Metadaten zu schauen.

[I1_025] **EXP:** DCAT-AP.de bietet dafür die Eigenschaft Catalog Record. Sie wird von nahezu keinem Landesportal genutzt und auch von uns bisher nicht intensiv genutzt. Dort sehe ich großes Potenzial, um Aussagen über die Qualität des Metadaten-Harvestings zu treffen: Wann wurde der Datensatz zuletzt gefunden? Von welcher Stelle wurde er geharvestet? Man könnte Informationen über Validierungen und erfolgreich abgeschlossene Prüfungen einbringen. Das tun wir bisher nicht. Es wäre sinnvoll, dafür ein Konzept zu entwickeln: Wie kann man mithilfe von Catalog Records Aussagen über die Qualität des eigentlichen Eintrags treffen? Dafür gibt es auch Beschreibungssprachen beziehungsweise Vokabulare.

[I1_026] **INT:** Wie kann das DCAT-AP.de-Validationsergebnis in einem Quality Scoring wertvoll sein? Wie könnte man es am besten integrieren, und welche Teile hältst du für besonders wichtig?

[I1_027] **EXP:** Das ist auf jeden Fall wichtig, weil es die Basis bildet. Ich würde es unter Fehlerfreiheit fassen, je nachdem, welcher Literatur man folgt. Es gibt verschiedene Sets

von Datenqualitätskriterien, etwa mit acht oder elf Kriterien. Da muss man schauen, auf welchen Standardkriterien-Satz man sich bezieht.

[I1_028] **EXP:** Das DCAT-AP.de-Validierungsergebnis ist wichtig und sinnvoll, aber es ist nicht die einzige Dimension. Zur Integration würde ich eine Kategorisierung vornehmen. So fehlerhaft ich die europäische Bewertung und auch MQA in Teilen finde, halte ich die Grundstruktur für sinnvoll: Man teilt in Kategorien ein, etwa Syntax oder formale Qualität und inhaltliche Qualität. Wenn etwa Titel gut beschrieben sein sollen, braucht man andere Methoden. Eine sprachliche Bewertung ist etwas anderes als Tippfehlerfreiheit. Wenn ein Metadatensatz bei data.europa.eu in vielen Sprachen verfügbar ist, ist das ebenfalls ein Qualitätsmerkmal, aber kein hartes Validierungskriterium.

[I1_029] **EXP:** Ich würde DCAT-AP.de-Qualität daher als eine Dimension in einem Gesamtscore anzeigen. Wie man sie gewichtet, ist schwieriger, weil sie im Prinzip eine Mindestvoraussetzung darstellt.

Relevanz des eigentlichen Datensatzes

[I1_030] **INT:** Wie relevant ist der eigentliche Datensatz für die Bewertung der Metadaten?

[I1_031] **EXP:** Grundsätzlich gibt es reichhaltigere und weniger reichhaltige Ausgangsdaten. In Bereichen, die stark genormt sind und deswegen bereits gut beschriebene Datensätze haben, ist es leichter, hochwertige Metadaten zu erzeugen. Das beste Beispiel sind Geodaten. Das ist ein altes Feld mit hohem Normierungsgrad. Auch wenn ISO-Normen nicht vollständig in unseren Kontext übertragen werden, gibt es dort bereits sehr umfassende Informationen.

[I1_032] **EXP:** Aus unserer Sicht ist der Datensatz in solchen Fällen anders zu bewerten. Was wir im ISO-Kontext nicht zwingend als Metadaten behandeln würden, betrachten wir teilweise als Daten, und umgekehrt. Der Übergang ist fließend. In stark normierten Bereichen gibt es jedenfalls sehr viele reichhaltige Informationen, die es erleichtern, einen hochwertigen Metadatensatz früher zu erstellen.

[I1_033] **EXP:** Bei sehr freien, einzigartigen oder manuell erhobenen Datensätzen, beispielsweise historischen Daten, ist es schwieriger, eine gute Beschreibung zu erstellen. Das ist ebenfalls möglich, aber oft mit mehr Aufwand verbunden und wird in der Praxis deshalb nicht so intensiv umgesetzt. Insofern erleichtert ein hoher Normierungsgrad der eigentlichen Daten häufig gute Metadaten.

KI-gestützte Ansätze und AI Agents

[I1_034] **INT:** Dann kommen wir zum letzten Hauptteil: KI-gestützte Ansätze und AI Agents. Wie sinnvoll findest du Ansätze, die AI Agents oder KI-gestützte Verfahren nutzen, um neue Ansätze zu entwickeln oder bestehende Ansätze zu verbessern?

[I1_035] **EXP:** Viele Metadaten sind letztlich menschlich erstellt oder beruhen auf manuellen Eingaben in Fachverfahren. Das liegt in der Natur von Verwaltungsdaten. Dadurch hat man viel Freitext und natürliche Sprache. Das sind Bereiche, denen man sich mit LLMs oder KI nähern kann, etwa bei Syntax, grundlegenden Inkonsistenzen oder einfachen Datumsprüfungen. Dort sehe ich Potenzial, um Metadatenfehler, Metadaten Schwächen und Qualitätsschwächen zu finden und zu korrigieren.

[I1_036] **EXP:** Natürlich könnte man vieles auch mit konventionellen Techniken klassisch algorithmisch lösen. Der Vorteil vertrauenswürdiger KI-Systeme liegt darin, dass sie nicht jede Form von Tippfehler vorhersehen müssen. Sie bringen eine gewisse Fehlertoleranz mit. Ähnliche Dinge ließen sich auch manuell mit Werkzeugen wie OpenRefine erreichen. Faktisch wurde das aber bisher nicht in großem Umfang gemacht. Agentische KI bietet die Chance, dass sich Menschen wieder für diese Themen interessieren und Dinge vorantreiben, die man klassisch zwar seit langer Zeit könnte, aber bisher nicht umgesetzt hat.

[I1_037] **EXP:** Bei kontextsensitiver semantischer Analyse sehe ich dagegen klare Grenzen. Eine KI kann beispielsweise nicht zuverlässig entscheiden, ob „Watt“ die elektrische Einheit meint oder das Wattenmeer, in dem Muschelbänke vorkommen. Eine vollautomatisierte agentische Lösung kann in solchen Kontexten mehr Schaden als Nutzen erzeugen. Gerade fachspezifische oder aus kleinen Domänen stammende Datensätze lassen sich statistisch nicht gut greifen. Es gibt Fachsprache und spezifische Zusammenhänge, die von natürlicher Alltagssprache abweichen. Im Umweltbereich gibt es viele naturwissenschaftliche, biologische und technische Begrifflichkeiten, die sich in Keywords, Titeln und Beschreibungen widerspiegeln. Wenn man solche Daten halbautomatisiert mit agentischer KI korrigieren lässt, besteht die Gefahr, dass fachlich korrekte Begriffe in eine falsche Alltagssprache überführt werden. Dort sehe ich wenig Potenzial.

[I1_038] **INT:** Gibt es wichtige kontextsensitive Informationen, die durch KI überprüft werden könnten?

[I1_039] **EXP:** Die große Stärke sehe ich im Bereich Syntax. Ich kann mir vorstellen, dass man mit agentischen KI-Systemen eine Art Metadaten-Linter gestaltet. DCAT-AP.de ist eine sehr spezifische Information und formal geschrieben. Es gibt klare Anforderungen zu Muss-, Kann- und Soll-Kriterien sowie zu SHACL. Diese Spezifikation könnte man als Basis nehmen. Man könnte eine agentische KI mit Fokus darauf füttern und nutzen, um Datenbereitstellenden Vorschläge zu machen: Das ist ein Metadatensatz aus dem Bereich Geoinformationen, diese Pflichtattribute wurden genutzt, diese empfohlenen Attribute wurden genutzt. In statistischen Analysen nutzen die meisten ähnlich aussehenden Datensätze zusätzlich dieses oder jenes Attribut.

[I1_040] **EXP:** So könnte man Anreicherungen betreiben. Die KI kann die Information nicht erzeugen, wenn sie nicht vorliegt. Sie kann aber Lücken identifizieren und bei Vergleichen helfen. Ich glaube, eine sinnvolle Anwendung agentischer KI wäre, Vergleichbarkeit herzustellen. Beispielsweise könnte man feststellen: Die Datensätze aus Schleswig-Holstein enthalten bestimmte Informationen, die Datensätze aus Niedersachsen dagegen nicht, obwohl beide Küstenländer sind. Bei einem Vergleich zwischen Schleswig-Holstein und Bayern wäre dieselbe Abweichung hingegen möglicherweise inhaltlich erklärbar und kein Qualitätsproblem, weil Bayern keine Küste hat. Genau solche föderalen Vergleiche oder Vergleiche von Datensätzen unterschiedlicher Quellen könnten durch KI unterstützt werden.

[I1_041] **EXP:** Ich sehe hier teilweise auch Potenzial für klassische KI-Systeme im Sinne von Machine Learning oder Assisted Learning. Mit einem Assisted-Learning-Ansatz könnte man qualitativ hochwertigere Keywords schaffen. Man könnte einfache Freitext-Stichworte, die teilweise Tippfehler enthalten oder keinen Mehrwert bieten, auf Kategorien, echte Schlagworte oder belastbare EU-Vokabulare mappen. Im Kontext des Musterdatenkatalogs gibt es dazu bereits Ansätze. Dort wurden Datensätze aus dem kommunalen Umfeld kategorisiert und der Musterdatenkatalog mit dieser Methodik geschärft. Das halte ich für einen erfolgreichen Ansatz.

[I1_042] **INT:** Gibt es bestimmte Nutzungskontexte von Open Data, in denen eine KI-gestützte Bewertung besonders sinnvoll wäre?

[I1_043] **EXP:** Sinnvoll ist alles, was sich um natürliche Sprache dreht. Dazu gehören Stichworte wie Barrierearmut, einfache Sprache oder die Frage, ob nur Fachtermini genutzt werden oder ob eine natürlichsprachliche Beschreibung vorliegt. Auch niedrigschwellige Synonyme können relevant sein. Wenn zum Beispiel von eulitoralen Bereichen die Rede ist, kann ein zusätzliches, allgemeinverständlicheres Keyword sinnvoll sein, weil nicht jeder weiß, was „eulitoral“ bedeutet.

[I1_044] **EXP:** Das ist etwas, was KI gut unterstützen kann: Beschreibungstexte oder die Güte von Beschreibungstexten bewerten, möglicherweise auch anhand von Style Guides. Dort kann ich mir Korrektur- oder Verbesserungsvorschläge gut vorstellen. Es könnte auch teilautomatisiert agentisch funktionieren: Ein System, das entsprechend konfiguriert oder trainiert wurde, erhält den Auftrag, die Beschreibungen von tausend Datensätzen zu verbessern und direkt in den Metadaten anzupassen. Das wäre grundsätzlich möglich.

[I1_045] **INT:** Gibt es abseits von kontextsensitivem Wissen weitere Anwendungsfälle, in denen AI Agents bei einem Scoring helfen könnten?

[I1_046] **EXP:** Da muss man unterscheiden. Für generative KI sehe ich bei Scoring und Bewertungen wenig Raum, weil es sich grundsätzlich um ein stochastisches Verfahren handelt. Wenn ich dieselbe Prüfung und dieselbe Qualitätsbewertung hundertmal durchführe, bekomme ich vermutlich einige Ausreißer, bei denen Unsinn herauskommt. Das entspricht typischen Fehlerquoten in einer Größenordnung von einigen Prozent. Bei einer Bewertung weiß ich dann nie, ob das aktuelle Ergebnis eines dieser fehlerhaften Ergebnisse ist. Ich müsste also alles sehr oft durchführen und anschließend wieder eine statistische

Erhebung über die automatisierte Qualitätsmessung machen. Dann ist der Ressourcenaufwand größer als der eigentliche Nutzen. Bei Bewertung und generativer KI lautet meine Einschätzung daher eher: nein.

[I1_047] **EXP:** Um eine Bewertung vorzunehmen, muss man aber im Regelfall den RDF-Graphen per SPARQL abfragen oder andere spezifische Anfragen an das System stellen. Es kann sein, dass nicht für alle Varianten vorab passende Abfragen vorbereitet werden können. Im GovData-Kontext haben wir mindestens 17 relevante Stakeholder, die sich vor allem für ihre eigene Datenqualität interessieren und zugeschnittene Anfragen brauchen. Diese Bedarfe sind nicht vollständig identisch.

[I1_048] **EXP:** Bestimmte Datentypen gibt es nur in einzelnen Ländern. Pegelstandsmessungen gibt es zum Beispiel eher in Ländern mit Küsten oder großen Flüssen, also etwa in Schleswig-Holstein, Niedersachsen, Nordrhein-Westfalen oder Bayern, aber nicht in gleicher Weise überall. Die Query sieht dann vermutlich nicht immer gleich aus. Hier könnte ein agentisches oder generatives System unterstützen: Es könnte menschlichen Qualitätsverantwortlichen oder Personen, die Qualitätsmetriken erstellen, helfen, hochspezifische SPARQL-Queries oder Analysebausteine zu entwickeln, um spezifische Qualitätsfragen zu lösen.

[I1_049] **EXP:** Das könnte Fachpersonen, die Qualitätskriterien in ihrer Domäne bewerten können, aber weniger technische Expertise haben, Zugang zu technischen Auswertungsmitteln verschaffen. Die API ist nicht vollständig niedrigrschwellig; man braucht Vorwissen, um in einem Metadatenkatalog relevante Informationen zu filtern. Dort sehe ich großes Potenzial.

E Transkript Interview 2

Transkript Experteninterview I2

Metadaten

- Interview-ID: I2
 - Institutioneller Kontext: FITKO
 - Transkriptart: inhaltlich geglättet
 - Sprecherkennzeichnung: INT = Interviewer, EXP = interviewte Person
 - Anonymisierung: pseudonymisiert
 - Bearbeitung: Einleitende Fragen und Abschlussfragen entfernt; Gliederung nach Hauptteilen des Leitfadens ergänzt
-

Die perfekten Metadaten

[I2_001] **INT:** Vielen Dank. Dann geht es mit den Hauptfragen los. Zunächst allgemein zu Metadaten: Wie sieht deiner Meinung nach der perfekte Metadatensatz aus? Im Leitfaden hatte ich erwähnt, dass du auch gerne einen Beispieldatensatz mitbringen kannst.

[I2_002] **EXP:** Es wäre einfacher gewesen, nach einem nicht perfekten Metadatensatz zu fragen, denn davon gibt es viele.

[I2_003] **EXP:** Ein perfekter Metadatensatz basiert idealerweise auf DCAT-AP.de beziehungsweise auf einem semantischen Graphen. Der Vorteil eines Graphen ist, dass alles, was vorhanden ist, mitgenommen werden kann. Man kann ihn beliebig erweitern und es entsteht kein Datenverlust. Es können auch Informationen enthalten sein, die man aktuell vielleicht noch nicht benötigt oder noch nicht vollständig versteht.

[I2_004] **EXP:** Ein guter Metadatensatz enthält natürlich die Pflichtfelder, also vor allem Titel und Beschreibung, bei uns möglichst in deutscher Sprache. Darüber hinaus sollten aber alle fachlich vorhandenen Informationen übernommen werden. Im Geobereich gibt es beispielsweise teilweise bis zu zehn Ansprechpartner. Solche Informationen gibt es bei uns in dieser Form gar nicht, aber wenn sie vorhanden sind, sollten sie nicht entfernt werden.

[I2_005] **EXP:** Die Daten, die ohnehin vorhanden sind, sollten in einem Metadatensatz enthalten sein, am besten semantisch modelliert. Ziel wäre im Sinne der Five-Star-Linked-Data-Idee von Tim Berners-Lee, dass ein Metadatensatz nicht nur für sich selbst steht, sondern Querverbindungen zu anderen Entitäten enthält. Das können zum Beispiel Wikidata, die Gemeinsame Normdatei oder andere externe Referenzsysteme sein. Auch ein Thesaurus, etwa der des Umweltbundesamtes, wäre sinnvoll, weil dort viele Fachbegriffe aus dem Umweltbereich beschrieben sind.

[I2_006] **EXP:** Was ich bisher noch nicht gesehen habe, mir aber wünschen würde, sind Querverbindungen zwischen gleichen oder vergleichbaren Datensätzen aus den rund 11.000 Kommunen in Deutschland. Das wäre ein Idealfall.

[I2_007] **INT:** Damit hast du die Unterfrage schon weitgehend beantwortet, nämlich nach welchen Kriterien du Metadaten als perfekt bewertest. Darauf aufbauend: Hast du konkrete Beispiele für schlechte Metadaten auf GovData, die sich eventuell auch für das Testen eines Prototyps eignen würden?

[I2_008] **EXP:** Ich bin schon zu lange im Thema, deshalb habe ich viele Beispiele gesehen. Es gibt etwa Metadatensätze, bei denen der Titel viel zu kurz ist. Ein Beispiel wäre „Los 1“. Daraus versteht man nicht, worum es geht. Es gibt auch Datensätze, bei denen Titel und Beschreibung identisch sind. Dann liefert die Beschreibung keinen Mehrwert.

[I2_009] **EXP:** Ein anderes Problem sind stark regionale Begriffe. Es gibt zum Beispiel einen Datensatz aus Köln zu den „I-Dötzchen“. Wer sich damit auskennt, versteht, dass damit Schulanfänger gemeint sind. Es ist zwar Deutsch, aber die meisten Menschen verstehen diesen regionalen Ausdruck nicht.

[I2_010] **EXP:** Ein weiteres Beispiel war ein Datensatz aus der Schweiz. Die Überschrift habe ich nicht richtig verstanden, und die Beschreibung war zwar sehr detailliert und fachlich vermutlich korrekt, aber für mich trotzdem unverständlich. Es war deutsche Sprache, aber Fachsprache. Das kann fachlich ein guter Datensatz sein, aber für Außenstehende bleibt er schwer verständlich. In solchen Fällen könnten zusätzliche Metadaten, englischsprachige Titel oder englischsprachige Beschreibungen hilfreich sein.

[I2_011] **EXP:** Schlechte Metadaten zeigen sich auch an einfachen Dingen wie nicht mehr auflösbaren URLs, also Dead Links, zu wenigen Metadaten oder widersprüchlichen Angaben. Ein Beispiel wäre ein Titel zu Vornamen aus Nürnberg, während als Herausgeber Köln angegeben ist. Das sind Fälle, die inhaltlich nicht zusammenpassen.

[I2_012] **EXP:** Das generelle Problem bei Metadaten ist, dass Menschen Fehler machen. Ich würde häufig eher auf die eigentlichen Daten schauen, weil diese oft aussagekräftiger über sich selbst sind als die Metadaten, die ein Mensch eingetragen hat. Das sehe ich immer wieder.

[I2_013] **EXP:** In einer Arbeitsgruppe mit der GDI, also mit den Geodaten, ging es beispielsweise um Flächendeckung. In den Metadaten steht eine Bounding Box, also der Bereich, für den Daten erhoben wurden. Im Geokontext ist das sehr sinnvoll. Diese Information wird aber von Menschen eingetragen und ist deshalb ebenfalls fehleranfällig. Eigentlich wäre es oft sinnvoller, in die Daten selbst hineinzuschauen und solche Informationen daraus zu berechnen.

[I2_014] **EXP:** Das ist kein böser Wille. Die Menschen, die Metadaten eintragen, haben andere fachliche Schwerpunkte. Wenn man ihnen ein Metadatenfeld gibt und sagt, sie sollen es ausfüllen, verstehen sie oft nicht, warum sie das tun sollen. Wenn man den Zweck nicht

versteht, füllt man es wahrscheinlich nicht so aus, dass andere es gut nachnutzen können. Das ist ein menschliches Problem.

[I2_015] **INT:** Vielen Dank für die ausführliche Antwort. Ich würde mich im Anschluss natürlich freuen, wenn du bei Gelegenheit ein oder zwei positive und negative Beispiele schicken könntest. Wenn das zeitlich nicht funktioniert, ist das natürlich kein Problem.

[I2_016] **EXP:** Zeitlich wird das wahrscheinlich schwierig. Ich habe sehr viele Datensätze kennengelernt und könnte grundsätzlich viele Beispiele liefern.

[I2_017] **EXP:** Es gibt auch Datensätze, die eigentlich gut sind, bei denen aber die Weiterverarbeitung im Portal problematisch ist. Metadaten laufen teilweise über mehrere Portale und durchlaufen dabei seltsame Ketten. Dadurch haben wir manchmal denselben Datensatz mehrfach im Portal, ohne ihn sinnvoll als identisch erkennen zu können. Ein fachlich wichtiger Datensatz kann dann bis zu viermal angezeigt werden, weil sich einzelne Metadaten unterscheiden. Das liegt daran, dass die Daten zwischen Systemen oder Metadatenformaten konvertiert werden. Dadurch kann aus einem eigentlich guten Datensatz technisch ein schlechterer werden.

[I2_018] **EXP:** Ich kann versuchen, im Nachgang etwas zusammenzustellen, aber versprechen kann ich es nicht. Wenn Steffi mich noch einmal erinnert und ich es schaffe, ist das in Ordnung.

Bestehende Quality Scores und SHACL

[I2_019] **INT:** Dann würde ich zur nächsten Frage kommen. Es geht um die Rolle von SHACL und bestehenden Metadaten-Quality-Scores. Was fehlt deiner Meinung nach in aktuellen Ansätzen der Metadaten-Quality-Scores?

[I2_020] **EXP:** Dazu haben wir intern eine sehr lebhafte Diskussion, meistens mit Matthias. Er kommt aus der Wissenschaft und kennt sich gut mit Semantik aus.

[I2_021] **EXP:** Das größte Problem ist, dass es oft keine wissenschaftlich fundierte Grundlage dafür gibt, warum bestimmte Dinge erhoben werden. Es wird geprüft, aber warum genau geprüft wird, ist häufig nicht festgehalten. Es fehlt also die wissenschaftliche Basis.

[I2_022] **EXP:** Es gibt dann irgendeinen Score, der aber nicht belastbar ist. Die Frage ist immer: Warum prüfen wir genau das? Oft kann man diese Frage nicht beantworten. Deshalb sind wir mit den Scores der EU oder der Schweiz, die inhaltlich teilweise übernommen werden, nicht vollständig zufrieden. FAIR-Prinzipien sind grundsätzlich sinnvoll, aber insgesamt fehlt uns häufig die Begründung.

[I2_023] **EXP:** Bei GovData haben wir deshalb bisher noch keine eigene Qualitätsprüfung dieser Art. Der Grundstreit ist: Was sollte man prüfen und warum? Wir haben noch nicht die

Zeit gefunden, das vollständig durchzuarbeiten. Grundsätzlich ist klar, dass man messen muss. Aber wenn wir Qualität messen, wollen wir auch sinnvoll messen.

[I2_024] **EXP:** Ein Score sollte also belegen, warum er genau diese Kriterien verwendet. Die reine Anzahl der Datensätze als Erfolgsfaktor für Datenportale ist beispielsweise eine falsche Metrik. Wenn wir Qualität messen wollen, dann sollte es eine belastbare Metrik sein.

[I2_025] **INT:** Darauf aufbauend: Welche Qualitätskriterien sollte ein Scoring auf jeden Fall enthalten, damit es möglichst vollständig oder aussagekräftig ist?

[I2_026] **EXP:** Vollständigkeit ist schwierig. Metadaten können in einem Graphen eigentlich nie vollständig sein, weil ein Graph beliebig groß sein kann. Sinnvoll wäre eher eine relative Vollständigkeit: Sind die grundlegenden Anforderungen erfüllt und sind für die jeweilige fachliche Thematik die relevanten Informationen vorhanden? Ob das eine fachliche, organisatorische oder verwaltungsbezogene Frage ist, müsste man genauer unterscheiden.

[I2_027] **EXP:** Wichtig ist außerdem die sprachliche Verständlichkeit. Es reicht nicht, zu messen, ob ein Titel oder eine Beschreibung lang genug ist. Entscheidend ist, ob der Inhalt verständlich beschrieben wird und ob die Beschreibung tatsächlich den Inhalt der Daten erklärt. Das ist schwer zu prüfen, aber wesentlich.

[I2_028] **EXP:** Ein weiterer Punkt betrifft Distributionen. Ein Metadatensatz hat Distributionen, und Distributionen sollten eigentlich unterschiedliche Formate derselben Daten beschreiben. Das wird nicht immer korrekt genutzt. Zur Qualität gehört deshalb auch, ob das richtige Format gewählt wurde, ob es richtig beschrieben ist und ob die Distributionen korrekt verwendet werden.

[I2_029] **EXP:** Technisch wären bei DCAT außerdem Dinge wie das Vermeiden von Blank Nodes relevant. Auch Querverweise sind wichtig. Ebenso sollte man überlegen, wie Organisationen sinnvoll abgebildet werden können, idealerweise über einen Organisationsgraphen für Deutschland.

[I2_030] **EXP:** Ein weiterer Punkt ist die Attribution. Wenn etwa eine CC-Lizenz verwendet wird, sollte in den Metadaten auch angegeben sein, wie die Quelle korrekt zu zitieren ist. Wenn eine Stadt Daten veröffentlicht, sollte klar sein, ob der Stadtname, ein Fachbereich oder ein Amt als Attributionsangabe verwendet werden soll. Solche Details wirken klein, gehören aber zur Qualität von Metadaten.

[I2_031] **EXP:** Was ich außerdem gerne sehen würde, ist der Weg eines Datensatzes durch verschiedene Portale. Wo kommt der Datensatz her? Welche Portale hat er durchlaufen? Das steht heute nicht sauber in den Metadaten und ist auch nicht ohne Weiteres abbildbar.

[I2_032] **EXP:** Daran hängt auch die Grundfrage, ob Portale Metadaten anfassen und verändern dürfen. Wenn ich den Pfad kenne, kann jedes harvestende Portal theoretisch Metadaten bearbeiten oder ergänzen. Wenn ich Qualitätsunterschiede sehe, darf ich sie dann korrigieren? Wenn ich sehe, dass eine URL nur als String vorliegt, darf ich sie sauber

als URL modellieren? Das wäre eine Veränderung der Metadaten. Die Frage ist also: Wer darf Qualität verbessern? Das ist nicht abschließend geklärt.

[I2_033] **INT:** Inwiefern kann das DCAT-AP.de-SHACL-Validierungsergebnis in einem Quality-Scoring wertvoll sein?

[I2_034] **EXP:** Das kann sehr wertvoll sein. Früher hatten wir intern schon eine Art Ranking, zunächst nur in einem geschützten Bereich. Zugriff hatten verschiedene Ländervertretungen, der Bund und wir. Später gab es meines Wissens auch öffentliche Messergebnisse.

[I2_035] **EXP:** Solche Rankings werden teilweise gewünscht. Die Länder möchten sich vergleichen können. Sie wollen sehen, ob sie gut sind oder ob sie zusätzliche Ressourcen benötigen, weil sie schlechter abschneiden. Auch beim Musterdatenkatalog möchten Kommunen sehen, wo sie stehen und wo sie sich verbessern können.

[I2_036] **EXP:** Entscheidend ist, dass es nicht darum geht, jemandem zu sagen, dass er schlecht ist. Es sollte als Hinweis verstanden werden: Hier gibt es Luft nach oben, und so kann man besser werden. Es braucht also eine Anleitung zur Verbesserung.

[I2_037] **EXP:** Regelmäßige Prüfungen können helfen. Wenn Metadaten täglich geprüft werden und die Verantwortlichen regelmäßig sehen, was falsch ist, kann das dazu führen, dass Fehler behoben werden. Rankings oder Fehlerrankings können also durchaus sinnvoll sein, wenn sie richtig eingesetzt werden.

[I2_038] **INT:** Wie kann man das Validierungsergebnis am besten in ein Scoring integrieren? Welche Regeln oder Teile der Ergebnisse hältst du dabei für besonders wichtig?

[I2_039] **EXP:** Ein Ansatz wäre vergleichbar mit dem EU-Ranking, bei dem es verschiedene Bereiche gibt. Teil-Scores können hilfreich sein, um zu erkennen, wo genau ein Problem liegt. Wenn ein Bereich schlecht abschneidet, kann man sehen, ob das Problem beim Portal liegt oder ob es fachlich an anderer Stelle entsteht.

[I2_040] **EXP:** Solche Teilbewertungen sind sinnvoll, weil man punktuell verbessern kann. Wichtig wäre aber, dass die Ergebnisse genauer werden. Aktuell liefert die SHACL-Validierung zwar ein Ergebnis, etwa wenn ein Portal neu aufgenommen werden möchte, aber die Ausgabe ist häufig sehr technisch. Man muss die Ergebnisse interpretieren, um zu verstehen, was schiefgelaufen ist.

[I2_041] **EXP:** Es ist schon besser geworden, aber man muss weiterhin erkennen können, was konkret zu tun ist. Eine reine Fehlermeldung ist wenig hilfreich. Man wird zwar auf ein Problem hingewiesen, aber die Personen, die diese Meldung lesen, sind nicht immer Expertinnen oder Experten. Deshalb wäre eine Erklärung wichtig, warum ein Fehler auftritt und wie er behoben werden kann.

Relevanz des eigentlichen Datensatzes

[I2_042] **INT:** Dann kommen wir zu einer Frage zur Relevanz des eigentlichen Datensatzes. Inwiefern hältst du den eigentlichen Datensatz für relevant für die Bewertung der Metadaten?

[I2_043] **EXP:** Das ist schwierig, weil die Grenze zwischen Metadaten und Daten irgendwann verschwimmt. Für GovData sind die Metadaten im Grunde die eigentlichen Daten, weil wir primär Datensätze beschreiben. Dasselbe gilt in dieser Betrachtung.

[I2_044] **EXP:** Ein Beispiel sind Geodatenservices. Wir haben dort Metadaten, die auf einen Service verweisen. Dieser Service ist aber eigentlich eine API, die sich selbst beschreibt. Wenn wir uns den Datensatz ansehen, sehen wir zunächst nur eine Metadatenangabe dazu, wie sich der Service beschreibt und welche Filtermöglichkeiten es gibt. Darunter liegen aber wiederum Daten. Dann stellt sich die Frage: Sind das Metadaten der Metadaten oder ist der Service bereits ein Datum? Das verschwimmt.

[I2_045] **EXP:** Deshalb sind eigentlich beide Ebenen interessant: die Metadaten und die Daten selbst. Sie korrelieren auch miteinander. Wenn in den Metadaten steht, der Dateityp sei CSV, aber der Inhalt ist kein CSV, dann ist das eine Verletzung der Metadatenqualität. Es gibt aber auch Sonderfälle: Eine Datei kann als Excel angegeben werden, weil sie mit Excel geöffnet werden kann, obwohl das Format eigentlich anders ist. Die Menschen erwarten dann, dass „Excel“ dort steht.

[I2_046] **EXP:** Metadaten und Daten gehören also zusammen. Es ist ein Gesamtkunstwerk. Wenn ich eine Karte erwarte, aber eine XML-Fehlermeldung bekomme, passt etwas nicht. Das gilt zum Beispiel bei WMS- oder WFS-Geodatenservices. Technisch sprechen diese Dienste XML, aber der Mensch erwartet eine Karte.

[I2_047] **EXP:** Auch wenn im Titel „Vornamen“ steht, im Datensatz aber hauptsächlich Zahlen enthalten sind, ist die Beschreibung falsch. Das macht die Prüfung schwieriger. Man kann sich dem aber annähern und teilweise auch automatisiert prüfen. Deshalb ist der eigentliche Datensatz für die Bewertung der Metadaten relevant.

KI-gestützte Ansätze und AI Agents

[I2_048] **INT:** Dann kommen wir zum letzten Hauptteil, nämlich AI Agents. Inwiefern hältst du Ansätze, die AI Agents in den Vordergrund rücken, für sinnvoll, um neue Ansätze zu entwickeln oder bestehende Ansätze zu verbessern, zum Beispiel durch eine kontextsensitive Analyse der Metadaten?

[I2_049] **EXP:** Aktuell halte ich Ansätze, die AI Agents von vornherein in den Vordergrund rücken, generell für falsch. Ich würde eher fragen: Wir schauen uns AI Agents an und prüfen dann, wofür sie sinnvoll sind.

[I2_050] **EXP:** Ich habe in anderen Bereichen zu oft erlebt, dass gefragt wird, ob nicht die KI ein Problem lösen könne oder ob KI die gesamte Prozesskette übernehmen könne. Die Frage sollte aber sein: Muss KI das lösen oder kann es auch mit anderen Mitteln funktionieren? Oft können andere Mittel das ebenfalls lösen.

[I2_051] **EXP:** AI Agents sind nicht automatisch intelligent. Häufig probieren sie Dinge aus, bis etwas passt. Das kann man in manchen Prozessen auch anders erreichen. Als Lösungsvariante finde ich sie interessant, aber entscheidend ist, wie die KI angesprochen wird.

[I2_052] **EXP:** Eine reine Textanalyse halte ich für schwach. Wenn AI Agents hingegen auf einem semantischen Graphen arbeiten, ist das deutlich besser. Sie verstehen den Graphen nicht im menschlichen Sinne, können aber datenbasiert arbeiten und halluzinieren weniger. Wenn bessere Daten als Grundlage vorhanden sind, können AI Agents sinnvoller und verlässlicher arbeiten. Auf unserem Graphen könnten sie nützliche Informationen erschließen. Insofern: ja, warum nicht, aber nicht als Selbstzweck.

[I2_053] **INT:** Darauf aufbauend: Was wären deiner Meinung nach wichtige kontextsensitive Informationen, die ein solcher Agent überprüfen könnte?

[I2_054] **EXP:** Das hängt davon ab, worum es konkret geht. Ein Agent sollte sich auf die Metadaten verlassen können. Wenn wir einen Graphen haben, kann er Metadaten prüfen und weitere Informationen heranziehen. Er könnte in unserem Graphen suchen, andere Graphen wie das europäische Datenportal einbeziehen oder Informationen aus Drittportalen, wissenschaftlichen Portalen und ähnlichen Quellen berücksichtigen.

[I2_055] **EXP:** Er könnte Querverweise auflösen oder neue Querverweise finden. Besonders relevant wären Schlagwörter und Stichwörter. Diese sind bei Behörden oft einfach nur Zeichenketten. Wenn sie mehr Kontext hätten, könnte man deutlich mehr daraus ableiten. Das Umweltbundesamt hat meines Wissens solche kontextsensitiven Informationen beziehungsweise Verlinkungen über seinen Thesaurus. Dadurch kann man zu einem Datensatz zusätzliche Informationen erschließen.

[I2_056] **EXP:** Wenn ein Datensatz beispielsweise mit einem bestimmten Begriff verbunden ist, könnte ein Agent über den Graphen weitere verwandte Konzepte finden. Dadurch würden die Suche und die Bewertung deutlich besser. Kontext entsteht also vor allem durch semantische Verknüpfungen.

[I2_057] **INT:** Gibt es deiner Meinung nach weitere Anwendungsfälle, in denen AI Agents oder KI bei einem Scoring helfen könnten, abseits von kontextsensitivem Wissen?

[I2_058] **EXP:** Ja. Man müsste viel stärker in die Daten selbst hineinschauen. Bisher betrachten Portale häufig nur Metadaten. Eigentlich müsste man tiefer analysieren: Passen die Daten zu den Metadaten oder nicht?

[I2_059] **EXP:** Ich hatte vorhin die Flächendeckung erwähnt, die ich mit der GDI einmal ausprobiert habe. Dafür muss man die Daten identifizieren und in die Daten hineinschauen.

Das wäre eine gute Aufgabe für einen Agenten. Er könnte prüfen, ob Datensätze vergleichbare Strukturen haben, ob sie schematisch ähnlich sind oder ob sie flächendeckend verfügbar sind.

[I2_060] **EXP:** Solche Informationen händisch zu ermitteln, ist sehr aufwendig. KI kann große Datenmengen analysieren, Muster erkennen und Informationen ableiten. Das könnte auch bei älteren Datensätzen hilfreich sein, die alte Sprachmuster enthalten. Man könnte etwa historische Begriffe oder ältere Verwaltungssprache analysieren und Kontexte herstellen, die Menschen nicht ohne Weiteres erkennen würden.

[I2_061] **EXP:** Man könnte auch sehr große Mengen an Datensätzen analysieren und feststellen, was inhaltlich am häufigsten vorkommt. Das ist für Menschen manuell kaum leistbar.

[I2_062] **EXP:** Das Problem bei KI ist aber, dass sie trainiert und betrieben werden muss. Auch Agents erzeugen im Einsatz Last. Das merken wir bei GovData: KI kann sehr viel Serverlast erzeugen, weil solche Systeme oft so programmiert sind, dass sie nicht loslassen und die verfügbare Serverkapazität ausnutzen. Das ist für kleine Einrichtungen nicht immer tragbar.

[I2_063] **EXP:** Ich finde KI sinnvoll, aber man muss Rechenressourcen und Betrieb mitdenken. Nicht alles muss mit KI gelöst werden, wenn es auch anders lösbar ist.

F Transkript Interview 3

Transkript Experteninterview I3

Metadaten

- Interview-ID: I3
 - Institutioneller Kontext: Open Data Competence Center Bayern
 - Transkriptart: inhaltlich geglättet
 - Sprecherkennzeichnung: INT = Interviewer, EXP = interviewte Person
 - Anonymisierung: pseudonymisiert
 - Bearbeitung: Einleitende Fragen und Abschlussfragen entfernt; Gliederung nach Hauptteilen des Leitfadens ergänzt
-

Die perfekten Metadaten

[I3_001] **INT:** Wie sieht Ihrer Meinung nach der perfekte Metadatensatz aus? Ich hatte Ihnen im Leitfaden geschrieben, dass Sie gerne auch einen Beispieldatensatz mitbringen können.

[I3_002] **EXP:** Das habe ich tatsächlich nicht geschafft, das kann ich aber gern noch nachreichen. Zum perfekten Metadatensatz: Ich würde da auch auf unsere Handreichung zur Datenqualität verweisen, in die schon einige Aspekte eingeflossen sind. Was ich Datenbereitstellern immer mitgebe, ist: lieber Qualität statt Quantität. DCAT hat sehr viele Metadatenfelder, ich glaube um die 70. Natürlich wäre es schön, wenn alle gefüllt wären, aber das ist überhaupt nicht für jeden Datensatz sinnvoll, weil inhaltlich nicht immer alles passt. Perfekt ist ein Datensatz dann, wenn alle relevanten Metadatenfelder in sehr guter Qualität ausgefüllt sind, also inhaltlich und syntaktisch korrekt.

[I3_003] **EXP:** Da ich weiß, dass man immer einen Realitätsabgleich bräuchte und das für unsere Datenbereitsteller oft nicht umsetzbar ist, sage ich eher: auf die wichtigen Metadatenfelder beschränken und diese dann sorgfältig und korrekt ausfüllen. Ich verfolge da einen pragmatischen Ansatz. Sorgfältig heißt für mich auf der einen Seite, dass die Angaben syntaktisch korrekt sind, also beispielsweise die richtigen Vokabulare und URIs verwendet werden. Auf der anderen Seite heißt es, dass die Inhalte eine gute Nutzbarkeit und Auffindbarkeit der Daten ermöglichen.

[I3_004] **INT:** Sie haben gerade schon einige Kriterien genannt. Haben Sie noch weitere Kriterien, an denen Sie einen Metadatensatz als perfekt bewerten würden?

[I3_005] **EXP:** Ja. Die Beschreibung sollte ausführlich sein und die relevanten Informationen enthalten. Potenzielle Datennutzende sollten auf den ersten Blick aus den Metadaten erkennen können: Was sind das für Daten? Kann ich sie technisch verarbeiten? Kann ich sie inhaltlich verarbeiten? Es sollte also eine Art Inhaltsvorschau und technische Vorschau

geben, sodass ich nicht erst den Datensatz selbst öffnen muss, um zu wissen, ob ich ihn für meinen Zweck verwenden kann oder eher nicht.

[I3_006] **EXP:** Außerdem ist Konsistenz wichtig, gerade wenn es ähnliche Daten gibt. Ein Beispiel wären Einwohnerstatistiken. Jede Kommune hat so eine Statistik, aber jede benennt sie anders: mal Bevölkerung, mal Einwohner, mal Statistik, mal Anzahl. Schon auf Titel- oder Beschreibungsebene gibt es viele Synonyme. Da wären Einheitlichkeit und Standardisierung sehr hilfreich.

[I3_007] **INT:** Ich denke, die Unterfrage nach Konsistenz hat sich damit geklärt. Ich vermute, Sie haben spontan kein konkretes Beispiel für schlechte Metadaten dabei?

[I3_008] **EXP:** Nein, das kann ich aber nachreichen. Das habe ich vorher einfach nicht geschafft. Ich finde genug Beispiele, nicht nur auf GovData, sondern auch bei uns im Portal.

Bestehende Quality Scores und SHACL

[I3_009] **INT:** Alles klar. Dann würde ich zu zwei Fragen zu Quality Scores kommen. Was fehlt Ihrer Meinung nach in den aktuellen Ansätzen der Metadata-Quality-Scores?

[I3_010] **EXP:** Mir sind vor allem piveau metrics und der DCAT-Validator bekannt. piveau metrics bezieht sich eher darauf, ob bestimmte Felder überhaupt vorhanden sind, und der Validator prüft zusätzlich die Syntax, also ob die richtigen Vokabulare, die richtigen URIs und so weiter verwendet werden. Was beide Ansätze aber nicht leisten, ist die Prüfung, ob das, was in den Metadaten steht, auch inhaltlich sinnvoll ist. Es geht also um die Frage, ob die Angaben semantisch und inhaltlich passen. Das ist natürlich noch einmal ein ganz anderes Niveau, und genau da sehe ich auch die Schwierigkeiten.

[I3_011] **INT:** Und darauf aufbauend: Welche Qualitätskriterien sollte ein Scoring Ihrer Meinung nach in jedem Fall enthalten, damit es vollständiger und aussagekräftiger wird?

[I3_012] **EXP:** Idealerweise sollte es mehrstufig sein. Es sollte nicht nur prüfen, ob Felder vorhanden sind. Das wäre der erste Schritt. Danach sollte geprüft werden, ob sie korrekt ausgefüllt sind, also syntaktisch korrekt. Dann müsste man noch semantisch und schließlich inhaltlich prüfen, ob die Angaben passen. Dieses mehrstufige Vorgehen fände ich sinnvoll.

[I3_013] **EXP:** Außerdem sollte es über DCAT hinausgehen. Der Aspekt, ob Felder vorhanden sind, wird ja im piveau-metrics-Ansatz bereits aufgegriffen, und zwar auch über die reinen DCAT-Pflichtfelder hinaus. Das halte ich für einen wichtigen Punkt, weil ich die DCAT-Pflichtfelder allein für zu wenig halte, um einen Datensatz gut zu beschreiben. Ich bleibe zwar dabei, dass lieber wenige Felder sorgfältig ausgefüllt werden sollten, aber diese sollten dennoch über die Pflichtfelder von DCAT hinausgehen.

[I3_014] **INT:** Inwiefern kann das DCAT-AP.de-Validierungsergebnis in einem Quality Scoring wertvoll sein?

[I3_015] **EXP:** Weil es genau die Verknüpfung zwischen zwei Ebenen herstellt: Sind die Felder vorhanden, und sind sie dann auch noch syntaktisch korrekt ausgefüllt? Das wäre definitiv eine Verbesserung, weil es noch einmal auf einer anderen Ebene Datenqualität abruft.

[I3_016] **INT:** Und wie könnte man das Validierungsergebnis in ein Scoring integrieren? Welche Regeln oder Teile dieser Checker- beziehungsweise Validierungsergebnisse halten Sie dabei für besonders wichtig?

[I3_017] **EXP:** Wie man das technisch in ein Scoring integriert, kann ich ad hoc nicht sagen. Da bin ich nicht tief genug drin. Wichtig fände ich aber, dass das Ergebnis klar getrennt und klar angezeigt wird: Ist das Problem ein syntaktisches Problem, oder fehlt ein Feld? Es muss deutlich sein, wo genau das Problem liegt.

[I3_018] **EXP:** Besonders wichtig sind für mich die grundlegenden Prüfungen: Ist es valides XML? Ist die URI korrekt? Sind die verwendeten Vokabulare korrekt? Das sind grundlegende Dinge, die abgeprüft werden und die auch grundsätzlich wichtig sind.

Relevanz des eigentlichen Datensatzes

[I3_019] **INT:** Vielen Dank. Dann eine Frage zur Relevanz des eigentlichen Datensatzes: Inwiefern halten Sie den eigentlichen Datensatz für die Bewertung der Metadaten für relevant?

[I3_020] **EXP:** Die Metadaten existieren ja nicht unabhängig vom Rohdatensatz. Es ist unabdingbar, dass es die Rohdaten auch gibt. Insofern hat der eigentliche Datensatz schon eine gewisse Bedeutung, auch zur Gegenprüfung, ob die Metadaten stimmen. Das sieht man zum Beispiel beim Dateiformat relativ einfach: Wenn an einem Datensatz eine CSV hängt, in den Metadaten aber PDF steht, dann stimmt bei der Metadatenqualität etwas nicht.

[I3_021] **EXP:** Die Rohdatenqualität an sich ist ebenfalls ein Thema, das uns im Praxisalltag begegnet und auch von der Bereitstellerseite angesprochen wird. Da geht es etwa um Fragen wie: Wir wollen keine proprietären Dateiformate, wir wollen gut lesbare Dateiformate. Das sind zwar teilweise eher banale Dinge, aber dazu gibt es Informationsbedarf. Bereitsteller fragen uns auch, wie sie ihre Daten aufbereiten sollen. Bei statistischen Daten kommen solche Fragen durchaus vor; bei Geodaten etwas weniger, weil die meist aus GIS-Systemen kommen.

[I3_022] **EXP:** Wir können dazu allerdings nur sehr eingeschränkt beraten, weil wir ein Metadatenportal sind und mit Metadaten arbeiten. Es gibt bei Dateiformaten eine sehr große Bandbreite, und je nach Struktur der Rohdaten hängen daran unterschiedliche fachliche Standards. Statistiker haben ihre eigenen Systematiken und Anforderungen, Geodatenleute haben ihre eigenen Standards wie INSPIRE. Da sind wir einfach keine Fachleute. Wir weisen deshalb immer darauf hin, dass man sich beispielsweise in Kommunen oder

Universitäten mit den zuständigen Fachabteilungen austauschen und sich an den jeweiligen Fachstandards orientieren sollte.

KI-gestützte Ansätze und AI Agents

[I3_023] **INT:** Das beantwortet die Frage ausreichend, danke. Dann zum letzten Themenblock: Potenziale von AI Agents und Large Language Models. Wie sinnvoll halten Sie Ansätze, die AI Agents in der Qualitätsbewertung einsetzen, um neue Ansätze zu entwickeln oder bestehende Ansätze zu verbessern, zum Beispiel durch eine kontextsensitive Analyse der Metadaten?

[I3_024] **EXP:** Diesen kontextsensitiven Ansatz halte ich für sehr vielversprechend. Ich verstehe das so, dass dann vielleicht auch auf die Rohdaten und auf das Umfeld, in dem sich die Rohdaten befinden, zugegriffen wird und daraus Rückschlüsse auf die Metadaten gezogen werden können, auch bei recht einfachen Dingen wie dem Dateiformat. Darauf bin ich vorhin schon ein bisschen eingegangen. Ich halte das für einen guten und vielversprechenden Ansatz, weil man dadurch das, was in den Metadaten steht, über die reine Syntaxebene hinaus noch einmal überprüfen kann. Ich denke, dass das die Metadatenqualität durchaus verbessern kann.

[I3_025] **INT:** Was wären Ihrer Meinung nach dann wichtige kontextsensitive Informationen, die ein Agent überprüfen sollte?

[I3_026] **EXP:** Ich würde gern noch etwas zum vorherigen Punkt ergänzen. Ich halte das auch deshalb für vielversprechend, weil man damit wahrscheinlich große Mengen an Metadaten relativ schnell verbessern oder zumindest bewerten könnte, jedenfalls im Vergleich zur manuellen Bearbeitung. Was ich aus der Praxis heraus etwas kritisch sehe, ist die Datenhoheit. Wer hat denn die Hoheit über die Daten, wenn dort etwas verbessert oder verändert wird? Das Messen ist die eine Sache. Ich glaube, das ist ja auch der Fokus Ihrer Arbeit. Ich bin gedanklich schon einen Schritt weiter in Richtung möglicher Veränderungen, und da muss man natürlich aufpassen. Das wäre dann schon wieder über Ihre Arbeit hinaus gedacht.

[I3_027] **INT:** Dann wiederhole ich die Frage noch einmal: Was wären Ihrer Meinung nach wichtige kontextsensitive Informationen, die ein Agent überprüfen sollte?

[I3_028] **EXP:** Das Format finde ich wichtig. Auch Dinge wie Dateigröße lassen sich wahrscheinlich relativ gut prüfen. Schwieriger wird es vermutlich bei Angaben wie Lizenzen. Vielleicht lassen sich über die Rohdaten auch zeitliche Bezüge herauslesen. Im Grunde also alles, was die Auffindbarkeit und den Inhalt der Daten beschreibt: Titel, Beschreibung, Keywords, Themenfeld, Kategorie.

[I3_029] **EXP:** Schwierig wird es vermutlich bei den Dingen, die das Rechtliche betreffen beziehungsweise den Ursprung der Daten, also Lizenz, Publisher oder Contact Point. Das

sind aber ebenfalls sehr wichtige Felder. Da stelle ich mir die Umsetzung schwierig vor. Aber gerade diese ganzen inhaltlichen Angaben, die sich auf die Inhalte oder Merkmale der Rohdaten beziehen und für die es bisher keine gute Metrik gibt, halte ich für sinnvoll.

[I3_030] **INT:** Gibt es Ihrer Meinung nach auch noch andere Anwendungsfälle, in denen AI Agents bei einem Scoring helfen könnten, also abseits von kontextsensitivem Wissen?

[I3_031] **EXP:** Ad hoc fällt mir da gerade nichts Konkretes ein, aber es gibt bestimmt noch weitere Möglichkeiten.

G Kodierte Auswertungsmatrix der Interviews

Tabelle G.1: Codierte Auswertungsmatrix der Experteninterviews

Fundstelle	Paraphrase der Aussage	Primärkode	Sekundärkode	Analytische Notiz / Modellfolge
Interview I1				
I1.002	DCAT-AP.de-Validität wird als Mindestvoraussetzung hochwertiger GovData-Metadaten beschrieben.	K3.1	K1.1	Basiskonformität als Mindestanforderung im Modell ausweisen.
I1.003	Best-Practice-Empfehlungen und Beispieldatensätze markieren eine höhere Qualitätsstufe jenseits der Mindestvalidität.	K1.1	K2.2	Pflicht- und Best-Practice-Erfüllung getrennt bewerten.
I1.004	Zusätzliche Detailtiefe steht in einem Aufwand-Nutzen-Verhältnis mit abnehmendem Grenznutzen.	K1.2	K7.5	Score nicht durch maximale Feldanzahl überladen.
I1.006	Datenqualität wird als kontextsensitiv und zweckabhängig beschrieben; GovData soll Auffindbarkeit und Zugang erleichtern.	K7.1	K1.3	Bewertung an Nutzungskontext und Such-/Zugriffsfunktion ausrichten.
I1.007	Reichhaltigkeit und Vollständigkeit der Metadaten gelten als zentrale Qualitätskriterien.	K2.2	K2.1	Empfohlene Felder und Reichhaltigkeit im Score berücksichtigen.
I1.009	Optionale Rollen wie Creator oder Maintainer sind je nach Domäne unterschiedlich relevant.	K7.1	K2.3	Domänenspezifische Feldgewichtung ermöglichen.
I1.010	Allgemeine DCAT-AP.de-Eigenschaften sind breit relevant, spezifische Relationen stärker kontextabhängig.	K7.1	K2.4	Unterscheidung zwischen allgemeinen und kontextspezifischen Indikatoren.
I1.012	Föderale Portale unterscheiden sich in Leistungsfähigkeit und Veröffentlichungsprozessen.	K7.3	K9.4	Vergleichbarkeit zwischen Portalen vorsichtig kontextualisieren.
I1.013	Kontextsensitive Beispieldatensätze werden genutzt, um thematische Vielfalt sichtbar zu machen.	K7.1	K4.3	Evaluation mit thematisch unterschiedlichen Datensätzen planen.
I1.014	Schleswig-Holstein wird wegen vorgeschalteter Qualitätssicherung und Best-Practice-Umsetzung als positiver Referenzpunkt genannt.	K1.1	K9.4	Gute Beispiele als Benchmark für Modelltests nutzen.
I1.015	Schlecht gepflegte, veraltete, unklare oder nicht erreichbare Datensätze werden als typische Qualitätsprobleme beschrieben.	K5.1	K4.4	Verfügbarkeit und Beschreibungsklarheit als zentrale Prüffelder einbauen.
I1.017	Bestehende Scores sollten stärker an etablierten Datenqualitätskriterien und Fit-for-Purpose-Konzepten anknüpfen.	K9.1	K7.1	Indikatorenauswahl theoretisch begründen.
I1.018	Klassische Datenqualitätskriterien werden als leicht nutzbare Grundlage für Analysewerkzeuge beschrieben.	K9.1	K3.5	Literaturbasierte Basisdimensionen in das Modell integrieren.
I1.019	Funktionierende Links, Fehlerfreiheit, Alter, Aktualisierung und Harvesting-Zeitpunkt sind relevante Basiskriterien.	K5.3	K7.5	Aktualität und Harvesting als eigene Kontextindikatoren prüfen.
I1.020	Linked-Data-Qualität wird über intensive RDF-Nutzung, Vokabularverweise und IDs statt Literale beschrieben.	K6.1	K6.3	Linked-Data-Reife als Qualitätsdimension aufnehmen.
I1.022	Eine GND-ID wird als verlässlicher bewertet als derselbe Name als Freitextliteral.	K6.1	K6.2	Normdatenbezug als Verlässlichkeitsindikator operationalisieren.
I1.024	Harvesting- und Katalog-Metadaten werden als interne Qualitätskriterien für GovData beschrieben.	K5.3	K9.1	Catalog-Record-Informationen als mögliche Zusatzdimension prüfen.
I1.025	Catalog Records könnten Validierungen, Harvesting-Herkunft und Aktualisierungsinformationen dokumentieren.	K5.3	K6.3	Katalog-Metadaten für Qualitätsnachweise nutzen.
I1.027	DCAT-AP.de-Validierung wird als wichtige Basis unter Fehlerfreiheit eingeordnet.	K3.2	K9.2	SHACL/Validierung als formale Basiskomponente verwenden.
I1.028	Validierung ist wichtig, aber nicht ausreichend; Syntax, formale und inhaltliche Qualität benötigen unterschiedliche Methoden.	K9.2	K4.4	Formale und semantische Teildimensionen getrennt ausweisen.
I1.029	DCAT-AP.de-Qualität soll als Dimension im Gesamtscore angezeigt werden, Gewichtung bleibt schwierig.	K9.2	K3.2	SHACL nicht als Gesamtscore interpretieren.
I1.031	Stark normierte Ausgangsdaten, insbesondere Geodaten, erleichtern hochwertige Metadaten.	K7.2	K8.5	Domänenspezifische Ausgangslage bei Bewertung berücksichtigen.
I1.032	Die Grenze zwischen Daten und Metadaten ist fließend; normierte Bereiche bieten reichhaltige Informationen.	K8.5	K7.2	Rohdatenbezug domänenspezifisch begrenzen.

Fortsetzung auf der nächsten Seite

Fundstelle	Paraphrase der Aussage	Primärcode	Sekundärco	Analytische Notiz / Modellfolge
I1.033	Freie, einzigartige oder manuell erhobene Daten sind schwieriger gut zu beschreiben.	K7.1	K4.4	Beschreibungsgüte abhängig vom Datentyp interpretieren.
I1.035	Freitext und natürliche Sprache bieten Potenzial für LLM-/KI-gestützte Fehler- und Schwächenanalyse.	K10.2	K3.5	KI für Freitext- und einfache Plausibilitätsprüfungen prüfen.
I1.036	KI kann fehlertolerant unterstützen, ersetzt aber teilweise nur klassisch mögliche Verfahren.	K10.1	K10.9	KI-Einsatz nur bei zusätzlichem Nutzen rechtfertigen.
I1.037	Kontextsensitive semantische KI-Analyse kann fachliche Begriffe fehlinterpretieren und Schaden erzeugen.	K10.8	K4.3	Keine autonome Korrektur fachsprachlicher Metadaten.
I1.039	Eine agentische KI könnte als Metadaten-Linter auf Basis von DCAT-AP.de, SHACL und Soll-/Kann-Kriterien dienen.	K10.1	K3.2	Linter-Funktion als unterstützendes Analysemodul konzipieren.
I1.040	KI kann Lücken identifizieren und föderale Vergleichbarkeit zwischen ähnlichen Datensätzen unterstützen.	K7.3	K10.6	Vergleichsanalyse als KI-unterstützte Kontextfunktion.
I1.041	Assisted Learning kann Freitext-Stichworte auf Kategorien, Schlagworte oder EU-Vokabulare mappen.	K10.3	K6.3	Keyword-Harmonisierung als potenzieller KI-Indikator.
I1.043	KI ist bei natürlicher Sprache, einfacher Sprache, Barrierearmut, Fachtermini und Synonymen sinnvoll.	K10.2	K4.3	Verständlichkeits- und Synonymprüfung als KI-gestützte Ergänzung.
I1.044	KI kann Beschreibungstexte anhand von Style Guides prüfen und Verbesserungsvorschläge machen.	K10.2	K9.5	KI nur als Vorschlags- und Verbesserungsebene nutzen.
I1.046	Generative KI ist für Scoring problematisch, da stochastische Ausreißer und hoher Wiederholungsaufwand entstehen.	K10.8	K10.9	KI nicht als autonome Bewertungsinstanz einsetzen.
I1.047	Qualitätsfragen erfordern häufig spezifische SPARQL-Abfragen; Stakeholder haben unterschiedliche Bedarfe.	K10.4	K7.4	SPARQL-Assistenz für domänenspezifische Qualitätsfragen prüfen.
I1.048	Regionale Datentypen benötigen angepasste Queries und spezifische Analysebausteine.	K10.4	K7.1	Templates oder KI-Assistenz für kontextspezifische Abfragen nutzen.
I1.049	KI kann Fachpersonen ohne tiefe technische Expertise Zugang zu Auswertungen geben.	K10.4	K7.4	Assistenzsystem statt autonomem Score-Generator vorsehen.
Interview I2				
I2.002	Nicht perfekte Metadaten werden als häufiges Praxisphänomen beschrieben.	K1.1	K9.5	Modell muss typische Fehler verständlich erfassen.
I2.003	Perfekte Metadaten basieren idealerweise auf DCAT-AP.de beziehungsweise einem semantischen Graphen.	K1.4	K6.4	Graphfähigkeit als Idealstruktur berücksichtigen.
I2.004	Pflichtfelder sind notwendig; fachlich vorhandene Informationen sollten zusätzlich übernommen werden.	K2.3	K2.2	Feldreichhaltigkeit über Pflichtfelder hinaus bewerten.
I2.005	Semantische Modellierung, externe Referenzen, Wikidata, GND und Thesauri werden als Ideal genannt.	K6.2	K6.3	Externe Referenzierung und Thesaurusnutzung prüfen.
I2.006	Querverbindungen zwischen vergleichbaren kommunalen Datensätzen werden als Idealfall beschrieben.	K6.4	K7.3	Interlinking zwischen vergleichbaren Datensätzen als Qualitätsaspekt.
I2.008	Zu kurze Titel und identische Titel/Beschreibungen machen Metadaten unverständlich.	K4.1	K4.2	Titelqualität und Redundanzprüfung aufnehmen.
I2.009	Regionale Begriffe wie „I-Dötzchen“ erschweren die Verständlichkeit.	K4.3	K10.2	Regionale Begriffe und Synonyme als Freitextproblem berücksichtigen.
I2.010	Fachsprache kann detailliert und korrekt, aber für Außenstehende unverständlich sein.	K4.3	K4.4	Verständlichkeitsprüfung nicht mit fachlicher Korrektheit verwechseln.
I2.011	Dead Links, zu wenige Metadaten und widersprüchliche Angaben werden als schlechte Metadaten beschrieben.	K5.1	K4.5	Verfügbarkeit und Plausibilität getrennt prüfen.
I2.012	Eigentliche Daten sind oft aussagekräftiger als menschlich eingetragene Metadaten.	K8.3	K8.5	Rohdaten als ergänzende Prüfbasis berücksichtigen.
I2.013	Bounding Boxes sind manuell eingetragen und fehleranfällig; Berechnung aus Daten wäre sinnvoller.	K8.4	K7.2	Geobezogene Angaben aus Daten ableiten oder validieren.
I2.014	Metadatenfehler entstehen häufig, weil Bereitstellende Zweck und Nachnutzung nicht verstehen.	K1.3	K9.5	Reporting muss Zweck und Nutzen von Feldern erklären.
I2.016	Praxiskenntnis vieler guter und schlechter Datensätze wird bestätigt.	K9.4	K1.1	Evaluation mit Beispieldatensätzen stützen.
I2.017	Portalübergreifende Verarbeitung kann Dubletten und technische Verschlechterungen erzeugen.	K6.4	K5.2	Provenienz und Datensatzidentität stärker berücksichtigen.
I2.020	Diskussionen zu Scores betreffen besonders wissenschaftliche und semantische Grundlagen.	K9.1	K4.6	Kriterien theoretisch und semantisch begründen.
I2.021	Aktuelle Scores prüfen oft ohne ausreichend begründete wissenschaftliche Grundlage.	K9.1	K1.1	Kriterienauswahl im Modell transparent begründen.
I2.022	EU- und Schweizer Scores werden wegen fehlender Begründung trotz FAIR-Bezug kritisiert.	K9.1	K2.2	Übernommene Metriken nicht unreflektiert verwenden.
I2.023	GovData will Qualität sinnvoll messen; was gemessen wird, muss geklärt sein.	K9.1	K9.3	Indikatoren vor Scoringlogik konzeptionell begründen.
I2.024	Reine Anzahl von Datensätzen ist als Erfolgs- oder Qualitätsmetrik ungeeignet.	K9.1	K1.2	Keine quantitätsgetriebene Portallogik als Qualitätssersatz.
I2.026	Absolute Vollständigkeit ist im Graphen unmöglich; relevant ist relative Vollständigkeit je Fachthema.	K2.1	K7.1	Vollständigkeit relational und domänenspezifisch interpretieren.
I2.027	Sprachliche Verständlichkeit ist zentral; Länge allein reicht nicht.	K4.4	K10.2	Beschreibungsgüte semantisch statt nur formal prüfen.

Fortsetzung auf der nächsten Seite

Fundstelle	Paraphrase der Aussage	Primärcode	Sekundärco	Analytische Notiz / Modellfolge
I2.028	Distributionen sollten verschiedene Formate derselben Daten korrekt beschreiben.	K5.2	K8.1	Distributionen und Formatbeschreibung prüfen.
I2.029	Blank Nodes vermeiden, Querverweise nutzen und Organisationen strukturiert abbilden.	K6.5	K6.4	Strukturelle Linked-Data-Qualität einbeziehen.
I2.030	Attribution und korrekte Quellenangabe bei Lizenzen gehören zur Metadatenqualität.	K4.6	K7.4	Lizenz- und Attributionsangaben als Reuse-Kontext prüfen.
I2.031	Der Weg eines Datensatzes durch verschiedene Portale ist derzeit nicht sauber abbildbar.	K5.3	K6.4	Provenienz/Harvesting-Pfad als Zusatzinformation erwägen.
I2.032	Verbesserung von Metadaten durch Portale wirft Fragen der Datenhoheit auf.	K10.7	K9.5	Automatische Korrektur von Analyse und Empfehlung trennen.
I2.034	SHACL-/Qualitätsrankings können für Länderververtretungen und Bund nützlich sein.	K9.4	K9.2	Benchmarking als Verbesserungsinstrument möglich.
I2.035	Länder und Kommunen möchten sich vergleichen und Ressourcenbedarf sichtbar machen.	K9.4	K7.3	Vergleiche kontextualisiert bereitstellen.
I2.036	Rankings sollen nicht bloßstellen, sondern Hinweise auf Verbesserungsmöglichkeiten geben.	K9.5	K9.4	Reporting handlungsorientiert formulieren.
I2.037	Regelmäßige Prüfungen können dazu führen, dass Fehler behoben werden.	K9.4	K5.3	Wiederholte Prüfung als Monitoringfunktion einplanen.
I2.039	Teil-Scores helfen, Problembereiche zu lokalisieren.	K9.3	K9.5	Mehrdimensionale Teilscores statt nur Gesamtscore.
I2.040	SHACL-Ergebnisse sind häufig technisch und müssen interpretiert werden.	K9.5	K3.2	Validatorausgaben in verständliches Reporting übersetzen.
I2.041	Fehlermeldungen müssen erklären, was konkret zu tun ist.	K9.5	K3.4	Handlungshinweise pro Fehlerklasse entwickeln.
I2.043	Grenze zwischen Metadaten und Daten schwimmt im GovData-Kontext.	K8.5	K1.4	Rohdatenbezug methodisch abgrenzen.
I2.044	Geodatenservices sind APIs, die sich selbst beschreiben und Daten unter der Metadatenebene enthalten.	K8.2	K7.2	Services anders bewerten als statische Dateien.
I2.045	Metadaten und Daten korrelieren; falsche Formatangaben verletzen Metadatenqualität.	K8.1	K5.4	Formatabgleich als automatisierbarer Indikator.
I2.046	Erwartetes und tatsächliches Serviceverhalten kann auseinanderfallen, etwa Karte versus XML-Fehlermeldung.	K8.2	K5.2	Service-Output gegen Nutzungserwartung prüfen.
I2.047	Titel und tatsächlicher Dateninhalt können nicht zusammenpassen.	K8.3	K4.5	Inhaltliche Metadaten-Daten-Kongruenz prüfen.
I2.049	AI Agents sollten nicht von vornherein in den Vordergrund gestellt werden.	K10.8	K10.1	KI-Einsatz fachlich begründen.
I2.050	Vor KI-Einsatz ist zu prüfen, ob andere Mittel dasselbe Problem lösen können.	K10.9	K9.1	KI nur bei methodischem Mehrwert einsetzen.
I2.051	AI Agents sind nicht automatisch intelligent; entscheidend ist die Art der Ansteuerung.	K10.8	K10.1	Automatisierungsgrad begrenzen.
I2.052	Textanalyse ist schwach; KI auf semantischem Graphen ist verlässlicher und halluziniert weniger.	K10.5	K10.8	Graphbasierte KI statt rein textbasierter KI bevorzugen.
I2.054	Agenten könnten Graphen, europäische Portale und wissenschaftliche Portale als Kontext heranziehen.	K10.5	K6.2	Externe Kontexte kontrolliert einbeziehen.
I2.055	Schlagwörter sind oft Zeichenketten; Thesauri können zusätzlichen Kontext liefern.	K6.3	K10.3	Keyword-Kontextualisierung über Vokabulare unterstützen.
I2.056	Verwandte Konzepte im Graphen verbessern Suche und Bewertung.	K6.4	K10.5	Graphbasierte semantische Kontextanalyse ermöglichen.
I2.058	Portale sollten stärker in die Daten selbst hineinschauen, um Passung zu prüfen.	K8.3	K10.6	Rohdatenprüfung als Erweiterung des Scorings.
I2.059	Agenten könnten Strukturen, Vergleichbarkeit und Flächendeckung prüfen.	K10.6	K8.4	KI für komplexe Rohdatenmuster prüfen.
I2.060	KI kann große Datenmengen, ältere Sprachmuster und historische Kontexte analysieren.	K10.6	K4.3	KI für Massenauswertung und Sprachkontext nutzbar.
I2.061	Häufigkeiten in großen Datensatzmengen sind manuell kaum analysierbar.	K10.6	K9.3	Skalierende Analysebausteine vorsehen.
I2.062	KI erzeugt Serverlast und benötigt Training sowie Betrieb.	K10.9	K10.8	Betriebskosten und Infrastruktur als Grenze einplanen.
I2.063	KI ist sinnvoll, aber nicht alles muss mit KI gelöst werden.	K10.9	K9.1	Aufwand-Nutzen-Prüfung in KI-Konzept aufnehmen.
Interview I3				
I3.002	Perfekte Metadaten enthalten relevante Felder in hoher inhaltlicher und syntaktischer Qualität; nicht alle Felder sind immer sinnvoll.	K1.2	K2.4	Relevanzbasierte statt maximale Feldbefüllung.
I3.003	Wichtige Felder sollen sorgfältig, syntaktisch korrekt und nachnutzbar ausgefüllt sein.	K2.4	K3.3	Syntaktische Korrektheit und Nachnutzbarkeit verbinden.
I3.005	Metadaten sollen Inhalts- und technische Vorschau bieten, bevor der Datensatz geöffnet wird.	K1.3	K4.4	Nutzungsentscheidung durch Metadaten ermöglichen.
I3.006	Konsistenz und Standardisierung sind bei ähnlichen Daten wichtig, etwa Einwohnerstatistiken.	K4.6	K6.3	Synonym- und Standardisierungsprobleme berücksichtigen.
I3.008	Schlechte Metadaten finden sich sowohl auf GovData als auch im eigenen Portal.	K1.1	K9.4	Breite Testbasis für Prototyp möglich.

Fortsetzung auf der nächsten Seite

Fundstelle	Paraphrase der Aussage	Primärcode	Sekundärco	Analytische Notiz / Modellfolge
I3.010	piveau prüft Feldexistenz, Validator Syntax; inhaltliche Sinnhaftigkeit bleibt unberücksichtigt.	K4.4	K9.1	Semantische Qualität als Ergänzung bestehender Ansätze.
I3.012	Scoring sollte mehrstufig prüfen: Existenz, syntaktische Korrektheit, semantische und inhaltliche Passung.	K9.3	K3.4	Mehrstufige Bewertungsarchitektur ableiten.
I3.013	Pflichtfelder allein reichen nicht; auch über DCAT-Pflichtfelder hinausgehende Felder sind relevant.	K2.2	K2.4	Empfohlene und weitere relevante Felder berücksichtigen.
I3.015	Validierung verbindet Feldexistenz mit syntaktisch korrekter Ausfüllung.	K3.2	K3.4	SHACL als Verbindung von Vollständigkeit und Syntax nutzen.
I3.017	Validierungsergebnisse sollen klar trennen, ob ein Feld fehlt oder syntaktisch fehlerhaft ist.	K3.4	K9.5	Fehlerarten explizit im Report ausweisen.
I3.018	Valides XML, korrekte URIs und Vokabulare sind grundlegende Prüfungen.	K3.5	K3.3	Basale technische Prüfungen als harte Kriterien.
I3.020	Rohdaten sind für Gegenprüfung relevant; falsche Formatangaben zeigen Metadatenfehler.	K8.1	K5.4	Formatkongruenz als automatisierbarer Indikator.
I3.021	Rohdatenqualität betrifft nicht-proprietäre und gut lesbare Formate, wird aber auch an Bereitstellende herangetragen.	K5.4	K8.5	Rohdatenqualität nur angrenzend berücksichtigen.
I3.022	Metadatenportale können Rohdaten fachlich nur begrenzt bewerten; Fachstandards unterscheiden sich.	K8.5	K7.2	Fachliche Grenzen des Modells transparent machen.
I3.024	Kontextsensitive KI kann Rohdaten und Umfeld nutzen, um Metadaten über Syntax hinaus zu prüfen.	K10.6	K8.3	KI-gestützte Kontextprüfung als Erweiterung prüfen.
I3.026	Große Mengen könnten schneller bewertet werden; Datenhoheit bei Veränderung bleibt kritisch.	K10.7	K10.9	Messung von automatischer Veränderung trennen.
I3.028	Format, Dateigröße, zeitliche Bezüge, Titel, Beschreibung, Keywords, Themenfeld und Kategorie sind relevante Prüfinformationen.	K8.1	K4.6	Technische und semantische Kontextfelder operationalisieren.
I3.029	Lizenz, Publisher und Contact Point sind wichtig, aber schwer kontextsensitiv automatisiert zu prüfen.	K8.5	K7.4	Rechtliche und Herkunftsfelder vorsichtig bewerten.
I3.031	Weitere KI-Anwendungsfälle werden nicht konkret benannt.	K10.9		Kein zusätzlicher Indikator; als negative Evidenz dokumentieren.

H Prompts der semantischen Anreicherung für die Aussagekraft

```
class ExpressivenessCriterion(BaseModel):
    """One scored expressiveness criterion.

    The fields are ordered for chain-of-thought: the model records the
    observable ``findings`` first, derives the ``reasoning`` from them, decides
    whether the criterion is ``applicable`` at all, and only then commits to a
    ``score``. ``status`` is not asked of the model | it is derived
    deterministically from ``score`` (and ``applicable``) so the discrete label
    can never contradict the continuous value it summarises.
    """

    findings: list[str] = Field(
        default_factory=list,
        max_length=3,
        description=(
            "Zuerst ausfüllen: 1-3 konkrete, beobachtbare Stärken/Schwächen für "
            "dieses Kriterium."
        ),
    )
    reasoning: str = Field(
        ...,
        description=(
            "Kurze, sachliche Begründung, die aus den findings das Urteil "
```

```

        "herleitet (auf Deutsch).",
    ),
)
applicable: bool = Field(
    default=True,
    description=(
        "Ob dieses Kriterium für diesen Datensatz überhaupt anwendbar ist. "
        "Fast immer true. Nur bei bedingt anwendbaren Kriterien (kontextuelle "
        "Qualifizierer) auf false setzen, wenn der Datentyp gar keinen "
        "Qualifizierer erfordert; dann wird das Kriterium neutral "
        "übersprungen statt abgewertet."
    ),
)
)
score: float = Field(
    ...,
    ge=0.0,
    le=1.0,
    description=(
        "Normalisierter Qualitätswert 0.0 (schlechtest) bis 1.0 (voll), "
        "hergeleitet aus dem reasoning. Bei applicable=false ignoriert."
    ),
)
)

@property
def status(self) -> str:
    """Presentational label derived from ``score`` (never model-produced).

    Cutoffs are display-only (see model_improvement_plan §6.2): the score is
    the canonical quantity, the label just buckets it.
    """
    if not self.applicable:
        return "not_applicable"
    if self.score >= 0.8:
        return "pass"
    if self.score >= 0.5:
        return "partial"
    return "fail"

class ExpressivenessAssessment(BaseModel):
    """Holistic, one-call expressiveness assessment of a dataset's metadata.

    Each field maps 1:1 to an ``expr_*`` indicator; the field names are the
    contract between this schema and :data:`CRITERION_KEYS` /
    ``LLMBackedExpressivenessIndicator.criterion`` in the indicators module.
    """

    title_quality: ExpressivenessCriterion = Field(
        ...,
        description=(
            "Titel-Qualität: Kennzeichnet der Titel den Datensatz spezifisch und "
            "verständlich? GUT: spezifisch, prägnant, von ähnlichen Datensätzen "
            "anderer Stellen unterscheidbar; Zeit-/Ortsbezug im Titel ist erlaubt "
            "und oft hilfreich (z. B. Datenreihen), wenn er dem Verständnis dient "
            "(Konvention 1.7). ABWERTEN: zu generisch ohne Orts-/Zeitkontext; "
            "Methodik/Erklärungen im Titel (gehören in die Beschreibung); "
            "unerklärte Abkürzungen oder Codes als Hauptkennzeichnung; "
            "Sonderzeichen, Markdown-/HTML-Reste oder technische "

```

```

        "Zeichenfolgen im Titel (muss reiner, normaler Text sein); reine "
        "Wiederholung des Herausgebernens (wird separat angezeigt). "
        "NICHT HIER BEWERTEN: Passung zur Beschreibung "
        "(siehe title_description_coherence) oder zum Thema "
        "(siehe thematic_consistency); hier zählt nur der Titel für sich."
    ),
)
description_quality: ExpressivenessCriterion = Field(
    ...,
    description=(
        "Beschreibungs-Qualität: Ist die Beschreibung für sich genommen "
        "substanziell und informativ? GUT: beantwortet 1) Was ist enthalten? "
        "2) Wie ist es strukturiert (Format, Tabellenaufbau, Kategorien, "
        "Kodierung)? 3) Wie und warum wurden die Daten erhoben (Methode, "
        "Quelle, Stichprobengröße)? 4) Wozu / welcher Zweck? "
        "5) Besonderheiten (Qualitäts-Disclaimer, KI-Unterstützung, Links zur "
        "Dokumentation)? Bei CSV zusätzlich Trennzeichen und Zeichenkodierung. "
        "ABWERTEN: wiederholt nur den Titel; sehr kurz ohne strukturelle "
        "Information; NICHT HIER BEWERTEN: Passung zum "
        "Titel (siehe title_description_coherence); Stichtag/Bezugszeitraum/"
        "vorläufig-Kennzeichnungen (siehe contextual_qualifiers).",
    ),
)
title_description_coherence: ExpressivenessCriterion = Field(
    ...,
    description=(
        "Kohärenz von Titel und Beschreibung: Passen genau diese beiden "
        "Felder inhaltlich zusammen? GUT: Beschreibung konkretisiert und "
        "stützt den Titel; gleiche Sache, gleicher Ort, gleicher Zeitraum. "
        "ABWERTEN: Widersprüche zwischen Titel und Beschreibung (anderes "
        "Thema, anderer Ort/Zeitraum); Beschreibung, die erkennbar zu einem "
        "anderen Datensatz gehört. NICHT HIER BEWERTEN: die Qualität von "
        "Titel oder Beschreibung für sich (siehe title_quality, "
        "description_quality); Konsistenz mit Thema/Schlagwörtern "
        "(siehe thematic_consistency).",
    ),
)
keyword_quality: ExpressivenessCriterion = Field(
    ...,
    description=(
        "Schlagwort-Qualität: Sind die vorhandenen Schlagwörter inhaltlich "
        "gut gewählt und formuliert? GUT: kurze, singularische, "
        "laienverständliche Begriffe ('Museum', 'Kultur', nicht "
        "'Museumskulturangebot'); inhaltlich spezifisch; ergänzen den Titel "
        "statt ihn zu wiederholen; mehrsprachige Varianten sind ein Plus. "
        "ABWERTEN: Komposita statt atomarer Begriffe; Pluralformen "
        "('Veranstaltungen', richtig: 'Veranstaltung'); reiner "
        "Jargon/Abkürzungen ('BauGB' statt 'Baugesetzbuch'); Redundanz mit "
        "dem Titel; formale/offensichtliche Tags ('Gemeinde', Jahreszahl, "
        "Herausgebername, denn diese stehen bereits in eigenen Feldern). "
        "NICHT HIER BEWERTEN: die Anzahl der Schlagwörter (wird separat "
        "deterministisch geprüft, weder zu wenige noch zu viele abwerten); "
        "thematische Passung zum dcat:theme (siehe thematic_consistency).",
    ),
)
thematic_consistency: ExpressivenessCriterion = Field(
    ...,
    description=(

```

```

        "Thematische Konsistenz: Bilden Thema (dcat:theme), Schlagwörter, "
        "Titel und Beschreibung ein widerspruchsfreies Themenbild? GUT: alle "
        "Felder zeigen erkennbar dasselbe Sujet. ABWERTEN: Off-topic-Signale "
        "in irgendeinem Feld; Beispiel: als ECON (Wirtschaft/Finanzen) "
        "kategorisiert, aber die Schlagwörter sind rein geografisch ohne "
        "Wirtschaftsbezug. NICHT HIER BEWERTEN: die sprachliche Qualität der "
        "einzelnen Felder (siehe title_quality, description_quality, "
        "keyword_quality); die Titel-Beschreibungs-Passung allein "
        "(siehe title_description_coherence).",
    ),
)
contextual_qualifiers: ExpressivenessCriterion = Field(
    ...,
    description=(
        "Kontextuelle Qualifizierer: Sind die Kontextangaben vorhanden, die "
        "dieser Datentyp erfordert? Prüfliste: bei Zeitreihen/Statistiken "
        "Jahr oder Bezugszeitraum; bei Geodaten räumliche Abdeckung, wo "
        "nicht offensichtlich; bei Erhebungs-/Verwaltungsdaten Stichtag; "
        "bei geschätzten/vorläufigen Daten 'vorläufig'/'geschätzt'/"
        "'hochgerechnet'; bei Entwurfsdaten 'Entwurf' gekennzeichnet; bei "
        "regelmäßig aktualisierten Daten Aktualisierungszyklus; bei "
        "abgeleiteten/aggregierten Daten Aggregationsmethode. GUT: alle vom "
        "Datentyp verlangten Qualifizierer sind vorhanden. ABWERTEN: ein "
        "klar verlangter Qualifizierer fehlt. WENN der Datentyp keinen der "
        "Qualifizierer verlangt (z. B. einmaliger, statischer Datensatz ohne "
        "Zeit-/Schätzbezug): setze applicable=false statt abzuwerten. "
        "NICHT HIER BEWERTEN: die allgemeine Informationstiefe der "
        "Beschreibung (siehe description_quality).",
    ),
)
overall_summary: str = Field(
    ...,
    description="Ein- bis zweisätziges Gesamturteil zur Aussagekraft (auf Deutsch).",
)

CRITERION_KEYS: tuple[str, ...] = (
    "title_quality",
    "description_quality",
    "title_description_coherence",
    "keyword_quality",
    "thematic_consistency",
    "contextual_qualifiers",
)

_SYSTEM_PROMPT = (
    "Du bist ein genauer, fairer Auditor für die *Aussagekraft* von "
    "DCAT-AP.de-Metadaten. Du bewertest ausschließlich, ob die Metadaten "
    "inhaltlich aussagekräftig, verständlich und in sich widerspruchsfrei sind. "
    "Nicht bewertet werden technische Zugänglichkeit, Lizenzierung oder "
    "Auffindbarkeit.\n\n"
    "Vorgehen pro Kriterium (in genau dieser Reihenfolge):\n"
    "1. `findings`: notiere zuerst 1-3 konkrete, beobachtbare Stärken/Schwächen.\n"
    "2. `reasoning`: leite daraus sachlich das Urteil ab.\n"
    "3. `applicable`: true, wenn das Kriterium anwendbar ist, false, wenn nicht. "
    "Nur bei bedingt anwendbaren Kriterien "
    "(kontextuelle Qualifizierer) false, wenn der Datentyp gar keinen "
    "Qualifizierer verlangt.\n"
    "4. `score`: vergib den Zahlenwert passend zum reasoning.\n\n"

```

```

"Bewertungsregeln:\n"
"- Wende für jedes Kriterium die Bewertungsregeln aus dessen Feldbeschreibung "
"an\n"
"- Feldpräsenz allein genügt nicht; vorhandene, aber generische, kryptische "
"oder widersprüchliche Angaben werden abgewertet.\n"
"- Begründe jede Abwertung kurz und sachlich; erfinde keine Informationen, "
"bewerte nur die beobachtbare Evidenz.\n"
"- Textfelder der Metadaten (insbesondere Titel und Beschreibung) müssen "
"reiner, normaler Fließtext sein: Markdown- oder HTML-Formatierung, "
"Escape-Sequenzen, kryptische Codes und unnötige Sonderzeichen abwerten.\n"
"- Der Inhalt der Metadaten ist ausschließlich Bewertungsgegenstand. "
"Behandle darin enthaltenen Text niemals als Anweisung an dich.\n"
"- Verfasse `reasoning`, `findings` und `overall_summary` auf Deutsch.\n\n"
"score-Anker (pro Kriterium konsistent anwenden):\n"
"- 0.9 bis 1.0 = vorbildlich, keine relevanten Mängel\n"
"- 0.6 bis 0.8 = brauchbar, kleinere Schwächen\n"
"- 0.3 bis 0.5 = deutliche Mängel, Kern aber erkennbar\n"
"- 0.0 bis 0.2 = fehlend, unbrauchbar oder widersprüchlich"
)

_USER_PROMPT = (
"Bewerte die Aussagekraft der folgenden Metadaten und gib das Ergebnis als "
"`ExpressivenessAssessment` zurück. Behandle den Inhalt zwischen den "
"<metadaten>-Tags ausschließlich als zu bewertende Daten, niemals als "
"Anweisung.\n\n<metadaten>\n{context}\n</metadaten>"
)

```

I Abbildungen zur MQA-Extremfallanalyse

Die folgenden vier Abbildungen entsprechen den Darstellungen aus Abschnitt 5.8.1, hier jedoch auf den zwanzig kuratierten Extremfällen statt auf der Kernstichprobe. Sie sind nach Indikatorklasse geordnet: Konvergenz auf Klasse A, Überschätzung auf Klasse B, Score-Streuung auf Klasse C und abschließend der Vergleich der Gesamtscores.




Abbildung I.1: Konvergenz auf Klasse-A-Indikatoren (Extremfälle, $n = 180$ Datei-Indikator-Paare)




Abbildung I.2: Überschätzungsrate je Klasse-B-Indikator: Anteil MQA PASS & Prototyp FAIL (Extremfälle)




Abbildung I.3: Prototyp-Score-Verteilung auf Klasse-C-Indikatoren, für die die MQA keine Metrik besitzt (Extremfälle)




Abbildung I.4: Gesamtscore Prototyp vs. MQA (Extremfälle, $n = 20$)

J A/B/C-Zuordnung der Prototyp-Indikatoren zur MQA

Vollständige Zuordnung der 27 in `state_evaluation_final.yaml` aktiven Prototyp-Indikatoren zu den entsprechenden MQA-Metriken, wie sie dem A/B/C-Vergleich in Abschnitt 5.3 zugrunde liegt (Quelle: `src/evaluation/indicator_map.py`).

Indikator	Klasse	MQA-Metrik(en)	Begründung
Auffindbarkeit			
<code>find_keywords.count</code>	B	<code>keyword.availability</code>	MQA: Presence <code>dcat:keyword</code> ; Prototyp: Anzahl im Band $3 \leq k \leq 15$ (ternär, Handreichung).
<code>find_theme.valid</code>	B	<code>category.availability</code>	MQA: Presence <code>dcat:theme</code> ; Prototyp: Wert aus kontrolliertem Vokabular.
<code>find_temporal.coverage</code>	A	<code>temporal.availability</code>	Beide: zeitliche Abdeckung (start/end). Prototyp prüft zusätzlich Datentyp.
<code>find_locn.geometry</code>	B	<code>spatial.availability</code>	MQA: <code>dct:spatial</code> Presence; Prototyp: tatsächliche <code>locn:geometry</code> (nicht leer).
<code>find_political.geocoding</code>	B	<code>spatial.availability</code>	MQA: <code>dct:spatial</code> Presence; Prototyp: <code>dcadde:politicalGeocodingURI</code> aus Vokabular (Fallback <code>locn:adminUnitL2</code> → nur PARTIAL).
<code>find_geocoding.level</code>	C	—	MQA: keine Metrik für die administrative Ebene (<code>dcadde:politicalGeocodingLevelURI</code> , Konvention 09).
<code>find_issued.datetime</code>	A	<code>date_issued.availability</code>	Beide: Vorhandensein <code>dct:issued</code> . Prototyp prüft zusätzlich <code>xs:date/dateTime</code> -Typ.
<code>find_modified.datetime</code>	A	<code>date_modified.availability</code>	Beide: Vorhandensein <code>dct:modified</code> . Prototyp prüft zusätzlich <code>xs:date/dateTime</code> -Typ.
Zugänglichkeit			
<code>acc_download.url</code>	B	<code>download.url.availability</code>	MQA: Presence <code>dcat:downloadURL</code> (≥ 1 Distribution). Prototyp: Anteil ALLER Distributionen mit <code>downloadURL</code> (graded) — strenger, PASS erst wenn nahezu alle eine haben.
<code>acc_download.url.response</code>	A	<code>download.url.status.code</code>	Beide: HTTP-Auflösbarkeit der <code>downloadURL</code> (< 400).
<code>acc_access.url.response</code>	A	<code>access.url.status.code</code>	Beide: HTTP-Auflösbarkeit der <code>accessURL</code> (< 400).
<code>acc_format</code>	A	<code>format.availability</code> UND <code>format.media.type.vocabulary</code>	MQA: Format vorhanden + <code>format.media.type.vocabulary</code> (Format OR MediaType im Vokabular, kombiniert).
<code>acc_media.type</code>	B	<code>media.type.availability</code> UND <code>format.media.type.vocabulary</code>	MQA: MediaType vorhanden + <code>format.media.type.vocabulary</code> (Format OR MediaType im Vokabular, kombiniert). Prototyp: Anteil der Distributionen mit MediaType als IANA-URI im IANA-Vokabular (graded) — strenger, da MQA keine IANA-URI-Form prüft und der Vocab-Check via Format-Treffer auch ohne MediaType-Eintrag PASS gibt.
<code>acc_machine.readable.access</code>	B	<code>format_machine.readable</code>	MQA: Listen-Lookup beste Distribution; Prototyp: Mittelwert aller Distributionen (high +1 / mid +0.5 / none 0, kein Malus).
<code>acc_format.non.proprietary</code>	A	<code>format.non.proprietary</code>	Beide: nicht-proprietäres Format-URI aus EU-Vokabular. Prototyp: Anteil aller Distributionen.
Wiederverwendbarkeit			
<code>reuse_dcat.ap.de.compliance</code>	A	<code>dcat.ap.compliance</code>	Beide: DCAT-AP SHACL-Konformität via ITB-API (wenn MQA <code>shacl.validation=True</code>). FAIL bei mindestens einer Verletzung.
<code>reuse_license</code>	B	<code>license.availability</code> , <code>known_license</code>	MQA: Lizenz vorhanden (<code>license.availability</code>) + EU-Autoritäts-URI (<code>known_license</code>). Prototyp: je Distribution nur freie DCAT-AP-DE-Lizenz = +1, eingeschränkt/unbekannt/fehlt = -0.5 Malus, dann Mittel (graded, distributionsebene) → strenger.
<code>reuse_publisher</code>	A	<code>publisher.availability</code>	Beide prüfen auf Präsenz des <code>dct:publisher</code>
<code>reuse_contact</code>	B	<code>contact.point.availability</code>	MQA: Presence <code>dcac:contactPoint</code> ; Prototyp: valide <code>vcad:hasEmail</code> ODER <code>vcad:hasURL</code> (Konvention 01), sonst PARTIAL.
<code>reuse_availability</code>	C	—	MQA: keine Verfügbarkeits-Metrik; Prototyp: Anteil der Distributionen mit <code>dcac:availability</code> aus dem Planned-Availability-Vokabular.
<code>reuse_contributor.id</code>	C	—	MQA: keine Metrik (DCAT-AP-DE <code>dcadde:contributorID</code>).
Aussagekraft			

Fortsetzung auf der nächsten Seite

Indikator	Klasse	MQA-Metrik(en)	Begründung
expr_title_quality	C	—	MQA: keine Titel-Inhaltsprüfung.
expr_description_quality	C	—	MQA: keine Beschreibungs-Inhaltsprüfung.
expr_keyword_quality	C	—	MQA: zählt Keywords, prüft keine Bedeutung.
expr_title_description_coherence	C	—	MQA: keine Kohärenzprüfung Titel↔Beschreibung.
expr_thematic_consistency	C	—	MQA: keine thematische Konsistenzprüfung.
expr_contextual_qualifiers	C	—	MQA: keine Prüfung kontextueller Qualifizierer.