

Qualitätsmessung von Metadaten nach DCAT- AP.de Standard

Lars Bürger

Master of Science Informatik, HTWG Konstanz

Betreuerin: Stephanie Bornholdt

Zweitbetreuer: Prof. Dr. Markus Eiglsperger

Ausgangslage

1

GovData aggregiert Metadaten von Bund, Ländern und Kommunen – gepflegt werden sie dezentral, in sehr unterschiedlicher Qualität.

2

151.579 Datensätze (Stand 05/2026) – eine manuelle Qualitätsprüfung ist ausgeschlossen.

3

Unvollständige und inkonsistente Metadaten erschweren Auffindbarkeit und Nachnutzung.

4

Die SHACL-Validierung prüft die formale Struktur – nicht die Nutzbarkeit.



Forschungsfragen

ZENTRALE FORSCHUNGSFRAGE

„Wie kann ein Bewertungsmodell für die Qualität von DCAT-AP.de-Metadaten im GovData-Kontext entwickelt werden, das formale Prüfverfahren mit ergänzenden kontext- und semantikbezogenen Qualitätsindikatoren verbindet?“

TEILFRAGEN

- 1** Übertragbarkeit bestehender Ansätze
- 2** Relevante Qualitätsdimensionen und Indikatoren
- 3** Ergänzende semantik- und kontextbezogene Prüfungen
- 4** Konzeption und prototypische Operationalisierung
- 5** Menschenlesbares Qualitätsreporting

Bewertungslücke bestehender Ansätze

Ansatz	liefert	offen bleibt
ISO 25012 / Wang & Strong	abstrakte Qualitätsbegriffe, Fit for Purpose	keine operationalisierten Metriken
Zaveri et al. (Linked-Data-Qualität)	Qualitätslogiken jenseits formaler Validität	Kontextwissen nötig, kaum automatisierbar
DCAT-AP.de-SHACL	verlässliche formale Basis	binär, kein Score, technische Ausgabe
MQA (data.europa.eu)	automatisiert, portalerprobt	Inhalt der Felder ungeprüft

BEWERTUNGSLÜCKE

Kein bestehender Ansatz verbindet formale Prüfung mit semantischer Bewertung bei voller Nachvollziehbarkeit.

Experteninterviews: zentrale Anforderungen

QUALITATIVE AUSWERTUNG

3

Experten- interviews

LEITPRINZIP

**„Fit for Purpose
statt Formal-
erfüllung“**

ZENTRALE ANFORDERUNGEN

- 1 Formale Validierung als Basisschicht**
DCAT-AP.de- / SHACL-Konformität notwendig aber nicht gleich Gesamtqualität
- 2 Kontextsensitive Vollständigkeit**
Relevante Felder zählen, nicht alle
- 3 Semantische Qualitätsaspekte**
Aussagekraft von Titel, Beschreibung, Keywords und Kategorien statt bloßer Feldexistenz
- 4 Technische Nutzbarkeit**
Die technische Erreichbarkeit und praktische Nachnutzbarkeit der referenzierten Ressourcen muss geprüft werden
- 5 Transparentes Reporting**
Nachvollziehbare Teilscores mit konkreten Verbesserungsvorschlägen

Verdichtung der Kandidatendimensionen zu finalen Dimensionen

VERDICHTUNG

15 Kandidaten-
dimensionen



4 finale
Dimensionen

Auswahl nach Relevanz,
Prüfbarkeit und Praxisnutzen.

DIE VIER FINALEN QUALITÄTSDIMENSIONEN

01 Auffindbarkeit

Kann der Datensatz gefunden und eingeordnet werden?

02 Zugänglichkeit

Ist die Ressource technisch erreichbar und nutzbar?

03 Nachnutzbarkeit

Ist die Ressource rechtlich, organisatorisch und maschinell weiterverwendbar?

04 Aussagekraft

Sind die Metadaten inhaltlich verständlich und plausibel?

Aus Literatur, Bewertungslücke und Interviews abgeleitet; 27 aktive Einzelindikatoren.

Indikatoren: formal, technisch, semantisch

Formal (FI)	Technisch (TI)	Semantisch (SI)
• Schlagwortanzahl • Themenkategorie aus Vokabular • Lizenz aus Lizenzliste	• Erreichbarkeit Download-URL • HTTP-Statuscode • Maschinenlesbarer Zugriffsweg	• Aussagekraft des Titels • Kohärenz Titel/Beschreibung • Thematische Konsistenz

Insgesamt 27 Indikatoren, jeder mit Herleitung aus Standard, Konvention, Literatur oder Interview.

Vier Prinzipien des Messmodells

BEWERTUNGSLOGIK

01 Ternär vs. graduell

Diskrete Stufen versus kontinuierlicher Erfüllungsgrad von 0 bis 1.

02 Mittelung über Distributionen

Statt Best-Distribution-Prinzip: Jede defekte Distribution wird sichtbar.

03 Malus-Prinzip

Defekte URL oder unklare Lizenz werden negativ statt mit null bewertet.

04 Nicht anwendbar

Fachlich nicht zutreffende Kriterien werden neutral übersprungen.

Sprachmodellgestützte Bewertung der **Aussagekraft**

MODELL

GPT-5.5

ARCHITEKTURPRINZIP

Ein Aufruf statt Agentenkette:

- weniger Kosten
- höhere Konsistenz
- bessere Nachvollziehbarkeit.


STRUKTURIERTE AUSGABE — FESTE REIHENFOLGE

findings → reasoning → applicable → score

SECHS KRITERIEN

- | | |
|--------------------------------------|-------------------------------------|
| 1 Aussagekraft Titel | 4 Qualität Schlagwörter |
| 2 Aussagekraft Beschreibung | 5 Thematische Konsistenz |
| 3 Kohärenz Titel/Beschreibung | 6 Kontextuelle Qualifizierer |

Verarbeitungspipeline



Technologie

Python 3.12 · rdflib (RDF) · Pydantic (strukturierte LLM-Ausgabe) · LangChain (Modellanbindung) · Hydra (Konfiguration)

Bedarfsgesteuert

Netzabruf und Sprachmodellaufruf laufen nur, wenn ein aktiver Indikator sie tatsächlich benötigt.

Erweiterbar

Neue Indikatoren registrieren sich selbst, keine Anpassung der Pipeline nötig.

Drei externe Abhängigkeiten: Distributions-Endpunkte, Sprachmodell, SHACL-Validierungsdienst.

Scoring & Gewichtung

ZWEI AGGREGATIONSTUFEN

01 Dimensionswert = gewichteter Mittelwert der Indikatorpunkte
bei 0 nach unten begrenzt

02 Gesamtscore = gewichteter Mittelwert der vier Dimensionswerte

GEWICHTUNGSLOGIK

- Zugänglichkeit und Aussagekraft erhalten mit 2,0 die höchsten Dimensionsgewichte, da ein Versagen hier den Datensatz am stärksten entwertet.
- Datenbrechende Indikatoren wie Erreichbarkeit und Lizenz werden zusätzlich auf Indikatorebene angehoben.

Vom Prüfergebnis zum Befund

EINHEITLICHE BEFUND-STRUKTUR ÜBER ALLE 27 INDIKATOREN

1 Kernaussage
sofort erfassbar

2 Ist-Angaben
mit konkreter Fundstelle

3 Handlungsanweisung
statt technischer Fehlermeldung

DREI ZIELGRUPPEN — UNTERSCHIEDLICHER AUFLÖSUNGSBEDARF

Datennutzende: Gesamtscore · Datenbereitstellende: Einzelbefund je Indikator · Portalbetreibende: Aggregation über den Bestand

Datensätze durchsuchen

Suchbegriff, z. B. Flächennutzungsplan, Haushalt, Verkehr ...

Suchen

Erweiterte Suche

Kartensuche

Metadaten-Qualität

Gut (B) 9

Befriedigend (C) 26

Ausreichend (D) 14

Mangelhaft (F) 1

Dateiformate

HTML 17

WM5_SVC 13

CSV 13

PDF 11

application/pdf 10

WFS_SVC 8

csv 8

GML 7

50 Datensätze

Relevanz

Datensatz Regierung und öffentlicher Sektor Regionen und Städte Letzte Änderung: 19.02.2026

Geodatenatz Flächennutzungsplan Stadt Hameln (Zusammenzeichnung)

Dieser Geodatenatz beinhaltet den Flächennutzungsplan der in der Überschrift angegebenen Kommune des Landes Niedersachsen in einem standardisierten Format. Eine rechtlich verbindliche Auskunft zur Flächennutzungsplanung erteilt jedoch ausschließlich die...

Metadaten-Qualität 80/100

Gut (B)

Datensatz Bildung, Kultur und Sport Regierung und öffentlicher Sektor Letzte Änderung: 17.06.2025

Feuerwehren der Verwaltungsgemeinschaft Lindenberg/Eichsfeld

Der Datensatz enthält die Feuerwehrstandorte der Verwaltungsgemeinschaft Lindenberg/Eichsfeld. Es handelt sich um einen Sekundärdatenbestand.

Metadaten-Qualität 66/100

Befriedigend (C)

Datensatz Regierung und öffentlicher Sektor Regionen und Städte Letzte Änderung: 13.11.2025

Bebauungspläne und Satzungen der Gemeinde Unterwellenborn

Der Datensatz enthält die Geltungsbereiche der Bebauungspläne und Satzungen der Gemeinde Unterwellenborn mit Verlinkung auf die Planunterlagen. Es handelt sich um einen Sekundärdatenbestand. Hinweis: Die im Datensatz verlinkten Unterlagen dienen...

Metadaten-Qualität 69/100

Befriedigend (C)

Format aus EU-Vokabular [dct:format](#) 0.00 1.00

0/2 Distribution(en) mit Format aus dem Vokabular

[Hinweise ausblenden](#)

SO STEHT ES IM METADATENSATZ

Distribution 1

<https://example.org/vokabular/dateiformat/PDF-DOKUMENT>

<https://example.org/testfall/falsche-werte/verteilung-1>

Distribution 2

<https://example.org/vokabular/dateiformat/EXCEL-TABELLE>

<https://example.org/testfall/falsche-werte/verteilung-2>

HINWEISE

Setzen Sie je Distribution eine Format-URI, z. B. <http://publications.europa.eu/resource/authority/file-type/CSV>.

Zugelassene Werte: **EU-Dateiformate**

SO SOLLTE ES AUSSEHEN

```
<dc:Distribution rdf:about="">
  <dct:format rdf:resource="http://publications.europa.eu/resource/authority/file-type/CSV"/>
</dc:Distribution>
```

Der Demonstrator bildet die GovData-Portaloberfläche nach.

Evaluationsdesign

GROUND TRUTH

- Manuelle Referenzbewertung
- 50 Datensätze Kernstichprobe + 20 Extremfälle
- Sechsstufige Skala je Dimension
- Blind gegenüber Prototyp-Scores

MQA-BASELINE

- Reimplementierte Metadata Quality Assessment von data.europa.eu
- Gleicher RDF-Input wie beim Prototyp

HYPOTHESEN

- H1** Konvergenz auf äquivalenten Prüfungen **H2** Mehrwert durch tiefere Prüfung **H3** Höhere Korrektheit als Baseline

Hauptergebnisse im Überblick

EVALUATION AUF KERNSTICHPROBE UND EXTREMFÄLLEN

$\rho = 0,765$

Rangkorrelation mit Ground Truth
Kernstichprobe

92 %

korrekte Gesamteinordnung
gut / mittel / schlecht

$\rho = 0,834$

Korrelation Gesamtscore
mit MQA-Baseline

15,8 %

Überschätzungsrate der MQA-Baseline
auf vertieft geprüften Indikatoren


5/6 · 6/6

Zielgrößen näher am menschlichen Urteil
Kernstichprobe · Extremfälle

Konvergenz auf Klasse A, Überschätzung auf Klasse B


KLASSE A — ÄQUIVALENTE PRÜFUNG

96 % Übereinstimmung mit MQA



KLASSE B — VORHANDENSEIN VS. GÜLTIGKEIT

15,8 % MQA überschätzt; polit.
Geokodierung: 56 %




Triangulation: wer liegt näher am menschlichen Urteil?

GROUND TRUTH ALS GEMEINSAMER VERGLEICHSMASSTAB


KERNSTICHPROBE

- Prototyp bei 5 von 6 Zielgrößen vorn.
- Einzige Ausnahme: Auffindbarkeit — zugleich niedrigstes Dimensionsgewicht.



EXTREMFÄLLE

- Prototyp bei allen 6 Zielgrößen vorn.
- Deutlich größere Abstände zur Baseline.




Grenzfall: Aussagekraft auf den Extremfällen

BEFUND

$\rho = 0,321$ nur 34 % des theoretisch erreichbaren Werts

- 1 Relationale Kriterien bleiben zu hoch**
Kohärenz und thematische Konsistenz wirken bei durchgängig schwachem Inhalt dennoch widerspruchsfrei.
- 2 Mittelung kompensiert harte Defizite**
Die ungewichtete Mittelung über sechs Teilkriterien neutralisiert ein einzelnes hartes Defizit.

Kernstichprobe unauffällig: $\rho = 0,569$



Ein Beispiel: Justizblatt-Datensatz

WARUM EIN HARTES DEFIZIT IM MITTEL VERSCHWINDET

METADATEN-AUSSCHNITT

 Beschreibung
„Justizblatt“

Ein Wort liefert kaum Kontext, Zweck
oder thematische Einordnung.

BEWERTUNG

Beschreibungsqualität **FAIL · 0,15**

Übrige 5 Kriterien **0,65–0,95**

Gemittelter Dimensionswert **0,72**

Ein einzelnes hartes Defizit wird durch fünf unauffällige Werte praktisch neutralisiert.

Antworten auf die Teilfragen

Teilfrage	Antwort in einem Satz
TF1	Bestehende Ansätze sind schichtweise übertragbar; entscheidend ist die Prüfbarkeit aus dem Metadatensatz.
TF2	Vier Dimensionen, 27 Indikatoren, vier von fünf Interview-Anforderungen umgesetzt.
TF3	LLM-gestützte Aussagekraft ergänzt das Modell nachvollziehbar, bleibt aber schwächste Dimension.
TF4	Durchgehende Verarbeitungspipeline mit vier zentralen Messmodell-Entscheidungen.
TF5	Einheitlicher Befund mit Handlungsanweisung statt Punktzahl; empirisch nicht mit Datenbereitstellenden geprüft.

Konzeptionelle Grenze

VOLLSTÄNDIGKEIT DER BEWERTUNG HÄNGT STARK VOM NUTZUNGSKONTEXT AB

Referenzdatensatz: Lübeck Feinstaub

NUTZUNGSSZENARIO 01

Einmalige Auswertung

BEWERTUNG **vollständig**

NUTZUNGSSZENARIO 02

Fortlaufender Dienst

BEWERTUNG **unvollständig**

Grund: Aktualisierungsfrequenz fehlt.

KONSEQUENZ FÜR DIE INTERPRETATION

Das Nutzungsszenario ist Teil des Bewertungsmaßstabs.

Die Rangkorrelation von 0,765 zeigt Übereinstimmung mit diesem Maßstab – **nicht objektive Richtigkeit.**

Methodische & technische Grenzen

METHODISCH

- Gewichte begründet, aber nicht validiert.
- Referenzbewertung durch eine einzige Person; keine Inter-Rater-Reliabilität bestimmbar.
- Lineare Aggregation erlaubt Kompensation zwischen Dimensionen.

TECHNISCH

- Modellabhängigkeit; reproduzierbar nur mit Angabe von Modell und Prompt.
- Laufende Kosten: ca. 1,79 USD je 50 Datensätze.
- Konformitätsprüfung abhängig von externem SHACL-Dienst.

Drei Befunde über diese Arbeit hinaus

GENERALISIERBARE MESSPRINZIPIEN

- 1 Modellauswahl braucht Reproduzierbarkeitsprüfung**
Sie liefert die Auflösungsgrenze für interpretierbare Unterschiede.

- 2 Messunsicherheit muss kleiner als der Informationsbeitrag bleiben**
Andernfalls verschlechtert der Indikator das Gesamturteil.

- 3 Gesamtscore-Vergleich allein ist nicht aussagekräftig**
Hier: $\rho = 0,829$ Korrelation trotz 15,8 % nachweisbarer Überschätzung auf Indikatorebene.

Beitrag, Ausblick, Praxis

BEITRAG

- Rückführbare Indikatormenge aus Literatur und Empirie
- Vollständig operationalisiert
- Gegen menschliches Urteil geprüft

AUSBLICK

- Mehrfachbewertung durch unabhängige Personen
- Sensitivitätsanalyse der Gewichte
- „Nicht anwendbar“ für relationale Kriterien bei schwachem Inhalt
- Vergleich mit MQA Metrics v2

PRAXIS

- Formale Validierung als Vorstufe statt gleichrangiger Indikator
- Wirkung erst durch Befund mit Handlungsanweisung
- LLM-Prüfungen nur ohne deterministischen Sachverhalt

Vielen Dank für Ihre Aufmerksamkeit

Fragen?

ZENTRALE FORSCHUNGSFRAGE

„Wie kann ein Bewertungsmodell für die Qualität von DCAT-AP.de-Metadaten im GovData-Kontext entwickelt werden, das formale Prüfverfahren mit ergänzenden kontext- und semantikbezogenen Qualitätsindikatoren verbindet?“