

QUALITÄTSMESSUNG VON METADATEN NACH DCAT-AP.DE STANDARD

Lars Bürger

Master of Science Informatik · HTWG Konstanz

Betreuerin: Stephanie Bornholdt

Zweitbetreuer: Prof. Dr. Markus Eiglsperger

AUSGANGSLAGE

- 1 GovData aggregiert Metadaten von Bund, Ländern und Kommunen – gepflegt werden sie dezentral und in sehr unterschiedlicher Qualität.
- 2 **151.579** Datensätze (Stand 05/2026) – eine manuelle Qualitätsprüfung ist ausgeschlossen.
- 3 Unvollständige und inkonsistente Metadaten erschweren Auffindbarkeit und Nachnutzung.
- 4 **Die SHACL-Validierung prüft die formale Struktur – nicht die Nutzbarkeit.**

FORSCHUNGSFRAGEN

„Wie kann ein Bewertungsmodell für die Qualität von DCAT-AP.de-Metadaten im GovData-Kontext entwickelt werden, das formale Prüfverfahren mit ergänzenden kontext- und semantikbezogenen Qualitätsindikatoren verbindet?“

- 1 Übertragbarkeit bestehender Ansätze
- 2 Relevante Qualitätsdimensionen und Indikatoren
- 3 Ergänzende semantik- und kontextbezogene Prüfungen
- 4 Konzeption und prototypische Operationalisierung
- 5 Menschenlesbares Qualitätsreporting

BEWERTUNGSLÜCKE BESTEHENDER ANSÄTZE

Abstrakte Konzepte

Wang & Strong · ISO/IEC 25012 · FAIR

Liefern begriffliche Rahmung, legen aber nicht fest, was konkret zu prüfen ist.

Nicht operationalisierbare Metriken

Zaveri et al. · Nogueras-Iso et al.

Zeigen Qualität jenseits formaler Validität, benötigen aber Kontextwissen und manuelle Bewertung.

Geringe Prüftiefe

Neumaier et al. · MQA

Anwendungsnah, aber auf leicht messbare formale Kriterien verengt.


Keine Gruppe verbindet Anwendungsnähe, Operationalisierbarkeit und semantische Tiefe.

3 Experteninterviews qualitativ ausgewertet

„Fit for Purpose
statt Formalerfüllung“

- 1 Formale Qualität – notwendig, aber nicht hinreichend
- 2 Kontextsensitive Vollständigkeit – relevante statt aller Felder
- 3 Semantische Qualitätsaspekte – Aussagekraft statt Feldexistenz
- 4 Technische Nutzbarkeit – Erreichbarkeit und Nachnutzbarkeit
- 5 Transparentes Reporting – Scores mit Handlungsempfehlung

VERDICHTUNG: 15 KANDIDATENDIMENSIONEN ZU 4 FINALEN DIMENSIONEN



Kandidatendimensionen



finale Dimensionen

- | | | |
|---|------------------------|---|
| 1 | Auffindbarkeit | Kann der Datensatz gefunden und eingeordnet werden? |
| 2 | Zugänglichkeit | Ist die Ressource technisch erreichbar und nutzbar? |
| 3 | Nachnutzbarkeit | Ist die Ressource rechtlich, organisatorisch und maschinell weiterverwendbar? |
| 4 | Aussagekraft | Sind die Metadaten inhaltlich verständlich und aussagekräftig? |

27 aktive Einzelindikatoren

INDIKATOREN & MESSMODELL

Formal	Technisch	Semantisch
Schlagwortanzahl	Erreichbarkeit Download-URL	Aussagekraft Titel
Themenkategorie aus Vokabular	HTTP-Statuscode	Kohärenz Titel/Beschreibung
Lizenz aus Lizenzliste	Maschinenlesbarer Zugriffsweg	Thematische Konsistenz

Ternär vs. graduell

Diskrete Stufen vs.
Erfüllungsgrad 0–1

Mittlung über Distributionen

Statt Best-Distribution

Fehlerprinzip

Defekte URL oder Lizenz
negativ statt null

Neutral überspringen

Nicht relevante Kriterien
fließen nicht ein

SCORING & GEWICHTUNG

DIMENSIONSEBENE

Dimensionswert = gewichteter Mittelwert der anwendbaren Indikatorwerte

bei 0 nach unten begrenzt

GESAMTEBENE

Gesamtscore = gewichteter Mittelwert der vier Dimensionswerte

- Zugänglichkeit und Aussagekraft erhalten mit 2,0 die höchsten Dimensionsgewichte, da ein Versagen hier den Datensatz am stärksten entwertet.
- Datenbrechende Indikatoren wie Erreichbarkeit und Lizenz werden zusätzlich auf Indikatorebene angehoben.

SPRACHMODELLGESTÜTZTE BEWERTUNG DER AUSSAGEKRAFT

MODELL

GPT-5.5

Ein Aufruf statt Agentenkette


- weniger Kosten
- höhere Konsistenz
- bessere Nachvollziehbarkeit

STRUKTURIERTE AUSGABE

findings → reasoning → applicable → score

- | | |
|--------------------------------------|-------------------------------------|
| 1 Aussagekraft Titel | 2 Aussagekraft Beschreibung |
| 3 Kohärenz Titel/Beschreibung | 4 Qualität Schlagwörter |
| 5 Thematische Konsistenz | 6 Kontextuelle Qualifizierer |

VERARBEITUNGSPipeline



Live-Demo

EVALUATIONSDESIGN

Ground Truth

- manuelle Referenzbewertung
- 50 Datensätze Kernstichprobe + 20 Extremfälle
- sechsstufige Skala je Dimension
- blind gegenüber Prototyp-Scores

MQA-Baseline

- reimplementierte Metadata Quality Assessment von data.europa.eu
- gleicher RDF-Input wie beim Prototyp

H1 Konvergenz auf äquivalenten Prüfungen

H2 Mehrwert durch tiefere Prüfung

H3 Höhere Korrektheit als Baseline

HAUPTERGEBNISSE IM ÜBERBLICK

$\rho = 0,765$

Rangkorrelation mit Ground Truth
Kernstichprobe

92 %

korrekte Gesamteinordnung
gut · mittel · schlecht

$\rho = 0,834$

Korrelation Gesamtscore
mit MQA-Baseline

15,8 %

Überschätzungsrate der MQA-Baseline
auf vertieft geprüften Indikatoren

5/6 · 6/6


Zielgrößen näher am menschlichen Urteil
Kernstichprobe · Extremfälle

TRIANGULATION AUF DER KERNSTICHPROBE

- Prototyp bei 5 von 6 Zielgrößen vorn.
- Einzige Ausnahme: Auffindbarkeit – zugleich niedrigstes Dimensionsgewicht.

Extremfälle

- Prototyp bei allen Zielgrößen mit größeren Abständen vorne.




GRENZFALL: AUSSAGEKRAFT AUF DEN EXTREMFÄLLEN

$$\rho = 0,321$$

nur 34 % des theoretisch erreichbaren Werts

- 1 Relationale Kriterien bleiben zu hoch
- 2 Mittelung kompensiert harte Defizite

Kernstichprobe unauffällig: $\rho = 0,569$



EIN BEISPIEL: JUSTIZBLATT-DATENSATZ

⚠ „Justizblatt“

Ein Wort liefert kaum Kontext, Zweck oder thematische Einordnung.

BEWERTUNG

Beschreibungsqualität **FAIL · 0,15**

Übrige 5 Kriterien **0,65–0,95**

Gemittelter Dimensionswert **0,72**

ANTWORTEN AUF DIE TEILFRAGEN

Teilfrage	Antwort
TF1	Bestehende Ansätze sind schichtweise übertragbar; entscheidend ist die Prüfbarkeit aus dem Metadatensatz.
TF2	Vier Dimensionen, 27 Indikatoren; vier von fünf Interview-Anforderungen umgesetzt.
TF3	LLM-gestützte Aussagekraft ergänzt das Modell nachvollziehbar um eine semantische Dimension.
TF4	Durchgehende Verarbeitungspipeline mit vier Dimensionen und 27 Indikatoren prototypisch umgesetzt.
TF5	Einheitlicher Befund mit Handlungsanweisung statt Punktzahl; empirisch nicht mit Datenbereitstellenden geprüft.

KONZEPTIONELLE GRENZE

Beispiel: Umweltnetz Lübeck · Feinstaub

Nutzungsszenario 1 – Einmalige Auswertung

Bewertung vollständig

Nutzungsszenario 2 – Fortlaufender Dienst

Bewertung unvollständig

Grund: Aktualisierungsfrequenz fehlt

Die Rangkorrelation von 0,765 zeigt Übereinstimmung mit dem gewählten Maßstab – nicht objektive Richtigkeit.

METHODISCHE & TECHNISCHE GRENZEN

Methodisch

- Gewichte begründet, aber nicht validiert
- Referenzbewertung durch eine einzige Person; keine Inter-Rater-Reliabilität bestimmbar
- Lineare Aggregation erlaubt Kompensation zwischen Dimensionen

Technisch

- Modellabhängigkeit; reproduzierbar nur mit Angabe von Modell und Prompt
- Laufende Kosten: ca. 1,79 USD je 50 Datensätze
- Konformitätsprüfung abhängig von externem SHACL-Dienst

BEITRAG, AUSBLICK, PRAXIS

Beitrag

- Rückführbare Indikatormenge aus Literatur und Empirie
- Vollständig operationalisiert und prototypisch umgesetzt
- Gegen menschliches Urteil geprüft

Ausblick

- Mehrfachbewertung durch unabhängige Personen
- Sensitivitätsanalyse der Gewichte
- „Nicht anwendbar“ für relationale Kriterien bei schwachem Inhalt
- Vergleich mit MQA Metrics v2

Praxis

- Formale Validierung als Vorstufe statt gleichrangiger Indikator
- Wirkung entsteht erst durch Befund mit Handlungsanweisung
- LLM nur für nicht deterministische Sachverhalte einsetzen



VIELEN DANK FÜR IHRE AUFMERKSAMKEIT

Fragen?



QUELLEN & GRUNDLAGEN

BACKUP

- | | | |
|---|--|--|
| 1 | Standard & Kontext | DCAT-AP.de · GovData · data.europa.eu Metadata Quality Assessment |
| 2 | Qualitätsmodelle | Wang & Strong · ISO/IEC 25012 · FAIR-Prinzipien |
| 3 | Metadaten- und Linked-Data-Qualität | Zaveri et al. · Nogueras-Iso et al. · Neumaier et al. |
| 4 | Empirie der Arbeit | 3 Experteninterviews · manuelle Referenzbewertung · Kern- und Extremstichprobe |

Vollständige bibliografische Angaben: Masterthesis und Literaturverzeichnis.

BACKUP: SCORING-LOGIK

GEWICHTE, ANWENDBARKEIT UND FEHLERBEHANDLUNG

AGGREGATION

Dimensionswert
= gewichteter Mittelwert anwendbarer
Indikatoren

Gesamtscore
= gewichteter Mittelwert der 4 Dimensionen

ENTSCHEIDUNGSREGELN

2,0

höchste Gewichte für Zugänglichkeit
und Aussagekraft

Fehler

defekte URL oder Lizenz wird negativ
statt null bewertet

Neutral

nicht anwendbare Kriterien werden
übersprungen