

Transkript Experteninterview I1

Metadaten

- Interview-ID: I1
 - Institutioneller Kontext: FITKO
 - Transkriptart: inhaltlich geglättet
 - Sprecherkennzeichnung: INT = Interviewer, EXP = interviewte Person
 - Anonymisierung: pseudonymisiert
 - Bearbeitung: Einleitende Fragen und Abschlussfragen entfernt; Gliederung nach Hauptteilen des Leitfadens ergänzt
-

Die perfekten Metadaten

[I1_001] **INT:** Dann würde ich mit den Hauptfragen beginnen. Zunächst geht es um den perfekten Metadatensatz. Wie würdest du einen qualitativ hochwertigen Metadatensatz im GovData-Kontext beschreiben?

[I1_002] **EXP:** Für GovData gilt DCAT-AP.de als verpflichtend zu nutzender Standard. Die Minimalvoraussetzung ist daher, dass ein Datensatz valide geliefert wird. Das heißt, er erfüllt die Mindest- beziehungsweise Pflichtanforderungen aus DCAT-AP.de. Das ist ehrlich gesagt nicht immer der Fall, aber wir sind historisch bedingt auch gutmütig.

[I1_003] **EXP:** Ein perfekter oder qualitativ hochwertiger Metadatensatz erfüllt zusätzlich unsere Best-Practice-Empfehlungen. Einerseits gibt es Kriterien, die wir im Rahmen der Spezifikation empfehlen. Andererseits haben wir zusammen mit den zuständigen Expertinnen und Experten aus dem föderalen Umfeld eine Art Beispieldatensatz entworfen. Den gibt es auch zum Herunterladen auf der DCAT-AP.de-Seite. Er ist in der aktuellen Seitenstruktur etwas versteckt, findet sich aber unter „Tools und Beispiele“. Aus unserer Sicht bildet er eine Best Practice ab.

[I1_004] **EXP:** Das ist aber immer eine Mischung aus Aufwand und Nutzen. Man kann sicher noch detaillierter werden, bewegt sich dann aber in einem Long Tail: Der zusätzliche Nutzen wird geringer, während der Aufwand steigt.

[I1_005] **INT:** Welche Qualitätsmerkmale sind aus deiner Sicht grundsätzlich relevant?

[I1_006] **EXP:** Qualität, auch Datenqualität, hängt immer vom Betrachtungskontext ab. Man spricht hier von Kontextsensitivität beziehungsweise Fit for Purpose. Die Frage ist also: Was ist unser Purpose? Als Metadatenportal wollen wir einen möglichst gut durchsuchbaren Metadatenkatalog haben. Dieser Katalog soll möglichst vielen Nutzenden, also Menschen,

Maschinen und weiteren Beteiligten, möglichst leicht zeigen, welche Datensätze in unseren aggregierten Portalen verfügbar sind. Man soll möglichst leicht zu den Datensätzen gelangen, die durch unsere Metadaten beschrieben werden.

[I1_007] **EXP:** Dafür ist aus unserer Sicht der wichtigste Faktor die Reichhaltigkeit der Metadaten. Die Möglichkeiten von DCAT-AP.de sollten möglichst umfassend genutzt werden. Man sollte sich nicht auf die Minimalkriterien beschränken, sondern auch die empfohlenen Kriterien nutzen. Wenn man das mit klassischen Datenqualitätsmetriken erfasst, entspricht das der Vollständigkeit. In der klassischen Datenqualität gibt es Metriken wie Vollständigkeit, Aktualität und Ähnliches. Für uns ist Vollständigkeit der Datensätze das erste Qualitätskriterium.

[I1_008] **INT:** Welche Qualitätsmerkmale hängen in diesem Zusammenhang besonders stark vom jeweiligen Nutzungskontext ab?

[I1_009] **EXP:** Wir haben Pflichtkriterien, empfohlene Kriterien und Kriterien, die man optional nutzen kann. Letztere hängen besonders stark vom Nutzungskontext ab. Ein Beispiel sind spezielle Rollen innerhalb eines Metadatensatzes. Wenn wir nicht nur den Herausgeber als Publisher kennen, sondern auch Creator, Maintainer oder ähnliche Rollen, kann das je nach Kontext relevant sein. Für Geodaten ist das zum Beispiel ein wichtiger Faktor, weil solche Rollen dort im ISO-Standard vorgesehen sind. Für statistische Daten spielt das dagegen häufig keine Rolle.

[I1_010] **EXP:** Sehr spezifische Eigenschaften oder Relationen in DCAT-AP.de sind also nur für bestimmte Kontexte relevant. Allgemeinere Kriterien wie Datensatz, Datenservice, Dokumentation, Homepage, Publisher, zuständige Stelle oder Rechtsgrundlage sind dagegen für fast alle relevant. Auch sie sind kontextsensitiv, aber nicht in dem gleichen Maße wie beispielsweise Media Type oder Geolocation.

[I1_011] **INT:** Hast du konkrete Beispiele für Metadaten auf GovData, die sich für das Testen eines Prototyps eignen würden? Das können besonders gute oder auch besonders schlechte Metadaten sein.

[I1_012] **EXP:** Aus unserer Sicht gibt es im föderalen Raum leistungsfähigere und weniger leistungsfähige Portale. Man kann auch sagen, dass Bundesländer zu unterschiedlichen Zeitpunkten mit bestimmten Veröffentlichungsprozessen begonnen haben. Einen konkreten Datensatz kann ich hier nicht explizit benennen.

[I1_013] **EXP:** Für interne Beispiele oder öffentliche Präsentationen suchen wir uns oft kontextsensitive Datensätze aus, die Aufmerksamkeit erzeugen und die Vielfalt der Themen zeigen. Beispiele wären etwa Kartoffelernten aus Niedersachsen, eulitorale Muschelbänke im Watt oder die Anzahl bestimmter Fahrradparkplätze.

[I1_014] **EXP:** Für gute Datensätze würde ich tendenziell auf das Transparenzportal beziehungsweise Open-Data-Angebot aus Schleswig-Holstein schauen, weil dort ein Qualitätssicherungsprozess vorgeschaltet wird, bevor Daten zu uns geliefert werden. Das ist

insofern besonders, als dort relativ viel Arbeit investiert wird, um nicht nur valide DCAT-AP.de-Daten zu liefern, sondern auch Best-Practice-Anforderungen umzusetzen. Das machen nicht alle Länder. Andere tun es ebenfalls, aber Schleswig-Holstein ist ein naheliegender Ausgangspunkt.

[I1_015] **EXP:** Für schlechte Datensätze muss man vermutlich nicht lange suchen. Es gibt historisch viele Datensätze, die veraltet sind, nicht gut gepflegt wurden, einmal eingestellt wurden und dann Linkrot oder ähnlichen Problemen unterliegen. Mit einer kurzen Suche auf GovData findet man wahrscheinlich mehrere Datensätze, die Probleme aufweisen: schlecht beschriebene Datensätze, bei denen unklar ist, worum es geht, oder Datensätze mit defekten Links. Das ist ein Kernproblem. Wenn ein Datensatz auf einen Distributionslink, einen Download oder einen Datenservice verweist, der nicht mehr funktioniert, ist das besonders gravierend. Genau diese Verfügbarkeit ist für die Nutzung wichtig. Es erzeugt viel Feedback, wenn Menschen oder Maschinen etwas suchen, was angeblich verfügbar ist, dann aber nicht auffindbar ist.

Bestehende Quality Scores und SHACL

[I1_016] **INT:** Dann gehen wir weiter zu bestehenden Ansätzen für Quality Scores und zur Rolle von DCAT-AP.de und SHACL. Was fehlt deiner Meinung nach in aktuellen Ansätzen der Metadata Quality Scores, gerade mit Blick auf data.europa.eu, den MQA-Ansatz und den Schweizer Ansatz?

[I1_017] **EXP:** Grundsätzlich kenne ich diese Ansätze. MQA ist im weiteren Sinne der klassische Ansatz. Was mir fehlt, ist, dass aus meiner Sicht gerade im Bereich data.europa.eu nicht genug Mühe in die Recherche klassischer Datenqualitätskriterien investiert wurde. Diese Kriterien sind inhaltlich teilweise seit mehr als 20 Jahren etabliert. Wir gehen da bis in die 1990er- oder 1980er-Jahre zurück, teilweise sogar weiter. Dort wurden Metriken und Konzepte wie Fit for Purpose entwickelt. Dazu gibt es Standardliteratur, die Grunddimensionen wie Aktualität oder syntaktische Fehlerfreiheit beschreibt und erklärt, wie man sie misst.

[I1_018] **EXP:** Diese klassischen Kriterien kann man als ersten Ansatz sehr gut nutzen. Aus meiner Sicht ist das nicht umfassend genug geschehen. Das sind eigentlich Low-Hanging Fruits. Man sollte zunächst einen Schritt zurücktreten und diese Grundlagen in die Analysewerkzeuge integrieren.

[I1_019] **EXP:** Im GovData-Kontext reicht das allein aber nicht aus. Solche Dimensionen sollte man in der Basis erfassen: funktionierende Links, Fehlerfreiheit, Alter eines Datensatzes, Zeitpunkt der letzten Aktualisierung oder des letzten Harvestings. Dabei muss man bewerten, welche Aktualität für welchen Kontext relevant ist. Für Datenbereitstellende kann ein alter Datensatz weiterhin völlig valide sein. Für Datennutzende wirkt ein sehr alter Datensatz dagegen möglicherweise verdächtig, weil sie sich fragen, ob es aktuellere Daten

gibt. Ein Harvesting-Datum kann für einen Metadatenkatalog daher ein gutes Kriterium sein, weil es zeigt: Dieser Eintrag wurde gestern geharvestet und entspricht dem letzten Stand.

[I1_020] **EXP:** Danach müsste man tiefer in Richtung Linked Data schauen. Aus meiner Sicht sollte stärker bewertet werden, ob ein Metadatensatz die Möglichkeiten des RDF-Datenmodells intensiv nutzt. Eine Angabe, die auf ein konkretes Vokabular der EU oder auf ein von uns gepflegtes Vokabular verweist, ist besser als ein reines Literal. Wenn ich auf eine ID verweisen kann, ist das besser, als dieselbe Information nur als Freitext zu speichern. Das wird in den meisten Scoring-Ansätzen bisher nicht ausreichend berücksichtigt, ist aber für Linked Data zentral.

[I1_021] **INT:** Welche Dimensionen fehlen oder werden zu schwach berücksichtigt?

[I1_022] **EXP:** Die Dimensionen beziehen sich letztlich auf Qualitätskriterien. Für den gerade genannten Faktor gibt es meines Wissens kein explizites Kriterium. Man könnte ihn unter Richtigkeit oder Verlässlichkeit einordnen. Eine Verlässlichkeitsdimension müsste berücksichtigen, dass ein Verweis auf eine GND-ID zur Identifikation eines Agenten verlässlicher ist als derselbe Name als Freitext, zum Beispiel „Bundesministerium des Innern und für Heimat“. Diese Dimension der Verlässlichkeit müsste man nachziehen.

[I1_023] **INT:** Gibt es weitere Qualitätskriterien, die ein Scoring auf jeden Fall enthalten sollte, damit es möglichst vollständig und aussagekräftig ist?

[I1_024] **EXP:** Das kann man nicht allgemein beantworten. Für uns wäre zusätzlich relevant, ob wir Metadaten über das Harvesting haben. Das ist ein internes Qualitätskriterium. Für GovData wäre es wichtig, neben öffentlichen Qualitätskriterien, die für Nutzende oder den Katalog relevant sind, getrennt auf das Thema Harvesting-Metadaten oder Katalog-Metadaten zu schauen.

[I1_025] **EXP:** DCAT-AP.de bietet dafür die Eigenschaft Catalog Record. Sie wird von nahezu keinem Landesportal genutzt und auch von uns bisher nicht intensiv genutzt. Dort sehe ich großes Potenzial, um Aussagen über die Qualität des Metadaten-Harvestings zu treffen: Wann wurde der Datensatz zuletzt gefunden? Von welcher Stelle wurde er geharvestet? Man könnte Informationen über Validierungen und erfolgreich abgeschlossene Prüfungen einbringen. Das tun wir bisher nicht. Es wäre sinnvoll, dafür ein Konzept zu entwickeln: Wie kann man mithilfe von Catalog Records Aussagen über die Qualität des eigentlichen Eintrags treffen? Dafür gibt es auch Beschreibungssprachen beziehungsweise Vokabulare.

[I1_026] **INT:** Wie kann das DCAT-AP.de-Validationsergebnis in einem Quality Scoring wertvoll sein? Wie könnte man es am besten integrieren, und welche Teile hältst du für besonders wichtig?

[I1_027] **EXP:** Das ist auf jeden Fall wichtig, weil es die Basis bildet. Ich würde es unter Fehlerfreiheit fassen, je nachdem, welcher Literatur man folgt. Es gibt verschiedene Sets

von Datenqualitätskriterien, etwa mit acht oder elf Kriterien. Da muss man schauen, auf welchen Standardkriterien-Satz man sich bezieht.

[I1_028] **EXP:** Das DCAT-AP.de-Validierungsergebnis ist wichtig und sinnvoll, aber es ist nicht die einzige Dimension. Zur Integration würde ich eine Kategorisierung vornehmen. So fehlerhaft ich die europäische Bewertung und auch MQA in Teilen finde, halte ich die Grundstruktur für sinnvoll: Man teilt in Kategorien ein, etwa Syntax oder formale Qualität und inhaltliche Qualität. Wenn etwa Titel gut beschrieben sein sollen, braucht man andere Methoden. Eine sprachliche Bewertung ist etwas anderes als Tippfehlerfreiheit. Wenn ein Metadatensatz bei data.europa.eu in vielen Sprachen verfügbar ist, ist das ebenfalls ein Qualitätsmerkmal, aber kein hartes Validierungskriterium.

[I1_029] **EXP:** Ich würde DCAT-AP.de-Qualität daher als eine Dimension in einem Gesamtscore anzeigen. Wie man sie gewichtet, ist schwieriger, weil sie im Prinzip eine Mindestvoraussetzung darstellt.

Relevanz des eigentlichen Datensatzes

[I1_030] **INT:** Wie relevant ist der eigentliche Datensatz für die Bewertung der Metadaten?

[I1_031] **EXP:** Grundsätzlich gibt es reichhaltigere und weniger reichhaltige Ausgangsdaten. In Bereichen, die stark genormt sind und deswegen bereits gut beschriebene Datensätze haben, ist es leichter, hochwertige Metadaten zu erzeugen. Das beste Beispiel sind Geodaten. Das ist ein altes Feld mit hohem Normierungsgrad. Auch wenn ISO-Normen nicht vollständig in unseren Kontext übertragen werden, gibt es dort bereits sehr umfassende Informationen.

[I1_032] **EXP:** Aus unserer Sicht ist der Datensatz in solchen Fällen anders zu bewerten. Was wir im ISO-Kontext nicht zwingend als Metadaten behandeln würden, betrachten wir teilweise als Daten, und umgekehrt. Der Übergang ist fließend. In stark normierten Bereichen gibt es jedenfalls sehr viele reichhaltige Informationen, die es erleichtern, einen hochwertigen Metadatensatz früher zu erstellen.

[I1_033] **EXP:** Bei sehr freien, einzigartigen oder manuell erhobenen Datensätzen, beispielsweise historischen Daten, ist es schwieriger, eine gute Beschreibung zu erstellen. Das ist ebenfalls möglich, aber oft mit mehr Aufwand verbunden und wird in der Praxis deshalb nicht so intensiv umgesetzt. Insofern erleichtert ein hoher Normierungsgrad der eigentlichen Daten häufig gute Metadaten.

KI-gestützte Ansätze und AI Agents

[I1_034] **INT:** Dann kommen wir zum letzten Hauptteil: KI-gestützte Ansätze und AI Agents. Wie sinnvoll findest du Ansätze, die AI Agents oder KI-gestützte Verfahren nutzen, um neue Ansätze zu entwickeln oder bestehende Ansätze zu verbessern?

[I1_035] **EXP:** Viele Metadaten sind letztlich menschlich erstellt oder beruhen auf manuellen Eingaben in Fachverfahren. Das liegt in der Natur von Verwaltungsdaten. Dadurch hat man viel Freitext und natürliche Sprache. Das sind Bereiche, denen man sich mit LLMs oder KI nähern kann, etwa bei Syntax, grundlegenden Inkonsistenzen oder einfachen Datumsprüfungen. Dort sehe ich Potenzial, um Metadatenfehler, Metadaten Schwächen und Qualitätsschwächen zu finden und zu korrigieren.

[I1_036] **EXP:** Natürlich könnte man vieles auch mit konventionellen Techniken klassisch algorithmisch lösen. Der Vorteil vertrauenswürdiger KI-Systeme liegt darin, dass sie nicht jede Form von Tippfehler vorhersehen müssen. Sie bringen eine gewisse Fehlertoleranz mit. Ähnliche Dinge ließen sich auch manuell mit Werkzeugen wie OpenRefine erreichen. Faktisch wurde das aber bisher nicht in großem Umfang gemacht. Agentische KI bietet die Chance, dass sich Menschen wieder für diese Themen interessieren und Dinge vorantreiben, die man klassisch zwar seit langer Zeit könnte, aber bisher nicht umgesetzt hat.

[I1_037] **EXP:** Bei kontextsensitiver semantischer Analyse sehe ich dagegen klare Grenzen. Eine KI kann beispielsweise nicht zuverlässig entscheiden, ob „Watt“ die elektrische Einheit meint oder das Wattenmeer, in dem Muschelbänke vorkommen. Eine vollautomatisierte agentische Lösung kann in solchen Kontexten mehr Schaden als Nutzen erzeugen. Gerade fachspezifische oder aus kleinen Domänen stammende Datensätze lassen sich statistisch nicht gut greifen. Es gibt Fachsprache und spezifische Zusammenhänge, die von natürlicher Alltagssprache abweichen. Im Umweltbereich gibt es viele naturwissenschaftliche, biologische und technische Begrifflichkeiten, die sich in Keywords, Titeln und Beschreibungen widerspiegeln. Wenn man solche Daten halbautomatisiert mit agentischer KI korrigieren lässt, besteht die Gefahr, dass fachlich korrekte Begriffe in eine falsche Alltagssprache überführt werden. Dort sehe ich wenig Potenzial.

[I1_038] **INT:** Gibt es wichtige kontextsensitive Informationen, die durch KI überprüft werden könnten?

[I1_039] **EXP:** Die große Stärke sehe ich im Bereich Syntax. Ich kann mir vorstellen, dass man mit agentischen KI-Systemen eine Art Metadaten-Linter gestaltet. DCAT-AP.de ist eine sehr spezifische Information und formal geschrieben. Es gibt klare Anforderungen zu Muss-, Kann- und Soll-Kriterien sowie zu SHACL. Diese Spezifikation könnte man als Basis nehmen. Man könnte eine agentische KI mit Fokus darauf füttern und nutzen, um Datenbereitstellenden Vorschläge zu machen: Das ist ein Metadatensatz aus dem Bereich Geoinformationen, diese Pflichtattribute wurden genutzt, diese empfohlenen Attribute wurden genutzt. In statistischen Analysen nutzen die meisten ähnlich aussehenden Datensätze zusätzlich dieses oder jenes Attribut.

[I1_040] **EXP:** So könnte man Anreicherungen betreiben. Die KI kann die Information nicht erzeugen, wenn sie nicht vorliegt. Sie kann aber Lücken identifizieren und bei Vergleichen helfen. Ich glaube, eine sinnvolle Anwendung agentischer KI wäre, Vergleichbarkeit herzustellen. Beispielsweise könnte man feststellen: Die Datensätze aus Schleswig-Holstein enthalten bestimmte Informationen, die Datensätze aus Niedersachsen dagegen nicht, obwohl beide Küstenländer sind. Bei einem Vergleich zwischen Schleswig-Holstein und Bayern wäre dieselbe Abweichung hingegen möglicherweise inhaltlich erklärbar und kein Qualitätsproblem, weil Bayern keine Küste hat. Genau solche föderalen Vergleiche oder Vergleiche von Datensätzen unterschiedlicher Quellen könnten durch KI unterstützt werden.

[I1_041] **EXP:** Ich sehe hier teilweise auch Potenzial für klassische KI-Systeme im Sinne von Machine Learning oder Assisted Learning. Mit einem Assisted-Learning-Ansatz könnte man qualitativ hochwertigere Keywords schaffen. Man könnte einfache Freitext-Stichworte, die teilweise Tippfehler enthalten oder keinen Mehrwert bieten, auf Kategorien, echte Schlagworte oder belastbare EU-Vokabulare mappen. Im Kontext des Musterdatenkatalogs gibt es dazu bereits Ansätze. Dort wurden Datensätze aus dem kommunalen Umfeld kategorisiert und der Musterdatenkatalog mit dieser Methodik geschärft. Das halte ich für einen erfolgreichen Ansatz.

[I1_042] **INT:** Gibt es bestimmte Nutzungskontexte von Open Data, in denen eine KI-gestützte Bewertung besonders sinnvoll wäre?

[I1_043] **EXP:** Sinnvoll ist alles, was sich um natürliche Sprache dreht. Dazu gehören Stichworte wie Barrierearmut, einfache Sprache oder die Frage, ob nur Fachtermini genutzt werden oder ob eine natürlichsprachliche Beschreibung vorliegt. Auch niedrigschwellige Synonyme können relevant sein. Wenn zum Beispiel von eulitoralen Bereichen die Rede ist, kann ein zusätzliches, allgemeinverständlicheres Keyword sinnvoll sein, weil nicht jeder weiß, was „eulitoral“ bedeutet.

[I1_044] **EXP:** Das ist etwas, was KI gut unterstützen kann: Beschreibungstexte oder die Güte von Beschreibungstexten bewerten, möglicherweise auch anhand von Style Guides. Dort kann ich mir Korrektur- oder Verbesserungsvorschläge gut vorstellen. Es könnte auch teilautomatisiert agentisch funktionieren: Ein System, das entsprechend konfiguriert oder trainiert wurde, erhält den Auftrag, die Beschreibungen von tausend Datensätzen zu verbessern und direkt in den Metadaten anzupassen. Das wäre grundsätzlich möglich.

[I1_045] **INT:** Gibt es abseits von kontextsensitivem Wissen weitere Anwendungsfälle, in denen AI Agents bei einem Scoring helfen könnten?

[I1_046] **EXP:** Da muss man unterscheiden. Für generative KI sehe ich bei Scoring und Bewertungen wenig Raum, weil es sich grundsätzlich um ein stochastisches Verfahren handelt. Wenn ich dieselbe Prüfung und dieselbe Qualitätsbewertung hundertmal durchführe, bekomme ich vermutlich einige Ausreißer, bei denen Unsinn herauskommt. Das entspricht typischen Fehlerquoten in einer Größenordnung von einigen Prozent. Bei einer Bewertung weiß ich dann nie, ob das aktuelle Ergebnis eines dieser fehlerhaften Ergebnisse ist. Ich müsste also alles sehr oft durchführen und anschließend wieder eine statistische

Erhebung über die automatisierte Qualitätsmessung machen. Dann ist der Ressourcenaufwand größer als der eigentliche Nutzen. Bei Bewertung und generativer KI lautet meine Einschätzung daher eher: nein.

[I1_047] **EXP:** Um eine Bewertung vorzunehmen, muss man aber im Regelfall den RDF-Graphen per SPARQL abfragen oder andere spezifische Anfragen an das System stellen. Es kann sein, dass nicht für alle Varianten vorab passende Abfragen vorbereitet werden können. Im GovData-Kontext haben wir mindestens 17 relevante Stakeholder, die sich vor allem für ihre eigene Datenqualität interessieren und zugeschnittene Anfragen brauchen. Diese Bedarfe sind nicht vollständig identisch.

[I1_048] **EXP:** Bestimmte Datentypen gibt es nur in einzelnen Ländern. Pegelstandsmessungen gibt es zum Beispiel eher in Ländern mit Küsten oder großen Flüssen, also etwa in Schleswig-Holstein, Niedersachsen, Nordrhein-Westfalen oder Bayern, aber nicht in gleicher Weise überall. Die Query sieht dann vermutlich nicht immer gleich aus. Hier könnte ein agentisches oder generatives System unterstützen: Es könnte menschlichen Qualitätsverantwortlichen oder Personen, die Qualitätsmetriken erstellen, helfen, hochspezifische SPARQL-Queries oder Analysebausteine zu entwickeln, um spezifische Qualitätsfragen zu lösen.

[I1_049] **EXP:** Das könnte Fachpersonen, die Qualitätskriterien in ihrer Domäne bewerten können, aber weniger technische Expertise haben, Zugang zu technischen Auswertungsmitteln verschaffen. Die API ist nicht vollständig niedrighschwellig; man braucht Vorwissen, um in einem Metadatenkatalog relevante Informationen zu filtern. Dort sehe ich großes Potenzial.
