

Transkript Experteninterview I2

Metadaten

- Interview-ID: I2
 - Institutioneller Kontext: FITKO
 - Transkriptart: inhaltlich geglättet
 - Sprecherkennzeichnung: INT = Interviewer, EXP = interviewte Person
 - Anonymisierung: pseudonymisiert
 - Bearbeitung: Einleitende Fragen und Abschlussfragen entfernt; Gliederung nach Hauptteilen des Leitfadens ergänzt
-

Die perfekten Metadaten

[I2_001] **INT:** Vielen Dank. Dann geht es mit den Hauptfragen los. Zunächst allgemein zu Metadaten: Wie sieht deiner Meinung nach der perfekte Metadatensatz aus? Im Leitfaden hatte ich erwähnt, dass du auch gerne einen Beispieldatensatz mitbringen kannst.

[I2_002] **EXP:** Es wäre einfacher gewesen, nach einem nicht perfekten Metadatensatz zu fragen, denn davon gibt es viele.

[I2_003] **EXP:** Ein perfekter Metadatensatz basiert idealerweise auf DCAT-AP.de beziehungsweise auf einem semantischen Graphen. Der Vorteil eines Graphen ist, dass alles, was vorhanden ist, mitgenommen werden kann. Man kann ihn beliebig erweitern und es entsteht kein Datenverlust. Es können auch Informationen enthalten sein, die man aktuell vielleicht noch nicht benötigt oder noch nicht vollständig versteht.

[I2_004] **EXP:** Ein guter Metadatensatz enthält natürlich die Pflichtfelder, also vor allem Titel und Beschreibung, bei uns möglichst in deutscher Sprache. Darüber hinaus sollten aber alle fachlich vorhandenen Informationen übernommen werden. Im Geobereich gibt es beispielsweise teilweise bis zu zehn Ansprechpartner. Solche Informationen gibt es bei uns in dieser Form gar nicht, aber wenn sie vorhanden sind, sollten sie nicht entfernt werden.

[I2_005] **EXP:** Die Daten, die ohnehin vorhanden sind, sollten in einem Metadatensatz enthalten sein, am besten semantisch modelliert. Ziel wäre im Sinne der Five-Star-Linked-Data-Idee von Tim Berners-Lee, dass ein Metadatensatz nicht nur für sich selbst steht, sondern Querverbindungen zu anderen Entitäten enthält. Das können zum Beispiel Wikidata, die Gemeinsame Normdatei oder andere externe Referenzsysteme sein. Auch ein Thesaurus, etwa der des Umweltbundesamtes, wäre sinnvoll, weil dort viele Fachbegriffe aus dem Umweltbereich beschrieben sind.

[I2_006] **EXP:** Was ich bisher noch nicht gesehen habe, mir aber wünschen würde, sind Querverbindungen zwischen gleichen oder vergleichbaren Datensätzen aus den rund 11.000 Kommunen in Deutschland. Das wäre ein Idealfall.

[I2_007] **INT:** Damit hast du die Unterfrage schon weitgehend beantwortet, nämlich nach welchen Kriterien du Metadaten als perfekt bewertest. Darauf aufbauend: Hast du konkrete Beispiele für schlechte Metadaten auf GovData, die sich eventuell auch für das Testen eines Prototyps eignen würden?

[I2_008] **EXP:** Ich bin schon zu lange im Thema, deshalb habe ich viele Beispiele gesehen. Es gibt etwa Metadatensätze, bei denen der Titel viel zu kurz ist. Ein Beispiel wäre „Los 1“. Daraus versteht man nicht, worum es geht. Es gibt auch Datensätze, bei denen Titel und Beschreibung identisch sind. Dann liefert die Beschreibung keinen Mehrwert.

[I2_009] **EXP:** Ein anderes Problem sind stark regionale Begriffe. Es gibt zum Beispiel einen Datensatz aus Köln zu den „I-Dötzchen“. Wer sich damit auskennt, versteht, dass damit Schulanfänger gemeint sind. Es ist zwar Deutsch, aber die meisten Menschen verstehen diesen regionalen Ausdruck nicht.

[I2_010] **EXP:** Ein weiteres Beispiel war ein Datensatz aus der Schweiz. Die Überschrift habe ich nicht richtig verstanden, und die Beschreibung war zwar sehr detailliert und fachlich vermutlich korrekt, aber für mich trotzdem unverständlich. Es war deutsche Sprache, aber Fachsprache. Das kann fachlich ein guter Datensatz sein, aber für Außenstehende bleibt er schwer verständlich. In solchen Fällen könnten zusätzliche Metadaten, englischsprachige Titel oder englischsprachige Beschreibungen hilfreich sein.

[I2_011] **EXP:** Schlechte Metadaten zeigen sich auch an einfachen Dingen wie nicht mehr auflösbaren URLs, also Dead Links, zu wenigen Metadaten oder widersprüchlichen Angaben. Ein Beispiel wäre ein Titel zu Vornamen aus Nürnberg, während als Herausgeber Köln angegeben ist. Das sind Fälle, die inhaltlich nicht zusammenpassen.

[I2_012] **EXP:** Das generelle Problem bei Metadaten ist, dass Menschen Fehler machen. Ich würde häufig eher auf die eigentlichen Daten schauen, weil diese oft aussagekräftiger über sich selbst sind als die Metadaten, die ein Mensch eingetragen hat. Das sehe ich immer wieder.

[I2_013] **EXP:** In einer Arbeitsgruppe mit der GDI, also mit den Geodaten, ging es beispielsweise um Flächendeckung. In den Metadaten steht eine Bounding Box, also der Bereich, für den Daten erhoben wurden. Im Geokontext ist das sehr sinnvoll. Diese Information wird aber von Menschen eingetragen und ist deshalb ebenfalls fehleranfällig. Eigentlich wäre es oft sinnvoller, in die Daten selbst hineinzuschauen und solche Informationen daraus zu berechnen.

[I2_014] **EXP:** Das ist kein böser Wille. Die Menschen, die Metadaten eintragen, haben andere fachliche Schwerpunkte. Wenn man ihnen ein Metadatenfeld gibt und sagt, sie sollen es ausfüllen, verstehen sie oft nicht, warum sie das tun sollen. Wenn man den Zweck nicht

versteht, füllt man es wahrscheinlich nicht so aus, dass andere es gut nachnutzen können. Das ist ein menschliches Problem.

[I2_015] **INT:** Vielen Dank für die ausführliche Antwort. Ich würde mich im Anschluss natürlich freuen, wenn du bei Gelegenheit ein oder zwei positive und negative Beispiele schicken könntest. Wenn das zeitlich nicht funktioniert, ist das natürlich kein Problem.

[I2_016] **EXP:** Zeitlich wird das wahrscheinlich schwierig. Ich habe sehr viele Datensätze kennengelernt und könnte grundsätzlich viele Beispiele liefern.

[I2_017] **EXP:** Es gibt auch Datensätze, die eigentlich gut sind, bei denen aber die Weiterverarbeitung im Portal problematisch ist. Metadaten laufen teilweise über mehrere Portale und durchlaufen dabei seltsame Ketten. Dadurch haben wir manchmal denselben Datensatz mehrfach im Portal, ohne ihn sinnvoll als identisch erkennen zu können. Ein fachlich wichtiger Datensatz kann dann bis zu viermal angezeigt werden, weil sich einzelne Metadaten unterscheiden. Das liegt daran, dass die Daten zwischen Systemen oder Metadatenformaten konvertiert werden. Dadurch kann aus einem eigentlich guten Datensatz technisch ein schlechterer werden.

[I2_018] **EXP:** Ich kann versuchen, im Nachgang etwas zusammenzustellen, aber versprechen kann ich es nicht. Wenn Steffi mich noch einmal erinnert und ich es schaffe, ist das in Ordnung.

Bestehende Quality Scores und SHACL

[I2_019] **INT:** Dann würde ich zur nächsten Frage kommen. Es geht um die Rolle von SHACL und bestehenden Metadaten-Quality-Scores. Was fehlt deiner Meinung nach in aktuellen Ansätzen der Metadaten-Quality-Scores?

[I2_020] **EXP:** Dazu haben wir intern eine sehr lebhafte Diskussion, meistens mit Matthias. Er kommt aus der Wissenschaft und kennt sich gut mit Semantik aus.

[I2_021] **EXP:** Das größte Problem ist, dass es oft keine wissenschaftlich fundierte Grundlage dafür gibt, warum bestimmte Dinge erhoben werden. Es wird geprüft, aber warum genau geprüft wird, ist häufig nicht festgehalten. Es fehlt also die wissenschaftliche Basis.

[I2_022] **EXP:** Es gibt dann irgendeinen Score, der aber nicht belastbar ist. Die Frage ist immer: Warum prüfen wir genau das? Oft kann man diese Frage nicht beantworten. Deshalb sind wir mit den Scores der EU oder der Schweiz, die inhaltlich teilweise übernommen werden, nicht vollständig zufrieden. FAIR-Prinzipien sind grundsätzlich sinnvoll, aber insgesamt fehlt uns häufig die Begründung.

[I2_023] **EXP:** Bei GovData haben wir deshalb bisher noch keine eigene Qualitätsprüfung dieser Art. Der Grundstreit ist: Was sollte man prüfen und warum? Wir haben noch nicht die

Zeit gefunden, das vollständig durchzuarbeiten. Grundsätzlich ist klar, dass man messen muss. Aber wenn wir Qualität messen, wollen wir auch sinnvoll messen.

[I2_024] **EXP:** Ein Score sollte also belegen, warum er genau diese Kriterien verwendet. Die reine Anzahl der Datensätze als Erfolgsfaktor für Datenportale ist beispielsweise eine falsche Metrik. Wenn wir Qualität messen wollen, dann sollte es eine belastbare Metrik sein.

[I2_025] **INT:** Darauf aufbauend: Welche Qualitätskriterien sollte ein Scoring auf jeden Fall enthalten, damit es möglichst vollständig oder aussagekräftig ist?

[I2_026] **EXP:** Vollständigkeit ist schwierig. Metadaten können in einem Graphen eigentlich nie vollständig sein, weil ein Graph beliebig groß sein kann. Sinnvoll wäre eher eine relative Vollständigkeit: Sind die grundlegenden Anforderungen erfüllt und sind für die jeweilige fachliche Thematik die relevanten Informationen vorhanden? Ob das eine fachliche, organisatorische oder verwaltungsbezogene Frage ist, müsste man genauer unterscheiden.

[I2_027] **EXP:** Wichtig ist außerdem die sprachliche Verständlichkeit. Es reicht nicht, zu messen, ob ein Titel oder eine Beschreibung lang genug ist. Entscheidend ist, ob der Inhalt verständlich beschrieben wird und ob die Beschreibung tatsächlich den Inhalt der Daten erklärt. Das ist schwer zu prüfen, aber wesentlich.

[I2_028] **EXP:** Ein weiterer Punkt betrifft Distributionen. Ein Metadatensatz hat Distributionen, und Distributionen sollten eigentlich unterschiedliche Formate derselben Daten beschreiben. Das wird nicht immer korrekt genutzt. Zur Qualität gehört deshalb auch, ob das richtige Format gewählt wurde, ob es richtig beschrieben ist und ob die Distributionen korrekt verwendet werden.

[I2_029] **EXP:** Technisch wären bei DCAT außerdem Dinge wie das Vermeiden von Blank Nodes relevant. Auch Querverweise sind wichtig. Ebenso sollte man überlegen, wie Organisationen sinnvoll abgebildet werden können, idealerweise über einen Organisationsgraphen für Deutschland.

[I2_030] **EXP:** Ein weiterer Punkt ist die Attribution. Wenn etwa eine CC-Lizenz verwendet wird, sollte in den Metadaten auch angegeben sein, wie die Quelle korrekt zu zitieren ist. Wenn eine Stadt Daten veröffentlicht, sollte klar sein, ob der Stadtname, ein Fachbereich oder ein Amt als Attributionsangabe verwendet werden soll. Solche Details wirken klein, gehören aber zur Qualität von Metadaten.

[I2_031] **EXP:** Was ich außerdem gerne sehen würde, ist der Weg eines Datensatzes durch verschiedene Portale. Wo kommt der Datensatz her? Welche Portale hat er durchlaufen? Das steht heute nicht sauber in den Metadaten und ist auch nicht ohne Weiteres abbildbar.

[I2_032] **EXP:** Daran hängt auch die Grundfrage, ob Portale Metadaten anfassen und verändern dürfen. Wenn ich den Pfad kenne, kann jedes harvestende Portal theoretisch Metadaten bearbeiten oder ergänzen. Wenn ich Qualitätsunterschiede sehe, darf ich sie dann korrigieren? Wenn ich sehe, dass eine URL nur als String vorliegt, darf ich sie sauber

als URL modellieren? Das wäre eine Veränderung der Metadaten. Die Frage ist also: Wer darf Qualität verbessern? Das ist nicht abschließend geklärt.

[I2_033] **INT:** Inwiefern kann das DCAT-AP.de-SHACL-Validierungsergebnis in einem Quality-Scoring wertvoll sein?

[I2_034] **EXP:** Das kann sehr wertvoll sein. Früher hatten wir intern schon eine Art Ranking, zunächst nur in einem geschützten Bereich. Zugriff hatten verschiedene Ländervertretungen, der Bund und wir. Später gab es meines Wissens auch öffentliche Messergebnisse.

[I2_035] **EXP:** Solche Rankings werden teilweise gewünscht. Die Länder möchten sich vergleichen können. Sie wollen sehen, ob sie gut sind oder ob sie zusätzliche Ressourcen benötigen, weil sie schlechter abschneiden. Auch beim Musterdatenkatalog möchten Kommunen sehen, wo sie stehen und wo sie sich verbessern können.

[I2_036] **EXP:** Entscheidend ist, dass es nicht darum geht, jemandem zu sagen, dass er schlecht ist. Es sollte als Hinweis verstanden werden: Hier gibt es Luft nach oben, und so kann man besser werden. Es braucht also eine Anleitung zur Verbesserung.

[I2_037] **EXP:** Regelmäßige Prüfungen können helfen. Wenn Metadaten täglich geprüft werden und die Verantwortlichen regelmäßig sehen, was falsch ist, kann das dazu führen, dass Fehler behoben werden. Rankings oder Fehlerrankings können also durchaus sinnvoll sein, wenn sie richtig eingesetzt werden.

[I2_038] **INT:** Wie kann man das Validierungsergebnis am besten in ein Scoring integrieren? Welche Regeln oder Teile der Ergebnisse hältst du dabei für besonders wichtig?

[I2_039] **EXP:** Ein Ansatz wäre vergleichbar mit dem EU-Ranking, bei dem es verschiedene Bereiche gibt. Teil-Scores können hilfreich sein, um zu erkennen, wo genau ein Problem liegt. Wenn ein Bereich schlecht abschneidet, kann man sehen, ob das Problem beim Portal liegt oder ob es fachlich an anderer Stelle entsteht.

[I2_040] **EXP:** Solche Teilbewertungen sind sinnvoll, weil man punktuell verbessern kann. Wichtig wäre aber, dass die Ergebnisse genauer werden. Aktuell liefert die SHACL-Validierung zwar ein Ergebnis, etwa wenn ein Portal neu aufgenommen werden möchte, aber die Ausgabe ist häufig sehr technisch. Man muss die Ergebnisse interpretieren, um zu verstehen, was schiefgelaufen ist.

[I2_041] **EXP:** Es ist schon besser geworden, aber man muss weiterhin erkennen können, was konkret zu tun ist. Eine reine Fehlermeldung ist wenig hilfreich. Man wird zwar auf ein Problem hingewiesen, aber die Personen, die diese Meldung lesen, sind nicht immer Expertinnen oder Experten. Deshalb wäre eine Erklärung wichtig, warum ein Fehler auftritt und wie er behoben werden kann.

Relevanz des eigentlichen Datensatzes

[I2_042] **INT:** Dann kommen wir zu einer Frage zur Relevanz des eigentlichen Datensatzes. Inwiefern hältst du den eigentlichen Datensatz für relevant für die Bewertung der Metadaten?

[I2_043] **EXP:** Das ist schwierig, weil die Grenze zwischen Metadaten und Daten irgendwann verschwimmt. Für GovData sind die Metadaten im Grunde die eigentlichen Daten, weil wir primär Datensätze beschreiben. Dasselbe gilt in dieser Betrachtung.

[I2_044] **EXP:** Ein Beispiel sind Geodatenservices. Wir haben dort Metadaten, die auf einen Service verweisen. Dieser Service ist aber eigentlich eine API, die sich selbst beschreibt. Wenn wir uns den Datensatz ansehen, sehen wir zunächst nur eine Metadatenangabe dazu, wie sich der Service beschreibt und welche Filtermöglichkeiten es gibt. Darunter liegen aber wiederum Daten. Dann stellt sich die Frage: Sind das Metadaten der Metadaten oder ist der Service bereits ein Datum? Das verschwimmt.

[I2_045] **EXP:** Deshalb sind eigentlich beide Ebenen interessant: die Metadaten und die Daten selbst. Sie korrelieren auch miteinander. Wenn in den Metadaten steht, der Dateityp sei CSV, aber der Inhalt ist kein CSV, dann ist das eine Verletzung der Metadatenqualität. Es gibt aber auch Sonderfälle: Eine Datei kann als Excel angegeben werden, weil sie mit Excel geöffnet werden kann, obwohl das Format eigentlich anders ist. Die Menschen erwarten dann, dass „Excel“ dort steht.

[I2_046] **EXP:** Metadaten und Daten gehören also zusammen. Es ist ein Gesamtkunstwerk. Wenn ich eine Karte erwarte, aber eine XML-Fehlermeldung bekomme, passt etwas nicht. Das gilt zum Beispiel bei WMS- oder WFS-Geodatenservices. Technisch sprechen diese Dienste XML, aber der Mensch erwartet eine Karte.

[I2_047] **EXP:** Auch wenn im Titel „Vornamen“ steht, im Datensatz aber hauptsächlich Zahlen enthalten sind, ist die Beschreibung falsch. Das macht die Prüfung schwieriger. Man kann sich dem aber annähern und teilweise auch automatisiert prüfen. Deshalb ist der eigentliche Datensatz für die Bewertung der Metadaten relevant.

KI-gestützte Ansätze und AI Agents

[I2_048] **INT:** Dann kommen wir zum letzten Hauptteil, nämlich AI Agents. Inwiefern hältst du Ansätze, die AI Agents in den Vordergrund rücken, für sinnvoll, um neue Ansätze zu entwickeln oder bestehende Ansätze zu verbessern, zum Beispiel durch eine kontextsensitive Analyse der Metadaten?

[I2_049] **EXP:** Aktuell halte ich Ansätze, die AI Agents von vornherein in den Vordergrund rücken, generell für falsch. Ich würde eher fragen: Wir schauen uns AI Agents an und prüfen dann, wofür sie sinnvoll sind.

[I2_050] **EXP:** Ich habe in anderen Bereichen zu oft erlebt, dass gefragt wird, ob nicht die KI ein Problem lösen könne oder ob KI die gesamte Prozesskette übernehmen könne. Die Frage sollte aber sein: Muss KI das lösen oder kann es auch mit anderen Mitteln funktionieren? Oft können andere Mittel das ebenfalls lösen.

[I2_051] **EXP:** AI Agents sind nicht automatisch intelligent. Häufig probieren sie Dinge aus, bis etwas passt. Das kann man in manchen Prozessen auch anders erreichen. Als Lösungsvariante finde ich sie interessant, aber entscheidend ist, wie die KI angesprochen wird.

[I2_052] **EXP:** Eine reine Textanalyse halte ich für schwach. Wenn AI Agents hingegen auf einem semantischen Graphen arbeiten, ist das deutlich besser. Sie verstehen den Graphen nicht im menschlichen Sinne, können aber datenbasiert arbeiten und halluzinieren weniger. Wenn bessere Daten als Grundlage vorhanden sind, können AI Agents sinnvoller und verlässlicher arbeiten. Auf unserem Graphen könnten sie nützliche Informationen erschließen. Insofern: ja, warum nicht, aber nicht als Selbstzweck.

[I2_053] **INT:** Darauf aufbauend: Was wären deiner Meinung nach wichtige kontextsensitive Informationen, die ein solcher Agent überprüfen könnte?

[I2_054] **EXP:** Das hängt davon ab, worum es konkret geht. Ein Agent sollte sich auf die Metadaten verlassen können. Wenn wir einen Graphen haben, kann er Metadaten prüfen und weitere Informationen heranziehen. Er könnte in unserem Graphen suchen, andere Graphen wie das europäische Datenportal einbeziehen oder Informationen aus Drittportalen, wissenschaftlichen Portalen und ähnlichen Quellen berücksichtigen.

[I2_055] **EXP:** Er könnte Querverweise auflösen oder neue Querverweise finden. Besonders relevant wären Schlagwörter und Stichwörter. Diese sind bei Behörden oft einfach nur Zeichenketten. Wenn sie mehr Kontext hätten, könnte man deutlich mehr daraus ableiten. Das Umweltbundesamt hat meines Wissens solche kontextsensitiven Informationen beziehungsweise Verlinkungen über seinen Thesaurus. Dadurch kann man zu einem Datensatz zusätzliche Informationen erschließen.

[I2_056] **EXP:** Wenn ein Datensatz beispielsweise mit einem bestimmten Begriff verbunden ist, könnte ein Agent über den Graphen weitere verwandte Konzepte finden. Dadurch würden die Suche und die Bewertung deutlich besser. Kontext entsteht also vor allem durch semantische Verknüpfungen.

[I2_057] **INT:** Gibt es deiner Meinung nach weitere Anwendungsfälle, in denen AI Agents oder KI bei einem Scoring helfen könnten, abseits von kontextsensitivem Wissen?

[I2_058] **EXP:** Ja. Man müsste viel stärker in die Daten selbst hineinschauen. Bisher betrachten Portale häufig nur Metadaten. Eigentlich müsste man tiefer analysieren: Passen die Daten zu den Metadaten oder nicht?

[I2_059] **EXP:** Ich hatte vorhin die Flächendeckung erwähnt, die ich mit der GDI einmal ausprobiert habe. Dafür muss man die Daten identifizieren und in die Daten hineinschauen.

Das wäre eine gute Aufgabe für einen Agenten. Er könnte prüfen, ob Datensätze vergleichbare Strukturen haben, ob sie schematisch ähnlich sind oder ob sie flächendeckend verfügbar sind.

[I2_060] **EXP:** Solche Informationen händisch zu ermitteln, ist sehr aufwendig. KI kann große Datenmengen analysieren, Muster erkennen und Informationen ableiten. Das könnte auch bei älteren Datensätzen hilfreich sein, die alte Sprachmuster enthalten. Man könnte etwa historische Begriffe oder ältere Verwaltungssprache analysieren und Kontexte herstellen, die Menschen nicht ohne Weiteres erkennen würden.

[I2_061] **EXP:** Man könnte auch sehr große Mengen an Datensätzen analysieren und feststellen, was inhaltlich am häufigsten vorkommt. Das ist für Menschen manuell kaum leistbar.

[I2_062] **EXP:** Das Problem bei KI ist aber, dass sie trainiert und betrieben werden muss. Auch Agents erzeugen im Einsatz Last. Das merken wir bei GovData: KI kann sehr viel Serverlast erzeugen, weil solche Systeme oft so programmiert sind, dass sie nicht loslassen und die verfügbare Serverkapazität ausnutzen. Das ist für kleine Einrichtungen nicht immer tragbar.

[I2_063] **EXP:** Ich finde KI sinnvoll, aber man muss Rechenressourcen und Betrieb mitdenken. Nicht alles muss mit KI gelöst werden, wenn es auch anders lösbar ist.
