

Transkript Experteninterview I3

Metadaten

- Interview-ID: I3
 - Institutioneller Kontext: Open Data Competence Center Bayern
 - Transkriptart: inhaltlich geglättet
 - Sprecherkennzeichnung: INT = Interviewer, EXP = interviewte Person
 - Anonymisierung: pseudonymisiert
 - Bearbeitung: Einleitende Fragen und Abschlussfragen entfernt; Gliederung nach Hauptteilen des Leitfadens ergänzt
-

Die perfekten Metadaten

[I3_001] **INT:** Wie sieht Ihrer Meinung nach der perfekte Metadatensatz aus? Ich hatte Ihnen im Leitfaden geschrieben, dass Sie gerne auch einen Beispieldatensatz mitbringen können.

[I3_002] **EXP:** Das habe ich tatsächlich nicht geschafft, das kann ich aber gern noch nachreichen. Zum perfekten Metadatensatz: Ich würde da auch auf unsere Handreichung zur Datenqualität verweisen, in die schon einige Aspekte eingeflossen sind. Was ich Datenbereitstellern immer mitgebe, ist: lieber Qualität statt Quantität. DCAT hat sehr viele Metadatenfelder, ich glaube um die 70. Natürlich wäre es schön, wenn alle gefüllt wären, aber das ist überhaupt nicht für jeden Datensatz sinnvoll, weil inhaltlich nicht immer alles passt. Perfekt ist ein Datensatz dann, wenn alle relevanten Metadatenfelder in sehr guter Qualität ausgefüllt sind, also inhaltlich und syntaktisch korrekt.

[I3_003] **EXP:** Da ich weiß, dass man immer einen Realitätsabgleich bräuchte und das für unsere Datenbereitsteller oft nicht umsetzbar ist, sage ich eher: auf die wichtigen Metadatenfelder beschränken und diese dann sorgfältig und korrekt ausfüllen. Ich verfolge da einen pragmatischen Ansatz. Sorgfältig heißt für mich auf der einen Seite, dass die Angaben syntaktisch korrekt sind, also beispielsweise die richtigen Vokabulare und URIs verwendet werden. Auf der anderen Seite heißt es, dass die Inhalte eine gute Nachnutzbarkeit und Auffindbarkeit der Daten ermöglichen.

[I3_004] **INT:** Sie haben gerade schon einige Kriterien genannt. Haben Sie noch weitere Kriterien, an denen Sie einen Metadatensatz als perfekt bewerten würden?

[I3_005] **EXP:** Ja. Die Beschreibung sollte ausführlich sein und die relevanten Informationen enthalten. Potenzielle Datennutzende sollten auf den ersten Blick aus den Metadaten erkennen können: Was sind das für Daten? Kann ich sie technisch verarbeiten? Kann ich sie inhaltlich verarbeiten? Es sollte also eine Art Inhaltsvorschau und technische Vorschau

geben, sodass ich nicht erst den Datensatz selbst öffnen muss, um zu wissen, ob ich ihn für meinen Zweck verwenden kann oder eher nicht.

[I3_006] **EXP:** Außerdem ist Konsistenz wichtig, gerade wenn es ähnliche Daten gibt. Ein Beispiel wären Einwohnerstatistiken. Jede Kommune hat so eine Statistik, aber jede benennt sie anders: mal Bevölkerung, mal Einwohner, mal Statistik, mal Anzahl. Schon auf Titel- oder Beschreibungsebene gibt es viele Synonyme. Da wären Einheitlichkeit und Standardisierung sehr hilfreich.

[I3_007] **INT:** Ich denke, die Unterfrage nach Konsistenz hat sich damit geklärt. Ich vermute, Sie haben spontan kein konkretes Beispiel für schlechte Metadaten dabei?

[I3_008] **EXP:** Nein, das kann ich aber nachreichen. Das habe ich vorher einfach nicht geschafft. Ich finde genug Beispiele, nicht nur auf GovData, sondern auch bei uns im Portal.

Bestehende Quality Scores und SHACL

[I3_009] **INT:** Alles klar. Dann würde ich zu zwei Fragen zu Quality Scores kommen. Was fehlt Ihrer Meinung nach in den aktuellen Ansätzen der Metadata-Quality-Scores?

[I3_010] **EXP:** Mir sind vor allem piveau metrics und der DCAT-Validator bekannt. piveau metrics bezieht sich eher darauf, ob bestimmte Felder überhaupt vorhanden sind, und der Validator prüft zusätzlich die Syntax, also ob die richtigen Vokabulare, die richtigen URIs und so weiter verwendet werden. Was beide Ansätze aber nicht leisten, ist die Prüfung, ob das, was in den Metadaten steht, auch inhaltlich sinnvoll ist. Es geht also um die Frage, ob die Angaben semantisch und inhaltlich passen. Das ist natürlich noch einmal ein ganz anderes Niveau, und genau da sehe ich auch die Schwierigkeiten.

[I3_011] **INT:** Und darauf aufbauend: Welche Qualitätskriterien sollte ein Scoring Ihrer Meinung nach in jedem Fall enthalten, damit es vollständiger und aussagekräftiger wird?

[I3_012] **EXP:** Idealerweise sollte es mehrstufig sein. Es sollte nicht nur prüfen, ob Felder vorhanden sind. Das wäre der erste Schritt. Danach sollte geprüft werden, ob sie korrekt ausgefüllt sind, also syntaktisch korrekt. Dann müsste man noch semantisch und schließlich inhaltlich prüfen, ob die Angaben passen. Dieses mehrstufige Vorgehen fände ich sinnvoll.

[I3_013] **EXP:** Außerdem sollte es über DCAT hinausgehen. Der Aspekt, ob Felder vorhanden sind, wird ja im piveau-metrics-Ansatz bereits aufgegriffen, und zwar auch über die reinen DCAT-Pflichtfelder hinaus. Das halte ich für einen wichtigen Punkt, weil ich die DCAT-Pflichtfelder allein für zu wenig halte, um einen Datensatz gut zu beschreiben. Ich bleibe zwar dabei, dass lieber wenige Felder sorgfältig ausgefüllt werden sollten, aber diese sollten dennoch über die Pflichtfelder von DCAT hinausgehen.

[I3_014] **INT:** Inwiefern kann das DCAT-AP.de-Validierungsergebnis in einem Quality Scoring wertvoll sein?

[I3_015] **EXP:** Weil es genau die Verknüpfung zwischen zwei Ebenen herstellt: Sind die Felder vorhanden, und sind sie dann auch noch syntaktisch korrekt ausgefüllt? Das wäre definitiv eine Verbesserung, weil es noch einmal auf einer anderen Ebene Datenqualität abruft.

[I3_016] **INT:** Und wie könnte man das Validierungsergebnis in ein Scoring integrieren? Welche Regeln oder Teile dieser Checker- beziehungsweise Validierungsergebnisse halten Sie dabei für besonders wichtig?

[I3_017] **EXP:** Wie man das technisch in ein Scoring integriert, kann ich ad hoc nicht sagen. Da bin ich nicht tief genug drin. Wichtig fände ich aber, dass das Ergebnis klar getrennt und klar angezeigt wird: Ist das Problem ein syntaktisches Problem, oder fehlt ein Feld? Es muss deutlich sein, wo genau das Problem liegt.

[I3_018] **EXP:** Besonders wichtig sind für mich die grundlegenden Prüfungen: Ist es valides XML? Ist die URI korrekt? Sind die verwendeten Vokabulare korrekt? Das sind grundlegende Dinge, die abgeprüft werden und die auch grundsätzlich wichtig sind.

Relevanz des eigentlichen Datensatzes

[I3_019] **INT:** Vielen Dank. Dann eine Frage zur Relevanz des eigentlichen Datensatzes: Inwiefern halten Sie den eigentlichen Datensatz für die Bewertung der Metadaten für relevant?

[I3_020] **EXP:** Die Metadaten existieren ja nicht unabhängig vom Rohdatensatz. Es ist unabdingbar, dass es die Rohdaten auch gibt. Insofern hat der eigentliche Datensatz schon eine gewisse Bedeutung, auch zur Gegenprüfung, ob die Metadaten stimmen. Das sieht man zum Beispiel beim Dateiformat relativ einfach: Wenn an einem Datensatz eine CSV hängt, in den Metadaten aber PDF steht, dann stimmt bei der Metadatenqualität etwas nicht.

[I3_021] **EXP:** Die Rohdatenqualität an sich ist ebenfalls ein Thema, das uns im Praxisalltag begegnet und auch von der Bereitstellerseite angesprochen wird. Da geht es etwa um Fragen wie: Wir wollen keine proprietären Dateiformate, wir wollen gut lesbare Dateiformate. Das sind zwar teilweise eher banale Dinge, aber dazu gibt es Informationsbedarf. Bereitsteller fragen uns auch, wie sie ihre Daten aufbereiten sollen. Bei statistischen Daten kommen solche Fragen durchaus vor; bei Geodaten etwas weniger, weil die meist aus GIS-Systemen kommen.

[I3_022] **EXP:** Wir können dazu allerdings nur sehr eingeschränkt beraten, weil wir ein Metadatenportal sind und mit Metadaten arbeiten. Es gibt bei Dateiformaten eine sehr große Bandbreite, und je nach Struktur der Rohdaten hängen daran unterschiedliche fachliche Standards. Statistiker haben ihre eigenen Systematiken und Anforderungen, Geodatenleute haben ihre eigenen Standards wie INSPIRE. Da sind wir einfach keine Fachleute. Wir weisen deshalb immer darauf hin, dass man sich beispielsweise in Kommunen oder

Universitäten mit den zuständigen Fachabteilungen austauschen und sich an den jeweiligen Fachstandards orientieren sollte.

KI-gestützte Ansätze und AI Agents

[I3_023] **INT:** Das beantwortet die Frage ausreichend, danke. Dann zum letzten Themenblock: Potenziale von AI Agents und Large Language Models. Wie sinnvoll halten Sie Ansätze, die AI Agents in der Qualitätsbewertung einsetzen, um neue Ansätze zu entwickeln oder bestehende Ansätze zu verbessern, zum Beispiel durch eine kontextsensitive Analyse der Metadaten?

[I3_024] **EXP:** Diesen kontextsensitiven Ansatz halte ich für sehr vielversprechend. Ich verstehe das so, dass dann vielleicht auch auf die Rohdaten und auf das Umfeld, in dem sich die Rohdaten befinden, zugegriffen wird und daraus Rückschlüsse auf die Metadaten gezogen werden können, auch bei recht einfachen Dingen wie dem Dateiformat. Darauf bin ich vorhin schon ein bisschen eingegangen. Ich halte das für einen guten und vielversprechenden Ansatz, weil man dadurch das, was in den Metadaten steht, über die reine Syntaxebene hinaus noch einmal überprüfen kann. Ich denke, dass das die Metadatenqualität durchaus verbessern kann.

[I3_025] **INT:** Was wären Ihrer Meinung nach dann wichtige kontextsensitive Informationen, die ein Agent überprüfen sollte?

[I3_026] **EXP:** Ich würde gern noch etwas zum vorherigen Punkt ergänzen. Ich halte das auch deshalb für vielversprechend, weil man damit wahrscheinlich große Mengen an Metadaten relativ schnell verbessern oder zumindest bewerten könnte, jedenfalls im Vergleich zur manuellen Bearbeitung. Was ich aus der Praxis heraus etwas kritisch sehe, ist die Datenhoheit. Wer hat denn die Hoheit über die Daten, wenn dort etwas verbessert oder verändert wird? Das Messen ist die eine Sache. Ich glaube, das ist ja auch der Fokus Ihrer Arbeit. Ich bin gedanklich schon einen Schritt weiter in Richtung möglicher Veränderungen, und da muss man natürlich aufpassen. Das wäre dann schon wieder über Ihre Arbeit hinaus gedacht.

[I3_027] **INT:** Dann wiederhole ich die Frage noch einmal: Was wären Ihrer Meinung nach wichtige kontextsensitive Informationen, die ein Agent überprüfen sollte?

[I3_028] **EXP:** Das Format finde ich wichtig. Auch Dinge wie Dateigröße lassen sich wahrscheinlich relativ gut prüfen. Schwieriger wird es vermutlich bei Angaben wie Lizenzen. Vielleicht lassen sich über die Rohdaten auch zeitliche Bezüge herauslesen. Im Grunde also alles, was die Auffindbarkeit und den Inhalt der Daten beschreibt: Titel, Beschreibung, Keywords, Themenfeld, Kategorie.

[I3_029] **EXP:** Schwierig wird es vermutlich bei den Dingen, die das Rechtliche betreffen beziehungsweise den Ursprung der Daten, also Lizenz, Publisher oder Contact Point. Das

sind aber ebenfalls sehr wichtige Felder. Da stelle ich mir die Umsetzung schwierig vor. Aber gerade diese ganzen inhaltlichen Angaben, die sich auf die Inhalte oder Merkmale der Rohdaten beziehen und für die es bisher keine gute Metrik gibt, halte ich für sinnvoll.

[I3_030] **INT:** Gibt es Ihrer Meinung nach auch noch andere Anwendungsfälle, in denen AI Agents bei einem Scoring helfen könnten, also abseits von kontextsensitivem Wissen?

[I3_031] **EXP:** Ad hoc fällt mir da gerade nichts Konkretes ein, aber es gibt bestimmt noch weitere Möglichkeiten.
